ЛР1, часть 2. Yandex DataLens на датасете Airbnb

Датасет: объявления Airbnb в Ванкувере (Inside Airbnb, выгрузка июня 2026), файл `airbnb_vancouver.csv` — 6 509 строк, 28 столбцов. Результат: подключение, датасет с вычисляемыми полями, 8 чартов разных типов (с картой) и дашборд с фильтрами.

!!! info Как пользоваться гайдом Жирным выделены кнопки и пункты меню, `моноширинным` — имена полей и формулы. Стрелка «→» означает «затем нажать». После каждого чарта есть строка **Контроль** — цифры, посчитанные по файлу заранее: если у вас совпало, чарт собран правильно. Интерфейс DataLens часто обновляется, поэтому названия кнопок могут немного отличаться.

Что сдавать

№	Требование методички	Где в гайде
1	Загрузить свой CSV и создать подключение в воркбуке	разделы 1–2
2	Собрать датасет: типы, агрегации, вычисляемые поля	раздел 3
3	≥ 5 осмысленных чартов разных типов, среди них карта	раздел 4 (8 чартов)
4	Дашборд со всеми чартами и фильтрами	раздел 5

0. Что за данные

Inside Airbnb — открытый проект, который регулярно выгружает все активные объявления Airbnb в крупных городах. Одна строка — одно объявление. Исходный файл `listings.csv.gz` из «Загрузок» (90 столбцов, 19,5 МБ) уже распакован и урезан до нужного: в папке `Лаба1/DataLens_Airbnb` лежит `airbnb_vancouver.csv` (1,4 МБ). Убраны длинные тексты (описания, списки удобств, ссылки на фото) и пустые столбцы.

Столбец	Что это	Роль в отчёте
`id`, `host_id`	номер объявления и хозяина	считаем уникальные
`name`	название объявления	для таблицы
`neighbourhood`	район города (23 района)	измерение, фильтр
`latitude`, `longitude`	координаты	карта
`room_type`	тип жилья: целиком / комната / общая / отель	измерение, фильтр
`property_type`	тип объекта (квартира, дом, сьют… — 51 вариант)	измерение
`accommodates`, `bedrooms`, `beds`, `bathrooms`	вместимость, спальни, кровати, ванные	показатели
`price`	цена за ночь **текстом**, в канадских долларах: `$425.00`	переводим в число
`host_is_superhost`	`t` / `f` — суперхост или нет	измерение
`calculated_host_listings_count`	сколько объявлений у этого хозяина	показатель
`first_review`, `last_review`	дата первого и последнего отзыва	даты
`number_of_reviews`, `reviews_per_month`	число отзывов	показатели
`review_scores_*`	оценки гостей от 0 до 5: общая, чистота, расположение, цена/качество	показатели
`availability_365`	свободных дней в ближайший год	показатель
`estimated_occupancy_l365d`, `estimated_revenue_l365d`	оценка занятых ночей и дохода за год	показатели

!!! note Особенности данных, которые надо учесть У 664 объявлений нет цены; у 1 136 нет отзывов, а значит, и рейтинга, и дат. Цена сильно скошена вправо: медиана 318, а максимум — **91 294** за ночь. Поэтому в отчёте используем медиану и отсекаем цены выше 2 000 (это 62 объявления).

1. Вход и воркбук

1. Откройте `https://datalens.yandex.ru` → **Открыть DataLens** → войдите аккаунтом Яндекса.
2. Слева **Коллекции и воркбуки** → **Создать** → **Воркбук** → имя `ОАД ЛР1 Airbnb` → **Создать**. Всё дальнейшее (подключение, датасет, чарты, дашборд) создавайте внутри этого воркбука кнопкой **Создать** справа вверху.

2. Подключение к файлу

1. В воркбуке **Создать** → **Подключение** → в блоке «Файлы и сервисы» выберите **Файлы**.
2. **Загрузить файлы** → `Лаба1/DataLens_Airbnb/airbnb_vancouver.csv`.

3. Справа появится предпросмотр. Проверьте: столбцы разбиты правильно, первая строка — заголовки, кириллицы нет, но названия объявлений с запятыми не разъехались по соседним столбцам. Если что-то не так — слева в настройках файла: **Разделитель: запятая**, **Наличие заголовка: да**, **Кодировка: UTF-8**.
4. В предпросмотре можно сразу поправить типы у столбцов (значок типа над столбцом). Поставьте **Строка** для `id` и `host_id`: это номера, а не числа — их не складывают. К тому же `id` бывают 19-значными, и тип «Дробное число» их округлит.
5. Справа вверху **Создать подключение** → имя `airbnb` → **Создать**.

3. Датасет

3.1. Создание

1. На странице подключения справа вверху **Создать датасет**.
2. Вкладка **Источники**: таблица `airbnb_vancouver` уже стоит на поле. Если нет — перетащите её из списка слева.
3. Перейдите на вкладку **Поля**. Здесь у каждого поля задаётся **тип** (строка, целое, дробное, дата…) и **агрегация** (нет, сумма, среднее, количество уникальных…). Поле без агрегации — это **измерение** (зелёное, по нему режут), поле с агрегацией — **показатель** (синее, его считают).

3.2. Типы исходных полей

Проверьте и при необходимости исправьте (щелчок по типу или агрегации в строке поля):

Поле	Тип	Агрегация
`id`, `host_id`, `name`, `neighbourhood`, `room_type`, `property_type`, `host_is_superhost`, `price`	Строка	Нет
`first_review`, `last_review`	Дата	Нет
`latitude`, `longitude`	Дробное число	Нет
`review_scores_*`, `reviews_per_month`	Дробное число	Среднее
`estimated_revenue_l365d`	Дробное число	Сумма
`number_of_reviews`, `estimated_occupancy_l365d`, `availability_365`, `accommodates`	Целое число	Среднее

Если `host_is_superhost` распознался как **Логический** — тоже нормально, тогда формула «Тип хоста» ниже пишется чуть иначе (дана в примечании).

3.3. Вычисляемые поля

Кнопка **+ Добавить поле** справа вверху → слева имя поля, справа формула → **Создать**. Имена полей в формулах пишутся в квадратных скобках; DataLens подсказывает их при вводе.

Измерения (у формулы нет агрегатной функции):

Имя	Формула	Зачем
`Цена`	`FLOAT(REPLACE(REPLACE([price], "$", ""), ",", ""))`	`$1,250.00` → `1250`: убираем `$` и запятую-разделитель тысяч, переводим в число
`Цена (очищ.)`	`IF([Цена] <= 2000, [Цена], NULL)`	цены выше 2 000 считаем выбросами и не учитываем
`Геоточка`	`GEOPOINT([latitude], [longitude])`	координаты для карты
`Тип хоста`	`IF([host_is_superhost] = "t", "Суперхост", "Обычный хост")`	понятные подписи вместо `t` / `f`
`Ценовой сегмент`	см. ниже	группы цен для фильтра
`Год появления`	`YEAR([first_review])`	год первого отзыва ≈ год, когда объявление начало работать

Формула ценового сегмента (цифры в начале нужны, чтобы сегменты сортировались по порядку):

```
IF(ISNULL([Цена]), "нет цены",
   [Цена] < 150, "1. до 150",
   [Цена] < 300, "2. 150–300",
   [Цена] < 500, "3. 300–500",
   "4. 500 и дороже")
```

Если `host_is_superhost` логический: `IF([host_is_superhost], "Суперхост", "Обычный хост")`.

Показатели (агрегатная функция внутри — DataLens сам сделает поле синим):

Имя	Формула	Смысл
`Объявлений`	`COUNTD([id])`	число уникальных объявлений
`Хозяев`	`COUNTD([host_id])`	число уникальных хозяев
`Медианная цена`	`MEDIAN([Цена (очищ.)])`	«типичная» цена за ночь
`Средний рейтинг`	`AVG([review_scores_rating])`	средняя оценка гостей
`Средний доход`	`AVG([estimated_revenue_l365d])`	доход одного объявления за год

4. Справа вверху **Сохранить** → имя `airbnb` → **Создать**.

Контроль. Вкладка **Предпросмотр** внизу. Строки там идут в **произвольном порядке** (база данных не обязана отдавать их так, как в файле), поэтому проверяйте любую строку:

- `Цена` = `price` без `$` и запятых: `$1,250.00` → 1250;
- `Ценовой сегмент` соответствует цене (89 → «1. до 150», 425 → «3. 300–500»; пустая `price` → «нет цены»);
- `Тип хоста`: `t` → «Суперхост», `f` → «Обычный хост».

Проверить конкретную строку можно чартом **Таблица** с фильтром `id` = `13126`: должно быть `Цена` 425, «3. 300–500», «Обычный хост».

!!! info Почему медиана, а не среднее Средняя цена по всем объявлениям — 405,6, медиана — 318. Один выброс в 91 294 тянет среднее вверх, а медиану почти не двигает. Подробнее — в разделе 7.

4. Чарты

Создание любого чарта: в воркбуке **Создать** → **Чарт в Wizard** → слева вверху выберите датасет `airbnb` → над полем выберите **тип визуализации** → перетащите поля из списка слева в секции (**X**, **Y**, **Цвета**, **Размер**, **Сортировка**, **Фильтры**) → справа появится предпросмотр. Каждый чарт: **Сохранить** справа вверху → имя.

Чарт 1. Индикаторы

Тип **Индикатор** → в секцию **Показатель** — `Объявлений`. Сохранить как `Объявлений`. Затем так же ещё три индикатора: `Хозяев`, `Медианная цена`, `Средний рейтинг`.

Контроль: 6 509 объявлений · 4 494 хозяина · медианная цена ≈ 315 · средний рейтинг 4,80.

Чарт 2. Карта объявлений

1. Тип **Карта**. Тип слоя — **Точки (Геоточки)**.
2. **Геоточки**: `Геоточка`. **Цвета**: `room_type`.
3. **Всплывающие подсказки**: `name`, `Цена`, `neighbourhood` — при наведении на точку видно, что это за объявление.
4. По желанию — второй слой: справа от названия слоя **+** → тип **Тепловая карта**, **Геоточки**: `Геоточка`. Покажет плотность объявлений.

Контроль: 6 509 точек в границах Ванкувера; плотнее всего — полуостров Downtown и West End; почти все точки одного цвета — «Entire home/apt».

Чарт 3. Районы

Тип **Линейчатая диаграмма** (горизонтальные полосы).

- **Y**: `neighbourhood`; **X**: `Объявлений`.
- **Цвета**: `Медианная цена` — полосы окрасятся градиентом: чем дороже район, тем темнее.
- **Сортировка**: `Объявлений` → щёлкните по полю в секции и выберите **по убыванию**.

Контроль: Downtown 1 534 (почти четверть всех), Kitsilano 440, Downtown Eastside 423, Kensington-Cedar Cottage 410, Mount Pleasant 394; меньше всего — Strathcona, 24.

Чарт 4. Типы жилья

Тип **Кольцевая диаграмма**. **Цвета**: `room_type`; **Показатели**: `Объявлений`. В настройках чарта (значок шестерёнки) включите **Подписи** → значения в процентах.

Контроль: Entire home/apt 81,8 % (5 322), Private room 17,9 % (1 168), Shared room 16 объявлений, Hotel room 3.

Чарт 5. Как рос Airbnb

Тип **Линейная диаграмма**. **X**: `Год появления`; **Y**: `Объявлений`. **Фильтры**: `Год появления` → **Не пусто** (убирает 1 136 объявлений без отзывов).

Контроль: 2019 — 283, **2020 — 115** (провал: ковид, туризм остановился), 2021 — 239, 2022 — 504, 2023 — 731, 2024 — 792, 2025 — 891, 2026 — 1 064.

!!! warn Как читать этот график Это не число новых объявлений по годам, а число **ещё живых** объявлений, которые появились в этом году. Объявления, закрытые до июня 2026, в выгрузку не

попали, поэтому старые годы занижены. Это «ошибка выжившего» (раздел 7). А 2026 год — неполный: выгрузка сделана в июне.

Чарт 6. Цена против рейтинга по районам

Тип **Точечная диаграмма**.

- **X**: `Медианная цена`; **Y**: `Средний рейтинг`.
- **Точки**: `neighbourhood`; **Размер**: `Объявлений`; **Цвета**: `neighbourhood` (или оставьте пустым).

Контроль: 23 точки. Самая крупная — Downtown (≈ 382; 4,83). Ниже всех по рейтингу — West End (4,68) и Shaughnessy (4,69), выше всех — Strathcona (4,94, но там только 24 объявления). Mount Pleasant — дёшево (≈ 209) и с невысоким рейтингом (4,70).

Чарт 7. Суперхосты

Два небольших чарта, которые на дашборде ставятся рядом. В один их лучше не объединять: доход — десятки тысяч, рейтинг — около 4,8, и на общей шкале рейтинг превратится в плоскую полосу у нуля.

1. **Столбчатая диаграмма**: **X** — `Тип хоста`, **Y** — `Средний доход`. Шестерёнка → **Подписи** → **Вкл.** Сохранить как «Суперхосты: доход».
2. Ещё одна **Столбчатая диаграмма**: **X** — `Тип хоста`, **Y** — `Средний рейтинг`, подписи включены. Сохранить как «Суперхосты: рейтинг».

Если нужна одна диаграмма с двумя шкалами: тип **Линейная диаграмма**, **X** — `Тип хоста`, **Y** — `Средний доход`, **Y2** — `Средний рейтинг` (вторая шкала справа).

Контроль: суперхост — средний доход ≈ 56 829 в год и рейтинг 4,88; обычный хост — ≈ 17 528 и 4,74. Суперхостов 2 636 из 6 509 (40,5 %), а зарабатывают они в среднем в 3,2 раза больше.

Чарт 8. Сводная: район × тип жилья

Тип **Сводная таблица**.

- **Строки**: `neighbourhood`; **Столбцы**: `room_type`; **Показатели**: `Медианная цена`.
- В настройках показателя (щелчок по полю) → **Цвет заливки** или **Градиент**, чтобы дорогие ячейки выделялись.

Контроль: Downtown / Entire home/apt ≈ 388, Kitsilano / Entire home/apt ≈ 445 (дороже всех среди крупных районов), Downtown / Private room ≈ 172.

!!! info Почему медианы могут чуть отличаться DataLens считает медиану на стороне базы данных (для файлов это ClickHouse), а там при чётном числе значений может взяться одно из двух средних значений, а не их полусумма. Расхождение в контрольных цифрах на 1–2 доллара — это нормально.

5. Дашборд

1. В воркбуке **Создать** → **Дашборд**.
2. **Добавить** → **Заголовок** → «Airbnb в Ванкувере: где, почём и как хорошо». **Добавить** → **Текст** → одна-две строки выводов (см. ниже).
3. **Добавить** → **Чарт** → выберите чарт → **Добавить**. Повторите для всех чартов (четыре индикатора и два чарта про суперхостов — по отдельности).
4. **Добавить** → **Селектор**: источник — **На основе датасета**, датасет `airbnb`, поле `neighbourhood`, вид — **Список**, включите **Множественный выбор** → заголовок «Район» → **Добавить**. Так же

селекторы по `room_type` («Тип жилья»), `Ценовой сегмент` и `Тип хоста`.

5. Расставьте блоки: селекторы и индикаторы — полосой сверху; карта — крупно слева; районы и кольцевая — справа; линейная, точечная, столбчатая и сводная — ниже. Блоки тянутся за правый нижний угол.
6. **Сохранить** справа вверху.

Селекторы, созданные на том же датасете, что и чарты, фильтруют их автоматически. Проверить связи: **Связи** (значок цепочки) на панели дашборда — у каждого селектора к чартам должна быть связь «Связан».

Контроль: выберите в селекторе «Район» значение Downtown → индикатор «Объявлений» покажет 1 534, на карте останутся точки только в центре. Выберите «Тип жилья» = Private room (без района) → 1 168 объявлений, медианная цена ≈ 160. Сбросьте фильтры.

Выводы для текстового блока (пример): «Почти 82 % объявлений — жильё целиком; четверть предложения сосредоточена в Downtown. Суперхосты зарабатывают в 3 раза больше обычных хозяев. В 2020 году приток новых объявлений упал в 2,5 раза».

Сдача: откройте дашборд в режиме просмотра (кнопка **Режим просмотра** / выход из редактирования), скопируйте ссылку через **Поделиться**. По умолчанию воркбук приватный: чтобы преподаватель увидел, в настройках доступа воркбука дайте доступ по ссылке или откройте экран на защите.

6. Чек-лист

- [ ] Подключение `airbnb` к файлу, `id` и `host_id` — строки.
- [ ] Датасет: `Цена`, `Цена (очищ.)`, `Геоточка`, `Тип хоста`, `Ценовой сегмент`, `Год появления` + 5 показателей.
- [ ] 8 чартов: индикатор, карта, линейчатая, кольцевая, линейная, точечная, столбчатая, сводная таблица.
- [ ] Дашборд: заголовок, текст с выводами, 4 селектора, все чарты; фильтр по району меняет все чарты.
- [ ] Можете объяснить: почему медиана, а не среднее; что такое измерение и показатель; почему график по годам занижает прошлое.

7. Теория

Как устроен DataLens

Объекты образуют цепочку: **подключение** (где лежат данные: файл, ClickHouse, PostgreSQL…) → **датасет** (какие поля, их типы, формулы) → **чарт** (как показать) → **дашборд** (собрать чарты вместе и связать фильтрами). Данные не копируются в чарт: каждый раз, когда вы открываете дашборд или меняете фильтр, DataLens строит SQL-запрос к источнику. Например, чарт 3 превращается примерно в

```
SELECT neighbourhood, COUNT(DISTINCT id), median(Цена_очищ)
FROM airbnb_vancouver
GROUP BY neighbourhood
ORDER BY 2 DESC
```

Отсюда главное правило: **измерения** уходят в `GROUP BY`, **показатели** — в агрегатные функции. Поэтому один и тот же показатель (`Объявлений`) в индикаторе даёт 6 509, а в чарте по районам — свою цифру для каждого района: агрегат пересчитывается в каждом срезе. Это та же идея, что и мера в Power BI.

Среднее и медиана

Среднее $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ реагирует на каждое значение: если одно значение увеличить на Δ, среднее сдвинется на Δ/n. Выброс в 91 294 при $n = 5\,845$ объявлениях с ценой добавляет к среднему около $91\,294/5\,845 \approx 15{,}6$.

Медиана — значение, которое делит упорядоченную выборку пополам: половина цен не больше её, половина не меньше. Чтобы сдвинуть медиану как угодно далеко, нужно испортить половину данных — говорят, что **точка срыва** медианы 50 %, а у среднего — 0 % (хватает одного значения). Поэтому для скошенных величин — цен, доходов, зарплат — «типичное» значение описывают медианой.

	Все цены	**Цены ≤ 2 000**
Среднее	405,6	360,9
Медиана	318	315

Отсечение 62 выбросов меняет среднее на 45, а медиану — на 3.

Как выбрать порог выбросов

Порог 2 000 выбран «на глаз». Стандартное правило — **межквартильный размах** (тот же, что в ЛР3): $Q_1 = 156$, $Q_3 = 496{,}7$, $IQR = Q_3 - Q_1 = 340{,}7$, верхняя граница $Q_3 + 1{,}5 \cdot IQR \approx 1\,008$. По этому правилу выбросами оказались бы 286 объявлений. Но для цен на жильё это слишком строго: дорогие пентхаусы — не ошибка, а настоящий сегмент рынка. Поэтому порог стоит выбирать по смыслу: отсечь явные ошибки ввода (цены в десятки тысяч за ночь), но оставить дорогое жильё. Есть и выбросы снизу: 337 объявлений дешевле 30 за ночь — это, скорее всего, помесячная аренда с пересчётом цены.

Ошибка выжившего

Выгрузка — это **снимок** на июнь 2026: в ней только объявления, которые живы на эту дату. Объявление, открытое в 2016 году и закрытое в 2019-м, в данных отсутствует. Поэтому, если считать «сколько объявлений появилось в году t» по снимку, получится $N_{\text{живых}}(t) = N_{\text{открыто}}(t) \cdot P(\text{дожило до } 2026 \mid t)$, а вероятность дожить тем меньше, чем раньше открылось объявление. График растёт быстрее, чем рос рынок на самом деле. Правильно оценить динамику можно только по серии снимков за разные даты (Inside Airbnb публикует архив).

Почему COUNTD, а не COUNT

`COUNT([id])` считает строки, `COUNTD([id])` — **уникальные** значения. Здесь одна строка = одно объявление, и результаты совпадут. Но если бы датасет был соединён с таблицей отзывов (одна строка = один отзыв), `COUNT` посчитал бы отзывы, а `COUNTD([id])` — по-прежнему объявления. Привычка считать сущности через `COUNTD` по ключу защищает от «размножения» строк при соединениях (JOIN). Аналогично `Хозяев = COUNTD([host_id])`: у одного хозяина бывает до 165 объявлений, и `COUNT` здесь дал бы неверный ответ.

Геоточка

`GEOPOINT(широта, долгота)` собирает пару координат в один геообъект. Координаты — в системе WGS 84 (как в GPS): широта от −90° до 90° (север положительный), долгота от −180° до 180° (восток положительный). Ванкувер — около 49,25° с. ш. и −123,1° (то есть 123,1° з. д.). Если перепутать порядок аргументов, точки окажутся в Антарктиде: широта −123 невозможна, DataLens выдаст ошибку или пустую карту.

Если что-то пошло не так

Симптом	Причина и решение
Поле `Цена` пустое или ошибка	В формуле не убрана запятая: `$1,250.00` без второго REPLACE не превращается в число. Проверьте оба REPLACE.
Названия объявлений «разъехались» по столбцам	Не распознаны кавычки. В настройках файла укажите разделитель «запятая»; в CSV названия с запятыми взяты в кавычки.
Карта пустая	`Геоточка` должна быть типа «Геоточка»; порядок аргументов — сначала `latitude`, потом `longitude`.
Показатель серый / не кладётся в «Показатели»	У поля стоит агрегация «Нет». Для `Объявлений` и других показателей формула должна содержать агрегат (COUNTD, AVG, MEDIAN).
Сегменты идут не по порядку	Оставьте цифры «1.», «2.» в начале подписей — сортировка строк идёт по алфавиту.
Селектор не фильтрует чарт	Чарт построен на другом датасете или связь выключена: **Связи** на дашборде → «Связан».
`Тип хоста` везде «Обычный хост»	Поле `host_is_superhost` логическое, а не строка. Используйте вариант формулы для логического поля.