Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Методические указания к лабораторной работе №2 по дисциплине ОАД

Разработали:
Старший преподаватель
Маслеников К.Ю.
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 3
1 LOGINOM 4
1.1 Начало работы 4
1.2 Импорт данных 6
1.3 Преобразование полей и добавление новых признаков 12
1.4 Фильтрация данных 18
1.5 Корреляционный анализ 21
1.6 Стратификация данных 28
1.7 Разбиение на обучающую и тестовую выборки 30
1.8 Обучение модели линейной регрессии 36
1.9 Анализ обученной модели 44
1.10 Практическое задание 47
СПИСОК ПОЛЕЗНЫХ ИСТОЧНИКОВ 49

ВВЕДЕНИЕ

В учебных задачах по аналитике важно не только получить итоговую диаграмму или модель, но и выстроить воспроизводимый процесс обработки данных. На практике это означает, что каждый шаг — загрузка источника, очистка полей, преобразование признаков и расчёт показателей — должен быть явно зафиксирован и понятен для повторного запуска. Такой подход формирует системное представление о жизненном цикле аналитической задачи.

Loginom удобен для этой цели благодаря визуальному конструированию сценариев. Пользователь работает не с разрозненными действиями, а с последовательностью связанных узлов, где результат каждого этапа передаётся дальше по цепочке. Это позволяет последовательно проверять корректность преобразований, быстро находить ошибки в логике обработки и накапливать библиотеку типовых решений.

Цель — познакомить с базовыми возможностями Loginom и показать, как из исходного набора данных получить осмысленный аналитический результат в формате законченного сценария. Далее будут рассмотрены структура интерфейса, ключевые этапы работы и практические действия, которые необходимо повторить при выполнении лабораторной работы.

1 LOGINOM

Loginom — аналитическая платформа для визуального проектирования процессов обработки данных и машинного обучения. Работа строится в формате сценария: пользователь добавляет узлы обработки, настраивает параметры каждого шага и соединяет узлы в единую цепочку. Такой подход позволяет прозрачно организовать процесс анализа, повторно использовать подготовленные блоки и контролировать качество результата на каждом этапе.

1.1 Начало работы

После запуска Loginom открывается главный экран с быстрыми действиями. Для начала новой лабораторной работы выберем команду **Создать пакет**. Пакет — это контейнер проекта, в котором хранятся модули, сценарии, подключения к источникам данных и пользовательские компоненты.

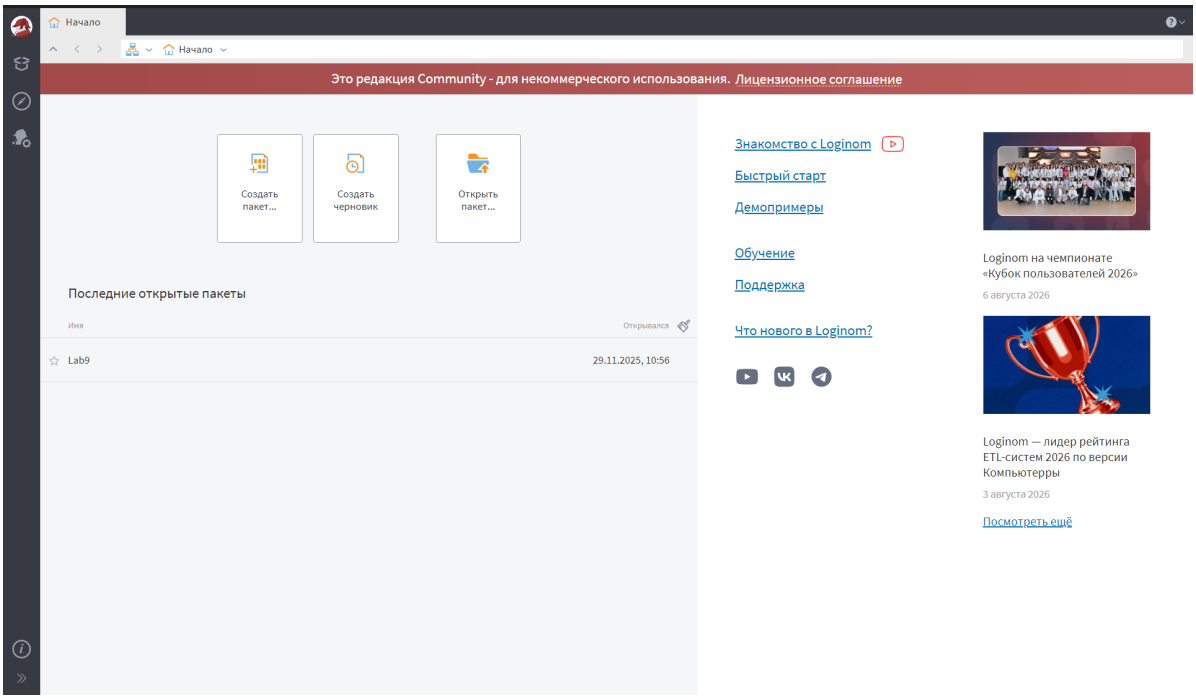


Рисунок 1 – Главный экран Loginom и выбор действия **Создать пакет**

После создания пакета откроется рабочая область, где выполняется основная часть анализа. На этом этапе важно понимать назначение ключевых зон интерфейса:

– **Главное меню слева** — быстрый доступ к разделам среды и основным командам навигации.

– **Верхняя панель** — вкладки открытых объектов, адресная строка текущего пути и элементы перехода между разделами пакета.

– **Панель компонентов** (слева в рабочей зоне) — библиотека узлов, разделённая по категориям: импорт, трансформации, управление и другие операции обработки данных.

– **Область построения сценария** (центр) — рабочее полотно, на которое добавляются узлы и связи между ними; именно здесь формируется логика решения.

– **Панель инструментов** над полотном — команды для работы со сценарием: выбор режима, выравнивание узлов, запуск вычислений и настройка элементов.

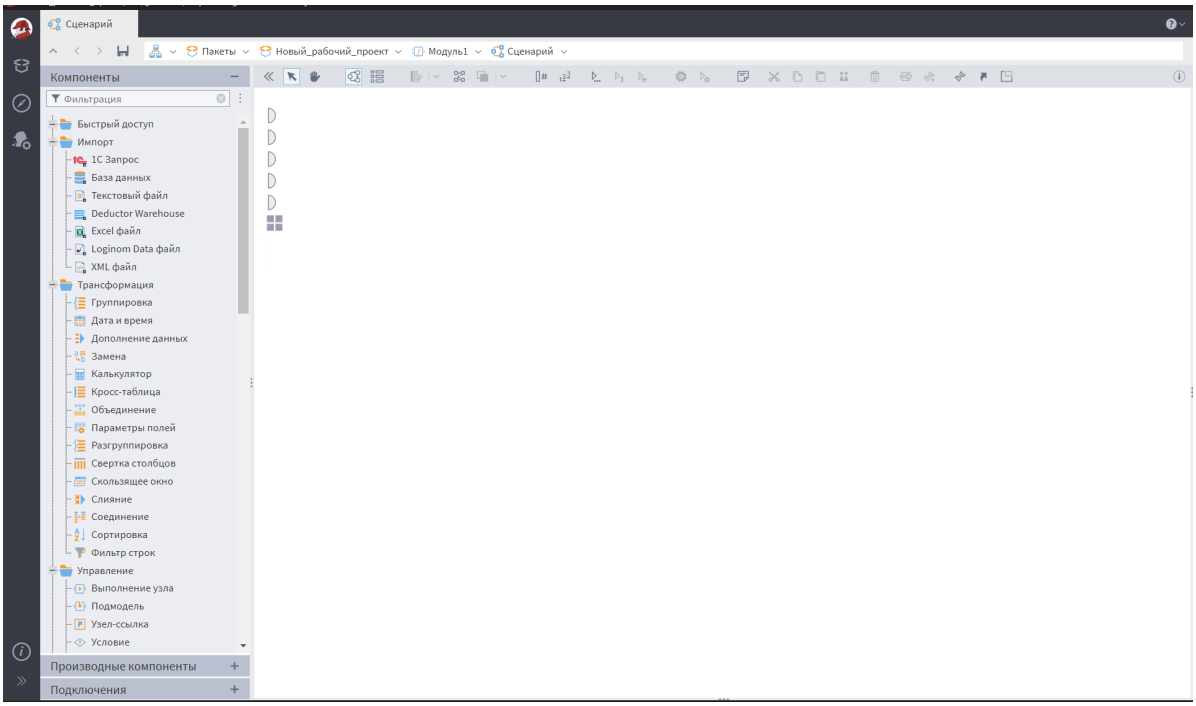


Рисунок 2 – Рабочая область Loginom после создания нового пакета

1.2 Импорт данных

В данной работе используем датасет **House Sales in King County, USA** (файл **kc_house_data.csv**). Набор содержит сведения о сделках с недвижимостью: дату продажи, цену, характеристики дома (площадь, этажность, состояние, класс), а также географические признаки (индекс, широта и долгота). Источник датасета: https://www.kaggle.com/datasets/harlfoxem/housesalesprediction. После загрузки файла перейдём к импорту и первичной настройке структуры данных в Loginom.

Перед началом импорта кратко зафиксируем термины, которые будут использоваться далее. Это позволит легче ориентироваться в интерфейсе и понимать, что именно происходит на каждом шаге:

– **Сценарий** — последовательность шагов обработки данных на рабочем полотне.

– **Компонент** — тип операции из левой панели (например, **Текстовый файл**, **Калькулятор**, **Фильтр строк**).

– **Узел** — экземпляр компонента, добавленный в сценарий и настроенный под конкретную задачу.

– **Порт** — вход или выход узла, через который данные передаются между шагами.

– **Визуализатор** — встроенный способ просмотра результата узла (таблица, статистика, диаграмма и др.).

В панели компонентов откроем раздел **Импорт** и добавим на полотно сценария компонент **Текстовый файл**. После добавления на полотне появляется первый узел, с которого начинается цепочка обработки. На практике это точка входа в сценарий: именно здесь задаются правила, по которым Loginom будет читать исходный CSV.

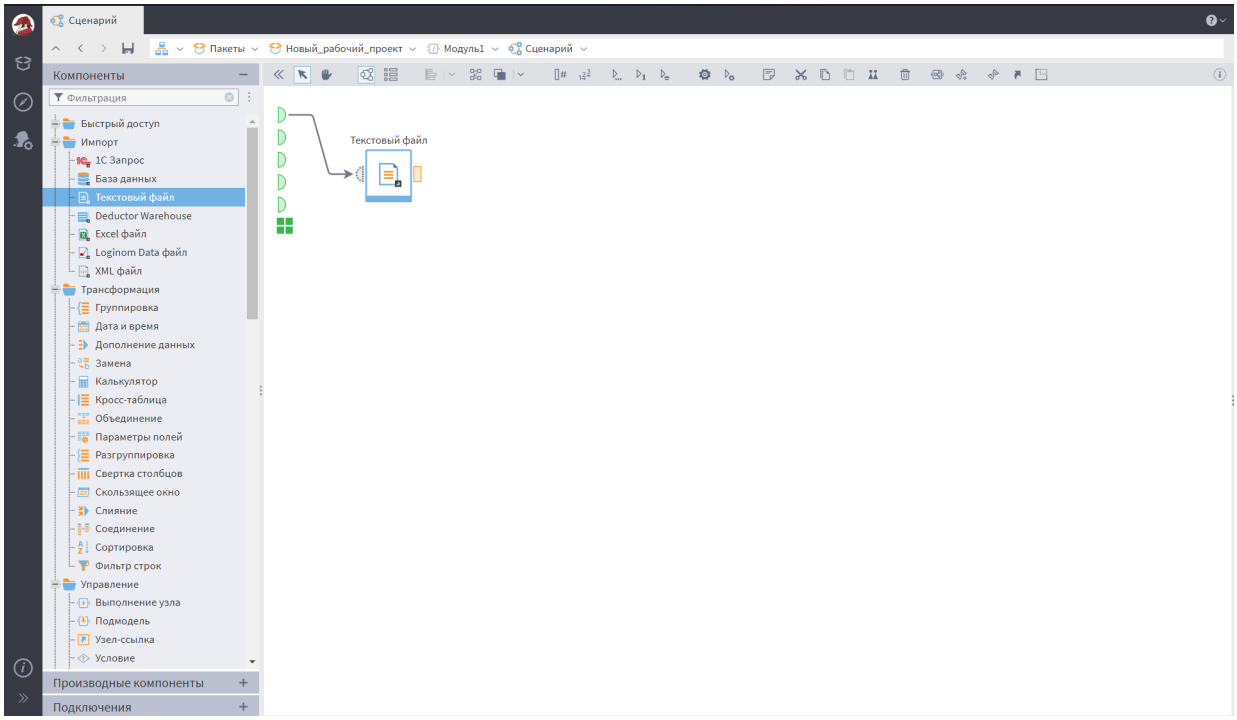


Рисунок 3 – Добавление первого узла **Текстовый файл** на полотно сценария

Далее открываем мастер настройки узла (иконка шестерёнки), указываем путь к файлу **kc_house_data.csv** и проверяем, что включена опция **Заголовок в первой строке**. Если этот флаг отключить, названия полей будут интерпретированы как обычная первая запись данных, что приведёт к некорректной структуре таблицы.

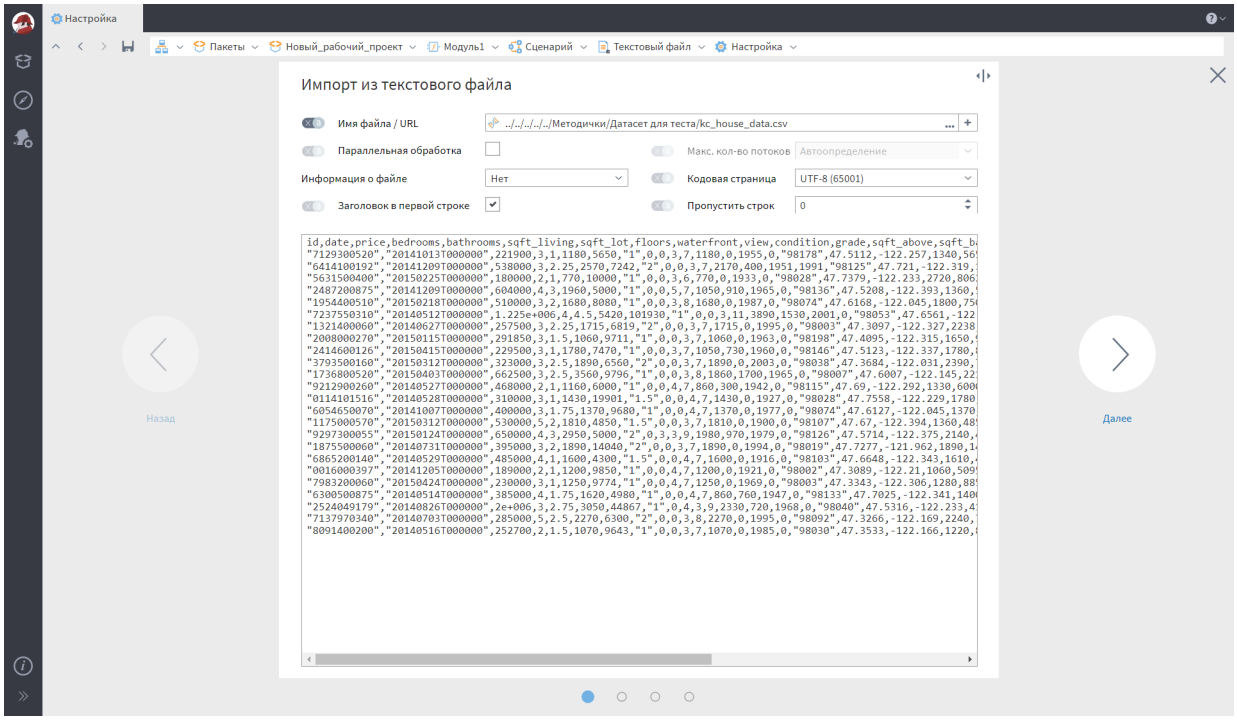


Рисунок 4 – Первый шаг мастера: выбор файла и базовые параметры импорта

На втором шаге задаём ключевые параметры формата:

– **Разделитель столбцов — Запятая**, так как CSV в датасете разделён запятыми.

– **Десятичный разделитель — Точка**, чтобы корректно прочитать дробные значения (например, 2.25 в поле bathrooms).

– При необходимости нажимаем **Обновить все**, чтобы пересчитать распознавание полей по текущим настройкам.

Если на этом этапе выбрать неверный разделитель, файл может быть считан как одна длинная строка. Поэтому сначала задаём правильные параметры формата, затем проверяем вкладку **Результат**, где сразу видно, корректно ли разбились столбцы.

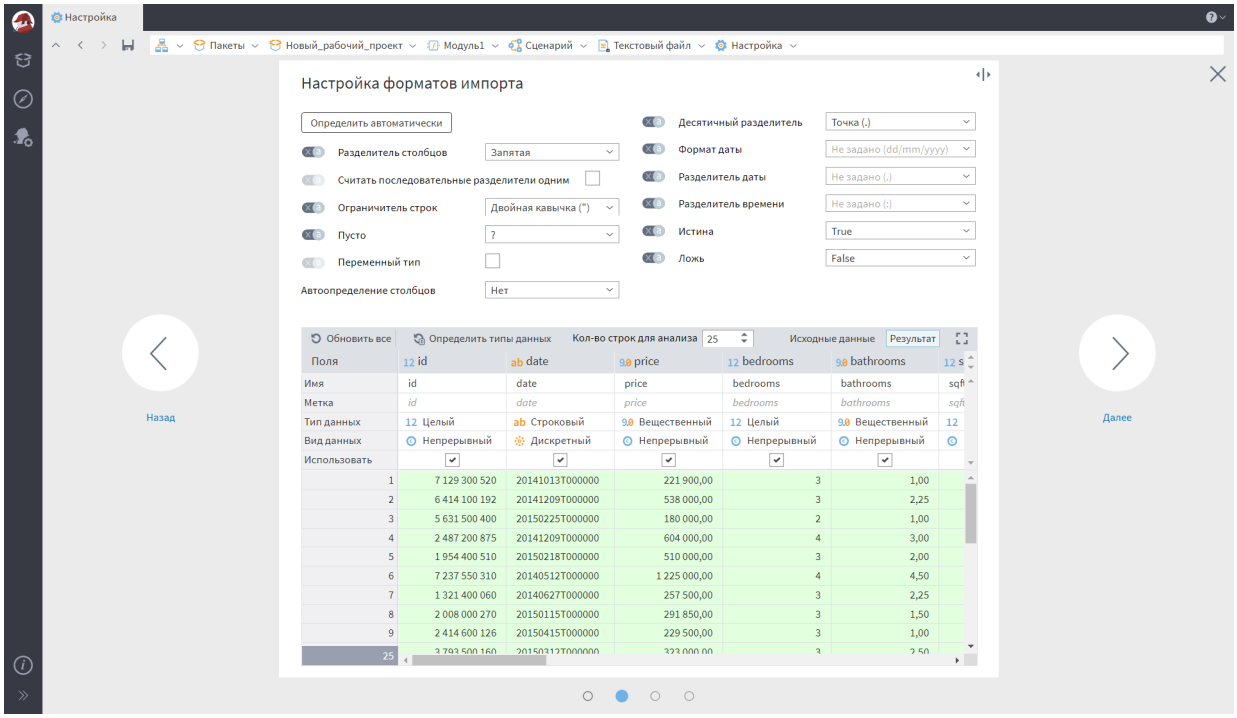


Рисунок 5 – Второй шаг мастера: форматы импорта и предварительный результат

При настройке полей учитываем следующее: тип данных описывает формат значения (строка, целое, вещественное), а вид данных нужен для аналитики и влияет на дальнейшие операции в узлах анализа и визуализации. **Непрерывный** применяем к числовым величинам с диапазоном значений (цена, площади, координаты), **Дискретный** — к категориальным или идентификационным признакам. Такая базовая классификация снижает риск ошибок на следующих этапах преобразований.

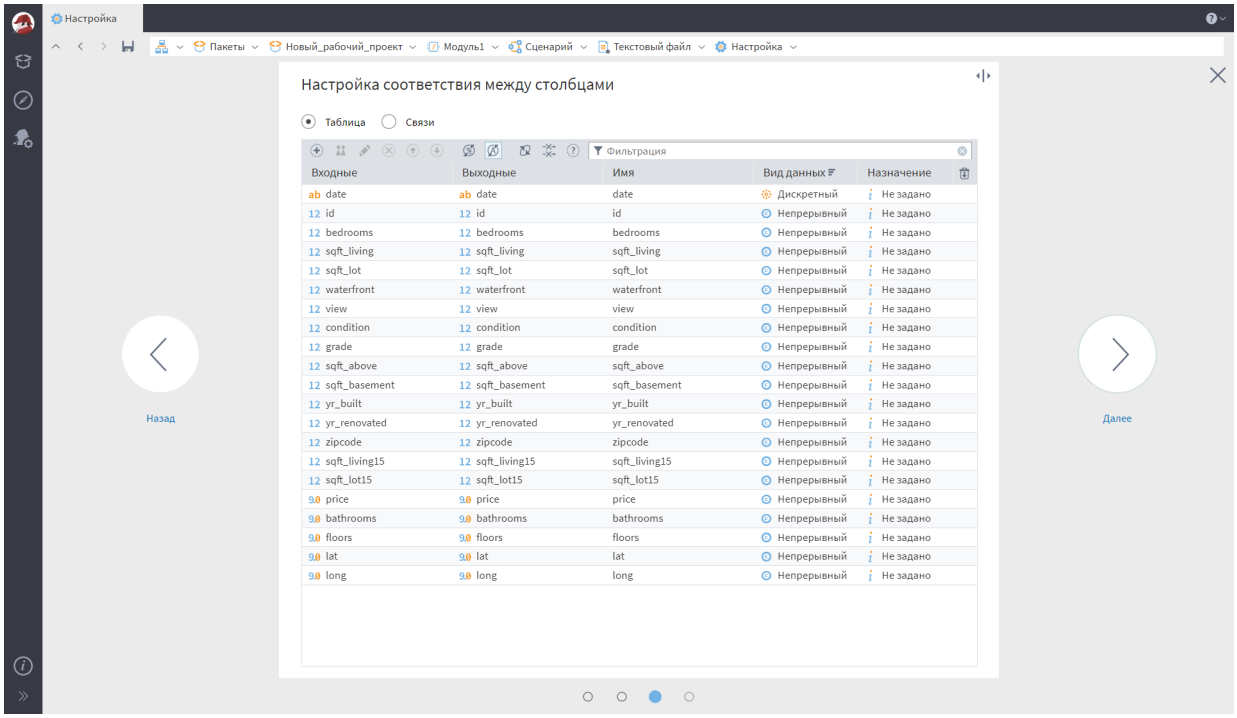


Рисунок 6 – Третий шаг мастера: проверка соответствия входных и выходных столбцов

На последнем шаге оставляем метку узла (автоматическую или пользовательскую), затем завершаем настройку и выполняем узел кнопкой **Выполнить**. Рекомендуется задать понятную метку сразу, чтобы при росте сценария быстро находить нужный узел среди других этапов обработки.

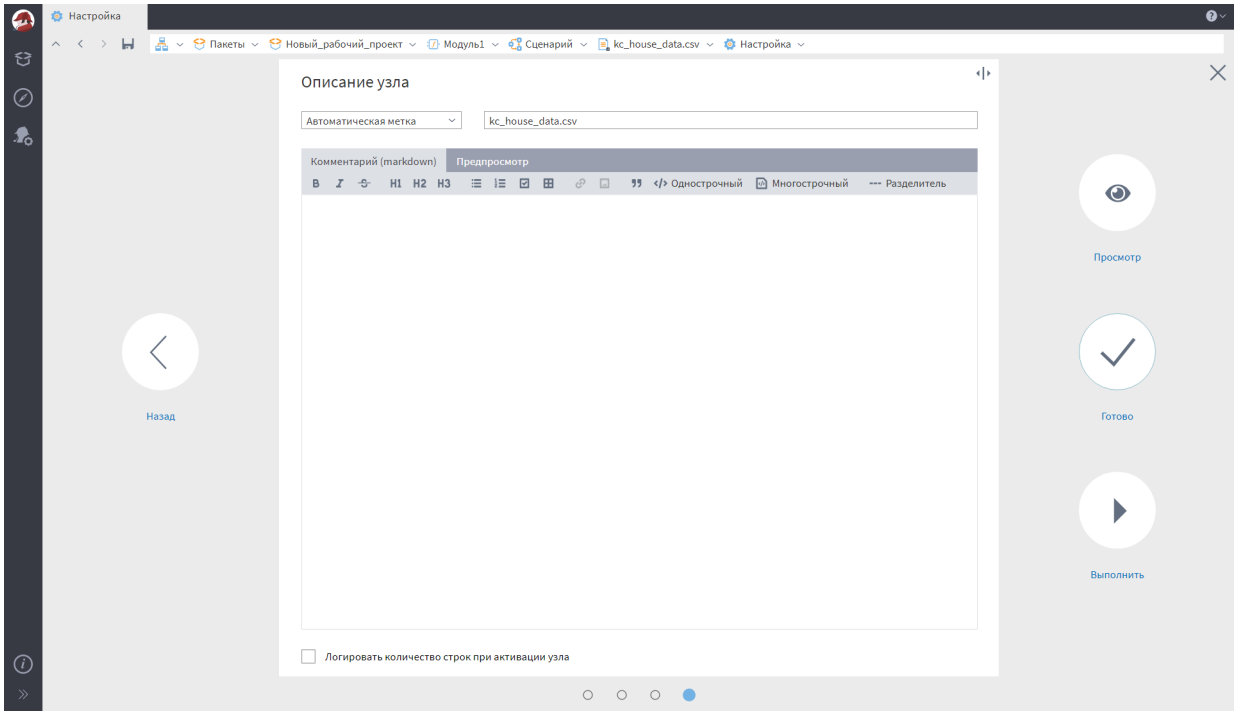


Рисунок 7 – Финальный шаг мастера: описание узла и запуск выполнения

После завершения импорта переходим в **Настройку визуализаторов** узла и добавляем представление **Таблица**. Этот шаг выполняем сразу после запуска узла: так удобнее проверить, что данные прочитаны корректно и готовы к дальнейшим преобразованиям.

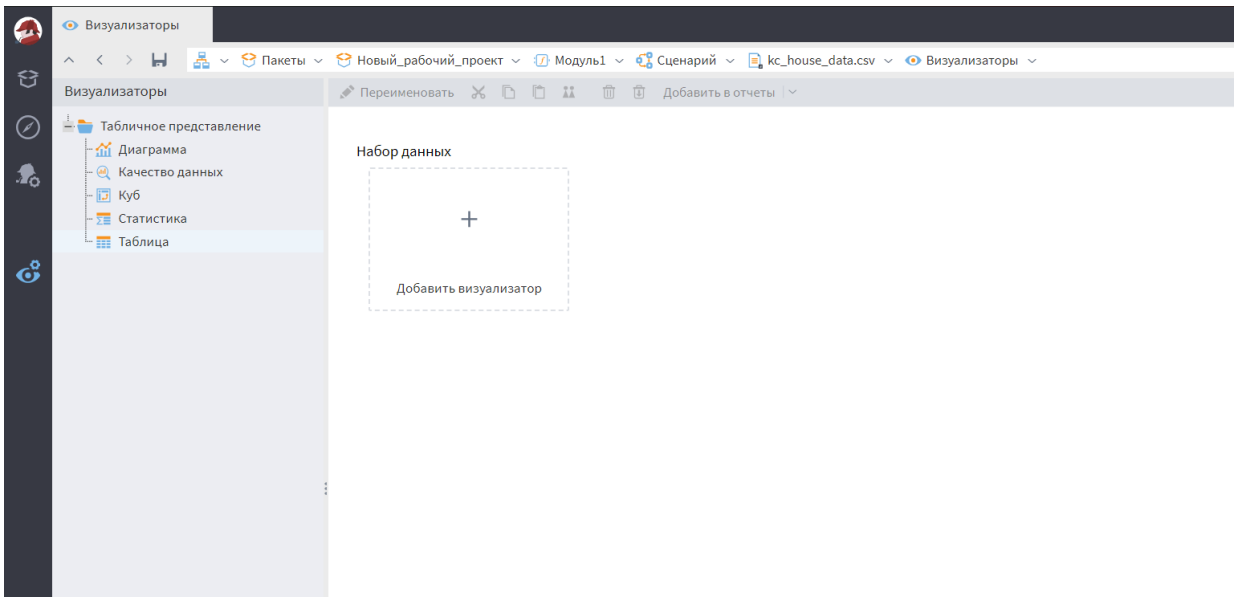
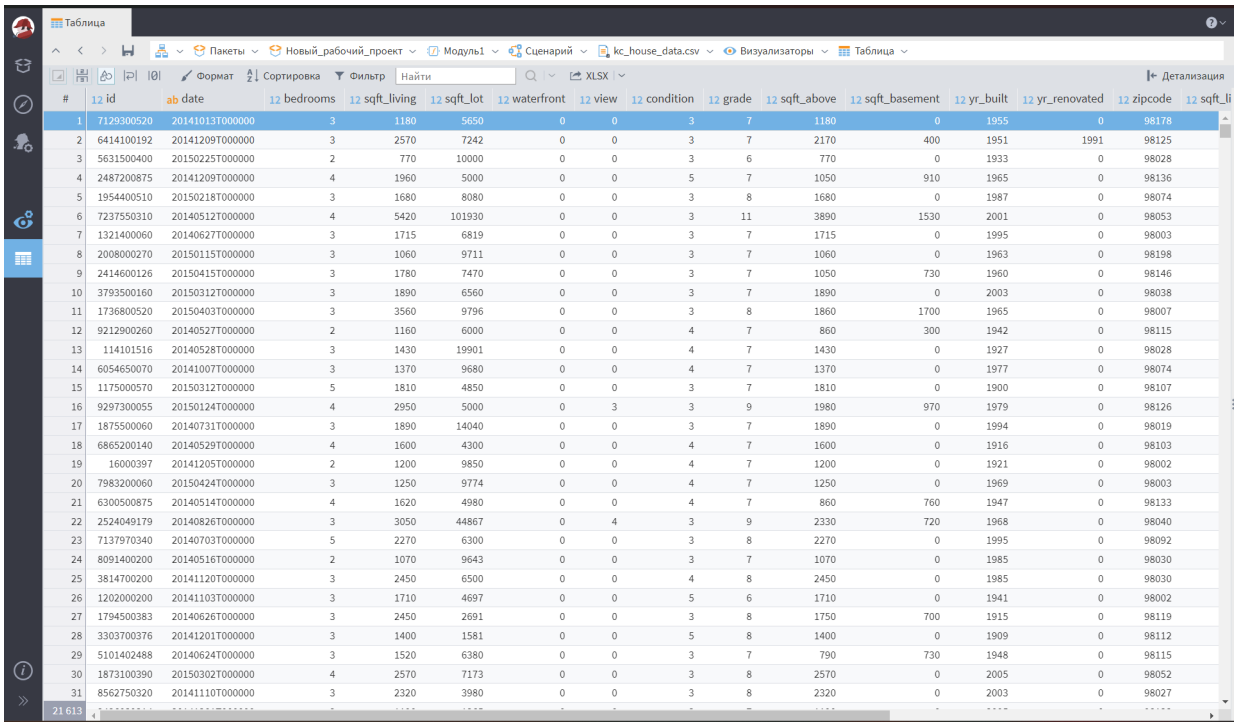


Рисунок 8 – Настройка визуализаторов: добавление табличного представления

После выбора таблицы можно просматривать итоги импорта: корректность разделения столбцов, применённые типы и вид данных, а также наличие возможных пропусков или ошибок парсинга. На этой проверке важно убедиться, что числовые поля читаются без пустых значений, а служебные поля (например, date) пока можно оставить строковыми для последующего преобразования через **Калькулятор**.



#	id	date	bedrooms	sqft_living	sqft_lot	waterfront	view	condition	grade	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	sqft_li
1	7129300520	20141013T000000	3	1180	5650	0	0	3	7	1180	0	1955	0	98178	
2	6414100192	20141209T000000	3	2570	7242	0	0	3	7	2170	400	1951	1991	98125	
3	5631500400	20150225T000000	2	770	10000	0	0	3	6	770	0	1933	0	98028	
4	2487200875	20141209T000000	4	1960	5000	0	0	5	7	1050	910	1965	0	98136	
5	1954400510	20150218T000000	3	1680	8080	0	0	3	8	1680	0	1987	0	98074	
6	7237550310	20140512T000000	4	5420	101930	0	0	3	11	3890	1530	2001	0	98053	
7	1321400060	20140627T000000	3	1715	6819	0	0	3	7	1715	0	1995	0	98003	
8	2008000270	20150115T000000	3	1060	9711	0	0	3	7	1060	0	1963	0	98198	
9	2414600126	20150415T000000	3	1780	7470	0	0	3	7	1050	730	1960	0	98146	
10	3793500160	20150312T000000	3	1890	6560	0	0	3	7	1890	0	2003	0	98038	
11	1736800520	20150403T000000	3	3560	9796	0	0	3	8	1860	1700	1965	0	98007	
12	9212900260	20140527T000000	2	1160	6000	0	0	4	7	860	300	1942	0	98115	
13	114101516	20140528T000000	3	1430	19901	0	0	4	7	1430	0	1927	0	98028	
14	6054650070	20141007T000000	3	1370	9680	0	0	4	7	1370	0	1977	0	98074	
15	1175000570	20150312T000000	5	1810	4850	0	0	3	7	1810	0	1900	0	98107	
16	9297300055	20150124T000000	4	2950	5000	0	3	3	9	1980	970	1979	0	98126	
17	1875500060	20140731T000000	3	1890	14040	0	0	3	7	1890	0	1994	0	98019	
18	6865200140	20140529T000000	4	1600	4300	0	0	4	7	1600	0	1916	0	98103	
19	16000397	20141205T000000	2	1200	9850	0	0	4	7	1200	0	1921	0	98002	
20	7983200060	20150424T000000	3	1250	9774	0	0	4	7	1250	0	1969	0	98003	
21	6300500875	20140514T000000	4	1620	4980	0	0	4	7	860	760	1947	0	98133	
22	2524049179	20140826T000000	3	3050	44867	0	4	3	9	2330	720	1968	0	98040	
23	7137970340	20140703T000000	5	2270	6300	0	0	3	8	2270	0	1995	0	98092	
24	8091400200	20140516T000000	2	1070	9643	0	0	3	7	1070	0	1985	0	98030	
25	3814700200	20141120T000000	3	2450	6500	0	0	4	8	2450	0	1985	0	98030	
26	1202000200	20141103T000000	3	1710	4697	0	0	5	6	1710	0	1941	0	98002	
27	1794500383	20140626T000000	3	2450	2691	0	0	3	8	1750	700	1915	0	98119	
28	3303700376	20141201T000000	3	1400	1581	0	0	5	8	1400	0	1909	0	98112	
29	5101402488	20140624T000000	3	1520	6380	0	0	3	7	790	730	1948	0	98115	
30	1873100390	20150302T000000	4	2570	7173	0	0	3	8	2570	0	2005	0	98052	
31	8562750320	20141110T000000	3	2320	3980	0	0	3	8	2320	0	2003	0	98027	

21 613

Рисунок 9 – Результат импорта данных в табличном визуализаторе

1.3 Преобразование полей и добавление новых признаков

Следующий этап — подготовка дополнительных аналитических полей в узле **Калькулятор**. Добавим узел в сценарий, соединим его с выходом импорта и откроем окно редактирования выражений.

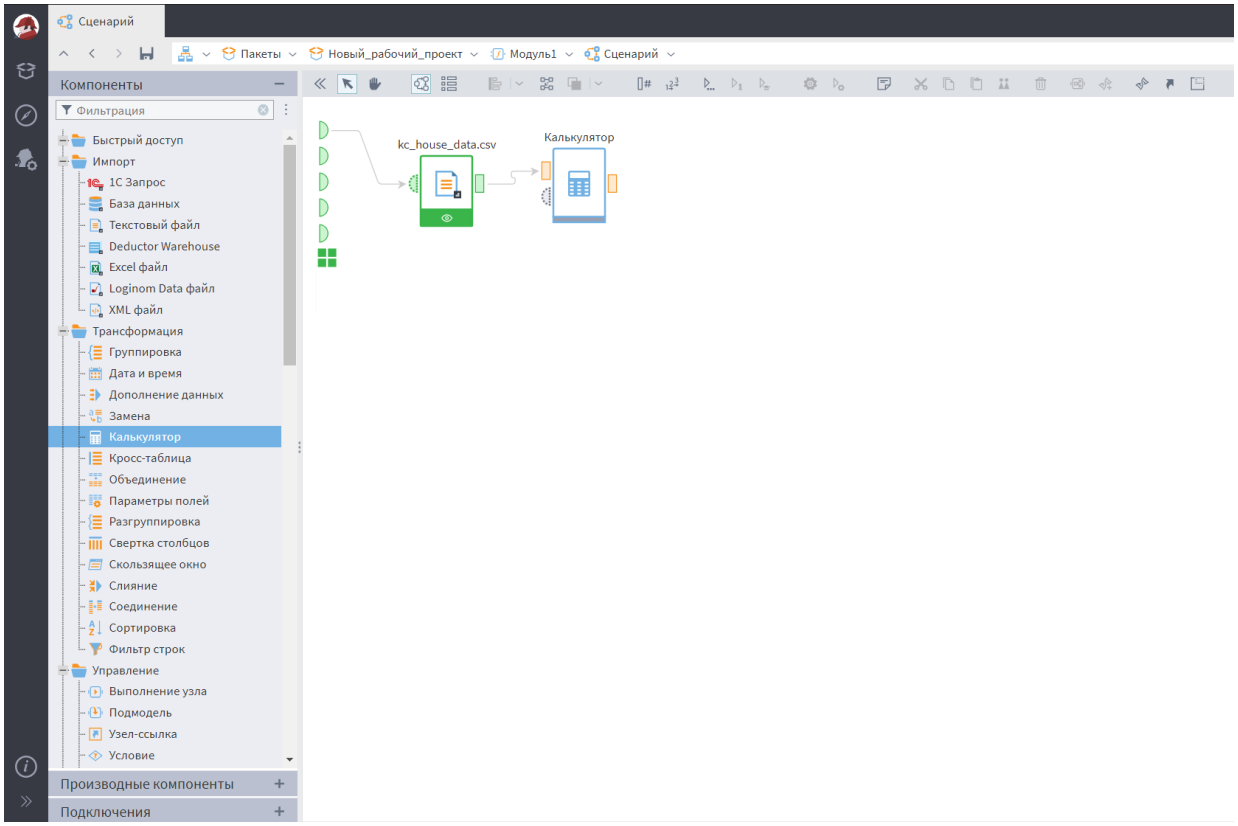


Рисунок 10 – Добавление второго узла **Калькулятор** в сценарий

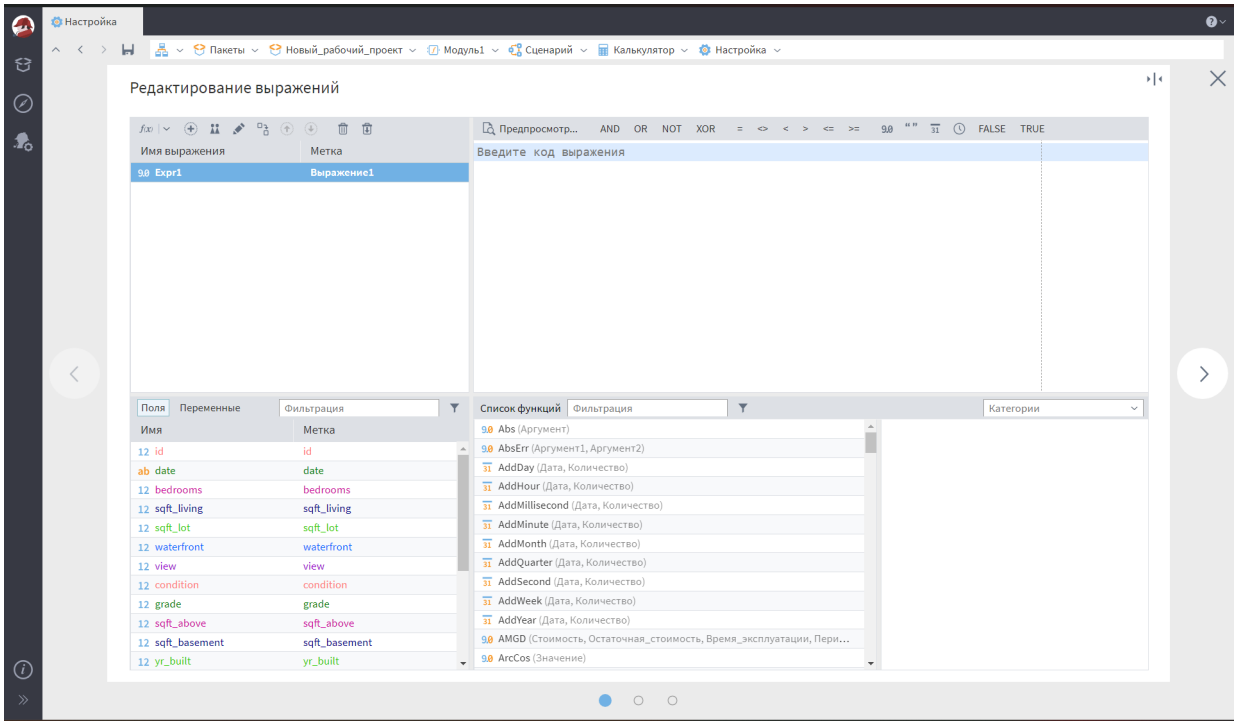


Рисунок 11 – Окно редактирования выражений в узле **Калькулятор**

Далее создадим три новых поля. Для каждого зададим имя, тип данных, формулу и проверим результат после выполнения узла.

Поле 1: sale_datetime

Исходное поле date хранится в строковом формате 20141013T000000, поэтому преобразуем его в тип **Дата/время**. Это позволит использовать временные функции, сортировку по дате и построение динамики продаж.

Создадим выражение sale_datetime и в параметрах укажем тип **Дата/время**.

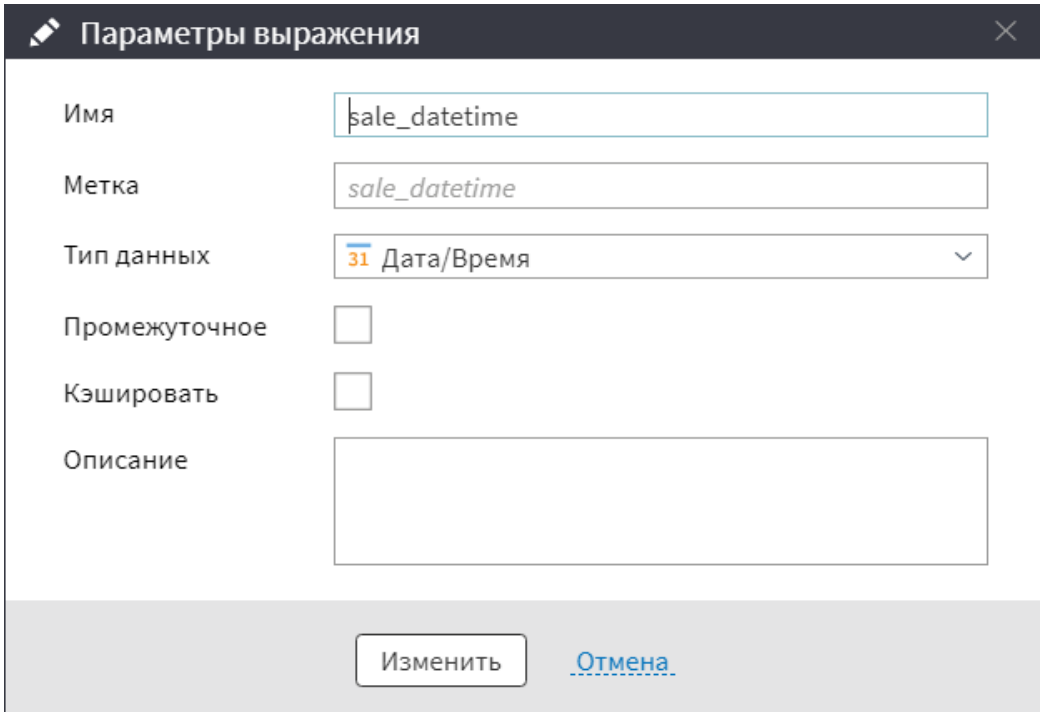


Рисунок 12 – Параметры выражения для поля sale_datetime

Формула преобразования:

```
StrToDate(
  SubStr(date,1,4)+"-"+SubStr(date,5,2)+"-"+SubStr(date,7,2)+" "+
  SubStr(date,10,2)+":"+SubStr(date,12,2)+":"+SubStr(date,14,2),
  "YYYY-MM-DD HH:NN:SS"
)
```

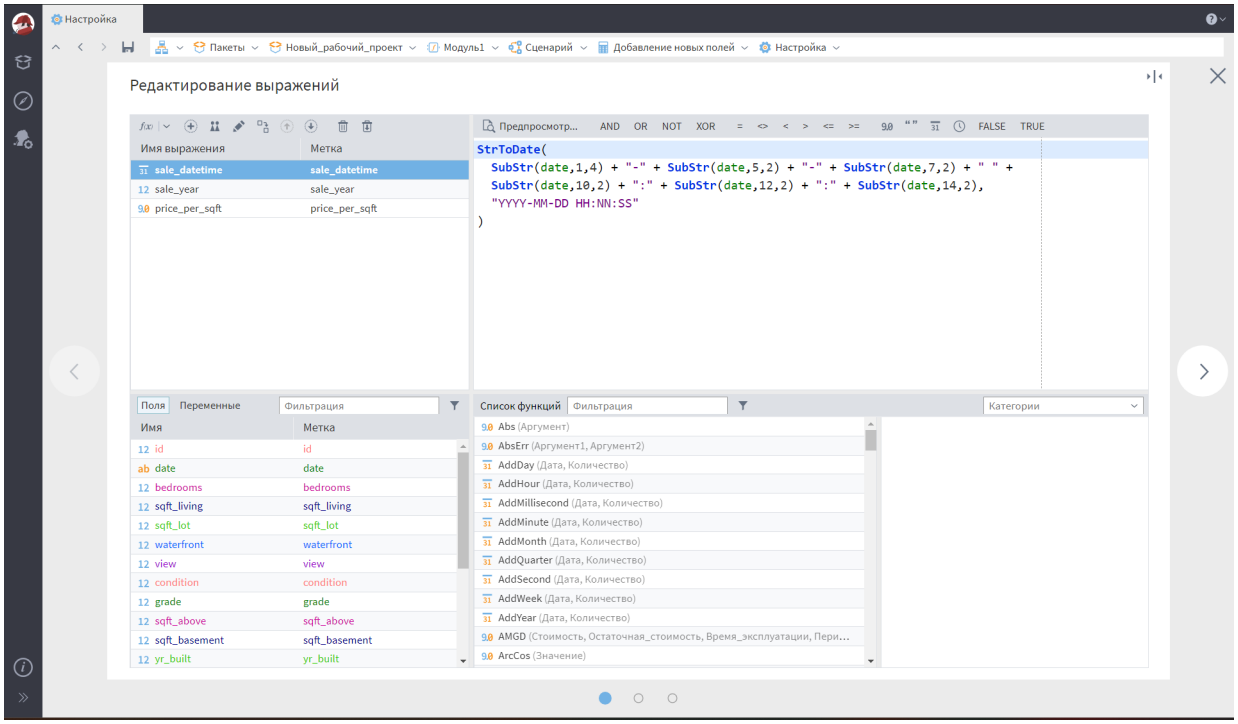


Рисунок 13 – Выражение для поля sale_datetime

Поле 2: sale_year

На основе sale_datetime извлечём год продажи — это удобный признак для группировки и сравнения показателей по годам. Тип результата — **Целый**, формула: Year(sale_datetime).

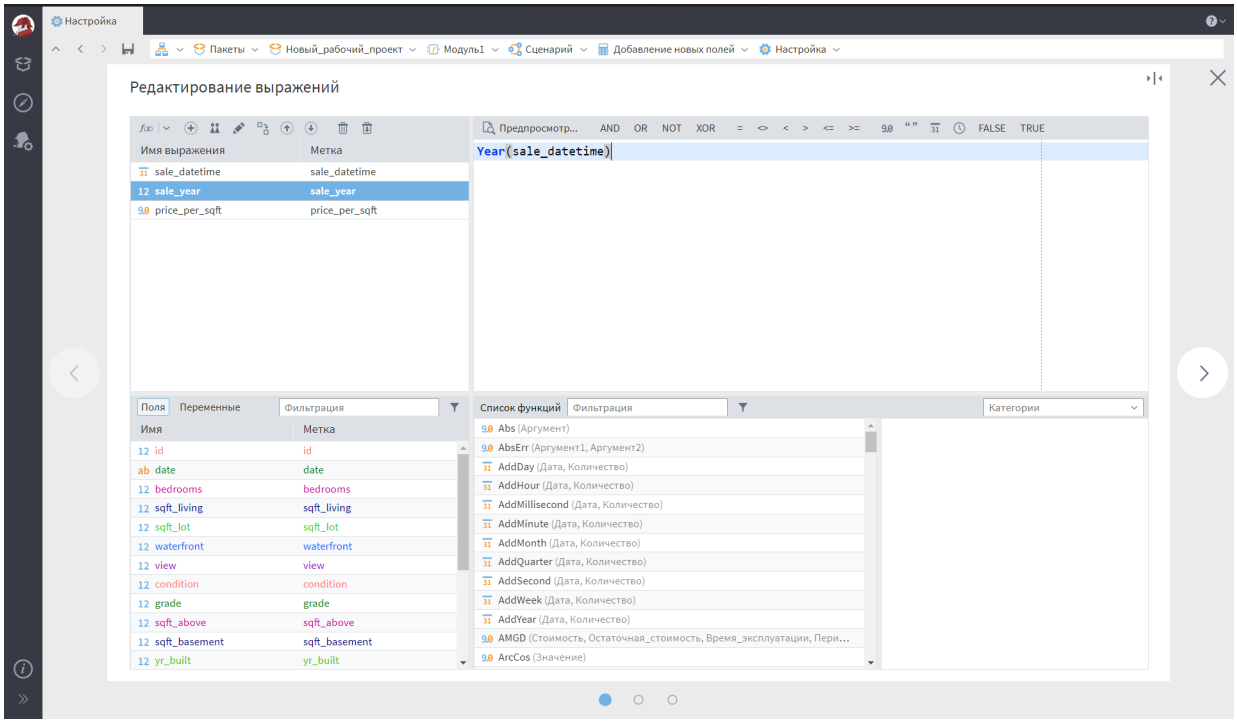


Рисунок 14 – **Выражение** Year(sale_datetime) **для поля** sale_year

Поле 3: price_per_sqft

Чтобы сравнивать объекты разной площади на единой шкале, рассчитаем нормированную стоимость: цена за квадратный фут жилой площади. Тип результата — **Вещественный**, формула: price / sqft_living.

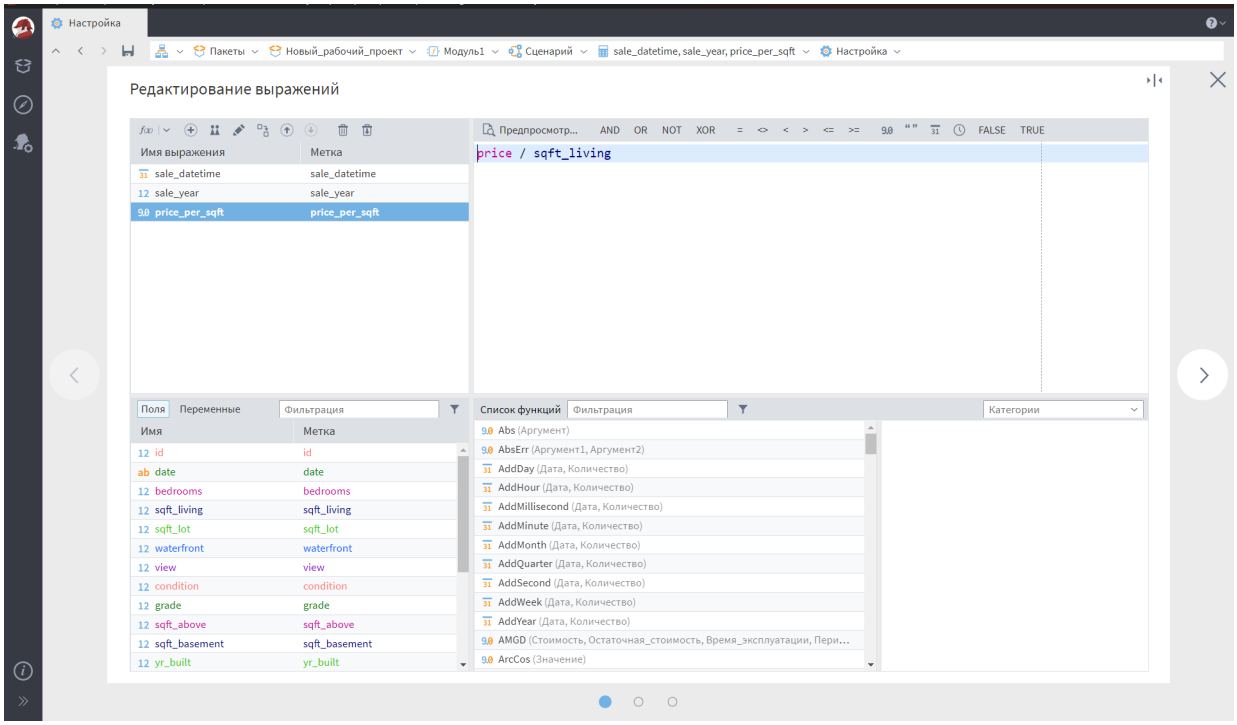


Рисунок 15 – Выражение price / sqft_living для поля price_per_sqft

После ввода всех трёх выражений сохраним настройки и выполним узел **Калькулятор**. В таблице результата проверим, что новые поля появились и заполнены корректными значениями.

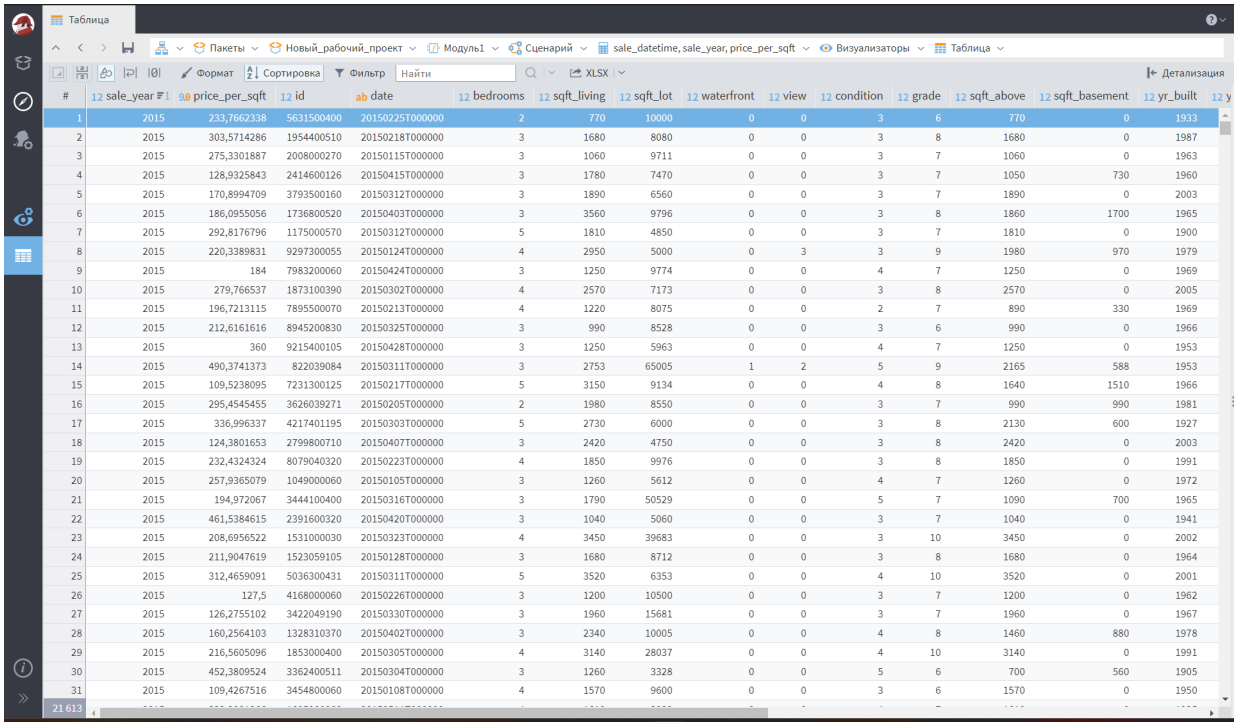
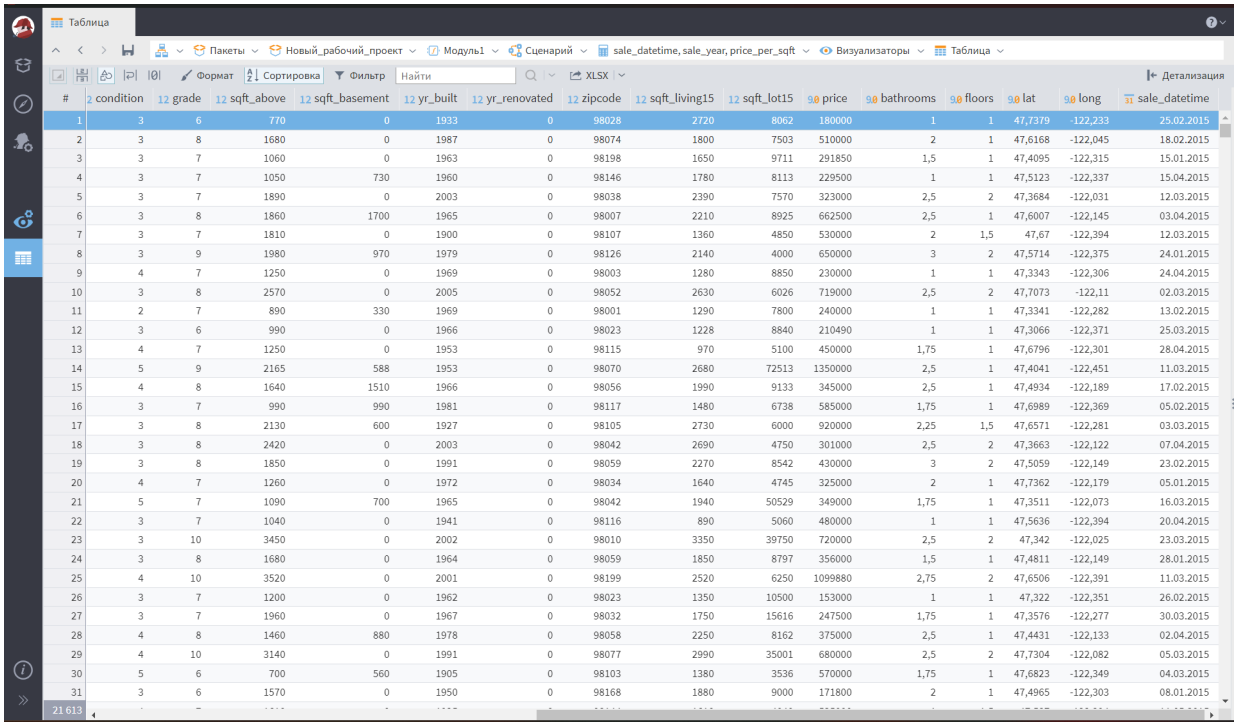


Рисунок 16 – Новые поля sale_year и price_per_sqft в таблице результата



#	condition	grade	sqft_above	sqft_basement	yr_built	yr_renovated	zipcode	sqft_living15	sqft_lot15	price	bathrooms	floors	lat	long	sale_datetime
1	3	6	770	0	1933	0	98028	2720	8062	180000	1	1	47,7379	-122,233	25.02.2015
2	3	8	1680	0	1987	0	98074	1800	7503	510000	2	1	47,6168	-122,045	18.02.2015
3	3	7	1060	0	1963	0	98198	1650	9711	291850	1,5	1	47,4095	-122,315	15.01.2015
4	3	7	1050	730	1960	0	98146	1780	8113	229500	1	1	47,5123	-122,337	15.04.2015
5	3	7	1890	0	2003	0	98038	2390	7570	323000	2,5	2	47,3684	-122,031	12.03.2015
6	3	8	1860	1700	1965	0	98007	2210	8925	662500	2,5	1	47,6007	-122,145	03.04.2015
7	3	7	1810	0	1900	0	98107	1360	4850	530000	2	1,5	47,67	-122,394	12.03.2015
8	3	9	1980	970	1979	0	98126	2140	4000	650000	3	2	47,5714	-122,375	24.01.2015
9	4	7	1250	0	1969	0	98003	1280	8850	230000	1	1	47,3343	-122,306	24.04.2015
10	3	8	2570	0	2005	0	98052	2630	6026	719000	2,5	2	47,7073	-122,11	02.03.2015
11	2	7	890	330	1969	0	98001	1290	7800	240000	1	1	47,3341	-122,282	13.02.2015
12	3	6	990	0	1966	0	98023	1228	8840	210490	1	1	47,3066	-122,371	25.03.2015
13	4	7	1250	0	1953	0	98115	970	5100	450000	1,75	1	47,6796	-122,301	28.04.2015
14	5	9	2165	588	1953	0	98070	2680	72513	1350000	2,5	1	47,4041	-122,451	11.03.2015
15	4	8	1640	1510	1966	0	98056	1990	9133	345000	2,5	1	47,4934	-122,189	17.02.2015
16	3	7	990	990	1981	0	98117	1480	6738	585000	1,75	1	47,6989	-122,369	05.02.2015
17	3	8	2130	600	1927	0	98105	2730	6000	920000	2,25	1,5	47,6571	-122,281	03.03.2015
18	3	8	2420	0	2003	0	98042	2690	4750	301000	2,5	2	47,3663	-122,122	07.04.2015
19	3	8	1850	0	1991	0	98059	2270	8542	430000	3	2	47,5059	-122,149	23.02.2015
20	4	7	1260	0	1972	0	98034	1640	4745	325000	2	1	47,7362	-122,179	05.01.2015
21	5	7	1090	700	1965	0	98042	1940	50529	349000	1,75	1	47,3511	-122,073	16.03.2015
22	3	7	1040	0	1941	0	98116	890	5060	480000	1	1	47,5636	-122,394	20.04.2015
23	3	10	3450	0	2002	0	98010	3350	39750	720000	2,5	2	47,342	-122,025	23.03.2015
24	3	8	1680	0	1964	0	98059	1850	8797	356000	1,5	1	47,4811	-122,149	28.01.2015
25	4	10	3520	0	2001	0	98199	2520	6250	1099880	2,75	2	47,6506	-122,391	11.03.2015
26	3	7	1200	0	1962	0	98023	1350	10500	153000	1	1	47,322	-122,351	26.02.2015
27	3	7	1960	0	1967	0	98032	1750	15616	247500	1,75	1	47,3576	-122,277	30.03.2015
28	4	8	1460	880	1978	0	98058	2250	8162	375000	2,5	1	47,4431	-122,133	02.04.2015
29	4	10	3140	0	1991	0	98077	2990	35001	680000	2,5	2	47,7304	-122,082	05.03.2015
30	5	6	700	560	1905	0	98103	1380	3536	570000	1,75	1	47,6823	-122,349	04.03.2015
31	3	6	1570	0	1950	0	98168	1880	9000	171800	2	1	47,4965	-122,303	08.01.2015

21 613

Рисунок 17 – Поле sale_datetime в формате **Дата/время**

1.4 Фильтрация данных

Следующим шагом выполним фильтрацию, чтобы убрать некорректные и экстремальные записи перед визуализацией и сравнительным анализом.

Шаг 1. Добавим узел фильтра.

– Добавим узел **Фильтр строк** после узла **Калькулятор**.

– Соединим выход **Калькулятора** со входом узла **Фильтр строк**.

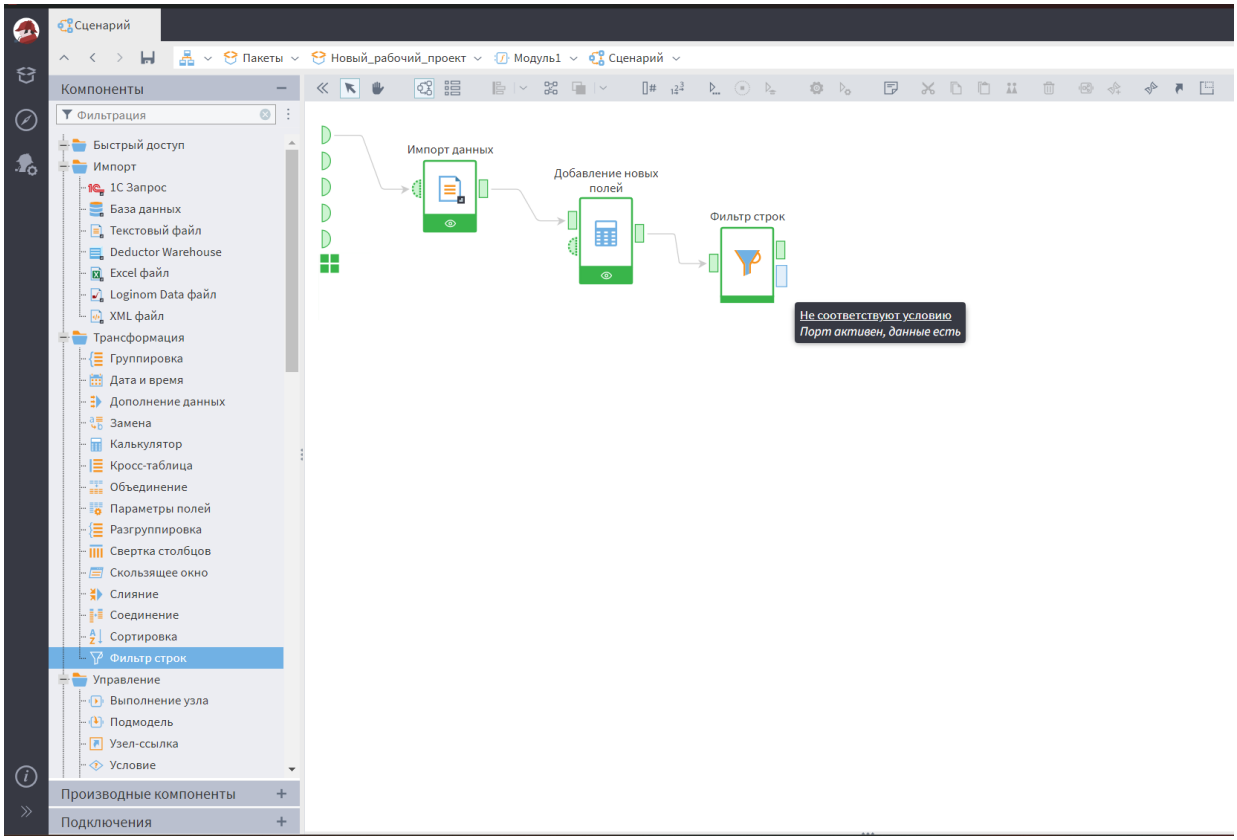


Рисунок 18 – Добавление узла **Фильтр строк** в сценарий

После добавления узла откроем его настройки. Если вход не активирован, нажмём **Активировать**, чтобы фильтр получил доступ к данным с предыдущего шага.

Шаг 2. Зададим условия фильтрации.

– $\text{price} > 0$

– $\text{sqft_living} > 0$

– $\text{price_per_sqft} >= 50 \text{ and } \text{price_per_sqft} <= 1500$

Первые два условия исключают технически некорректные строки (нулевая цена или нулевая площадь), а ограничение по price_per_sqft убирает экстремальные выбросы, которые искажают средние значения и диаграммы.

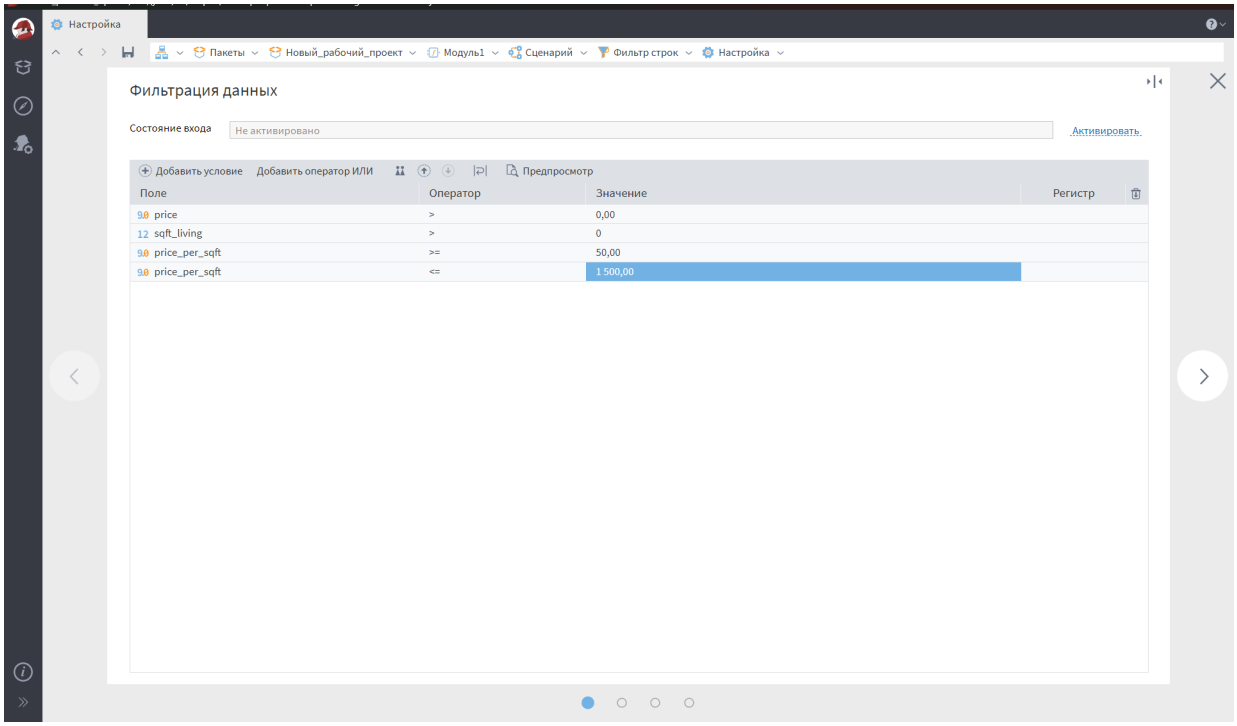


Рисунок 19 – Настройка условий фильтрации в узле **Фильтр строк**

Шаг 3. Выполним фильтр и проверим результат.

– Перейдём на шаг описания узла и зададим удобную метку, например **Фильтрация данных**.

– Выполним узел и проверим результат в табличном визуализаторе на **первом** выходном порте — **Соответствуют условию**.

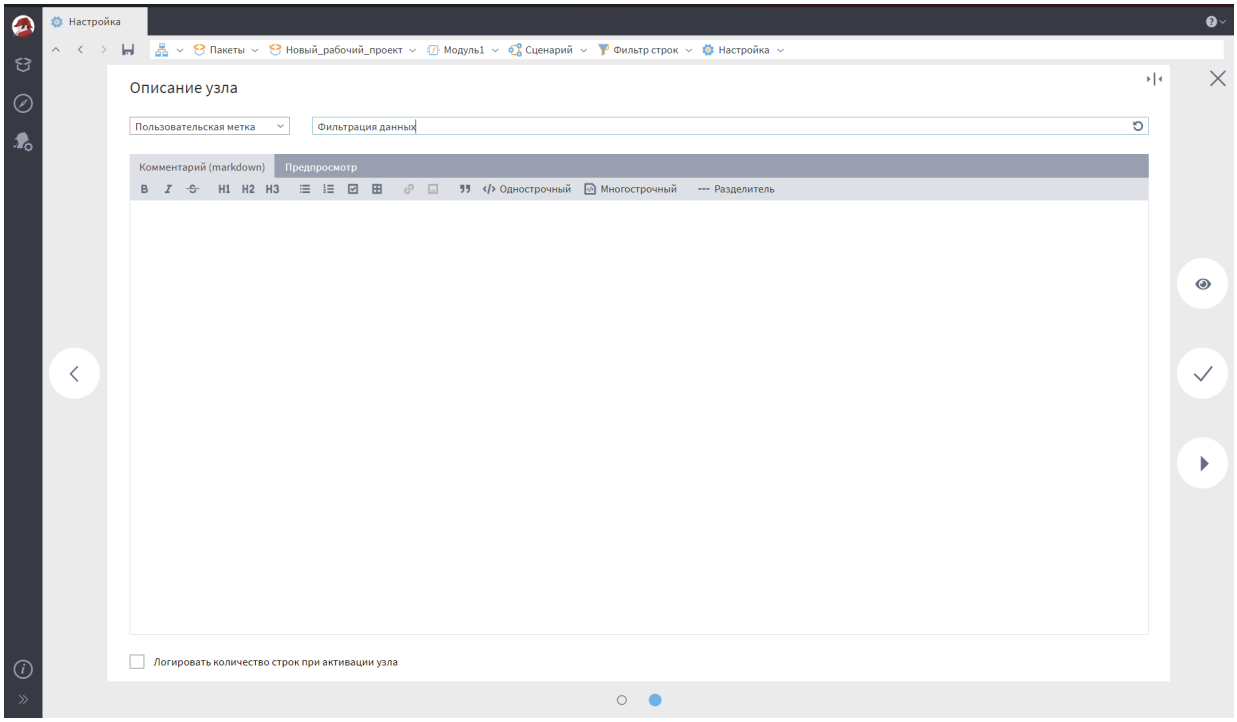


Рисунок 20 – Финальный шаг настройки фильтра: описание узла и готовность к выполнению

Важно про выходные порты. У узла **Фильтр строк** два выхода: первый — **Соответствуют условию** (данные, прошедшие фильтр), второй — **Не соответствуют условию** (отброшенные строки). Все последующие узлы сценария — корреляционный анализ, сортировка, стратификация и разбиение на выборки — подключаем только к **первому** порту. Если ошибочно взять второй, дальше окажется слишком мало записей, и расчёты (в том числе коэффициент Пирсона) дадут искажённый результат.

1.5 Корреляционный анализ

После фильтрации переходим к анализу взаимосвязей между признаками. **Корреляционный анализ** показывает, насколько сильно числовые поля изменяются согласованно: коэффициент Пирсона принимает значения от -1 до 1, где 1 означает прямую линейную связь, -1 — обратную, а 0 — отсутствие линейной зависимости. На этом этапе нас интересует, какие характеристики дома сильнее всего связаны с целевым признаком price. Это помогает понять

структуру данных до построения модели и заранее увидеть наиболее значимые факторы стоимости.

Добавим узел **Корреляционный анализ** и соединим его вход с первым выходным портом узла **Фильтр строк — Соответствуют условию**.

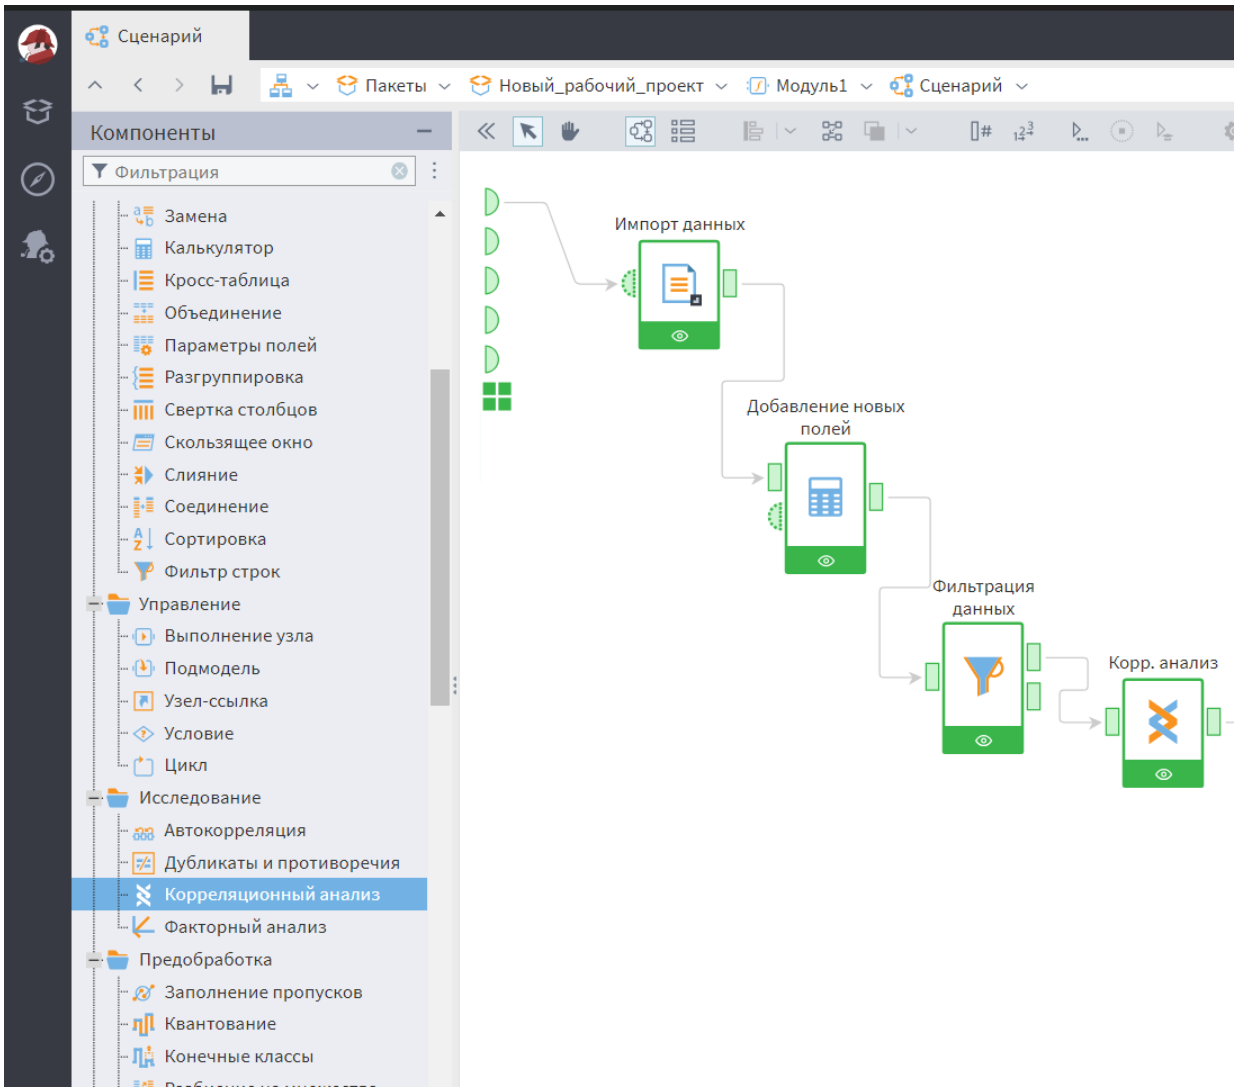


Рисунок 21 – Добавление узла **Корреляционный анализ** в сценарий

В качестве метода оставим только **Коэффициент корреляции Пирсона**, остальные варианты снимем. В таблице входных колонок настроим два набора полей:

– **Набор 1** — только price. Это целевой признак, относительно которого считается корреляция.

– **Набор 2** — числовые предикторы: sale_year, price_per_sqft, bedrooms, bathrooms, sqft_living, sqft_lot, floors, waterfront, view, condition, grade,

sqft_above, sqft_basement, yr_built, yr_renovated, lat, long, sqft_living15, sqft_lot15.

– Поля id, date, zipcode и sale_datetime не включаем: идентификатор, почтовый индекс и строковые или служебные форматы не подходят для расчёта коэффициента Пирсона.

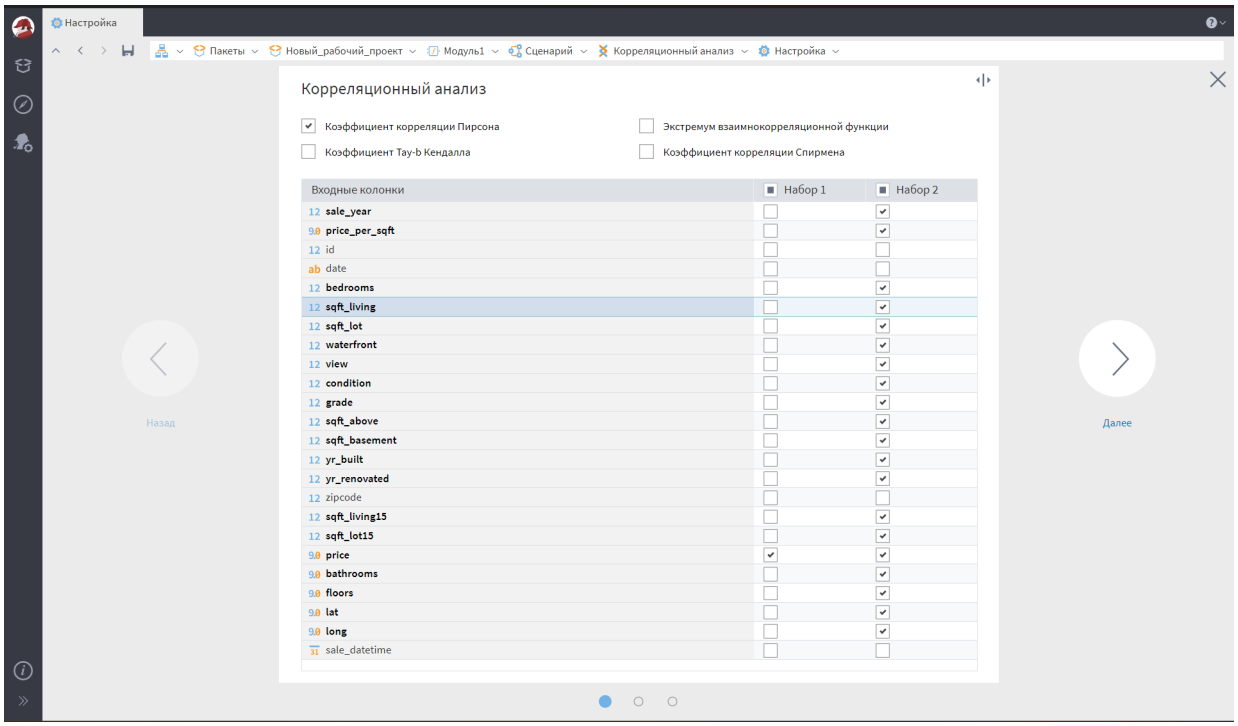


Рисунок 22 – Выбор метода Пирсона и полей для расчёта корреляции

На шаге описания узла зададим метку **Корр. анализ**, сохраним настройки и выполним узел.

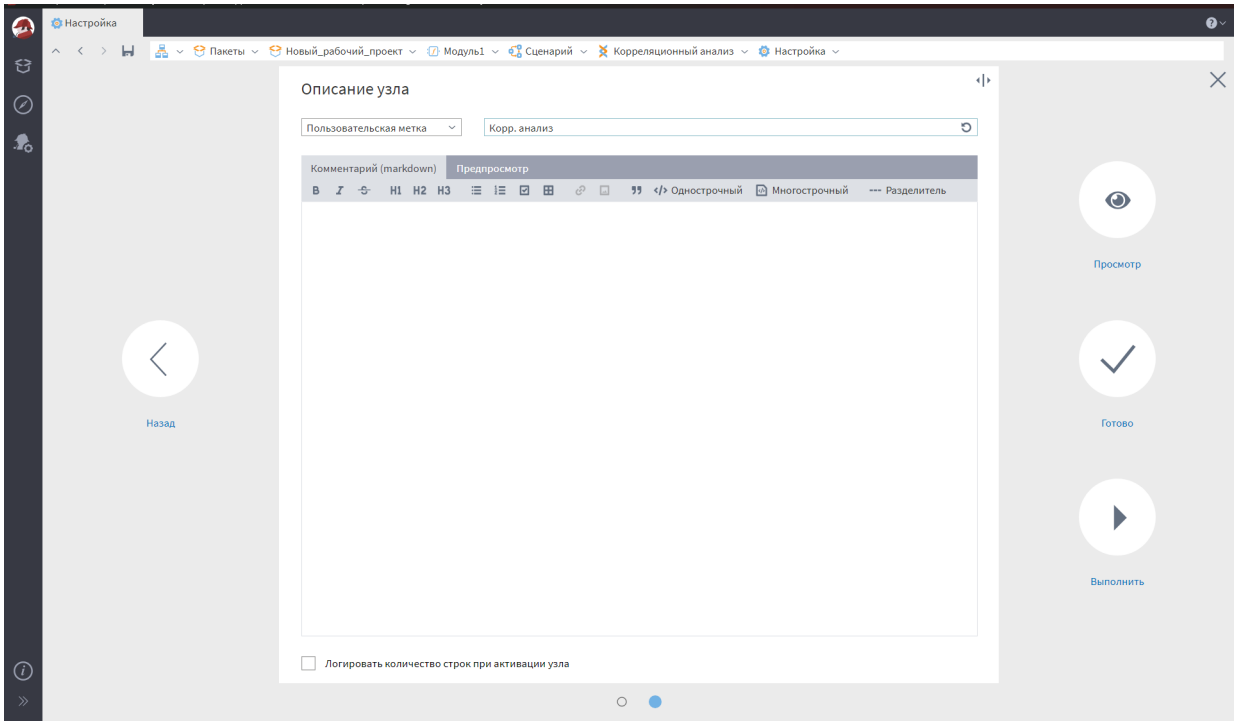


Рисунок 23 – Описание узла **Корреляционный анализ** перед выполнением

Чтобы быстрее увидеть наиболее значимые признаки, добавим узел **Сортировка** и соединим его вход с выходом **Корреляционного анализа**.

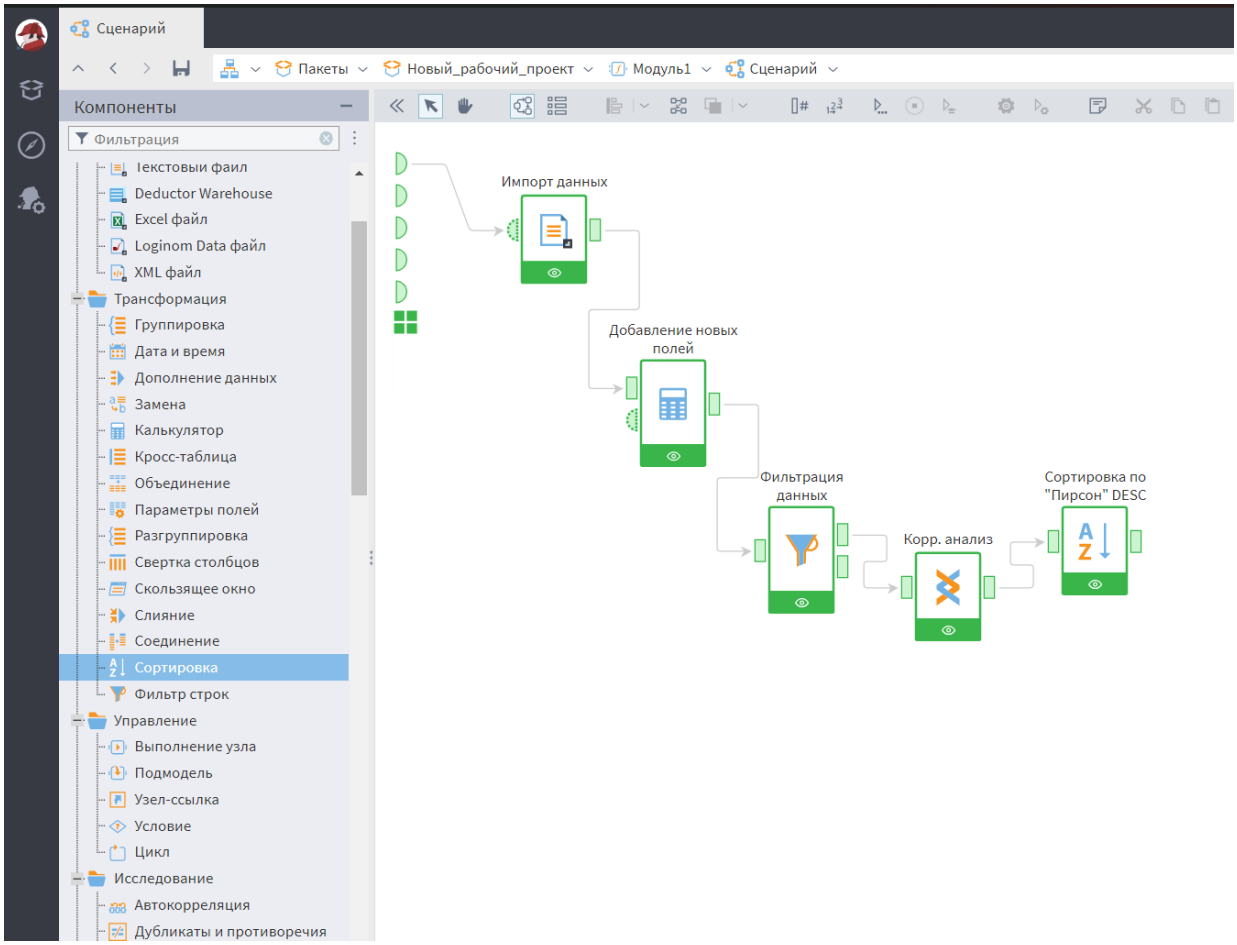


Рисунок 24 – Добавление узла **Сортировка** после корреляционного анализа

В настройках сортировки перенесём столбец **Пирсона** в список полей сортировки и установим порядок **по убыванию**. На шаге описания узла удобно зафиксировать метку **Сортировка по «Пирсон» DESC**.

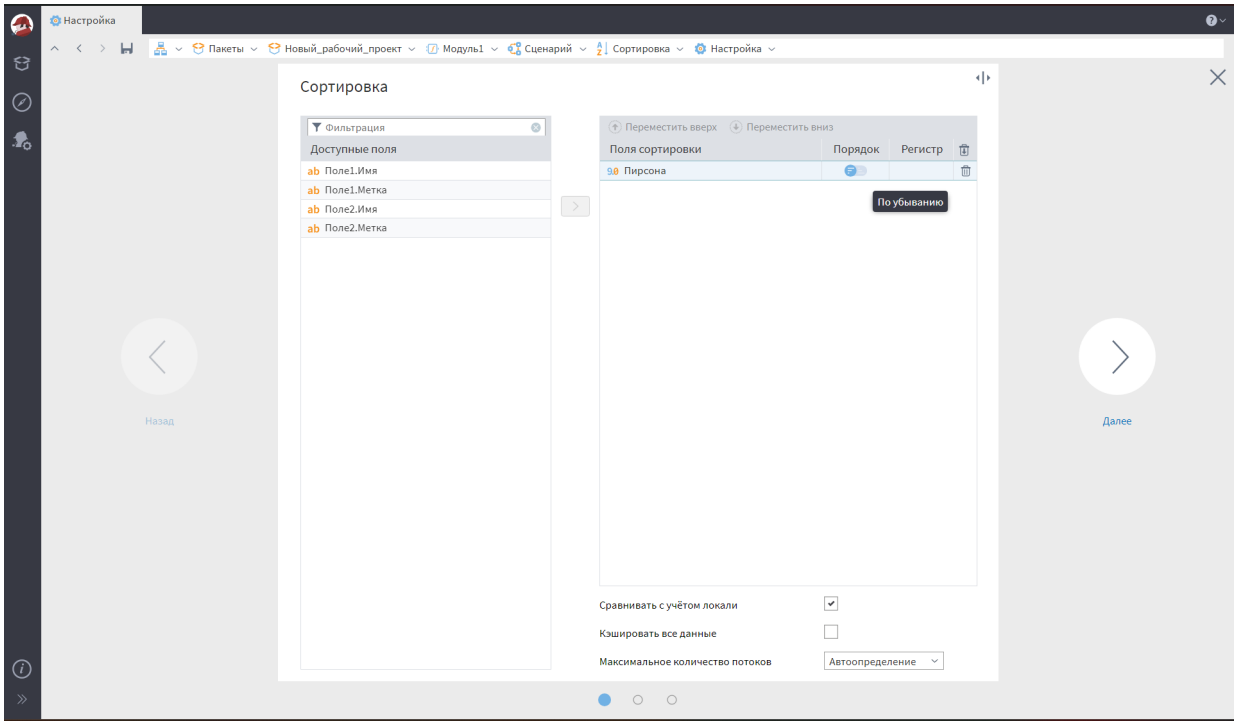


Рисунок 25 – Сортировка результатов по столбцу **Пирсона** по убыванию

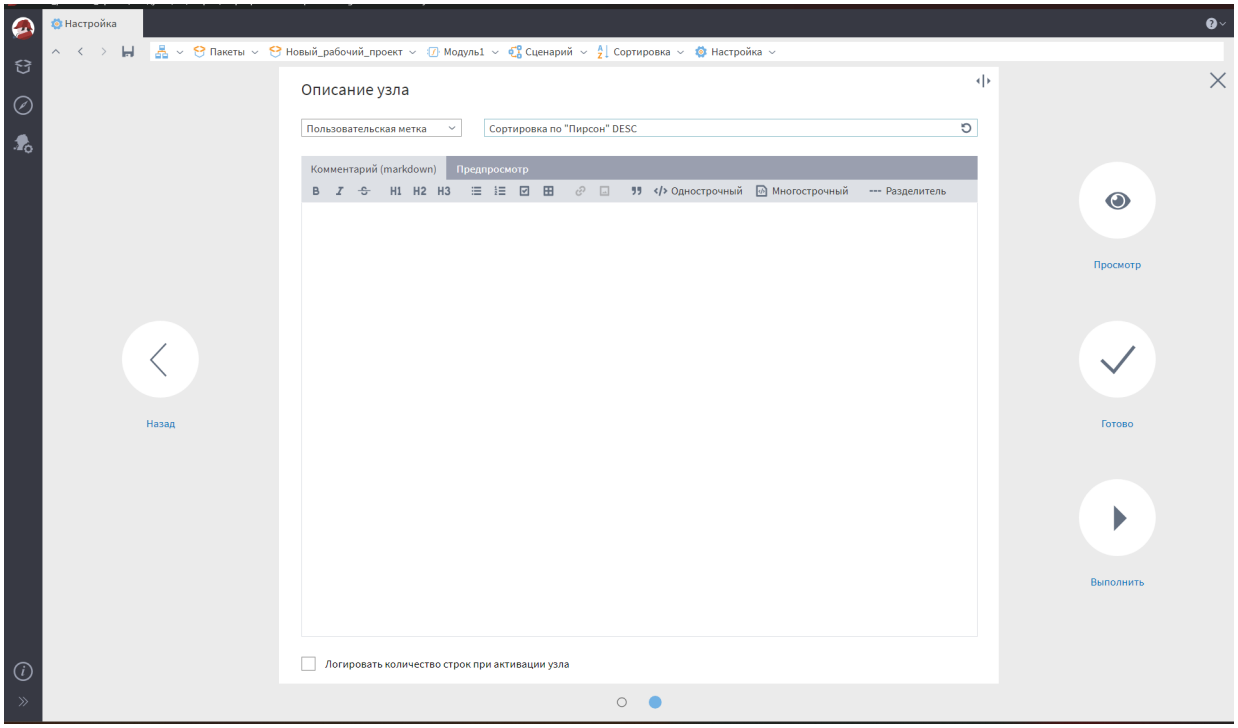
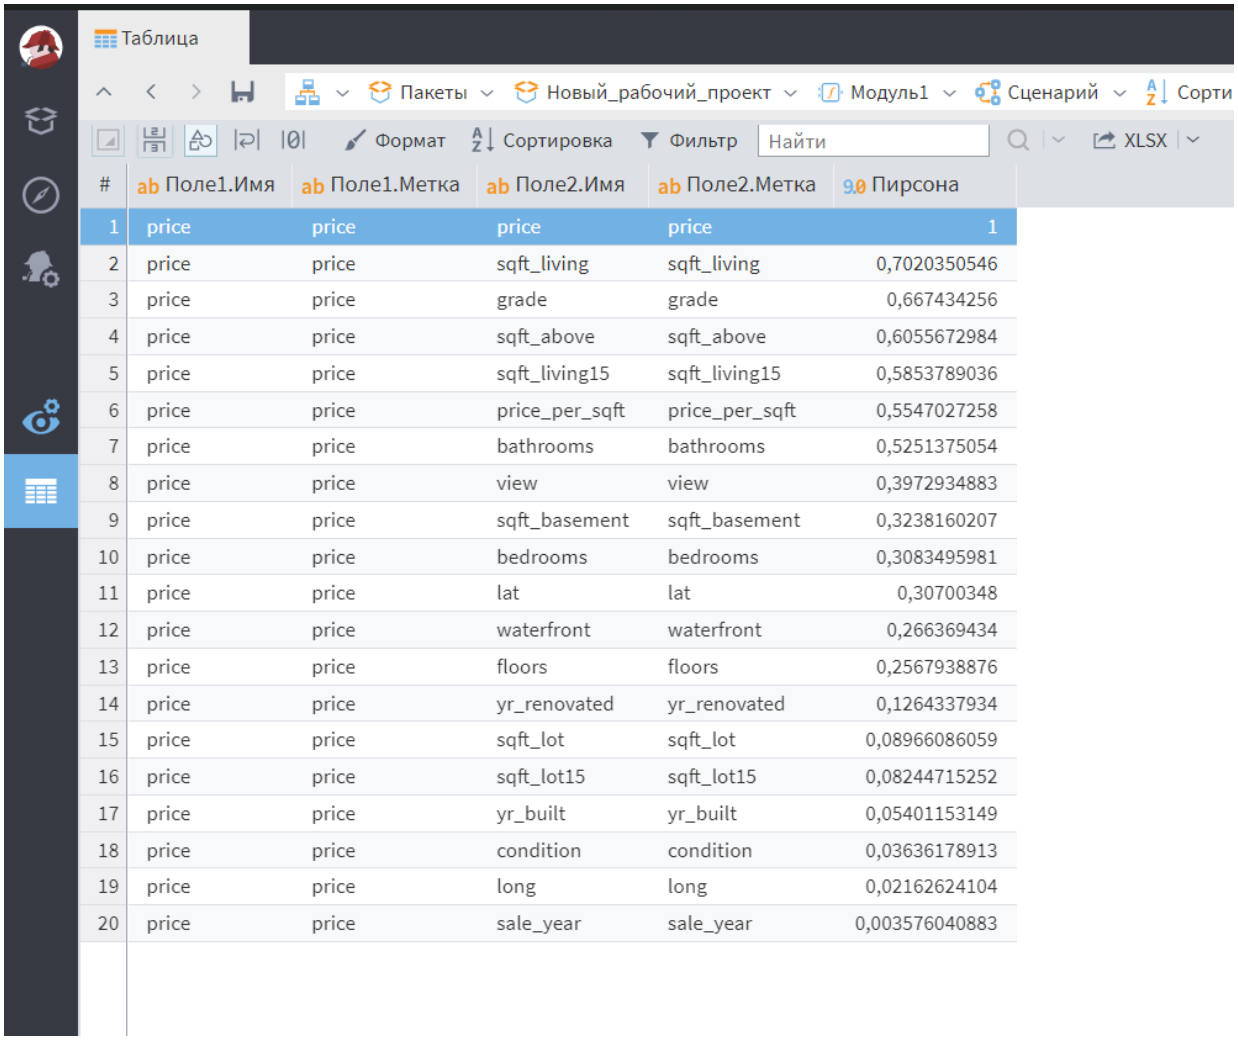


Рисунок 26 – Описание узла **Сортировка** перед выполнением

После выполнения узла откроем табличный визуализатор. В верхних строках окажутся признаки с наибольшей линейной связью с price.



#	Поле1.Имя	Поле1.Метка	Поле2.Имя	Поле2.Метка	Пирсона
1	price	price	price	price	1
2	price	price	sqft_living	sqft_living	0,7020350546
3	price	price	grade	grade	0,667434256
4	price	price	sqft_above	sqft_above	0,6055672984
5	price	price	sqft_living15	sqft_living15	0,5853789036
6	price	price	price_per_sqft	price_per_sqft	0,5547027258
7	price	price	bathrooms	bathrooms	0,5251375054
8	price	price	view	view	0,3972934883
9	price	price	sqft_basement	sqft_basement	0,3238160207
10	price	price	bedrooms	bedrooms	0,3083495981
11	price	price	lat	lat	0,30700348
12	price	price	waterfront	waterfront	0,266369434
13	price	price	floors	floors	0,2567938876
14	price	price	yr_renovated	yr_renovated	0,1264337934
15	price	price	sqft_lot	sqft_lot	0,08966086059
16	price	price	sqft_lot15	sqft_lot15	0,08244715252
17	price	price	yr_built	yr_built	0,05401153149
18	price	price	condition	condition	0,03636178913
19	price	price	long	long	0,02162624104
20	price	price	sale_year	sale_year	0,003576040883

Рисунок 27 – Таблица отсортированных коэффициентов корреляции с price

По результатам анализа наиболее сильную связь с price показывают признаки, описывающие размер и качество дома:

– sqft_living — 0,70 (жилая площадь);

– grade — 0,67 (класс постройки);

– sqft_above — 0,61 (площадь без подвала);

– sqft_living15 — 0,59 (площадь соседних домов);

– price_per_sqft — 0,56 (цена за квадратный фут, поле из узла **Калькулятор**);

– bathrooms — 0,53 (число ванных комнат).

Умеренную связь дают view (0,40), sqft_basement (0,32), bedrooms (0,31) и lat (0,31). Слабее с ценой связаны waterfront, floors, yr_renovated, площадь участка (sqft_lot, sqft_lot15), yr_built и condition. Практически отсутствует линейная зависимость от long (0,02) и sale_year (0,004): год продажи в

этом наборе данных не объясняет уровень цены. Эти выводы согласуются с содержательной логикой рынка недвижимости и пригодятся при выборе признаков для модели линейной регрессии.

1.6 Стратификация данных

Перед разбиением данных на обучающую и тестовую выборки выполним **стратификацию**. Это предварительное разделение записей на однородные группы по важному признаку — в нашем случае по уровню цены. Если просто случайно отделить часть строк, в train и test может попасть разная доля дешёвых и дорогих домов: модель обучится на одном распределении, а проверится на другом. Стратификация сохраняет пропорции таких групп в обеих выборках, поэтому оценка качества модели получается более репрезентативной.

Для стратификации введём категориальный признак price_category. Добавим ещё один узел **Калькулятор** и соединим его с **первым** выходным портом узла **Фильтр строк — Соответствуют условию**. Ветка корреляционного анализа при этом остаётся отдельной: калькулятор стратификации берёт данные напрямую с фильтра, где сохранены все исходные поля, включая price.

После подключения активируем вход узла, откроем окно редактирования выражений и создадим поле price_category с типом **Целый**:

```
If(price < 350000, 1,
  If(price < 500000, 2,
    If(price < 700000, 3,
      If(price < 1000000, 4, 5))))
```

Имена полей в формуле вводим без квадратных скобок; удобнее подставлять их двойным щелчком из списка слева. Границы категорий:

- 1 — цена до \$350 000;
- 2 — от \$350 000 до \$500 000;
- 3 — от \$500 000 до \$700 000;
- 4 — от \$700 000 до \$1 000 000;
- 5 — \$1 000 000 и выше.

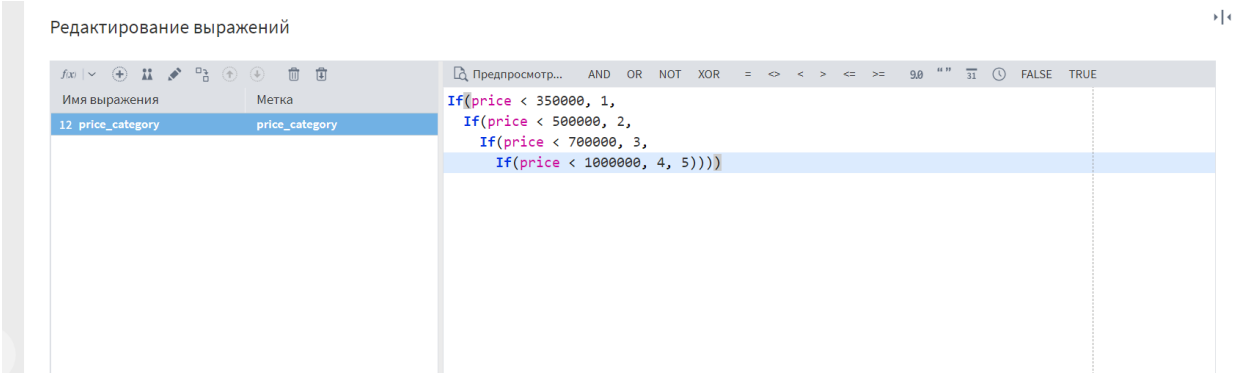


Рисунок 28 – Выражение для поля price_category в узле **Калькулятор**

Сохраним настройки, выполним узел и добавим визуализатор **Статистика**. Выберем поле price_category, откроем гистограмму и зададим **минимум** = 1, **максимум** = 5 — по фактическому диапазону категорий. В таблице статистики проверим, что пропусков нет, а минимум и максимум равны 1 и 5.

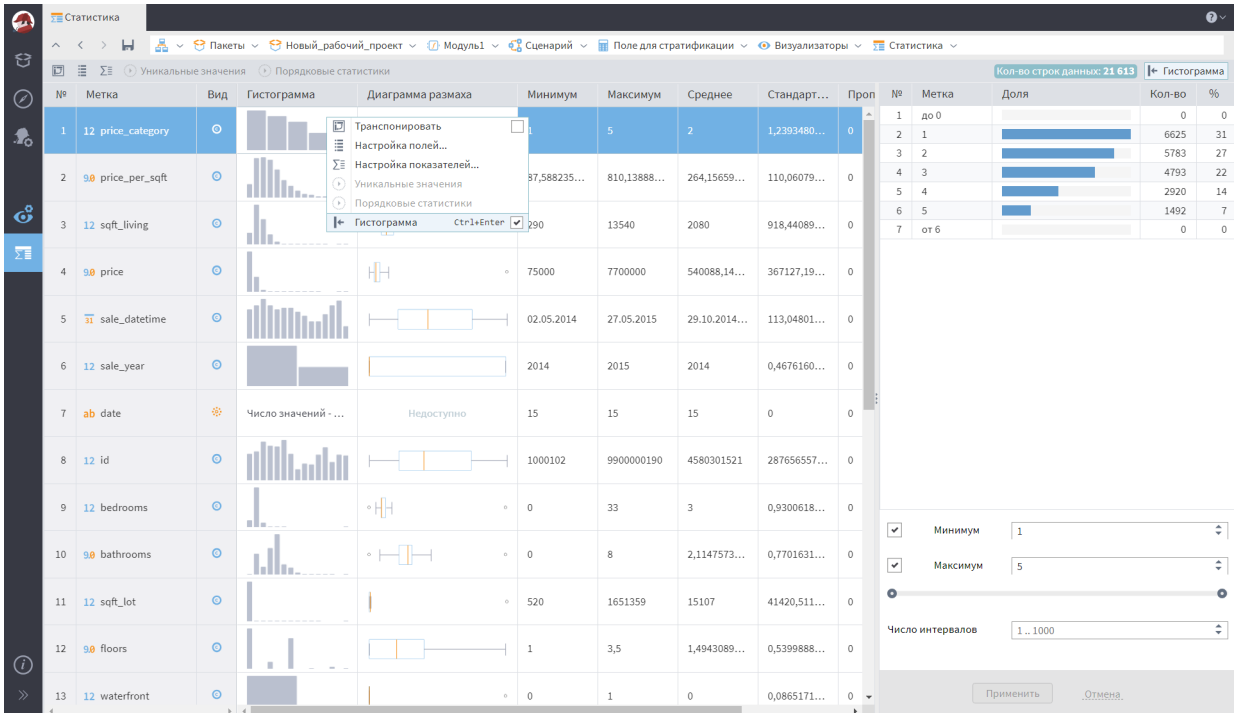


Рисунок 29 – Распределение price_category в визуализаторе **Статистика**

По гистограмме видно, что все пять категорий заполнены (всего **21 613** записей): категория 1 — 6 625 домов (31%), 2 — 5 783 (27%), 3 — 4 793 (22%), 4 — 2 920 (14%), 5 — 1 492 (7%). Распределение убывает от бюджетного сегмента к дорогому — для King County это ожидаемо. Пустых групп нет, поэтому

поле price_category можно использовать для стратифицированного разбиения на обучающий и тестовый наборы.

1.7 Разбиение на обучающую и тестовую выборки

Перед обучением модели разделим данные на две части. **Обучающая выборка** нужна, чтобы модель нашла зависимость между признаками и ценой price. **Тестовая выборка** — это данные, которые модель при обучении не видит; на них проверяют, насколько хорошо найденная закономерность работает на новых домах. Если обучать и оценивать качество на одном и том же наборе, модель может просто «запомнить» ответы, а не научиться прогнозировать — метрики будут завышены. Разбиение даёт честную оценку: модель учится на 80% записей, а качество проверяется на оставшихся 20%. Поскольку на предыдущем шаге мы ввели price_category, разбиение выполним **стратифицированным** методом, чтобы в обеих частях сохранились одинаковые доли дешёвых и дорогих объектов.

Добавим узел **Разбиение на множества** и соединим его вход с выходом калькулятора, в котором создано поле price_category. На вход узла должна поступать полная таблица после фильтрации и стратификации.

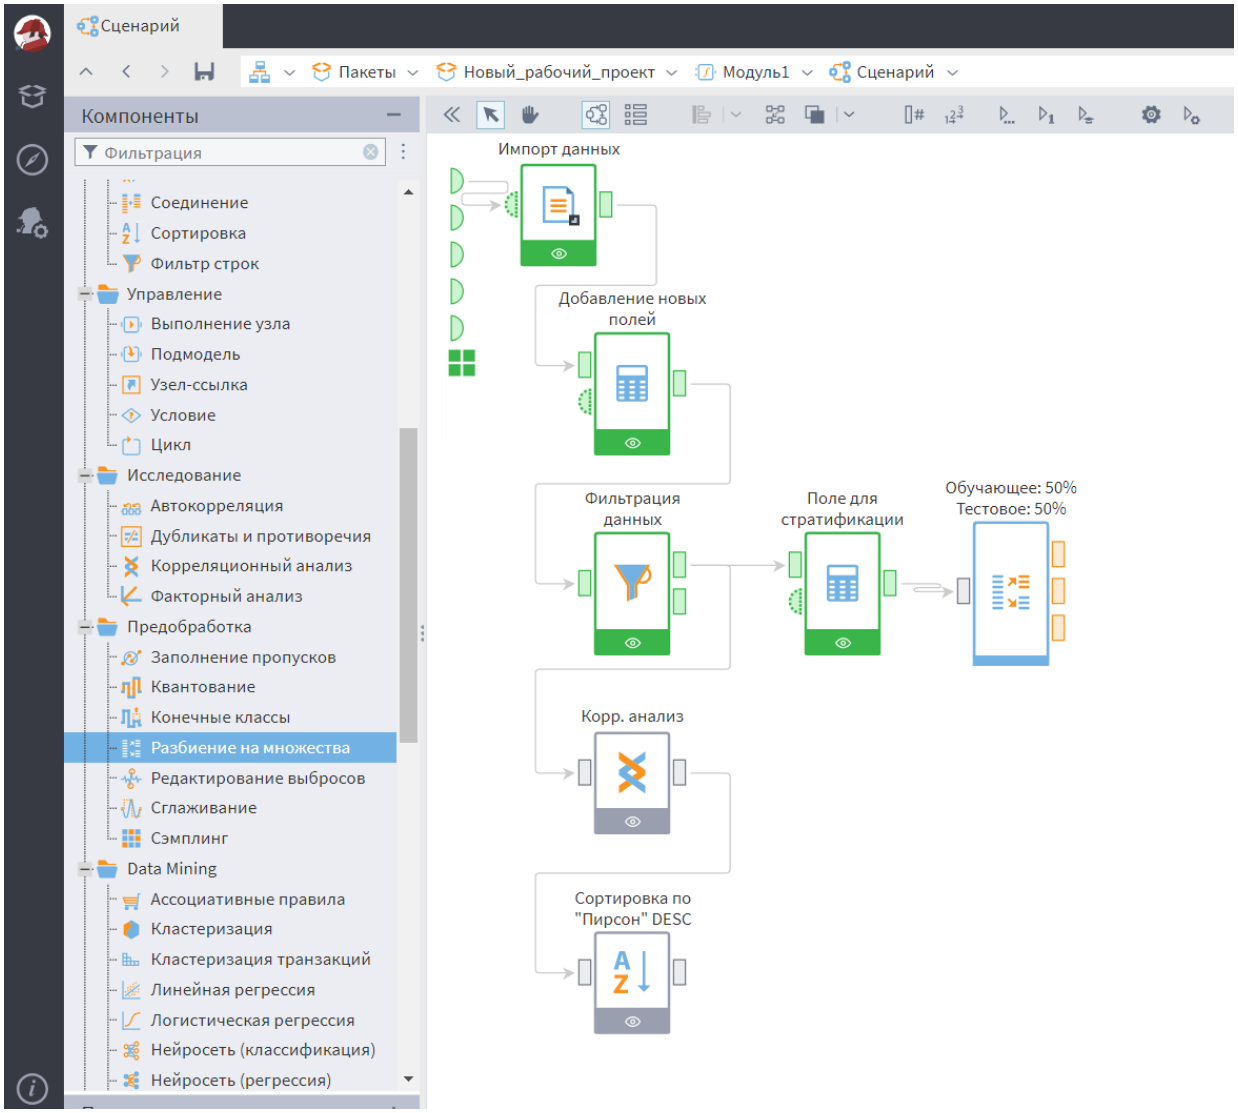


Рисунок 30 – Добавление узла **Разбиение на множества** после калькулятора стратификации

В настройках узла активируем вход и зададим параметры разбиения:

– **Обучающее множество — 80%** (17 290 записей).

– **Тестовое множество — 20%** (4 323 записи).

– **Метод сэмплинга — Стратифицированный**.

– **Поле стратификации** — price_category (остальные поля не отмечаем).

Общее число записей при этом остаётся **21 613**. Стратифицированный метод сохраняет в обучающей и тестовой выборках одинаковые доли каждой ценовой категории.

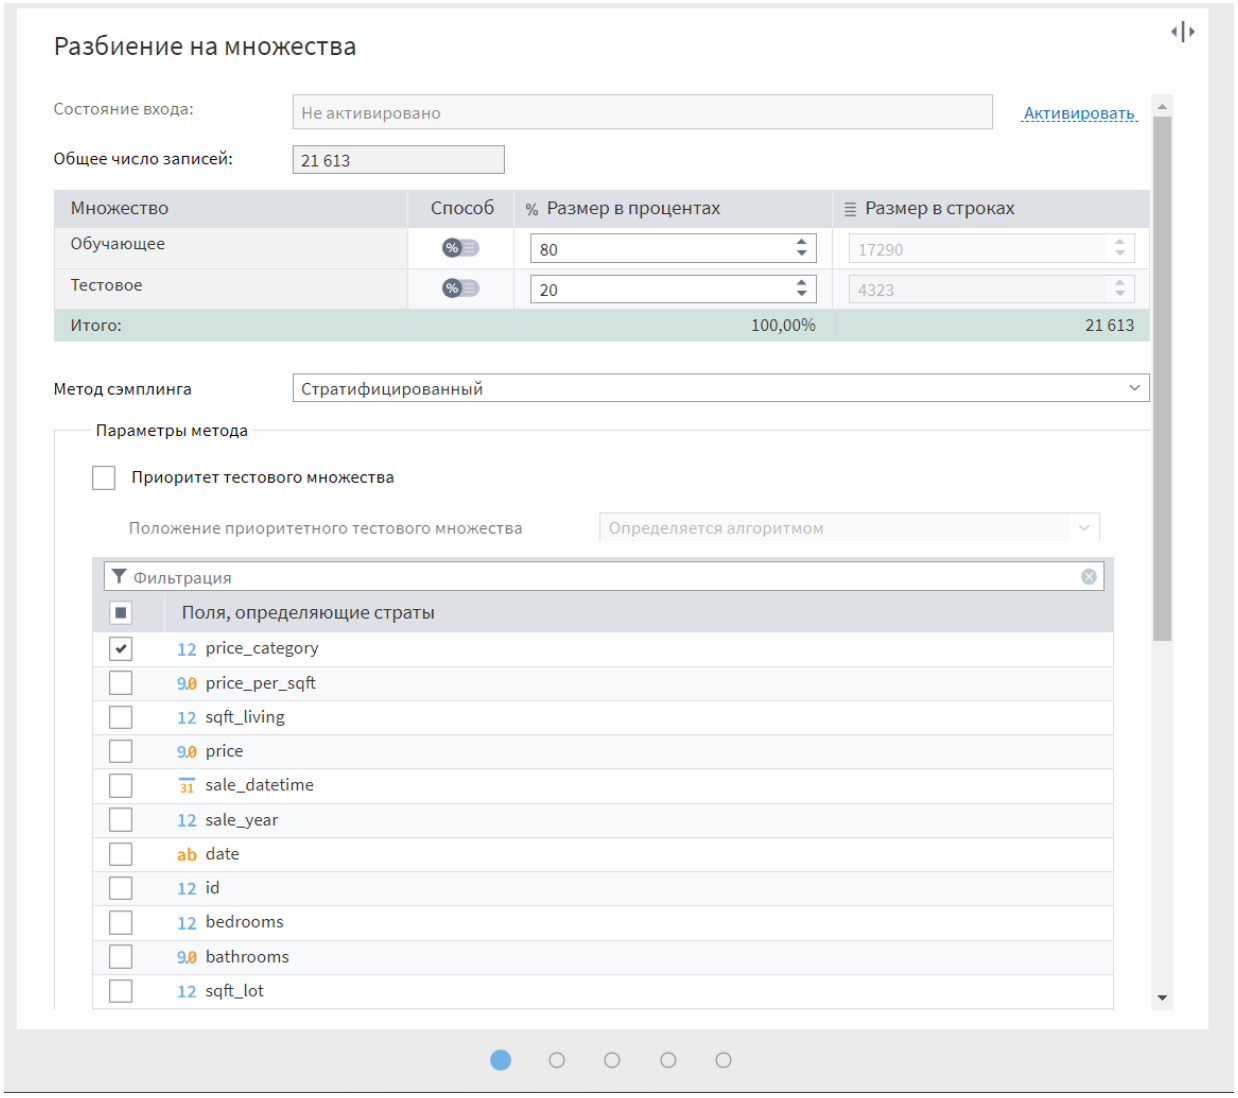


Рисунок 31 – Настройка разбиения 80%/20% со стратификацией по price_category

На шаге описания узла зададим метку **Обучающее: 80% Тестовое: 20%**, сохраним настройки и выполним узел. При необходимости переобучим узел через контекстное меню.

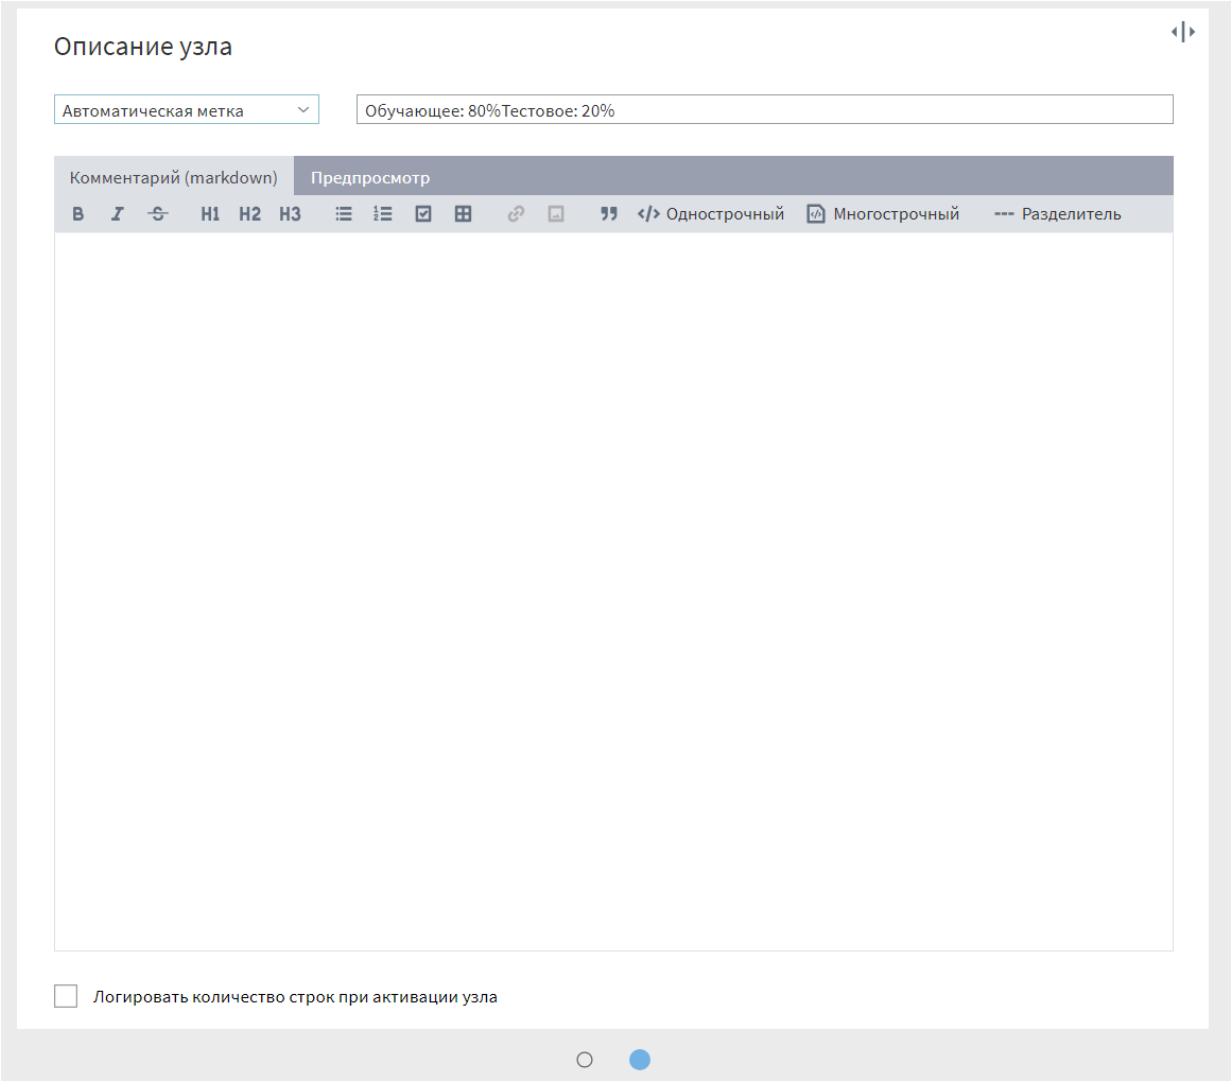


Рисунок 32 – Описание узла **Разбиение на множества** перед выполнением

Для проверки откроем **Настройку визуализаторов** и добавим **Статистику** на выходы **Обучающий выходной набор** и **Тестовый выходной набор**.

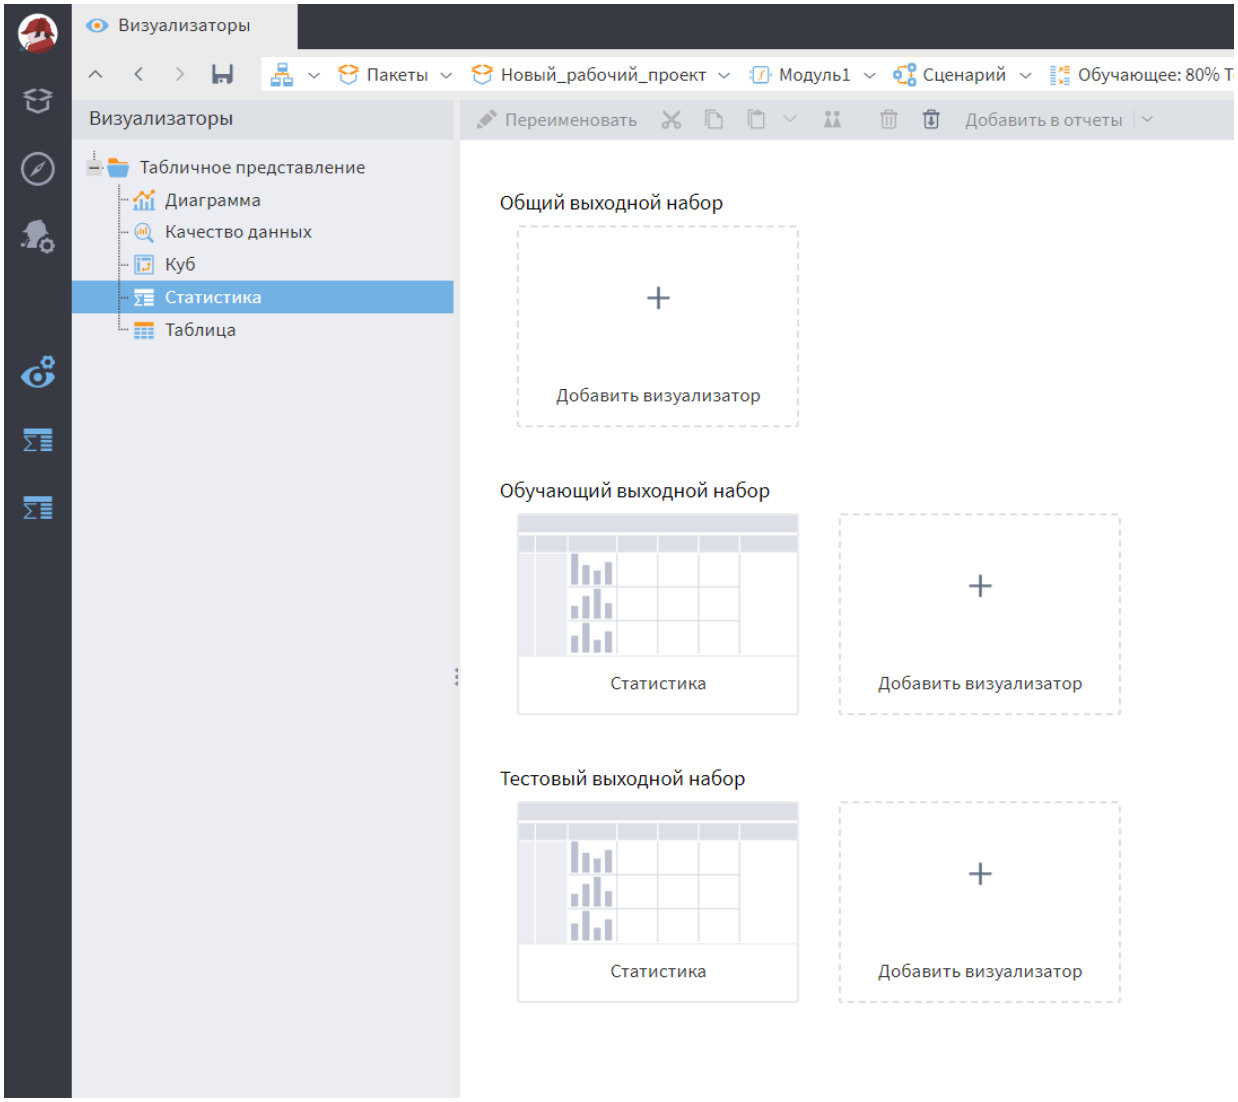


Рисунок 33 – Подключение визуализаторов **Статистика** к обучающему и тестовому выходам

В статистике для поля price_category на обоих выходах построим гистограммы с **минимум** = 1 и **максимум** = 5. Проценты по категориям должны совпадать между выборками:

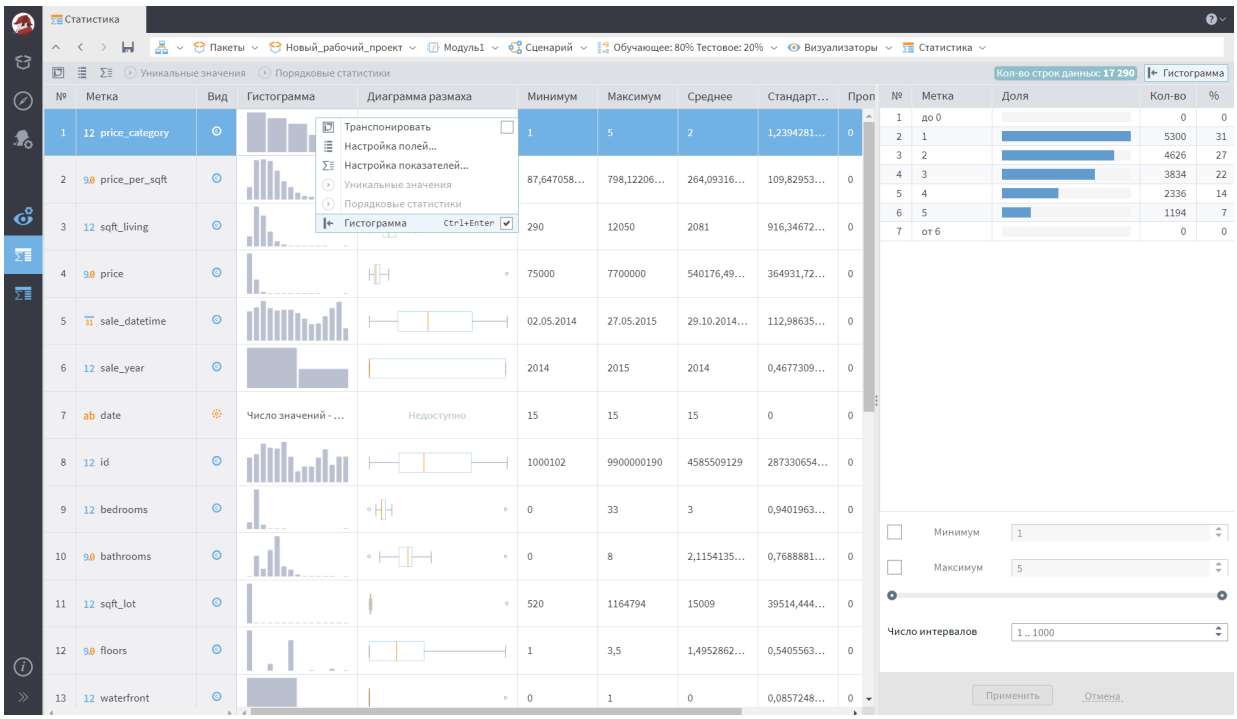


Рисунок 34 – Распределение price_category в обучающей выборке (17 290 записей)

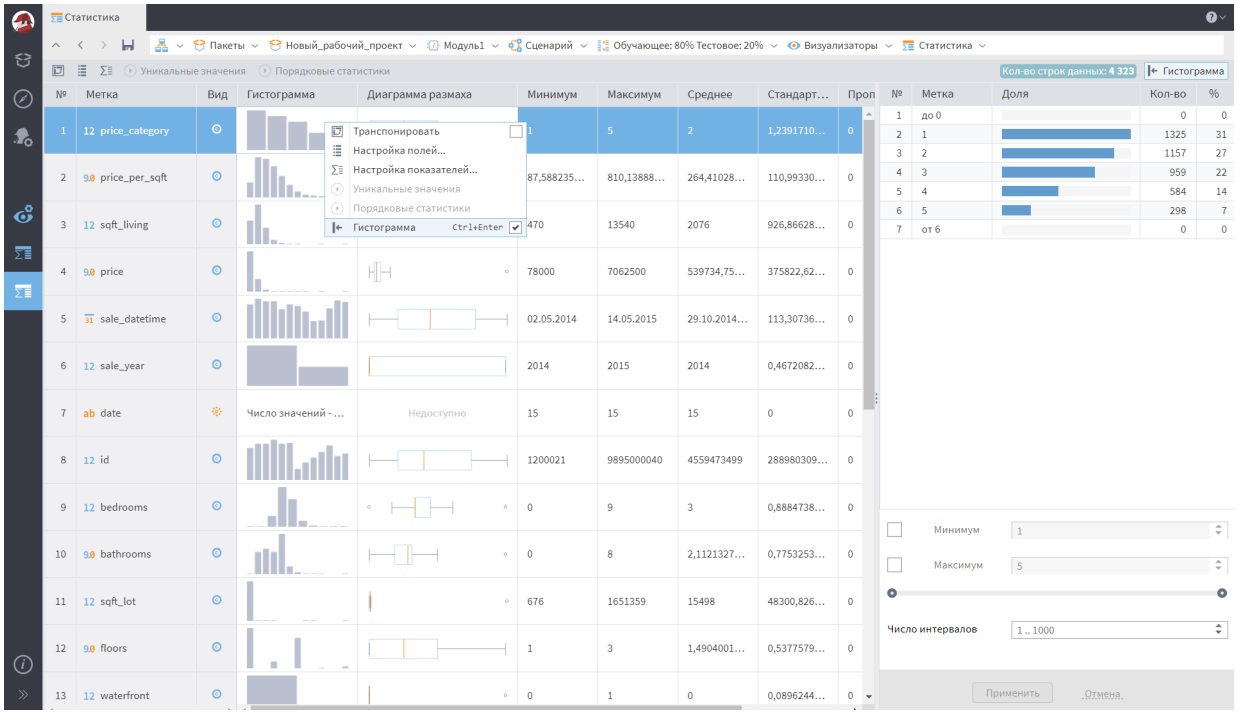


Рисунок 35 – Распределение price_category в тестовой выборке (4 323 записи)

Как видно из гистограмм, пропорции сохранены: категория 1 — 31%, 2 — 27%, 3 — 22%, 4 — 14%, 5 — 7% и в train, и в test. Стратификация выполнена корректно — можно переходить к обучению модели на обучающем множестве.

1.8 Обучение модели линейной регрессии

Линейная регрессия — метод прогнозирования, в котором целевой показатель (у нас — price) представляется как линейная комбинация входных признаков: площади, числа комнат, класса дома, координат и других числовых характеристик. Модель подбирает коэффициенты так, чтобы прогнозируемая цена в среднем была как можно ближе к фактической на обучающих данных. Чем сильнее признак связан с ценой (как показал корреляционный анализ), тем больший вклад он обычно вносит в итоговую формулу. Результат обучения — не просто одно число, а правило: по известным характеристикам дома можно получить оценку его стоимости.

На обучающем множестве построим такую модель. Добавим узел **Линейная регрессия** и подадим на его вход данные с порта **Обучающий выходной набор** узла разбиения.

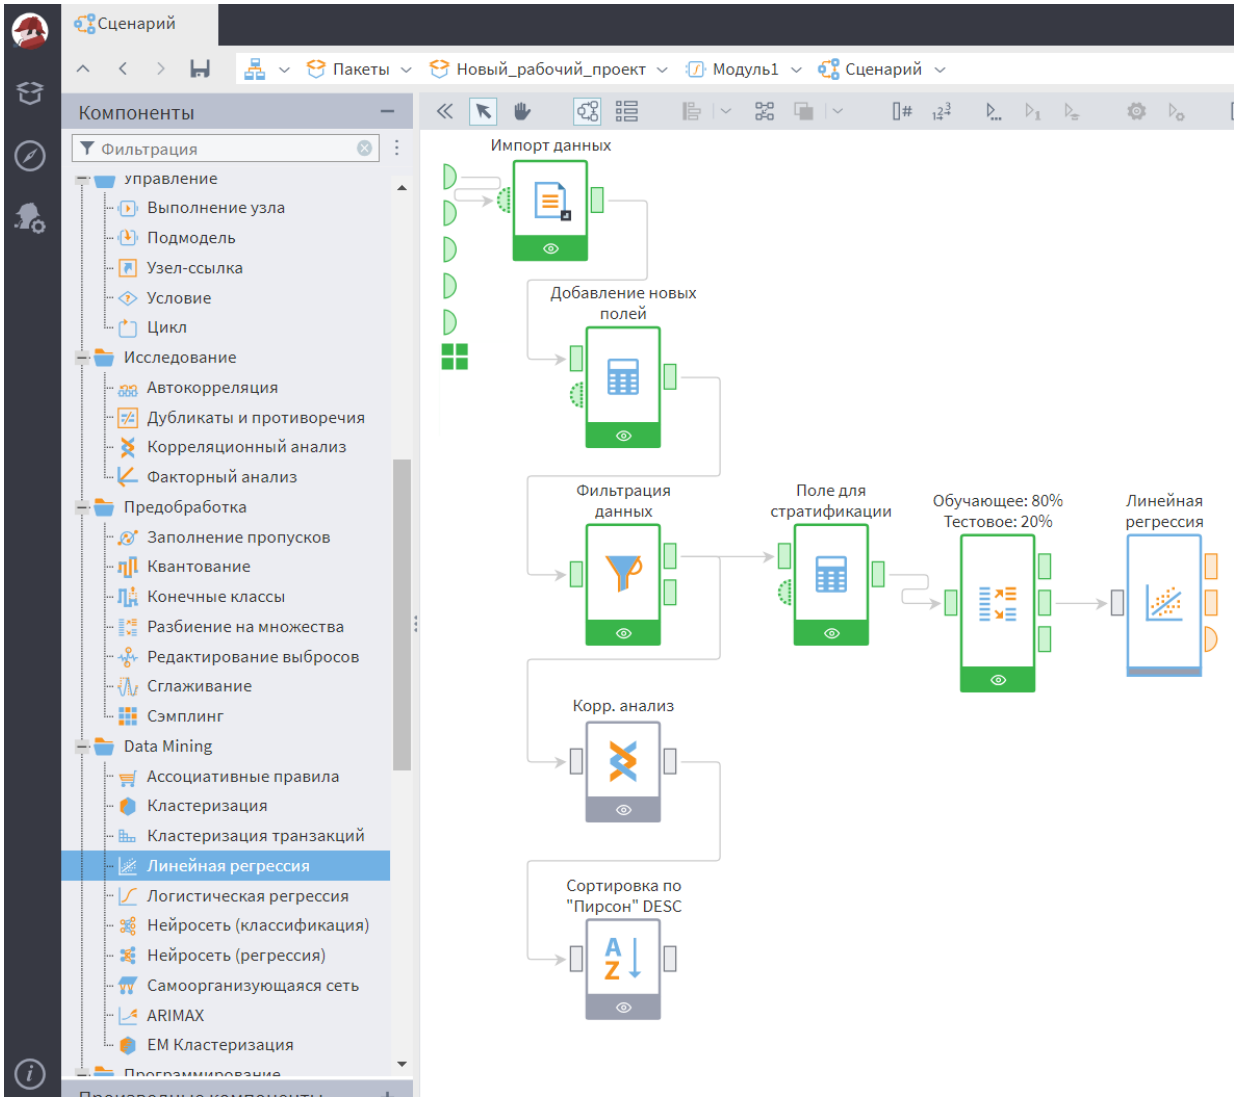


Рисунок 36 – Подключение узла **Линейная регрессия** к обучающему множеству

В мастере настройки на шаге **Настройка входных столбцов** зададим назначение полей:

– **Выходное** — price.

– **Входное** — sale_year, bedrooms, bathrooms, sqft_living, sqft_lot, floors, waterfront, view, condition, grade, sqft_above, sqft_basement, yr_built, yr_renovated, lat, long, sqft_living15, sqft_lot15.

– **Не задано** — id, date, zipcode, sale_datetime, price_category, price_per_sqft.

Поле price_category использовалось только для стратификации и в модель не включаем. Поле price_per_sqft также исключаем: оно вычислено через price и создаёт информационную утечку из целевой переменной.

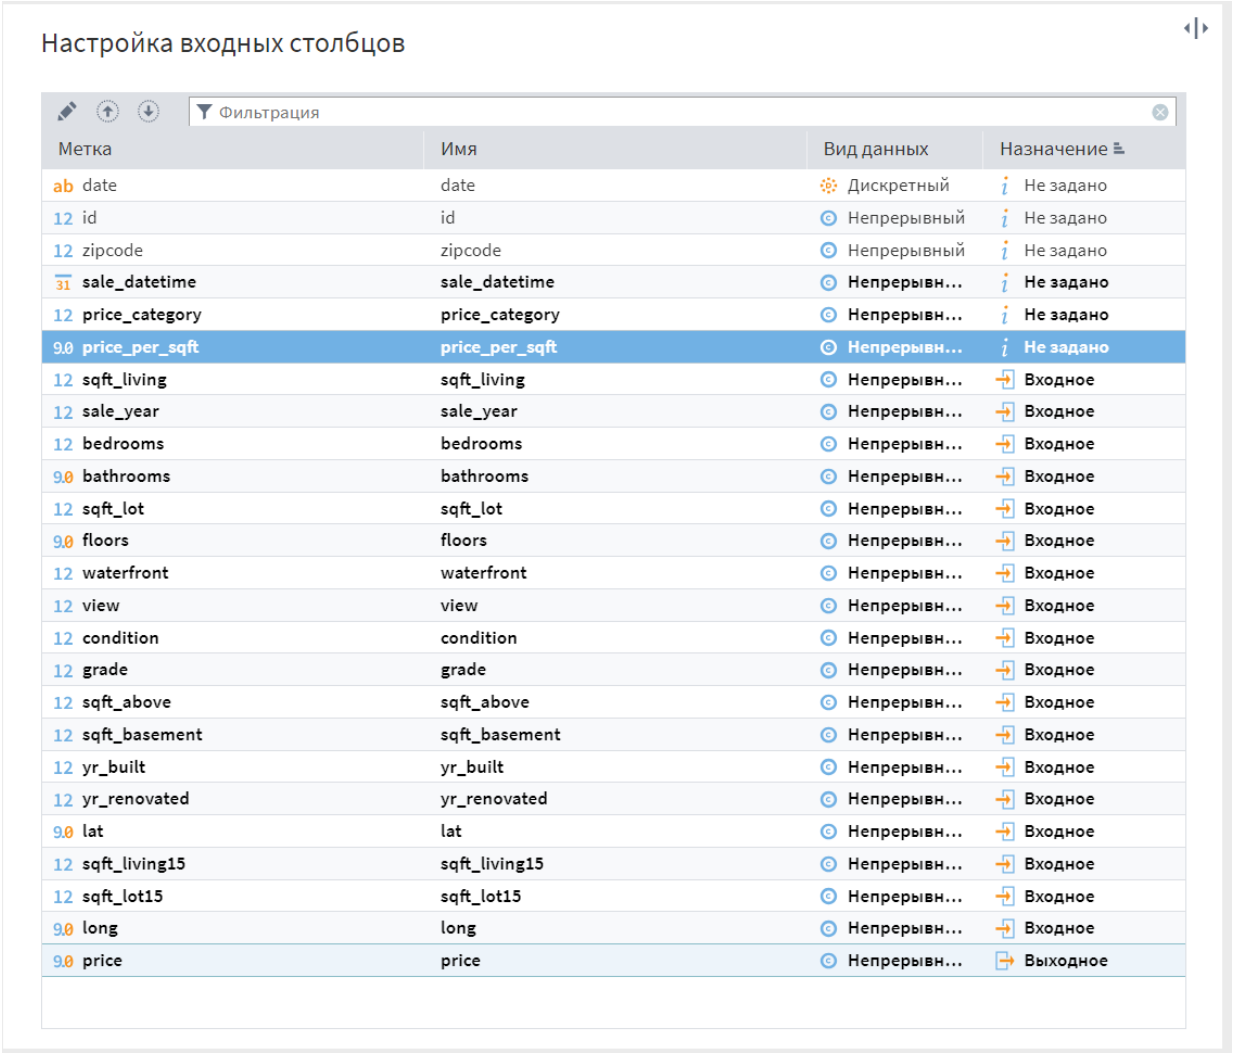


Рисунок 37 – Назначение входных и выходного полей в узле **Линейная регрессия**

На шаге **Настройки нормализации** для всех входных признаков выберем метод **Стандартизация**.

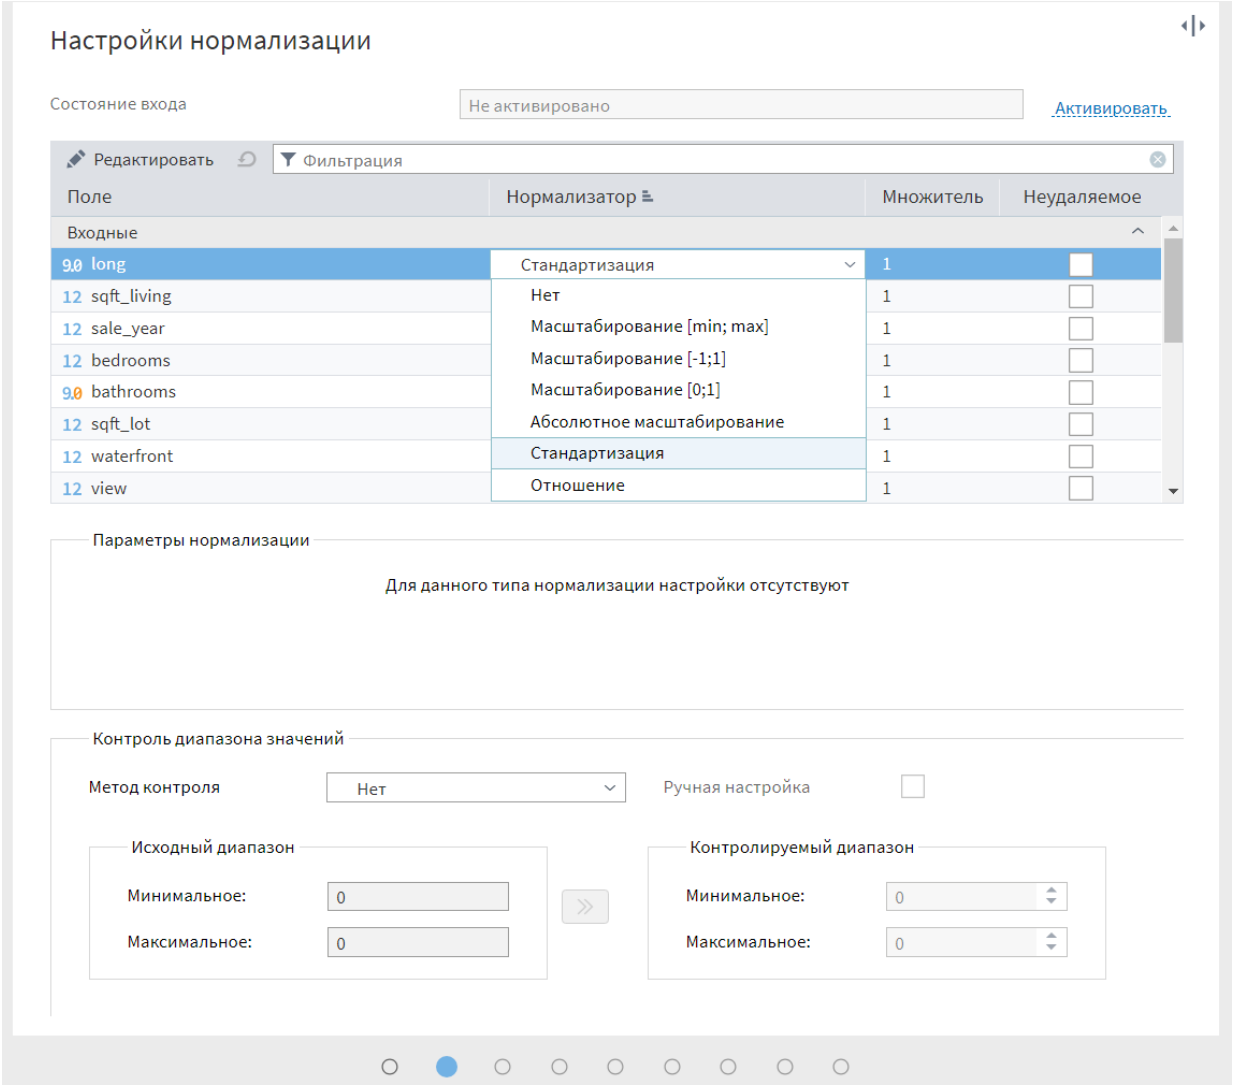


Рисунок 38 – Стандартизация входных признаков

На шаге **Разбиение на множества** внутри мастера регрессии оставим **100%** данных в обучающем множестве и **0%** в тестовом, а метод валидации — **Без валидации**. Разбиение train/test мы уже выполнили отдельным узлом; здесь на вход поступает только обучающая часть, и повторно делить её не нужно.

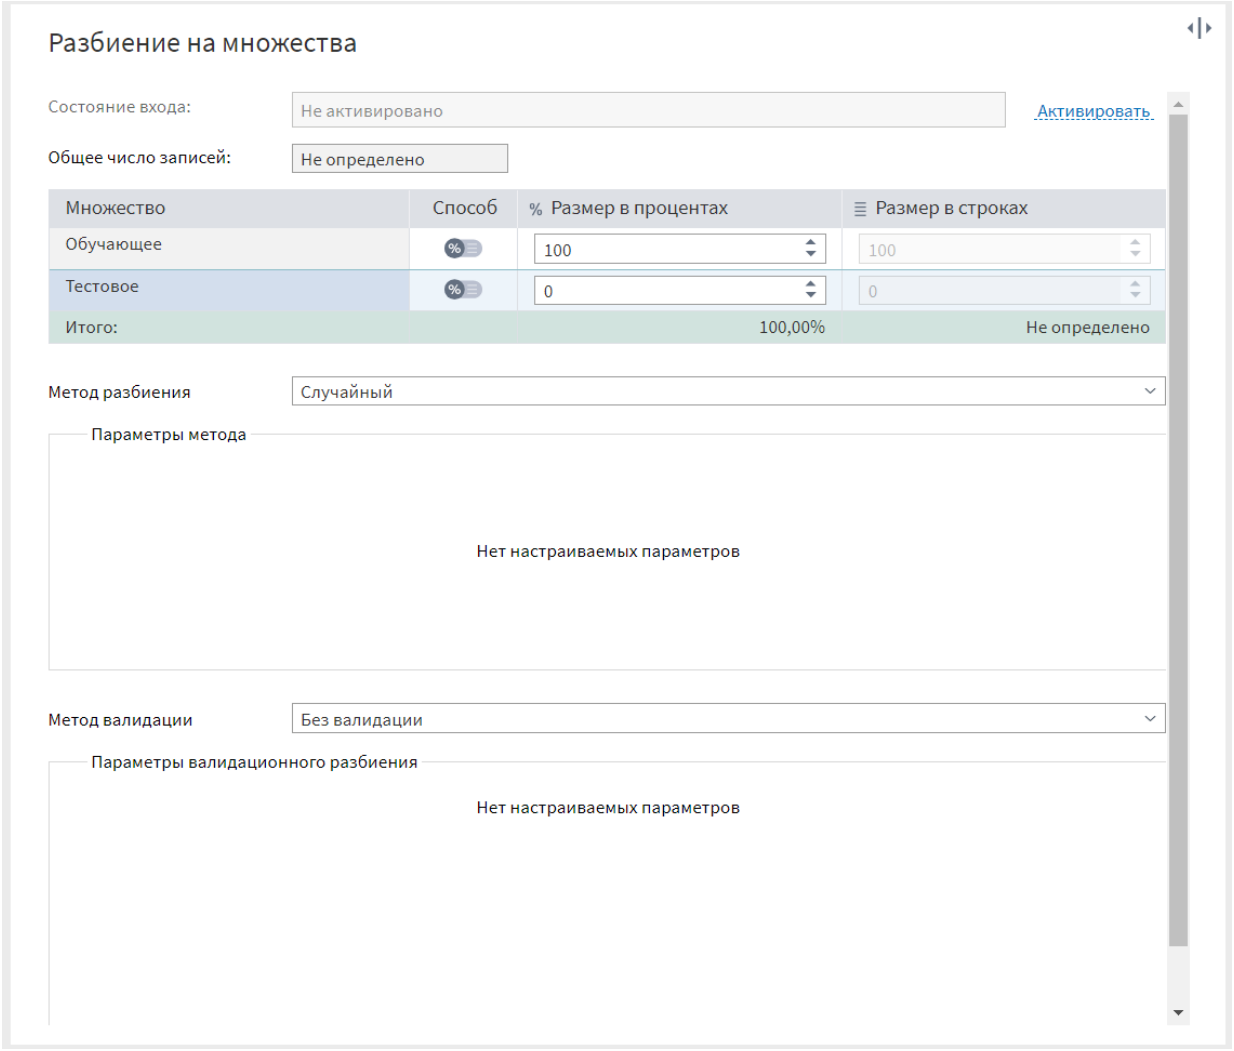


Рисунок 39 – Отключение повторного разбиения в мастере регрессии

На шаге **Настройка линейной регрессии** оставим **автоматическую настройку** включённой, сдвинем **приоритет автоматической настройки** в сторону точности и оставим остальные параметры по умолчанию (Loginom подберёт метод регуляризации, в нашем случае — Ridge-регрессию).

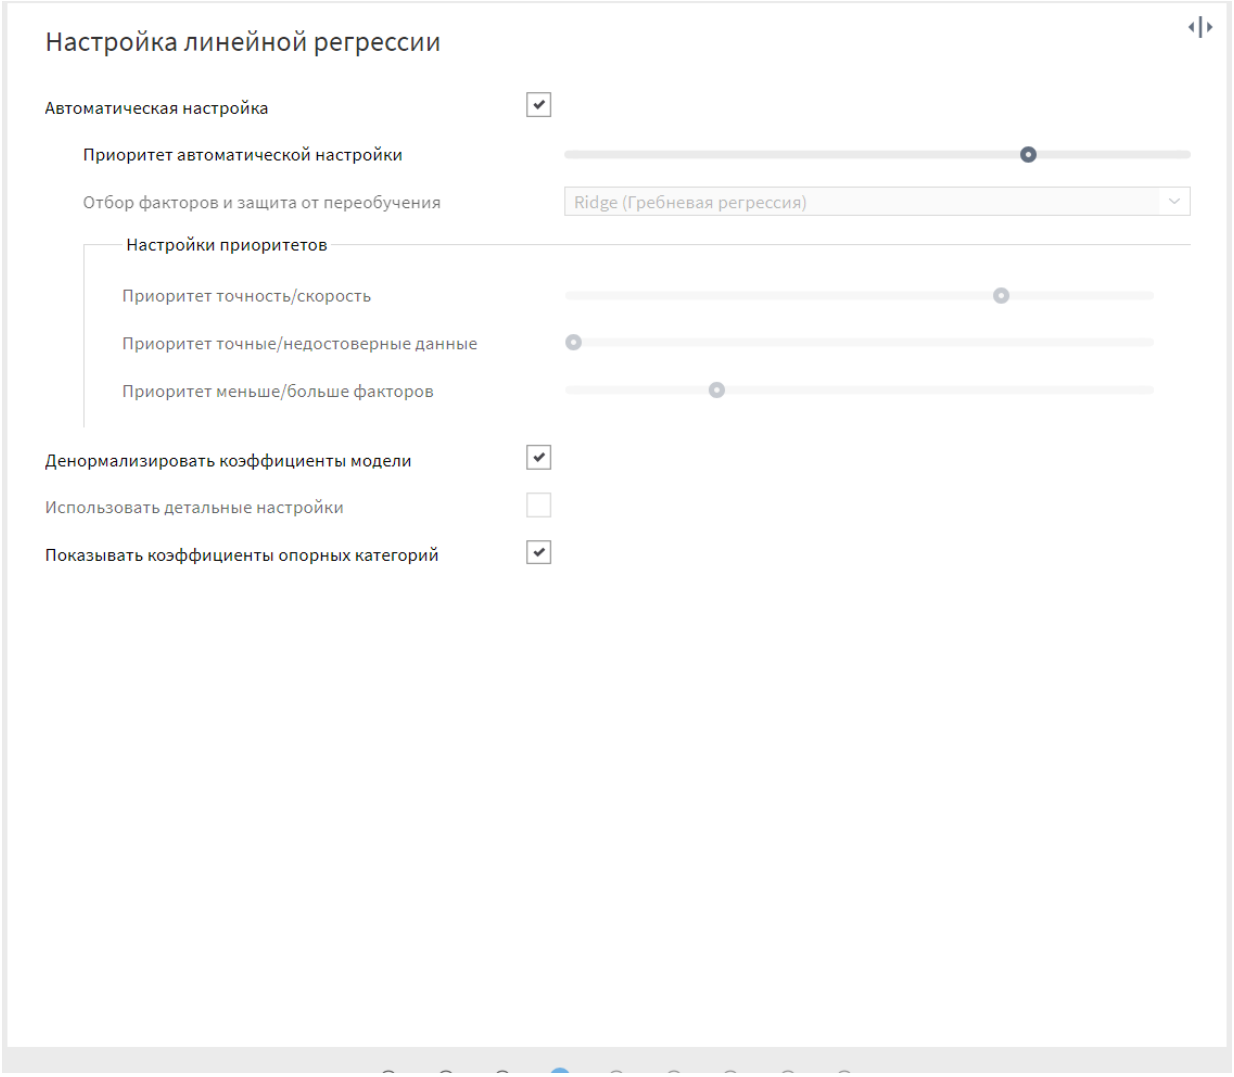


Рисунок 40 – Автоматическая настройка линейной регрессии

На шаге описания узла зададим метку **Линрегрессия**, сохраним настройки и **обучим** узел.

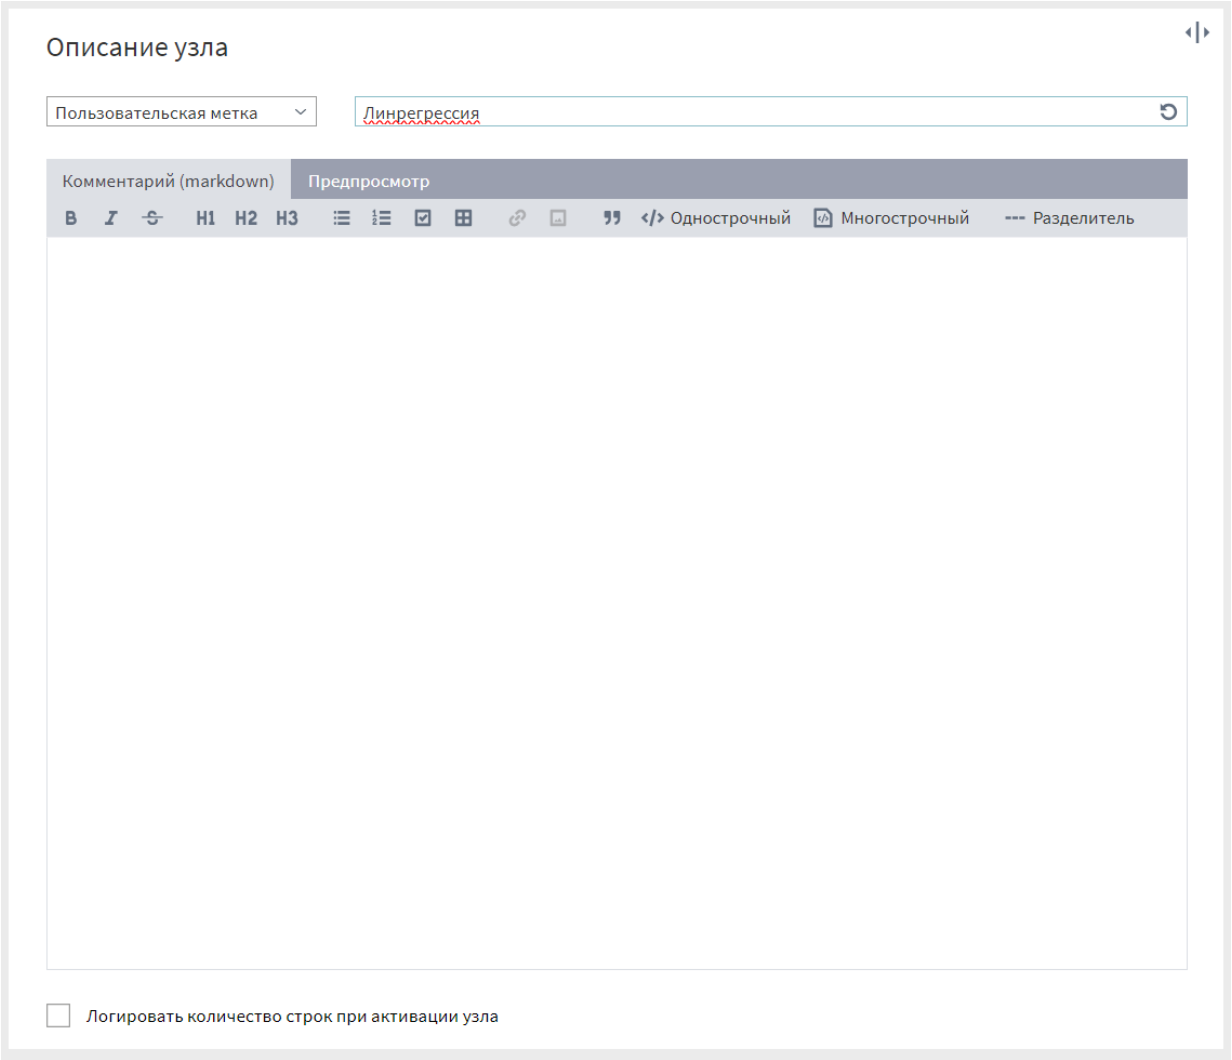


Рисунок 41 – Описание узла **Линейная регрессия** перед обучением

После обучения откроем быстрый просмотр порта **Сводка** (контекстное меню нижнего выходного порта узла).

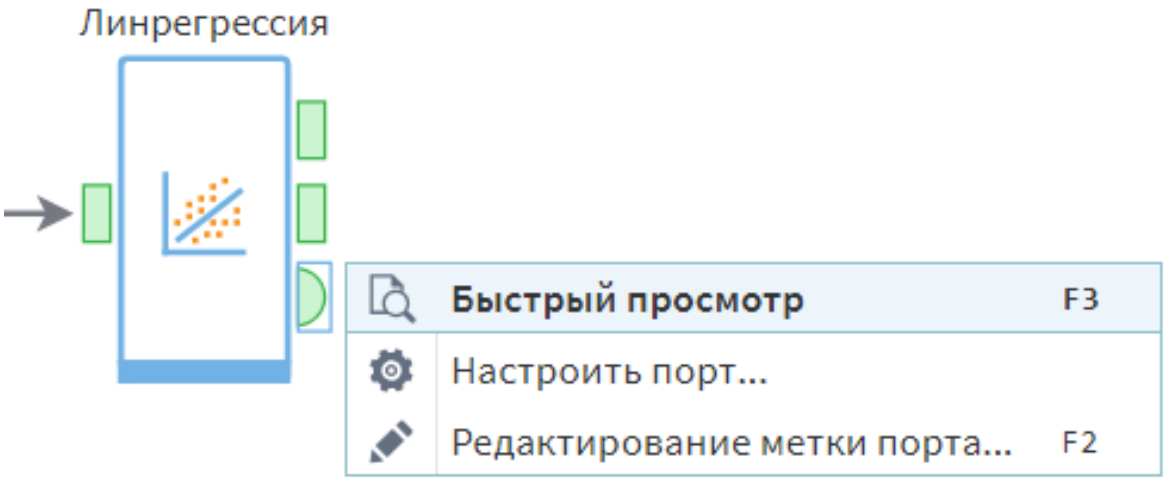


Рисунок 42 – Открытие сводки модели через **Быстрый просмотр**

Линрегрессия • Быстрый просмотр

Выход регрессии | Коэффициенты регрессионной модели | Сводка

№	Имя	Метка	Значение	Описание
1	TotalSamples	Всего примеров	17 290	
2	TotalSelectedSamples	Всего отобранных примеров	17 290	
3	TrainSamples	Примеров в обучающем множестве	17 290	
4	LogLikelihood	Логарифм функции правдоподобия	-235 539,05	
5	R2	Коэффициент детерминации	0,70	
6	AdjustedR2	Скорректированный коэффициент детерминации	0,70	
7	StdDev	Стандартное отклонение	199 677,62	
8	DFE	Число степеней свободы ошибки	17 271	
9	ModelDF	Число степеней свободы модели	18	
10	FStatistic	F-статистика	2 248,70	
11	AIC	Информационный критерий Акаике	27,25	
12	AICc	Информационный критерий Акаике скорректированный	27,25	
13	BIC	Информационный критерий Байеса	27,26	
14	HQC	Информационный критерий Ханнана-Куинна	27,25	
15	ModelPValue	P-значение модели	5,55e-16	

Рисунок 43 – Сводка обученной модели: основные метрики качества

По результатам обучения на **17 290** записях модель объясняет около **70%** дисперсии цены: $R^2 = 0{,}70$, скорректированный $R^2 = 0{,}70$. Стандартное

отклонение ошибки — около **199 678**, p-значение модели — $5{,}55 \times 10^{-16}$, то есть регрессия статистически значима. Эти показатели используем на следующем шаге при анализе качества прогноза.

1.9 Анализ обученной модели

После обучения модели на предыдущем шаге получили $R^2 = 0{,}70$ на **обучающем** множестве — это качество на данных, которые модель уже «видела». Чтобы проверить, переносится ли результат на новые дома, прогоним **тестовое** множество (4 323 записи): модель его не видела при обучении, поэтому сравнение фактической price с прогнозом на test даёт честную оценку качества.

Сначала кратко разберём обученную модель на train. Откроем **Сводку** (рис. 43): $R^2 = 0{,}70$, StdDev $\approx$ 199 678. На вкладке **Коэффициенты регрессионной модели** увидим, что наибольший вклад вносят признаки, связанные с площадью и классом дома — sqft_living, grade, sqft_above, что согласуется с корреляционным анализом.

Затем подключим к узлу **Линрегрессия** тестовый набор. Отключим от входа **обучающий выходной набор** (первый порт узла разбиения) и подадим данные с **тестового выходного набора** — второго порта (4 323 записи).

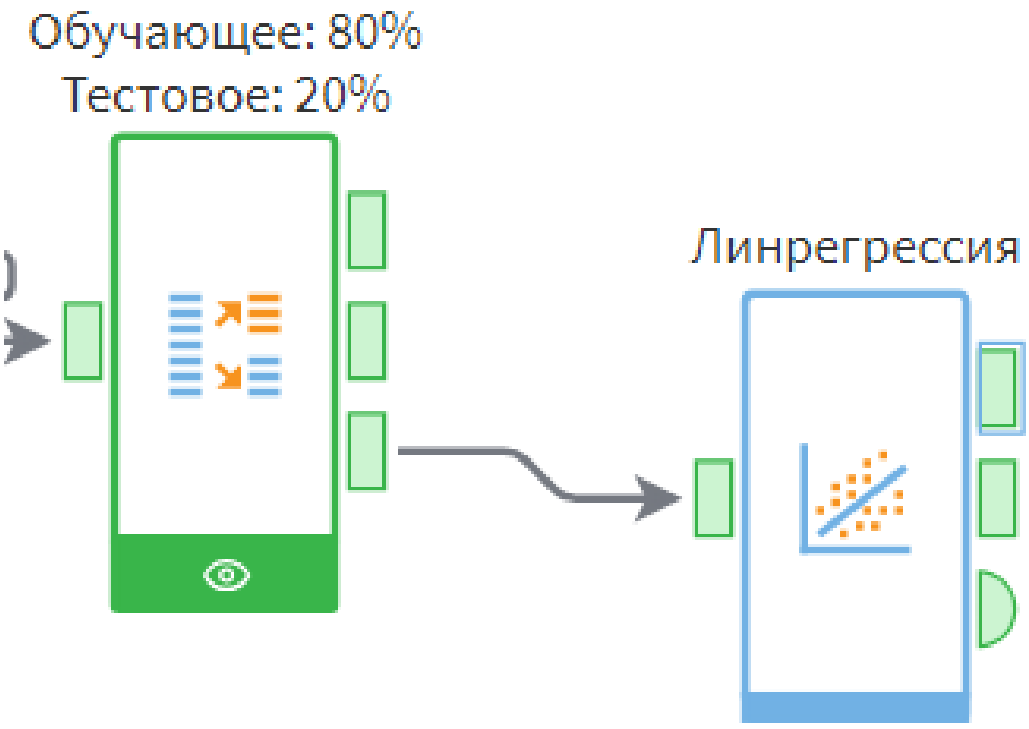
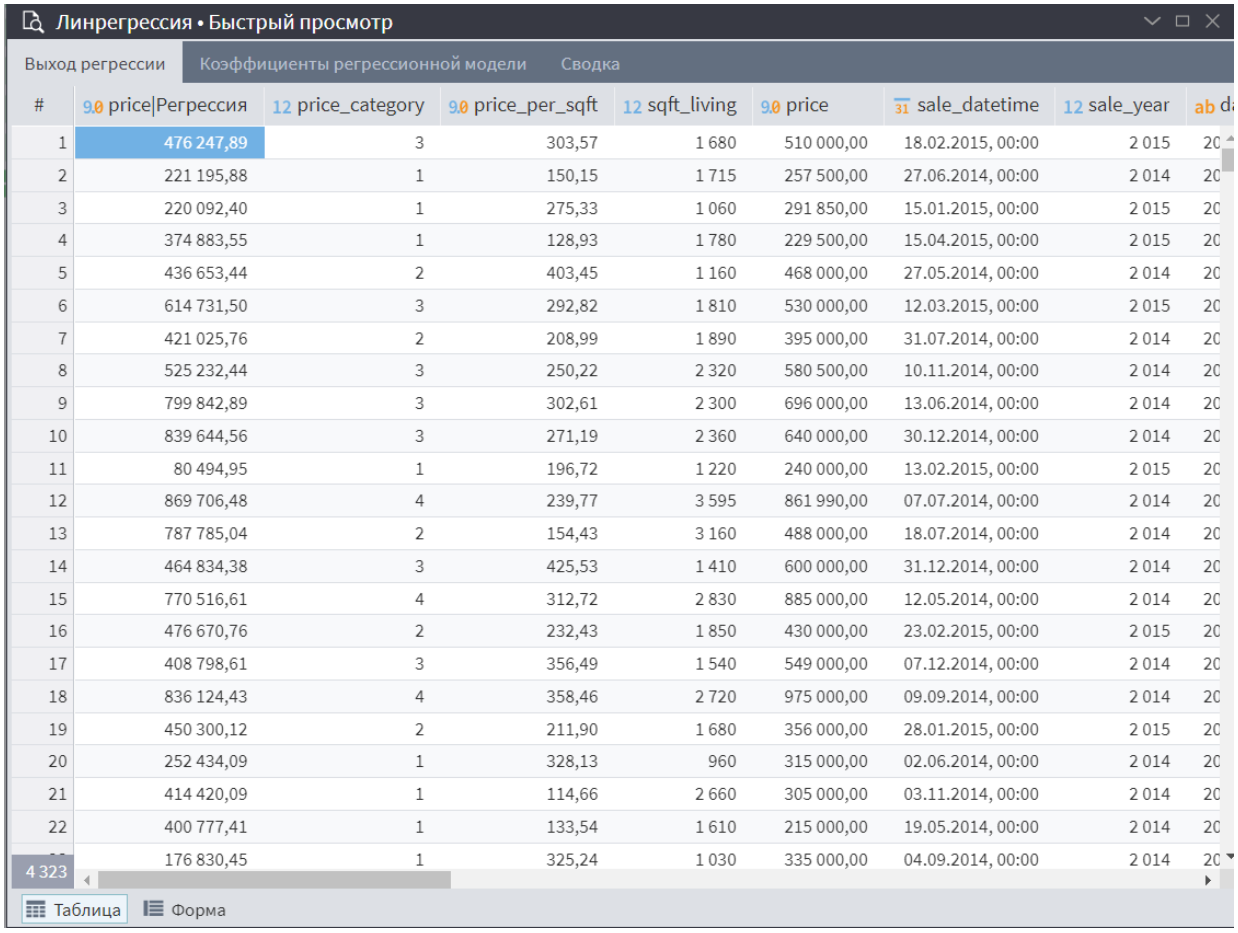


Рисунок 44 – Подключение **тестового выходного набора** к узлу **Линрегрессия**

Выполним узел командой **Выполнить**, а не **Переобучить узел**: модель уже обучена, на test нужно только получить прогнозы. **Сводка** при этом не изменится — она хранит метрики обучения (17 290 примеров, $R^2 = 0{,}70$). Оценку на тесте смотрим на вкладке **Выход регрессии**.

Откроем **Быстрый просмотр** → **Выход регрессии**. В таблице — **4 323** строки. Для сравнения факта и прогноза используем два столбца:

– price — фактическая цена продажи;
– price|Регрессия — прогноз модели.


Линрегрессия • Быстрый просмотр

Выход регрессии | Коэффициенты регрессионной модели | Сводка

#	price|Регрессия	price_category	price_per_sqft	sqft_living	price	sale_datetime	sale_year	da
1	476 247,89	3	303,57	1 680	510 000,00	18.02.2015, 00:00	2 015	20
2	221 195,88	1	150,15	1 715	257 500,00	27.06.2014, 00:00	2 014	20
3	220 092,40	1	275,33	1 060	291 850,00	15.01.2015, 00:00	2 015	20
4	374 883,55	1	128,93	1 780	229 500,00	15.04.2015, 00:00	2 015	20
5	436 653,44	2	403,45	1 160	468 000,00	27.05.2014, 00:00	2 014	20
6	614 731,50	3	292,82	1 810	530 000,00	12.03.2015, 00:00	2 015	20
7	421 025,76	2	208,99	1 890	395 000,00	31.07.2014, 00:00	2 014	20
8	525 232,44	3	250,22	2 320	580 500,00	10.11.2014, 00:00	2 014	20
9	799 842,89	3	302,61	2 300	696 000,00	13.06.2014, 00:00	2 014	20
10	839 644,56	3	271,19	2 360	640 000,00	30.12.2014, 00:00	2 014	20
11	80 494,95	1	196,72	1 220	240 000,00	13.02.2015, 00:00	2 015	20
12	869 706,48	4	239,77	3 595	861 990,00	07.07.2014, 00:00	2 014	20
13	787 785,04	2	154,43	3 160	488 000,00	18.07.2014, 00:00	2 014	20
14	464 834,38	3	425,53	1 410	600 000,00	31.12.2014, 00:00	2 014	20
15	770 516,61	4	312,72	2 830	885 000,00	12.05.2014, 00:00	2 014	20
16	476 670,76	2	232,43	1 850	430 000,00	23.02.2015, 00:00	2 015	20
17	408 798,61	3	356,49	1 540	549 000,00	07.12.2014, 00:00	2 014	20
18	836 124,43	4	358,46	2 720	975 000,00	09.09.2014, 00:00	2 014	20
19	450 300,12	2	211,90	1 680	356 000,00	28.01.2015, 00:00	2 015	20
20	252 434,09	1	328,13	960	315 000,00	02.06.2014, 00:00	2 014	20
21	414 420,09	1	114,66	2 660	305 000,00	03.11.2014, 00:00	2 014	20
22	400 777,41	1	133,54	1 610	215 000,00	19.05.2014, 00:00	2 014	20
4 323	176 830,45	1	325,24	1 030	335 000,00	04.09.2014, 00:00	2 014	20

Таблица | Форма

Рисунок 45 – Сравнение фактической price и прогноза price|Регрессия на тестовом множестве

По таблице видно, что прогноз в целом следует фактическим ценам, но отдельные дома модель оценивает заметно хуже. Например, для дома с фактической ценой **510 000** прогноз составил **476 248** — ошибка умеренная; для объекта за **229 500** модель дала **374 884**, то есть сильно завысила стоимость; для дорогого дома (**2 750 000**) прогноз **1 000 000** — модель недооценила цену премиального сегмента. Такие расхождения типичны для линейной модели: на бюджетных и средних объектах прогноз ближе к факту, на дорогих домах ошибка возрастает.

Итоги анализа. Линейная регрессия на 18 числовых признаках объясняет около **70%** дисперсии цены на обучающей выборке (R^2 = 0,70). На тестовых данных (4 323 дома) прогноз price|Регрессия в большинстве случаев близок к фактической price, что подтверждает: модель не просто «запомнила» обучающие примеры, а переносит закономерность на новые объекты. Наибольший вклад в

прогноз вносят характеристики площади и качества дома (sqft_living, grade), как и показал корреляционный анализ.

Модель далека от идеала — оставшиеся **30%** дисперсии и заметные ошибки на отдельных домах связаны с ограничениями линейного подхода:

– **Линейность** — зависимость цены от площади и других факторов может быть нелинейной, особенно в дорогом сегменте.

– **География** — координаты lat и long по отдельности слабо описывают пространственную структуру рынка.

– **Неучтённые факторы** — район (zipcode), нелинейные эффекты, выбросы.

Тем не менее для базового прогноза стоимости недвижимости в King County построенная модель пригодна: она даёт осмысленную оценку цены по характеристикам дома, а для повышения точности потребовались бы другие алгоритмы (например, нейросеть) или дополнительные признаки.

1.10 Практическое задание

В этом разделе мы разобрали полный сценарий работы в Loginom на учебном примере с датасетом **kc_house_data.csv**. Теперь Вам **необходимо повторить те же этапы самостоятельно** — на **своём уникальном датасете**. Содержание таблицы, названия полей и границы фильтрации определяются предметной областью данных; порядок действий и логика сценария описаны выше.

Необходимо выполнить:

1. Импортировать CSV-файл в Loginom, настроить разделители и типы полей, проверить результат в табличном визуализаторе.
2. В узле **Калькулятор** создать **не менее трёх** производных признаков, необходимых для анализа (например, дата или год события, нормированный показатель на единицу измерения).
3. Выполнить **фильтрацию** некорректных и экстремальных записей; дальнейшие узлы подключить к **первому** выходному порту фильтра.
4. Провести **корреляционный анализ** (Пирсон) относительно целевого числового поля и отсортировать результаты по убыванию связи.

5. Выполнить **стратификацию**: ввести категориальный признак для разбиения выборки и проверить распределение категорий визуализатором **Статистика**.

6. Разделить данные методом **стратифицированного** сэмплинга; убедиться, что пропорции категорий в train и test совпадают.

7. Обучить модель **линейной регрессии** на обучающем множестве (без информационной утечки из целевого поля), зафиксировать метрики **Сводки**.

8. Прогнать **тестовое** множество через обученную модель, сравнить фактические значения целевого поля с прогнозом и сформулировать выводы об ошибках модели.

СПИСОК ПОЛЕЗНЫХ ИСТОЧНИКОВ

1. *Loginom — руководство пользователя* [Электронный ресурс] / BaseGroup. — Режим доступа: https://help.loginom.ru/userguide/ (дата обращения: 09.08.2026).

2. *Линейная регрессия* [Электронный ресурс] / BaseGroup. — Loginom Help. — Режим доступа: https://help.loginom.ru/userguide/processors/datamining/linear-regression/index.html (дата обращения: 09.08.2026).

3. *House Sales Prediction* [Электронный ресурс] / harlfoxem. — Kaggle. — Режим доступа: https://www.kaggle.com/datasets/harlfoxem/housesalesprediction (дата обращения: 09.08.2026).

4. *Loginom: аналитическая платформа* [Электронный ресурс] / BaseGroup. — Режим доступа: https://loginom.ru/ (дата обращения: 09.08.2026).

5. Жерон, О. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow: концепции, инструменты и техники для создания интеллектуальных систем / пер. с англ. — СПб.: Альфа-книга, 2018. — 688 с.