ЛР2. Loginom — пошаговый гайд

Сценарий: импорт CSV → калькулятор признаков → фильтр → корреляция → стратификация → разбиение train/test → линейная регрессия → проверка на тесте. Учебный пример методички — `kc_house_data.csv`, а здесь разобран **другой** датасет, как и требует задание.

Что сдавать (п. 1.10 методички)

№	Требование	Шаг
1	Импорт CSV, разделители и типы, проверка в таблице	2
2	≥ 3 производных признака в Калькуляторе	3
3	Фильтрация некорректных и экстремальных записей; дальше — только первый порт фильтра	4
4	Корреляция Пирсона с целевым полем и сортировка по убыванию	5
5	Стратифицирующий категориальный признак, проверка визуализатором «Статистика»	6
6	Стратифицированное разбиение; одинаковые доли категорий в train и test	7
7	Линейная регрессия на train без утечки целевого поля; метрики Сводки	8
8	Прогон test через модель, сравнение факта и прогноза, выводы	9

1. Датасет

Рекомендуемый: Diamonds — 53 940 бриллиантов, `https://www.kaggle.com/datasets/shivam2503/diamonds` (файл `diamonds.csv`). Можно взять любой другой датасет для регрессии: шаги те же, меняются только имена полей.

Поле	Смысл	Тип/вид
`carat`	масса, карат	вещественный, непрерывный
`cut`	огранка: Fair < Good < Very Good < Premium < Ideal	строка, дискретный
`color`	цвет: J (худший) … D (лучший)	строка, дискретный
`clarity`	чистота: I1 < SI2 < SI1 < VS2 < VS1 < VVS2 < VVS1 < IF	строка, дискретный
`depth`, `table`	глубина и площадка, %	вещественный, непрерывный
`x`, `y`, `z`	длина, ширина, высота, мм	вещественный, непрерывный
`price`	цена, $ — **целевое поле**	целый, непрерывный

В файле Kaggle первый столбец без имени — номер строки. Его не используем.

2. Импорт CSV

1. Запустите Loginom → **Создать пакет**. Пакет — контейнер проекта; в нём модули, сценарии и подключения.
2. Слева **панель компонентов** → раздел **Импорт** → перетащите **Текстовый файл** на полотно сценария (центр).

3. Щёлкните по узлу → значок **шестерёнки** (мастер настройки).
4. **Шаг 1 мастера:** путь к `diamonds.csv`; включите **Заголовок в первой строке** → **Далее**.
5. **Шаг 2 (форматы): Разделитель столбцов: Запятая**, **Десятичный разделитель: Точка**, кодировка UTF-8 → **Обновить все** → откройте вкладку **Результат** и убедитесь, что столбцы разошлись правильно.
6. **Шаг 3 (столбцы):** задайте тип и вид данных: числа — **Вещественный/Целый, Непрерывный**; `cut`, `color`, `clarity` — **Строка, Дискретный**. У безымянного первого столбца снимите галочку (не импортировать).
7. **Шаг 4:** метка узла `Импорт diamonds` → **Готово** → кнопка **Выполнить** на панели над полотном (или правой кнопкой по узлу → **Выполнить**).
8. Правой кнопкой по узлу → **Настройка визуализаторов** → добавьте **Таблица** → **ОК**. Двойной щелчок по значку визуализатора на узле — проверьте 53 940 строк и отсутствие пустых значений.

3. Калькулятор: производные признаки

1. Раздел **Трансформация** → **Калькулятор** → перетащите на полотно и соедините выход импорта со входом калькулятора (тяните от порта к порту).
2. Шестерёнка → окно выражений. Для каждого нового поля: кнопка **+** (Добавить выражение) → **Имя**, **Тип**, **Вид** → формула в редакторе (поля удобно вставлять двойным щелчком из списка слева; имена пишутся **без** квадратных скобок).

Имя	Тип	Формула	Зачем
`volume`	Вещественный	`x * y * z`	объём камня, мм³ — сводит три размера в один
`cut_code`	Целый	`If(cut="Fair",1,If(cut="Good",2,If(cut="Very Good",3,If(cut="Premium",4,5))))`	порядковый код огранки
`color_code`	Целый	`If(color="J",1,If(color="I",2,If(color="H",3,If(color="G",4,If(color="F",5,If(color="E",6,7)))))))`	порядковый код цвета (D = 7)
`clarity_code`	Целый	`If(clarity="I1",1,If(clarity="SI2",2,If(clarity="SI1",3,If(clarity="VS2",4,If(clarity="VS1",5,If(clarity="VVS2",6,If(clarity="VVS1",7,8))))))))`	порядковый код чистоты
`price_per_carat`	Вещественный	`price / carat`	цена за карат — для анализа, **не для модели**

3. **ОК** → **Выполнить** → добавьте визуализатор **Таблица** и проверьте новые столбцы.

> **Почему коды, а не текст**
> Корреляция Пирсона и линейная регрессия работают с числами. У `cut`, `color`, `clarity` есть естественный порядок, поэтому порядковое кодирование честно передаёт смысл «лучше/хуже». Подробнее — в теории ЛР2 и ЛР4.

4. Фильтр строк

1. **Трансформация** → **Фильтр строк** → соедините выход калькулятора со входом фильтра.
2. Шестерёнка. Если вход серый — **Активировать**.
3. Добавьте условия (режим «все условия», то есть И):
   - `x > 0`, `y > 0`, `z > 0` — в датасете есть камни с нулевыми размерами (ошибки ввода);
   - `y < 20`, `z < 20` — убирает единичные явно ошибочные значения вроде $y = 58{,}9$ мм;
   - `depth >= 50` и `depth <= 75` — отсекает физически странные пропорции.
4. Метка `Фильтрация данных` → **Выполнить**.
5. **У фильтра два выхода:** первый — **Соответствуют условию**, второй — **Не соответствуют**. Все следующие узлы подключайте **к первому**. Добавьте на оба порта визуализатор **Таблица** и запишите, сколько строк ушло. Ожидаемо отбрасывается несколько десятков строк.

5. Корреляционный анализ

1. Раздел **Исследование** (или через поиск в панели компонентов) → **Корреляционный анализ** → вход от **первого** порта фильтра.
2. Шестерёнка → метод: оставьте только **Коэффициент корреляции Пирсона**.
3. **Набор 1:** `price`. **Набор 2:** `carat, depth, table, x, y, z, volume, cut_code, color_code, clarity_code`. Строковые поля и `price_per_carat` не включаем (последнее — потому что вычислено из `price`).
4. Метка `Корр. анализ` → **Выполнить**.
5. **Трансформация** → **Сортировка** → вход от корреляционного анализа → в поля сортировки перенесите столбец Пирсона, порядок **по убыванию** → метка `Сортировка по Пирсону DESC` → **Выполнить** → визуализатор **Таблица**.

Ожидаемая картина: `carat` ≈ 0,92, `volume`, `x`, `y`, `z` ≈ 0,86–0,90, `table` ≈ 0,13, `depth` ≈ 0. У кодов `color_code` и `clarity_code` корреляция **отрицательная** — это эффект смешения: камни высокой чистоты в среднем мельче. Обсудите это в выводах.

6. Стратификация

1. Новый **Калькулятор** → вход от **первого порта фильтра** (не от корреляции!).
2. Поле `price_category`, тип **Целый**, вид **Дискретный**. Границы — квартили цены, чтобы категории были примерно равными:

```
If(price < 950, 1, If(price < 2401, 2, If(price < 5324, 3, 4)))
```

3. **Выполнить** → **Настройка визуализаторов** → **Статистика** → откройте, выберите `price_category`: пропусков 0, минимум 1, максимум 4, на гистограмме (min = 1, max = 4) четыре столбца по ≈ 25 %.

7. Разбиение на множества

1. Компонент **Разбиение на множества** (поиск по названию в панели) → вход от калькулятора стратификации.

2. Шестерёнка → **Активировать** вход →
   - **Обучающее множество: 80 %**, **Тестовое: 20 %**;
   - **Метод сэмплинга: Стратифицированный**;
   - **Поле стратификации:** только `price_category`.
3. Метка `Обучающее 80% / Тестовое 20%` → **Выполнить**.
4. **Настройка визуализаторов** → на **оба** выхода (Обучающий и Тестовый выходной набор) добавьте **Статистика** → для `price_category` проценты по категориям должны совпадать (≈ 25/25/25/25). Сделайте скриншоты обеих гистограмм для отчёта.

8. Линейная регрессия

1. Раздел **Data Mining** → **Линейная регрессия** → вход от **Обучающего выходного набора**.
2. Шестерёнка → **Настройка входных столбцов**:
   - **Выходное:** `price`;
   - **Входное:** `carat, depth, table, x, y, z, volume, cut_code, color_code, clarity_code`;
   - **Не задано (Неиспользуемое):** `cut, color, clarity, price_per_carat, price_category`.
3. **Утечка:** `price_per_carat = price / carat` содержит ответ, поэтому во входы нельзя. `price_category` построена по `price` — тоже утечка.
4. **Нормализация:** для всех входов — **Стандартизация**.
5. **Разбиение на множества внутри мастера:** 100 % обучающее, 0 % тестовое, **Без валидации** (разбиение уже сделано отдельным узлом).
6. **Настройка линейной регрессии:** оставьте **Автоматическую настройку**, ползунок приоритета — в сторону точности.
7. Метка `Линрегрессия` → **Обучить**.
8. Правой кнопкой по нижнему выходному порту → **Быстрый просмотр** → **Сводка**: выпишите R^2, скорректированный R^2, стандартное отклонение ошибки и p-значение. Ожидаемо $R^2 \approx 0{,}9$. Вкладка **Коэффициенты** — какие признаки дают наибольший вклад (с учётом стандартизации коэффициенты сравнимы).

9. Проверка на тесте

1. Отсоедините от входа регрессии связь с обучающим портом и подайте **Тестовый выходной набор** (второй порт узла разбиения).
2. Правой кнопкой по узлу → **Выполнить** (не «Переобучить»! Модель уже обучена, нужны только прогнозы).
3. **Быстрый просмотр** → **Выход регрессии**: столбцы `price` (факт) и `price|Регрессия` (прогноз).
4. Для численной оценки добавьте **Калькулятор** после узла регрессии: `err = price|Регрессия - price`, `abs_err = Abs(err)`, `sq_err = err*err`. Затем узел **Группировка** без полей группировки с агрегатами *Среднее* для `abs_err` (это MAE) и `sq_err` (это MSE; RMSE = $\sqrt{\text{MSE}}$).
5. Выводы, которые ожидаются:
   - на дешёвых камнях линейная модель даёт даже **отрицательные** прогнозы цены — признак нелинейности;
   - ошибка растёт с ценой (гетероскедастичность);

- зависимость цены от массы нелинейна: $\mathrm{price} \sim \mathrm{carat}^{1{,}6\ldots1{,}8}$. Логарифмирование цены и массы заметно улучшило бы модель (см. теорию).

Чек-лист

- [ ] Импорт: разделители, типы и виды данных, таблица проверена.
- [ ] ≥ 3 производных признака (у нас 5).
- [ ] Фильтр: условия обоснованы, дальше подключён **первый** порт.
- [ ] Корреляция Пирсона + сортировка DESC, выводы о сильных и слабых признаках.
- [ ] `price_category` + визуализатор «Статистика».
- [ ] Стратифицированное 80/20, доли категорий совпадают (скриншоты).
- [ ] Регрессия без утечки, метрики Сводки выписаны.
- [ ] Тест прогнан через **Выполнить**, факт и прогноз сравнены, ошибки объяснены.