ЛР2. Теория: сценарий анализа, корреляция, стратификация, линейная регрессия

Математика, которая стоит за каждым узлом сценария Loginom. Обозначения — как в лекциях: выборка $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{\ell}$, $x_i \in \mathbb{R}^d$, матрица объектов $X \in \mathbb{R}^{\ell \times d}$.

1. Воспроизводимый сценарий

Аналитическая задача — это цепочка преобразований $\mathcal{D}_0 \xrightarrow{T_1} \mathcal{D}_1 \xrightarrow{T_2} \cdots \xrightarrow{T_k} \text{модель}$. В Loginom каждое T_j — узел, а стрелки — связи портов. Требования к цепочке:

- **детерминированность** — один и тот же вход даёт один и тот же выход (фиксируйте случайное зерно при разбиении);
- **порядок** — фильтрация до анализа, разбиение до обучения, а любые параметры, подсчитанные по данным (границы, средние, нормировки), считаются **только по обучающей части**;
- **прослеживаемость** — для каждого поля понятно, из чего оно получено (lineage).

2. Производные признаки

Производный признак — функция от исходных: $z = g(x)$. Типичные виды:

Вид	Пример	Смысл
Арифметический	$\text{volume} = x \cdot y \cdot z$	физическая величина
Нормированный	$\text{price_per_carat} = \text{price}/\text{carat}$	показатель на единицу
Временной	год, месяц, день недели из даты	сезонность, тренд
Порядковое кодирование	Fair → 1, …, Ideal → 5	перевод категорий с порядком в числа
Нелинейный	$\ln \text{carat}$, carat^2	линеаризация зависимости

Информационная утечка (target leakage) — признак, вычисленный с использованием целевого значения или недоступный в момент прогноза. Пример: $\text{price_per_carat} \cdot \text{carat} = \text{price}$ — если дать модели оба признака, она «узнает» ответ, и метрики на обучении будут фиктивно высокими.

3. Фильтрация

Фильтр — это предикат $\pi : \mathcal{X} \to \{0, 1\}$; результат — $\mathcal{D}' = \{(x_i, y_i) : \pi(x_i, y_i) = 1\}$. Различают:

- **некорректные записи** — нарушение физического смысла ($x = 0$ мм, отрицательная цена). Их удаляют всегда;
- **экстремальные записи** — корректны формально, но далеко от основной массы. Решение об удалении требует обоснования: правило IQR, квантили, правило трёх сигм (подробно — в ЛР3).

Фильтр меняет распределение. Всегда фиксируйте, сколько строк и какой доли данных он отбросил.

4. Корреляция Пирсона

4.1. Определение

Для выборок $(x_1, \dots, x_n)$ и $(y_1, \dots, y_n)$:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\,\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} = \frac{\operatorname{cov}(x, y)}{s_x s_y}.$$

4.2. Геометрический смысл и $|r| \le 1$

Обозначим центрированные векторы $\tilde{x} = x - \bar{x}\mathbf{1}$, $\tilde{y} = y - \bar{y}\mathbf{1} \in \mathbb{R}^n$. Тогда

$$r_{xy} = \frac{\langle \tilde{x}, \tilde{y} \rangle}{\|\tilde{x}\|_2 \, \|\tilde{y}\|_2} = \cos \angle(\tilde{x}, \tilde{y}).$$

По неравенству Коши–Буняковского $|\langle \tilde{x}, \tilde{y} \rangle| \le \|\tilde{x}\|\|\tilde{y}\|$, поэтому $|r| \le 1$. Равенство $|r| = 1$ достигается тогда и только тогда, когда $\tilde{y} = c\,\tilde{x}$, то есть $y = a + cx$ — точная линейная зависимость.

4.3. Свойства

- Инвариантен к линейным преобразованиям с положительным коэффициентом: $r(a + bx, c + dy) = \operatorname{sign}(bd)\, r(x, y)$. Поэтому масштабирование признаков корреляцию не меняет.
- Измеряет **только линейную** связь: при $y = x^2$, $x \sim U[-1, 1]$ имеем $r \approx 0$, хотя зависимость функциональная.
- Чувствителен к выбросам: одна далёкая точка может создать или разрушить корреляцию.
- Корреляция — не причинность. Отрицательная корреляция цены с `clarity_code` объясняется **смешивающей переменной** (массой): чистые камни в среднем мельче.

4.4. Значимость

Гипотеза $H_0 : \rho = 0$ проверяется статистикой

$$t = \frac{r\sqrt{n - 2}}{\sqrt{1 - r^2}} \sim t_{n-2} \quad \text{при } H_0.$$

При $n \approx 54\,000$ даже $r = 0{,}02$ статистически значим. Значимость ≠ сила связи: при больших выборках смотрят на величину $|r|$, а не на p-значение.

4.5. Связь с регрессией

Для парной регрессии $y \approx w_0 + w_1 x$ по МНК:

$$w_1 = r_{xy}\frac{s_y}{s_x}, \qquad R^2 = r_{xy}^2.$$

Так, $r = 0{,}92$ для массы означает, что одна масса объясняет $\approx 85\,\%$ дисперсии цены.

5. Стратифицированное разбиение

5.1. Идея

Пусть выборка разбита на **страты** $h = 1, \dots, H$ (у нас — ценовые категории) с долями $W_h = N_h / N$. При **пропорциональном** стратифицированном отборе из каждой страты берётся одна и та же доля f (например, 20 % в тест). Тогда доли страт в train и test совпадают с долями в генеральной совокупности **точно**, а не только в среднем.

5.2. Почему это уменьшает разброс оценок

Оценка среднего при стратифицированном отборе $\bar{y}_{st} = \sum_h W_h \bar{y}_h$. Её дисперсия (без поправки на конечность):

$$D(\bar{y}_{st}) = \sum_{h=1}^{H} W_h^2 \frac{\sigma_h^2}{n_h} = \frac{1}{n} \sum_h W_h \sigma_h^2,$$

а при простой случайной выборке $D(\bar{y}) = \frac{\sigma^2}{n}$, где по формуле полной дисперсии

$$\sigma^2 = \underbrace{\sum_h W_h \sigma_h^2}_{\text{внутри страт}} + \underbrace{\sum_h W_h (\mu_h - \mu)^2}_{\text{между стратами}}.$$

Стратификация убирает межстратную компоненту, поэтому $D(\bar{y}_{st}) \le D(\bar{y})$. Чем сильнее страты различаются по y, тем больше выигрыш. Именно поэтому страты строят по целевому полю.

5.3. Квантильные границы

Если границы — выборочные квартили $q_{0.25}, q_{0.5}, q_{0.75}$, то страты получаются равными (по 25 %). Квантиль уровня p — значение q_p, такое что $P(Y \le q_p) \approx p$.

6. Train / test

Модель $\hat{\alpha}$ подбирается по обучающей выборке, поэтому ошибка на ней — смещённая (оптимистичная) оценка теоретического функционала

$$M_L(\alpha) = \mathbb{E}_X \, \mathbb{E}_{Y|X} L(Y, \alpha(X)).$$

Для **фиксированной** модели эмпирический функционал на независимой тестовой выборке сходится к M_L по закону больших чисел:

$$Q_L(\hat{\alpha}, \mathcal{D}_{test}) = \frac{1}{m} \sum_{j=1}^{m} L(y_j, \hat{\alpha}(x_j)) \xrightarrow{P} M_L(\hat{\alpha}).$$

Поэтому качество оценивают на тесте, который модель не видела при обучении.

7. Линейная регрессия

7.1. Модель и МНК

$$\alpha(x) = w_0 + \sum_{j=1}^{d} w_j x^j = \langle w, x \rangle \quad (\text{после добавления признака } x^0 \equiv 1).$$

Метод наименьших квадратов минимизирует

$$Q(w) = \|Xw - y\|_2^2 \;\Rightarrow\; \nabla_w Q = 2X^T(Xw - y) = 0 \;\Rightarrow\; X^T X w = X^T y,$$

$$w^* = (X^T X)^{-1} X^T y \quad (\text{если } X^T X \text{ обратима}).$$

Вывод подробно — в лекции «Обучение линейной регрессии» и в теории ЛР5–ЛР6.

7.2. Стандартизация признаков

$$x'^j = \frac{x^j - \bar{x}^j}{s_j}.$$

После неё все признаки в одной шкале (среднее 0, стандартное отклонение 1). Коэффициенты w_j становятся сравнимыми: $|w_j|$ — изменение прогноза при сдвиге признака на одно стандартное отклонение. Прогнозы МНК без регуляризации от стандартизации не меняются, но **регуляризация** (Loginom выбрал Ridge) становится честной: штраф одинаково относится ко всем признакам.

7.3. Мультиколлинеарность

`carat`, `x`, `y`, `z`, `volume` почти линейно зависимы ($\text{carat} \approx \rho \cdot \text{volume}$). Тогда есть вектор v с $Xv \approx 0$, у X^TX появляется маленькое собственное число, и решение неустойчиво: коэффициенты могут получиться большими и разных знаков, хотя прогноз нормальный. Лекарство — регуляризация L_2 (Ridge):

$$w^* = (X^TX + \lambda I)^{-1} X^T y.$$

7.4. Метрики Сводки Loginom

Метрика	Формула	Смысл
R^2	$1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$	доля объяснённой дисперсии
Скорректированный R^2	$1 - (1 - R^2)\frac{n-1}{n-p-1}$	штраф за число признаков p
Станд. ошибка регрессии	$\hat{\sigma} = \sqrt{\frac{\sum(y_i - \hat{y}_i)^2}{n-p-1}}$	типичный размер ошибки, в единицах y
F-статистика	$F = \frac{R^2/p}{(1-R^2)/(n-p-1)}$	проверка «все $w_j = 0$»; отсюда p-значение
RMSE, MAE	$\sqrt{\frac{1}{n}\sum r_i^2}$, $\frac{1}{n}\sum\lvert r_i\rvert$	ошибка на тесте

$R^2 = 0$ — модель не лучше константы $\bar{y}$; $R^2 < 0$ на тесте — хуже константы.

7.5. Анализ остатков

Остатки $r_i = y_i - \hat{y}_i$ должны выглядеть как шум: без тренда относительно $\hat{y}$ и с постоянным разбросом. В Diamonds разброс растёт с ценой (**гетероскедастичность**), а связь цены с массой степенная:

$$\text{price} \approx C \cdot \text{carat}^{\beta} \implies \ln \text{price} \approx \ln C + \beta \ln \text{carat}.$$

После логарифмирования зависимость становится линейной, а ошибки — относительными (в процентах). Это первая идея для улучшения модели и прямая связь с ЛР4 (линеаризация).

8. Вопросы для самопроверки

1. Почему `price_per_carat` нельзя подавать в модель, а для анализа — можно?
2. Докажите, что $|r_{xy}| \le 1$. Когда $|r| = 1$?
3. Приведите пример сильной зависимости при $r \approx 0$.
4. Почему стратификация по целевому полю уменьшает разброс оценки качества?
5. Чем R^2 на обучении отличается от R^2 на тесте и почему тестовый обычно ниже?
6. Почему при почти коллинеарных признаках коэффициенты неустойчивы, а прогноз — нет?
7. Что означает отрицательный прогноз цены и как это исправить?