Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Методические указания к лабораторной работе №3 по дисциплине ОАД

Разработали:
Старший преподаватель
Маслеников К.Ю.
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

1 ЗАДАНИЕ 3
2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ 4
2.1 Первичный анализ набора данных 4
2.2 Анализ пропущенных значений 4
2.3 Выбор способов обработки пропущенных значений 5
2.4 Сравнение способов заполнения пропусков 5
2.5 Исследование распределений числовых признаков 5
2.6 Обнаружение выбросов 6
2.6.1 Правило трёх сигм 6
2.6.2 Метод межквартильного размаха 6
2.6.3 Квантильный подход 7
2.6.4 Сравнение методов 7
2.7 Обработка выбросов 8
2.8 Сравнение исходного и обработанного наборов данных 8

1 ЗАДАНИЕ

Необходимо выбрать набор данных (датасет), содержащий пропущенные значения и выбросы. Для выбранного набора данных на основе материалов лекций провести анализ и обработку пропущенных значений и выбросов.

Лекционные и дополнительные материалы, соответствующие данной лабораторной работе, размещены на диске[1].

При выполнении лабораторной работы допускается использование методов и подходов, не рассмотренных в лекционных материалах.

Результаты работы необходимо оформить в виде ноутбука. Приведённая ниже структура включает основные этапы анализа, которые должны быть представлены в работе.

[1] https://disk.yandex.ru/d/EEd2Kdd7ca1k-w

2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ

2.1 Первичный анализ набора данных

– Привести краткое описание набора данных:
  – предметная область;
  – количество объектов;
  – количество признаков;
  – назначение основных признаков;
  – целевое значение, если оно присутствует в наборе данных.
– Провести анализ типов признаков и определить тип каждого признака.
– Проверить данные на наличие некорректных или подозрительных значений, которые формально не являются пропусками.
– Для числовых признаков вычислить основные описательные статистики:
  – минимальное и максимальное значения;
  – среднее;
  – медиану;
  – стандартное отклонение;
  – первый и третий квартили.
– Для категориальных признаков определить:
  – количество уникальных значений;
  – наиболее часто встречающиеся категории;
  – частоты появления категорий.

2.2 Анализ пропущенных значений

– Исследовать распределение пропущенных значений по признакам и объектам.
– Визуализировать распределение пропущенных значений, например в виде диаграммы их долей по признакам.
– На основании проведённого анализа сделать предположение о случайном или неслучайном характере возникновения пропусков.

2.3 Выбор способов обработки пропущенных значений

Для **каждого признака, содержащего пропущенные значения**, выбрать способ обработки пропусков и обосновать его применение, указав преимущества выбранного метода и возможные искажения данных.

2.4 Сравнение способов заполнения пропусков

Для нескольких выбранных признаков провести сравнительный анализ различных способов обработки пропусков. В анализ необходимо включить как минимум один числовой и один категориальный признак. Для каждого из них сравнить не менее двух различных стратегий обработки.

Для числовых признаков сравнить характеристики распределения до и после обработки. Для категориальных признаков сравнить частотные характеристики.

Построить графики, необходимые для интерпретации полученных результатов. По каждому исследованному признаку сделать вывод, в котором пояснить, как изменилось распределение после обработки.

2.5 Исследование распределений числовых признаков

Для как минимум двух числовых признаков, в которых присутствуют экстремальные значения, провести анализ распределения. Для каждого выбранного признака выдвинуть гипотезу о виде распределения и проверить, насколько эмпирическое распределение согласуется с предполагаемым теоретическим распределением.

Для проверки гипотезы использовать подходящие графические и статистические характеристики. Например, построить Q–Q диаграмму и сравнить эмпирические квантили с квантилями предполагаемого теоретического распределения.

По результатам анализа сделать вывод о соответствии эмпирического распределения выдвинутой гипотезе.

2.6 Обнаружение выбросов

Для числовых признаков, выбранных в предыдущем подразделе, выполнить поиск потенциальных выбросов как минимум двумя различными методами.

2.6.1 Правило трёх сигм

Для признаков, распределение которых является нормальным или близким к нормальному, может применяться правило трёх сигм. Потенциальными выбросами считаются значения, находящиеся за пределами интервала

$$\mu - 3\sigma < x < \mu + 3\sigma,$$

где μ — среднее значение признака, а σ — его стандартное отклонение.

При использовании данного метода необходимо учитывать, что среднее значение и стандартное отклонение чувствительны к экстремальным значениям, поэтому применение правила трёх сигм к существенно асимметричным распределениям может приводить к некорректным результатам.

2.6.2 Метод межквартильного размаха

Более устойчивым к экстремальным значениям является метод межквартильного размаха. Межквартильный размах определяется как

$$IQR = Q_3 - Q_1,$$

где Q_1 и Q_3 — первый и третий квартили соответственно.

Потенциальными выбросами считаются значения, находящиеся за пределами интервала

$$Q_1 - K \cdot IQR < x < Q_3 + K \cdot IQR.$$

Обычно используется значение коэффициента $K = 1.5$.

При необходимости для выделения более экстремальных значений может использоваться значение $K = 3$.

2.6.3 Квантильный подход

Для выделения экстремальных значений также может использоваться квантильный подход. В этом случае задаются нижний и верхний квантили, за пределами которых наблюдения рассматриваются как потенциально экстремальные.

Например, при использовании квантилей уровней 0.05 и 0.95 выделяются значения

$$x < q_{0.05}, \qquad x > q_{0.95}.$$

Следует учитывать, что такой подход по определению выделяет приблизительно заданную долю наблюдений и поэтому нахождение значения за выбранными квантильными границами само по себе не означает, что оно является ошибочным.

2.6.4 Сравнение методов

Для выбранных числовых признаков провести сравнительный анализ применённых методов обнаружения выбросов.

Результаты представить в табличной форме. Для каждого признака и метода отразить нижнюю и верхнюю границы, количество и долю обнаруженных наблюдений.

Сопоставить результаты различных методов и проанализировать различия между множествами обнаруженных выбросов. По результатам сравнения пояснить, чем могут быть обусловлены полученные различия с учётом формы распределения и особенностей используемых методов.

Для обнаруженных экстремальных значений сделать предположение о том, являются ли они выбросами или корректными наблюдениями.

2.7 Обработка выбросов

Для экстремальных значений, которые по результатам проведённого анализа были отнесены к выбросам, выбрать и применить способ обработки.

После обработки проанализировать, как изменились характеристики распределения соответствующих признаков, и сделать вывод о последствиях выбранного способа обработки.

2.8 Сравнение исходного и обработанного наборов данных

По завершении обработки пропущенных значений и выбросов сформировать итоговый набор данных.

Провести сравнение исходного и обработанного наборов данных, представить сводную статистику изменений, внесённых в данные, и сделать вывод о влиянии выполненной обработки на объём данных и основные характеристики признаков.