ЛР3. Теория: типы признаков, пропуски, распределения, выбросы

Опирается на лекционные ноутбуки «missing» и «outliers» и закрывает вопросы РК1 № 1–2.

1. Семантические типы признаков

Шкалы Стивенса — по тому, какие операции над значениями имеют смысл:

Шкала	Допустимые операции	Пример	Центр	Разброс
Номинальная	$=, \neq$	тип жилья, район	мода	число категорий, энтропия
Порядковая	$=, <$	огранка Fair < … < Ideal, оценка 1–5	медиана, мода	квантили
Интервальная	$=, <, +, -$ (ноль условен)	температура °C, год	среднее	σ
Относительная	$=, <, +, -, \times, \div$ (абсолютный ноль)	цена, площадь	среднее, геом. среднее	σ, коэф. вариации

Отдельно выделяют **бинарные** признаки, **даты/время**, **текст**, **идентификаторы** (не признаки: номер строки, адрес). Тип хранения не равен смыслу: почтовый индекс — число по типу, но номинальный по смыслу.

2. Пропущенные значения

2.1. Механизмы пропусков (Рубин)

Пусть $R_{ij} = 1$, если значение x_{ij} пропущено. Разобьём данные на наблюдаемую часть X_{obs} и пропущенную X_{mis}.

Механизм	Формально	Смысл	Пример
MCAR (полностью случайно)	$P(R \mid X_{obs}, X_{mis}) = P(R)$	пропуск не связан ни с чем	анкета потеряна при пересылке
MAR (случайно)	$P(R \mid X_{obs}, X_{mis}) = P(R \mid X_{obs})$	зависит только от наблюдаемых признаков	площадь чаще не указана у квартир
MNAR (неслучайно)	зависит от самого X_{mis}	пропуск связан с ненаблюдаемым значением	богатые не указывают доход

Проверка на практике. Если пропуски MCAR, распределения других признаков у строк «с пропуском» и «без» совпадают. Сравнивают медианы, тестом Манна–Уитни (числовые) и χ^2 (категориальные). Различие опровергает MCAR. Отличить MAR от MNAR по данным нельзя — только по смыслу предметной области.

2.2. Удаление

- **Построчное (listwise):** удалить объекты с пропусками. Несмещённо только при MCAR; при доле пропусков p в каждом из k независимых признаков остаётся доля $(1-p)^k$ строк. Например,

$0{,}9^{10} \approx 0{,}35$.

- **Удаление признака:** при очень большой доле пропусков (> 60–70 %) и низкой ценности признака.

2.3. Заполнение одним значением

Среднее, медиана, мода, константа. Пусть из n значений наблюдаемы m, с выборочной дисперсией s^2_{obs}. После заполнения средним $\bar{x}_{obs}$ среднее не меняется, а дисперсия падает:

$$s^2_{new} = \frac{1}{n-1}\sum_{i \in obs}(x_i - \bar{x}_{obs})^2 = \frac{m-1}{n-1}\, s^2_{obs} < s^2_{obs}.$$

При 47 % пропусков стандартное отклонение уменьшается примерно в $\sqrt{0{,}53} \approx 0{,}73$ раза. Ковариации с другими признаками тоже стягиваются к нулю: у заполненных строк $x_i - \bar{x} = 0$. Поэтому корреляции ослабевают.

Способ	Плюсы	Минусы
Среднее	сохраняет среднее	чувствительно к выбросам, сжимает дисперсию
Медиана	устойчива к выбросам	сжимает дисперсию, пик в одной точке
Мода (категории)	просто	раздувает частую категорию
Константа / «Unknown»	честно помечает пропуск	искусственная категория или значение
«Хвост распределения» ($\mu + 3\sigma$ или $Q_3 + 3\,\mathrm{IQR}$)	отделяет пропуски от нормальных значений для деревьев	искажает распределение, плохо для линейных моделей
Флаг пропуска $I_{ij} = R_{ij}$	сохраняет информацию «значение было неизвестно» (важно при MNAR)	+1 признак
Групповая статистика	учитывает зависимость от других признаков (MAR)	нужны осмысленные группы

2.4. Многомерное заполнение

KNN-импутация. Для объекта с пропуском в признаке j находят k ближайших соседей по остальным признакам (расстояние по признакам, наблюдаемым у обоих объектов) и берут среднее их значений x_j. Расстояние зависит от масштаба — признаки **обязательно стандартизируют**.

MICE (Multivariate Imputation by Chained Equations), `IterativeImputer`:

1. заполнить пропуски простым способом (средним);
2. для каждого признака j с пропусками: обучить регрессию $x_j \sim x_{-j}$ на строках, где x_j известен, и предсказать пропущенные значения;
3. повторять п. 2 по кругу до стабилизации (10–20 итераций).

MICE сохраняет связи между признаками лучше одиночных методов. В «множественной» версии к прогнозам добавляют случайный шум из распределения остатков, чтобы не занижать дисперсию.

3. Распределения

3.1. Моменты

$$\bar{x} = \frac{1}{n}\sum x_i, \qquad s^2 = \frac{1}{n-1}\sum (x_i - \bar{x})^2,$$

$$\text{Асимметрия } \gamma_1 = \frac{\frac{1}{n}\sum (x_i-\bar{x})^3}{\hat{\sigma}^3}, \qquad \text{Эксцесс } \gamma_2 = \frac{\frac{1}{n}\sum (x_i-\bar{x})^4}{\hat{\sigma}^4} - 3.$$

У нормального распределения $\gamma_1 = \gamma_2 = 0$. Если $\gamma_1 > 0$, правый хвост длиннее и $\bar{x} > \text{med}$ — типично для цен и площадей. Если $\gamma_2 > 0$, хвосты тяжелее нормальных: экстремальных значений больше.

3.2. Типичные распределения

Распределение	Плотность / определение	Где встречается
Нормальное $N(\mu, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	ошибки измерений, рост
Логнормальное	$\ln X \sim N(\mu, \sigma^2)$	цены, доходы, площади
Экспоненциальное	$\lambda e^{-\lambda x}$, $x \geq 0$	время между событиями
Парето	$P(X > x) = (x_m/x)^a$	доходы богатейших, размеры городов

Логнормальное: $\text{med} = e^{\mu}$, $\mathbb{E}X = e^{\mu+\sigma^2/2} > \text{med}$. Проверка гипотезы «$X$ логнормально» сводится к проверке нормальности $\ln X$.

3.3. Q–Q график

Упорядочим выборку $x_{(1)} \leq \cdots \leq x_{(n)}$. Точке i сопоставим теоретический квантиль $F^{-1}(p_i)$, $p_i = \frac{i-0{,}5}{n}$. Q–Q график — точки $\left(F^{-1}(p_i),\ x_{(i)}\right)$.

- Если $X \sim F$ с точностью до сдвига и масштаба, точки лежат на прямой $x = \mu + \sigma q$.
- Выпуклость вверх справа — правый хвост тяжелее теоретического.
- S-образная форма — хвосты тяжелее (или легче) с обеих сторон.

3.4. Статистические тесты нормальности

Тест	Статистика	Особенности
Колмогорова–Смирнова	$D = \sup_x \lvert F_n(x) - F(x)\rvert$	при оценённых μ, σ нужна поправка Лиллиефорса
Шапиро–Уилка	корреляция упорядоченной выборки с ожидаемыми нормальными порядковыми статистиками	мощный; в SciPy до 5000 точек
Д'Агостино K^2 (`normaltest`)	объединяет асимметрию и эксцесс: $K^2 = Z_1^2(\gamma_1) + Z_2^2(\gamma_2) \sim \chi^2_2$	подходит для больших n

При n порядка 10^4 тесты отвергают нормальность из-за ничтожных отклонений. Поэтому выводы делают по Q–Q графику и величине γ_1, γ_2, а тест — как дополнение.

4. Выбросы

4.1. Определение

Выброс — наблюдение, которое заметно отклоняется от основной массы и может быть порождено другим механизмом: ошибка ввода, другая популяция, редкое, но реальное событие. Задача анализа — не только найти экстремальные значения, но и решить, ошибка это или корректное наблюдение.

4.2. Правило трёх сигм

Выброс, если $x \notin (\mu - 3\sigma,\ \mu + 3\sigma)$. Для нормального распределения

$$P(|X - \mu| > 3\sigma) = 2\big(1 - \Phi(3)\big) \approx 0{,}0027,$$

то есть 0,27 % наблюдений. Для произвольного распределения работает только неравенство Чебышёва:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2} \quad \Rightarrow \quad P(|X - \mu| \geq 3\sigma) \leq \frac{1}{9} \approx 11\,\%.$$

Проблемы: $\bar{x}$ и s сами сдвигаются выбросами (**эффект маскировки**). Для скошенных распределений нижняя граница уходит в отрицательную область, а «нормальные» значения правого хвоста помечаются как выбросы.

4.3. Межквартильный размах

$$\mathrm{IQR} = Q_3 - Q_1, \qquad \text{выброс, если } x < Q_1 - K \cdot \mathrm{IQR} \text{ или } x > Q_3 + K \cdot \mathrm{IQR}.$$

Связь с нормальным распределением: $Q_{1,3} = \mu \mp 0{,}674\sigma$, $\mathrm{IQR} = 1{,}349\sigma$. Тогда

- $K = 1{,}5$: границы $\mu \pm 2{,}698\sigma$, доля за границами $\approx 0{,}70\,\%$;
- $K = 3$: границы $\mu \pm 4{,}72\sigma$, доля $\approx 2{,}3 \cdot 10^{-6}$ («экстремальные» выбросы).

Квартили имеют **точку срыва** 25 %: пока выбросов меньше четверти, границы не «ломаются». У среднего точка срыва 0 — достаточно одного значения.

4.4. Квантильный подход

Выброс, если $x < q_\alpha$ или $x > q_{1-\alpha}$. По построению отсекается доля $\approx 2\alpha$ при **любых** данных — даже идеально нормальных. Это «экстремальные значения», а не обязательно выбросы.

4.5. Робастный z-показатель

$$z_i^{rob} = \frac{x_i - \mathrm{med}(x)}{1{,}4826 \cdot \mathrm{MAD}}, \qquad \mathrm{MAD} = \mathrm{med}\,|x_i - \mathrm{med}(x)|.$$

Множитель 1,4826 делает $1{,}4826 \cdot \mathrm{MAD}$ состоятельной оценкой σ для нормального распределения. Обычный порог — $|z^{rob}| > 3{,}5$.

4.6. Логарифмическая шкала

Для логнормальных данных правило 3σ применяют к $\ln x$:

$$\text{границы: } \exp(\mu_{\ln} \pm 3\sigma_{\ln}),$$

они несимметричны в исходной шкале и согласованы с формой распределения.

4.7. Сравнение множеств выбросов

Коэффициент Жаккара $J(A,B) = \dfrac{|A \cap B|}{|A \cup B|} \in [0,1]$: 1 — методы нашли одно и то же, 0 — ничего общего.

4.8. Обработка выбросов

Способ	Что происходит со статистиками
Удаление строк	теряем объём; если выбросы реальны — смещаем выборку
Винзоризация (clip к границам)	среднее и σ уменьшаются, медиана и квартили не меняются; на границе появляется пик
Замена медианой / как на пропуск	как при заполнении пропусков: сжатие дисперсии
Преобразование ($\ln$, $\sqrt{}$, Бокс–Кокс)	хвост «поджимается», порядок значений сохраняется
Оставить + робастная модель (MAE, Huber)	данные не меняются, модель меньше реагирует на выбросы

Связь с моделями (ЛР5): квадратичная функция потерь штрафует отклонение r как r^2, поэтому один выброс может «перетянуть» линейную регрессию. Абсолютная функция и функция Хьюбера растут линейно, поэтому устойчивее.

5. Вопросы для самопроверки (РК1 № 1–2)

1. Перечислите семантические типы признаков. Для каждого — по три способа обработки пропусков с плюсами и минусами.
2. Чем MCAR отличается от MAR и MNAR? Как проверить MCAR на данных?
3. Докажите, что заполнение средним уменьшает выборочную дисперсию, и найдите коэффициент уменьшения.
4. Почему для KNN-импутации признаки нужно масштабировать?
5. Дайте определение выброса. Три способа обнаружения и три способа обработки.
6. Какая доля нормальных данных выходит за границы IQR при $K = 1{,}5$? Выведите.
7. Почему правило трёх сигм плохо работает для скошенных распределений?
8. Как по Q–Q графику отличить тяжёлый правый хвост от лёгкого?