Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Методические указания к лабораторной работе №4 по дисциплине ОАД

Разработали:
Старший преподаватель
Маслеников К.Ю.
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

1 ЗАДАНИЕ 3
2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ 4
2.1 Первичный анализ признакового пространства 4
2.2 Кодирование категориальных признаков 4
2.3 Предметно обусловленное конструирование признаков 4
2.4 Линеаризация зависимости 5
2.5 Корреляционный анализ 5
2.5.1 Коэффициент корреляции Пирсона 5
2.5.2 Коэффициент корреляции Спирмена 6
2.6 Сравнение коэффициентов корреляции 6
2.7 Масштабирование признаков 7
2.7.1 Сравнение способов масштабирования 7

1 ЗАДАНИЕ

Необходимо выбрать набор данных (датасет), содержащий числовые и категориальные признаки. Рекомендуется использовать наборы данных, не содержащие пропущенных значений, либо набор данных, полученный по результатам выполнения предыдущей лабораторной работы, если он удовлетворяет требованиям.

Для выбранного набора данных на основе материалов лекций провести разведочный анализ данных (EDA).

Лекционные и дополнительные материалы, соответствующие данной лабораторной работе, размещены на диске[1].

При выполнении лабораторной работы допускается использование методов и подходов, не рассмотренных в лекционных материалах.

Результаты работы необходимо оформить в виде ноутбука. Приведённая ниже структура включает основные этапы анализа, которые должны быть представлены в работе.

[1] https://disk.yandex.ru/d/86DxIeRANie-9w

2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ

2.1 Первичный анализ признакового пространства

– Привести краткое описание используемого набора данных:
  – предметная область;
  – количество объектов;
  – количество исходных признаков;
  – назначение основных признаков;
  – целевое значение, если оно присутствует в наборе данных.
– Провести анализ типов признаков и определить тип каждого признака.
– Для числовых и категориальных признаков вычислить основные описательные и частотные характеристики.

2.2 Кодирование категориальных признаков

Для каждого категориального признака выбрать и применить наиболее подходящий способ кодирования.

Выбор способа кодирования необходимо обосновать с учётом типа признака, количества и смысла его категорий, наличия естественного порядка и особенностей выбранного метода.

Результаты представить в табличной форме, указав для каждого признака его тип и выбранный способ кодирования.

2.3 Предметно обусловленное конструирование признаков

Предположить, какие новые признаки могут быть осмысленными для выбранного набора данных, исходя из содержания и взаимосвязи исходных признаков. Сформировать как минимум два таких признака и обосновать их интерпретацию.

Например, если набор данных содержит площадь квартиры и количество комнат, можно рассмотреть новый признак

$$z = \frac{\text{площадь квартиры}}{\text{количество комнат}},$$

который характеризует среднюю площадь, приходящуюся на одну комнату.

2.4 Линеаризация зависимости

Исследовать возможность такого преобразования признакового пространства, при котором наблюдаемые зависимости получают более выраженное линейное представление.

Для каждого непрерывного признака построить диаграмму рассеяния целевого значения в зависимости от данного признака. Выбрать как минимум два признака, для которых наблюдается выраженная нелинейная зависимость, и предложить преобразование, позволяющее представить эту зависимость в более линейной форме.

Например, если для признака x наблюдается зависимость $y \approx x^2$, можно сформировать новый признак $z = x^2$, для которого зависимость y от z будет ближе к линейной.

Для выбранных признаков сравнить диаграммы рассеяния до и после преобразования.

2.5 Корреляционный анализ

Для итогового набора признаков провести корреляционный анализ с использованием коэффициентов корреляции Пирсона и Спирмена.

2.5.1 Коэффициент корреляции Пирсона

Пусть имеются два признака X и Y, содержащие наблюдения $x_1, \ldots, x_n$ и $y_1, \ldots, y_n$ соответственно.

Коэффициент корреляции Пирсона определяется как

$$\rho_{\mathrm{P}}(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2 \sum_{i=1}^{n}(y_i - \overline{y})^2}},$$

где $\overline{x}$ и $\overline{y}$ — средние значения соответствующих признаков.

Коэффициент Пирсона характеризует направление и выраженность линейной зависимости между признаками.

2.5.2 Коэффициент корреляции Спирмена

Пусть R_X и R_Y — ранговые представления признаков X и Y соответственно.

Коэффициент корреляции Спирмена определяется как коэффициент корреляции Пирсона между рангами наблюдений:

$$\rho_{\mathrm{S}}(X,Y) = \rho_{\mathrm{P}}(R_X, R_Y).$$

Коэффициент Спирмена характеризует направление и выраженность монотонной зависимости между признаками.

2.6 Сравнение коэффициентов корреляции

Для полученного набора признаков построить две корреляционные матрицы с использованием коэффициентов Пирсона и Спирмена и выполнить их визуализацию.

Сравнить значения коэффициентов корреляции признаков между собой и проанализировать случаи, в которых коэффициенты Пирсона и Спирмена заметно различаются.

Оценить связь исходных и созданных признаков с целевым значением и определить, подтвердились ли предположения, сформулированные при предметно обусловленном конструировании признаков и при линеаризации зависимостей.

По результатам сравнения сделать вывод о характере выявленных зависимостей и полезности созданных признаков.

2.7 Масштабирование признаков

Выбрать как минимум два числовых признака, существенно различающихся по масштабу.

Для каждого выбранного признака применить не менее двух различных методов масштабирования.

2.7.1 Сравнение способов масштабирования

Для выбранных числовых признаков провести сравнительный анализ результатов масштабирования.

Сравнить признаки до и после применения выбранных методов масштабирования. Для этого построить графики плотности распределения, вычислить основные описательные характеристики и сопоставить масштабы признаков.

По каждому исследованному признаку сделать вывод о влиянии выбранных методов масштабирования.

По результатам проведённого анализа выбрать один способ масштабирования, применить его к признакам полученного набора данных, для которых масштабирование является целесообразным, и обосновать сделанный выбор.