ЛР4. Теория: кодирование, конструирование и линеаризация признаков, корреляции, масштабирование

Опирается на лекционные ноутбуки «categorical», «features_datatypes», «normalization», «scaling» и закрывает вопросы РК1 № 3–4.

1. Кодирование категориальных признаков

Пусть признак принимает значения из множества категорий $\{c_1, \dots, c_K\}$.

1.1. Label / Ordinal encoding

$c_k \mapsto k$. Корректно **только для порядковых** признаков (огранка, образование), где порядок и, желательно, равные «шаги» осмыслены. Для номинальных признаков создаёт ложный порядок и ложные расстояния: линейная модель будет считать, что «район 3» ровно посередине между «районом 2» и «районом 4».

1.2. One-Hot encoding

Категория превращается в K бинарных признаков $e_k(x) = [x = c_k]$.

Ловушка фиктивных переменных. Для любого объекта $\sum_{k=1}^{K} e_k(x) = 1$. Если в модели есть свободный член (столбец единиц $\mathbf{1}$), то столбцы матрицы $X = [\mathbf{1}, E_1, \dots, E_K]$ линейно зависимы:

$$Xv = 0 \quad \text{для} \quad v = (1, -1, -1, \dots, -1)^T \neq 0.$$

По утверждению из лекции, тогда для любого решения w^* все $w^* + Cv$ дают те же ответы на обучении, решение не единственно, а $X^T X$ вырождена. Лекарство — удалить один столбец (`drop_first=True`); удалённая категория становится **базовой**, а веса остальных — сдвигами относительно неё.

Минусы one-hot: при большом K получаются сотни разреженных столбцов; редкие категории дают шумные веса.

1.3. Frequency (Count) encoding

$$c_k \mapsto \frac{n_k}{n} \quad (\text{или } n_k).$$

Один столбец при любом K. Минус — **коллизии**: разные категории с одинаковой частотой становятся неразличимы. Работает, если популярность категории связана с целью.

1.4. Target (Mean) encoding

Категорию заменяют средним значением цели в ней. Чтобы редкие категории не давали шумных оценок, используют **сглаживание** к общему среднему $\bar{y}$:

$$\mathrm{TE}(c_k) = \frac{n_k\,\bar{y}_k + m\,\bar{y}}{n_k + m} = \lambda_k \bar{y}_k + (1 - \lambda_k)\bar{y}, \qquad \lambda_k = \frac{n_k}{n_k + m}.$$

Это байесовская оценка: при $n_k \to \infty$ доверяем среднему категории, при $n_k \to 0$ — общему среднему; m задаёт силу «притяжения».

Утечка. Если считать $\bar{y}_k$ по всем данным, в среднее входит и y_i самого объекта i. Для редкой категории ($n_k = 1$) признак просто **равен** ответу. Поэтому применяют:

- **кросс-фиттинг** (out-of-fold): данные делят на K фолдов, объекты фолда f кодируют средними, посчитанными по остальным фолдам (так работает `sklearn.preprocessing.TargetEncoder`);
- на тесте используют кодировщик, обученный **только на train**.

1.5. Weight of Evidence (для бинарной цели)

$$\mathrm{WoE}(c_k) = \ln \frac{P(x = c_k \mid y = 1)}{P(x = c_k \mid y = 0)}, \qquad \mathrm{IV} = \sum_k \big(P(c_k \mid 1) - P(c_k \mid 0)\big)\,\mathrm{WoE}(c_k).$$

WoE — логарифм отношения правдоподобия. В логистической регрессии он линейно входит в логит. IV (information value) оценивает силу признака: < 0,02 — бесполезен, > 0,3 — сильный.

1.6. Сводка

Способ	Столбцов	Когда	Недостатки
Ordinal	1	порядковые признаки	ложный порядок для номинальных
One-Hot	$K - 1$	номинальные, K мал	размерность, разреженность, ловушка без drop
Frequency	1	большое K, важна популярность	коллизии, не связан с целью напрямую
Target	1	большое K, сильная связь с целью	утечка, переобучение на редких категориях
WoE	1	бинарная цель, кредитный скоринг	только для классификации

2. Признаки из дат и других типов

- **Компоненты даты:** год, месяц, день недели, признак выходного.
- **Интервалы:** возраст = год продажи − год постройки; дни с события.
- **Циклические признаки** (месяц, час) отображают на окружность, чтобы декабрь и январь оказались рядом:

$$x_{\sin} = \sin \frac{2\pi t}{T}, \qquad x_{\cos} = \cos \frac{2\pi t}{T}, \qquad T = 12 \text{ для месяцев.}$$

- **Отношения и произведения:** площадь на комнату, цена за единицу. Они кодируют знание предметной области, которое линейная модель сама не найдёт: линейная модель не умеет делить один признак на другой.

3. Линеаризация зависимостей

Линейная модель описывает y как $\langle w, x \rangle$. Если истинная зависимость нелинейна, преобразуем признак или цель так, чтобы она стала линейной.

Наблюдаемая форма	Модель	Линеаризация	Смысл коэффициента
y растёт всё медленнее	$y = a + b\ln x$	$z = \ln x$	+1 % к x → $+b/100$ к y
экспоненциальный спад	$y = Ce^{-ax}$	$\ln y = \ln C - ax$	+1 к x → y меняется на $\approx -100a\,\%$
степенной закон	$y = Cx^{\beta}$	$\ln y = \ln C + \beta \ln x$	**эластичность**: +1 % к x → $+\beta\,\%$ к y
гипербола	$y = a + b/x$	$z = 1/x$	—
парабола	$y = a + bx^2$	$z = x^2$	—

Эластичность в степенной модели: $\dfrac{d\ln y}{d\ln x} = \beta$.

3.1. Преобразование Бокса–Кокса (для $x > 0$)

$$x^{(\lambda)} = \begin{cases} \dfrac{x^{\lambda} - 1}{\lambda}, & \lambda \neq 0, \\ \ln x, & \lambda = 0. \end{cases}$$

Семейство непрерывно по λ: $\frac{x^{\lambda}-1}{\lambda} \to \ln x$ при $\lambda \to 0$. Частные случаи: $\lambda = 1$ — сдвиг, $\lambda = 0{,}5$ — корень, $\lambda = 0$ — логарифм, $\lambda = -1$ — обратная величина. λ подбирают максимизацией правдоподобия нормальности. **Йео–Джонсон** обобщает преобразование на $x \le 0$.

3.2. Почему логарифм цели полезен

Для логнормальной цели ошибки в исходной шкале растут с ценой (гетероскедастичность). В шкале $\ln y$ ошибка относительна: $\ln\hat{y} - \ln y \approx \frac{\hat{y}-y}{y}$. При обратном переходе $\hat{y} = e^{\widehat{\ln y}}$ получаем оценку **медианы**, а не среднего: $\mathbb{E}y = e^{\mu+\sigma^2/2}$.

4. Корреляции

4.1. Пирсон

$$\rho_P(X,Y) = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}} = \cos\angle(\tilde{x}, \tilde{y})$$

Измеряет **линейную** связь, $|\rho_P| \le 1$ по неравенству Коши–Буняковского (подробно — теория ЛР2).

4.2. Спирмен

$$\rho_S(X,Y) = \rho_P(R_X, R_Y),$$

где R_X — ранги. Без совпадающих значений:

$$\rho_S = 1 - \frac{6\sum_i d_i^2}{n(n^2-1)}, \qquad d_i = R_{X,i} - R_{Y,i}.$$

Вывод формулы. Ранги — перестановка чисел $1, \dots, n$, поэтому $\bar{R} = \frac{n+1}{2}$ и $\sum (R_i - \bar{R})^2 = \frac{n(n^2-1)}{12}$ одинаковы для X и Y. Из $\sum d_i^2 = \sum (R_{X,i} - \bar{R})^2 + \sum (R_{Y,i} - \bar{R})^2 - 2\sum (R_{X,i} - \bar{R})(R_{Y,i} - \bar{R})$ получаем

$$\rho_S = \frac{\sum (R_X - \bar{R})(R_Y - \bar{R})}{n(n^2-1)/12} = 1 - \frac{6\sum d_i^2}{n(n^2-1)}.$$

Свойства:

- $\rho_S = \pm 1$ для **любой** строго монотонной зависимости. Например, $y = x^3$: $\rho_S = 1$, а $\rho_P < 1$.

- Инвариантен к монотонным преобразованиям: $\rho_S(\ln X, Y) = \rho_S(X, Y)$.
- Устойчив к выбросам: выброс меняет ранг максимум до n.

4.3. Когда Пирсон и Спирмен расходятся

Ситуация	Пирсон	Спирмен
монотонная нелинейная связь	ниже	высокий
немонотонная связь (U-образная)	≈ 0	≈ 0
несколько выбросов создают связь	высокий	низкий
выбросы маскируют связь	низкий	высокий

4.4. Мультиколлинеарность

Корреляционная матрица C симметрична и неотрицательно определена: $C = \frac{1}{n-1} Z^T Z$, где Z — стандартизованные признаки, и $v^T C v = \frac{1}{n-1}\|Zv\|^2 \geq 0$. Почти линейная зависимость признаков даёт малое собственное число C. Мера для признака j — **VIF**:

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2},$$

где R_j^2 — коэффициент детерминации регрессии x_j на остальные признаки. $\mathrm{VIF} > 10$ — сильная коллинеарность.

5. Масштабирование

Метод	Формула	Диапазон	Устойчивость к выбросам
Стандартизация (z-score)	$\frac{x - \bar{x}}{s}$	неограничен, $\mu = 0$, $\sigma = 1$	средняя
Min-Max	$\frac{x - x_{\min}}{x_{\max} - x_{\min}}$	$[0, 1]$	низкая
Mean normalization	$\frac{x - \bar{x}}{x_{\max} - x_{\min}}$	$\approx [-1, 1]$, $\mu = 0$	низкая
Robust	$\frac{x - \mathrm{med}}{Q_3 - Q_1}$	неограничен	высокая
MaxAbs	$\frac{x}{\max\|x\|}$	$[-1, 1]$, сохраняет нули	низкая

Все эти методы — **аффинные** преобразования $x \mapsto (x - a)/b$. Поэтому они не меняют форму распределения, порядок значений, корреляции Пирсона и Спирмена. Форму меняют только нелинейные преобразования ($\ln$, Бокс–Кокс, квантильное).

5.1. Зачем масштабировать перед линейной моделью

1. **Градиентный спуск.** Для MSE гессиан $H = \frac{2}{\ell} X^T X$. При признаках разного масштаба его собственные числа отличаются на порядки, $\kappa(H) = \lambda_{\max}/\lambda_{\min} \gg 1$, рельеф — «овраг». Допустимый шаг $\eta < 2/\lambda_{\max}$ мал, и вдоль направления $\lambda_{\min}$ спуск ползёт медленно. Пример с двумя некоррелированными центрированными признаками со стандартными отклонениями $s_1 = 1000$ и $s_2 = 1$: $H \propto \mathrm{diag}(s_1^2, s_2^2)$, $\kappa = 10^6$. После стандартизации $H \propto C$ (корреляционная матрица), и κ определяется только корреляциями.

2. **Регуляризация.** Штраф $\lambda\|w\|^2$ сравнивает веса напрямую. Вес признака в километрах и в метрах отличается в 1000 раз при одинаковом вкладе — без масштабирования штраф несправедлив.
3. **Метрические методы** (KNN, кластеризация): расстояние определяется признаком с наибольшим масштабом.
4. **Интерпретация:** веса стандартизованных признаков сравнимы между собой.

Параметры масштабирования ($\bar{x}$, s, min, max) вычисляются **только на обучающей выборке** и затем применяются к тесту. Иначе статистики теста «утекают» в обучение.

6. Вопросы для самопроверки (РК1 № 3–4)

1. Семантические типы признаков. Принцип One-Hot, Frequency и Target Encoding; недостатки каждого.
2. Докажите, что one-hot без удаления столбца при наличии свободного члена даёт вырожденную X^TX.
3. Запишите формулу сглаженного target encoding. Что будет при $m = 0$ и $n_k = 1$?
4. Чем коэффициент Спирмена отличается от Пирсона? Выведите формулу через d_i.
5. Приведите пример, где $\rho_S = 1$, а $\rho_P < 1$, и пример, где оба близки к нулю, но зависимость есть.
6. Почему признаки масштабируют перед линейной моделью? Пять видов масштабирования.
7. Почему масштабирование не меняет корреляции, а логарифм — меняет Пирсона, но не Спирмена?
8. Как интерпретировать коэффициент в модели $\ln y = a + \beta \ln x$?