Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Методические указания к лабораторной работе №5 по дисциплине ОАД

Разработали:
Старший преподаватель
Маслеников К.Ю.
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

1 ЗАДАНИЕ 3
2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ 4
2.1 Подготовка набора данных 4
2.2 Архитектура программной реализации 4
2.3 Реализация линейной регрессионной модели 4
2.4 Выбор и анализ функционалов ошибки 5
2.5 Реализация методов оптимизации 5
2.6 Обучение модели на немасштабированных данных 6
2.6.1 Критерий сходимости 6
2.6.2 Подбор гиперпараметров 6
2.6.3 Оценка обусловленности задачи 7
2.6.4 Исследование динамики оптимизации 7
2.6.5 Оценка качества модели 8
2.7 Сравнение с моделями библиотеки scikit-learn 9
2.8 Сравнение результатов до и после масштабирования 9

1 ЗАДАНИЕ

Необходимо выбрать набор данных для задачи регрессии, содержащий не менее 10 000 объектов, и провести его предварительную обработку.

По результатам обработки сформировать две версии набора данных:

– без масштабирования признаков;

– с применением выбранного способа масштабирования.

Для обеих версий набора данных реализовать линейную регрессионную модель и исследовать процесс её обучения с использованием различных функционалов ошибки и градиентных методов оптимизации.

Лекционные и дополнительные материалы, соответствующие данной лабораторной работе, размещены на диске[1].

Результаты работы оформить в виде ноутбука. Приведённая ниже структура включает основные этапы, которые должны быть представлены в работе.

[1] https://disk.yandex.ru/d/aDGM6KOJvUiPUQ

2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ

2.1 Подготовка набора данных

Для выбранного набора данных провести предварительную обработку и сформировать две версии признакового пространства:

– без масштабирования признаков;

– с применением выбранного способа масштабирования.

Последующие вычислительные эксперименты выполнить отдельно для каждой из двух версий набора данных.

2.2 Архитектура программной реализации

Рекомендуется разделить программную реализацию на независимые компоненты.

Для организации общего интерфейса функционалов ошибки и методов оптимизации может быть полезно использовать абстрактные базовые классы.

Архитектура должна позволять независимо изменять функционал ошибки и метод оптимизации без существенного изменения реализации линейной модели.

2.3 Реализация линейной регрессионной модели

Самостоятельно реализовать класс линейной регрессионной модели, содержащий основные методы обучения и получения прогнозов.

Свободный коэффициент может быть реализован как отдельный параметр модели либо учтён посредством добавления к признаковому описанию единичного признака.

При проектировании интерфейса рекомендуется ориентироваться на класс LinearRegression библиотеки scikit-learn[2].

[2] https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

2.4 Выбор и анализ функционалов ошибки

Выбрать не менее трёх функционалов ошибки для задачи линейной регрессии.

Одним из выбранных функционалов обязательно должен быть MSE, а среди остальных — как минимум один функционал с ненулевой второй производной хотя бы на некоторой области определения.

Для каждого выбранного функционала:

– записать эмпирический функционал ошибки для линейной модели;

– получить градиент функционала по параметрам линейной модели;

– получить матрицу вторых производных — гессиан;

– указать точки, в которых соответствующие производные не существуют, если такие точки имеются.

Все математические выкладки выполнить в матрично-векторной форме.

Вывод градиента и гессиана для каждого функционала представить в отдельных текстовых ячейках ноутбука с использованием TEX.

2.5 Реализация методов оптимизации

Самостоятельно реализовать как минимум три из следующих методов градиентной оптимизации:

– GD;

– mini-batch SGD;

– Momentum;

– AdaGrad;

– RMSProp;

– Adam.

Каждый оптимизатор должен использовать общий интерфейс функционала ошибки и не зависеть от конкретного вида оптимизируемого функционала.

В ходе оптимизации необходимо сохранять информацию, необходимую для последующего анализа динамики процесса обучения.

2.6 Обучение модели на немасштабированных данных

Первый вычислительный эксперимент необходимо провести на версии набора данных без масштабирования признаков.

2.6.1 Критерий сходимости

В качестве критерия сходимости использовать норму **полного градиента** эмпирического функционала ошибки:

$$\left\|\nabla Q\left(w^{(k)}\right)\right\|_2 < \varepsilon,$$

где k — номер шага оптимизации, а $\varepsilon > 0$ — заранее выбранная точность, например $\varepsilon = 10^{-6}$.

Для всех вычислительных экспериментов использовать одно и то же значение ε.

2.6.2 Подбор гиперпараметров

Шаг обучения подбирать по валидационной выборке с использованием выбранной стратегии валидации, например поиска по логарифмической сетке:

$$\eta \in \left\{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\right\}.$$

Для методов, использующих затухающий шаг вида

$$\eta_k = \frac{C}{k + k_0},$$

значение k_0 зафиксировать, например $k_0 = 100$, а параметр C подобрать по валидационной выборке. Для C также рекомендуется использовать логарифмическую сетку, например

$$C \in \left\{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 10^2\right\}.$$

Приведённые диапазоны являются ориентировочными и при необходимости могут быть изменены с учётом особенностей выбранного набора данных и метода оптимизации.

Если используемый метод имеет дополнительные гиперпараметры, их также подобрать с использованием выбранной стратегии валидации.

2.6.3 Оценка обусловленности задачи

Для каждого выбранного функционала исследовать локальную геометрию оптимизационной задачи.

Пусть $H(w) = \nabla^2 Q(w)$ — матрица Гессе (гессиан) функционала ошибки в точке w. В точках, в которых гессиан существует и является неотрицательно определённым, обусловленность задачи определить как

$$\kappa(H) = \frac{\lambda_{\max}(H)}{\lambda_{\min}(H)},$$

где $\lambda_{\max}(H)$ и $\lambda_{\min}(H)$ — максимальное и минимальное собственные значения матрицы Гессе соответственно.

Если минимальное собственное значение равно нулю, считать матрицу Гессе вырожденной и положить $\kappa(H) = \infty$.

2.6.4 Исследование динамики оптимизации

Для каждого выбранного функционала и каждого реализованного метода оптимизации исследовать динамику процесса обучения.

Построить график зависимости нормы полного градиента от номера шага оптимизации:

$$k \longmapsto \left\| \nabla Q\left(w^{(k)}\right) \right\|_2 .$$

На графике необходимо дополнительно отобразить горизонтальную линию $y = \varepsilon$, соответствующую выбранному критерию сходимости.

Построить график зависимости обусловленности от номера шага оптимизации:

$$k \longmapsto \kappa\left(H\left(w^{(k)}\right)\right).$$

Если на отдельных шагах гессиан не существует или является вырожденным, соответствующие случаи необходимо отдельно отметить и учитывать при интерпретации результатов.

Построить график зависимости значения функционала ошибки от номера шага оптимизации:

$$k \longmapsto Q\left(w^{(k)}\right).$$

На основании полученных графиков проанализировать:

– скорость сходимости различных методов;

– наличие колебаний или нестабильного поведения;

– влияние выбранного функционала ошибки на процесс оптимизации;

– изменение локальной обусловленности задачи в процессе обучения;

– связь между обусловленностью функционала и характером сходимости метода.

2.6.5 Оценка качества модели

После завершения подбора гиперпараметров обучить итоговые модели и оценить их качество на тестовой выборке.

Для сравнения всех полученных моделей использовать единую метрику качества на тестовой выборке, например RMSE.

Сравнить качество моделей, полученных при использовании различных функционалов и различных методов оптимизации.

Сформулировать выводы о качестве полученных моделей на тестовой выборке.

2.7 Сравнение с моделями библиотеки scikit-learn

Для каждого выбранного функционала определить, существует ли в библиотеке scikit-learn линейная модель с соответствующим или эквивалентным функционалом ошибки.

Если такая реализация существует, необходимо:

– обучить соответствующую библиотечную модель на той же обучающей выборке без использования регуляризации, если она не является обязательной частью рассматриваемой реализации;

– подобрать по валидационной выборке шаг обучения и другие гиперпараметры библиотечной модели, если они предусмотрены используемым методом;

– оценить качество модели на тестовой выборке с использованием той же метрики, которая применялась для собственных реализаций.

Сформулировать выводы по результатам сравнения собственных и библиотечных моделей.

2.8 Сравнение результатов до и после масштабирования

Повторить вычислительный эксперимент для масштабированной версии набора данных.

Сопоставить полученные результаты и сформулировать выводы о влиянии масштабирования признаков на процесс оптимизации.