ЛР5. Теория: функционалы ошибки, матричное дифференцирование, градиентные методы, обусловленность

Лекции «Линейная регрессия», «Измерение ошибки», семинары «Матрично-векторное дифференцирование» и «Безусловная оптимизация». Закрывает вопросы РК1 № 5–13 и доказательства № 1–4, 6.

1. Постановка

Пары $(X, Y) \sim P^*_{X,Y}$, выборка $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{\ell}$ — независимые реализации. Модель $\alpha(x) = \langle w, x\rangle$ (свободный член — через единичный признак). Функция потерь $L(y, \alpha(x))$.

- **Теоретический функционал:** $M_L(\alpha) = \mathbb{E}_X\, \mathbb{E}_{Y|X} L(Y, \alpha(X))$.
- **Эмпирический:** $Q_L(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_i L(y_i, \alpha(x_i))$.

Для фиксированной модели $Q_L \xrightarrow{P} M_L$ по закону больших чисел (Чебышёв): слагаемые $Z_i = L(Y_i, \alpha(X_i))$ независимы, одинаково распределены и имеют конечную дисперсию. Обучение — $\hat{w} = \arg\min_w Q_L(w)$.

2. Матрично-векторное дифференцирование

Дифференциал $df = \langle \nabla f, dw\rangle = (\nabla f)^T dw$. Градиент читается из дифференциала, гессиан — из дифференциала градиента: $d(\nabla f) = H\, dw$.

Правило	Формула
линейная функция	$d(a^T w) = a^T dw$
линейное отображение	$d(Xw - y) = X\, dw$
квадратичная форма	$d(w^T A w) = w^T (A + A^T)\, dw$
норма	$d\lvert r\rvert_2^2 = 2 r^T dr$
поэлементная функция	$d\,\varphi(r) = \varphi'(r) \odot dr = \operatorname{diag}(\varphi'(r))\, dr$

2.1. Общая теорема для поэлементных потерь

Пусть $Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} \varphi(r_i)$, $r = Xw - y$, φ дважды дифференцируема. Тогда

$$dQ = \frac{1}{\ell} \sum_i \varphi'(r_i)\, dr_i = \frac{1}{\ell} \varphi'(r)^T X\, dw \;\Rightarrow\; \boxed{\nabla Q = \frac{1}{\ell} X^T \varphi'(r)},$$

$$d(\nabla Q) = \frac{1}{\ell} X^T \operatorname{diag}(\varphi''(r))\, dr = \frac{1}{\ell} X^T \operatorname{diag}(\varphi''(r)) X\, dw \;\Rightarrow\; \boxed{H = \frac{1}{\ell} X^T D X,\;\; D = \operatorname{diag}(\varphi''(r_i))}.$$

Следствие о выпуклости. Если $\varphi'' \geq 0$, то $v^T H v = \frac{1}{\ell} \sum_i \varphi''(r_i)(x_i^T v)^2 \geq 0$ — функционал выпуклый, а любой его локальный минимум глобален. Если $\varphi'' > 0$ всюду и $\operatorname{rank} X = d$, то $H \succ 0$, и минимум единственен.

3. Функционалы ошибки

Функционал	$\varphi(r)$	$\varphi'(r)$	$\varphi''(r)$	Недифференцируем
MSE	r^2	$2r$	2	—
MAE	$\lvert r\rvert$	$\operatorname{sign} r$	0 ($r \neq 0$)	$r_i = 0$
Huber	$\frac{1}{2}r^2$ при $\lvert r\rvert \le \delta$; $\delta(\lvert r\rvert - \frac{\delta}{2})$ иначе	$\operatorname{clip}(r, -\delta, \delta)$	$[\,\lvert r\rvert < \delta\,]$	2-я производная: $\lvert r_i\rvert = \delta$
Log-cosh	$\ln\cosh r$	$\tanh r$	$1 - \tanh^2 r = \operatorname{sech}^2 r$	—
Квантильная	$\tau \max(-r, 0) + (1 - \tau)\max(r, 0)$	$-\tau$ при $r < 0$; $1 - \tau$ при $r > 0$	0	$r_i = 0$

Подставляя в теорему §2.1:

$$\text{MSE:}\quad \nabla Q = \frac{2}{\ell} X^T(Xw - y), \qquad H = \frac{2}{\ell} X^T X;$$

$$\text{MAE:}\quad \nabla Q = \frac{1}{\ell} X^T \operatorname{sign}(Xw - y), \qquad H = 0 \text{ почти всюду};$$

$$\text{Huber:}\quad \nabla Q = \frac{1}{\ell} X^T \operatorname{clip}(r, -\delta, \delta), \qquad H = \frac{1}{\ell} X^T \operatorname{diag}\big([\lvert r_i\rvert < \delta]\big) X;$$

$$\text{Log-cosh:}\quad \nabla Q = \frac{1}{\ell} X^T \tanh(r), \qquad H = \frac{1}{\ell} X^T \operatorname{diag}\left(\operatorname{sech}^2 r_i\right) X.$$

Где производные не существуют. MAE: градиент не существует на объединении гиперплоскостей $\{w : x_i^T w = y_i\}$; там субдифференциал $\partial Q = \frac{1}{\ell}\sum_i x_i\, s_i$, где $s_i \in [-1, 1]$ для нулевых остатков. Huber: градиент существует всюду (стыковка гладкая: $\varphi'(\pm\delta) = \pm\delta$ с обеих сторон), гессиан — нет при $\lvert r_i\rvert = \delta$.

Что «видит» гессиан. У MSE он постоянен, и κ не меняется по ходу обучения. У Huber в H входят только объекты с $\lvert r_i\rvert < \delta$ — если таких мало, H вырождается ($\kappa = \infty$). У Log-cosh веса $\operatorname{sech}^2 r_i \to 0$ для больших остатков: в начале обучения (остатки большие) кривизна мала, к концу растёт.

3.1. Оптимальные ответы (доказательства № 1–3 РК)

Для фиксированного x минимизируем $m(a) = \mathbb{E}_{Y \mid X = x} L(Y, a)$, $p(y \mid x)$ — условная плотность, F_x — условная функция распределения.

Квадратичная потеря. $m(a) = \int (y - a)^2 p(y \mid x)\, dy$, $m'(a) = 2\int (a - y) p\, dy = 2(a - \mathbb{E}[Y \mid x]) = 0 \Rightarrow a^* = \mathbb{E}[Y \mid X = x]$.

Абсолютная потеря. $m(a) = \int_{y<a} (a - y) p\, dy + \int_{y>a} (y - a) p\, dy$, $m'(a) = F_x(a) - (1 - F_x(a)) = 2F_x(a) - 1 = 0 \Rightarrow a^* = \operatorname{med}(Y \mid X = x)$.

Квантильная потеря L_τ: $m'(a) = (1 - \tau)F_x(a) - \tau(1 - F_x(a)) = F_x(a) - \tau = 0 \Rightarrow a^* = q_\tau(Y \mid X = x)$.

Отсюда устойчивость: медиана почти не реагирует на выбросы, а среднее — реагирует. MAE и Huber устойчивее MSE.

3.2. Аналитическое решение для MSE (доказательство № 4)

$\nabla Q = \frac{2}{\ell} X^T(Xw - y) = 0 \Rightarrow X^T X w = X^T y \Rightarrow w^* = (X^T X)^{-1} X^T y$ при обратимой $X^T X$, то есть при $\operatorname{rank} X = d$. Это минимум, потому что $H = \frac{2}{\ell} X^T X \succeq 0$. Стоимость $O(\ell d^2 + d^3)$.

4. Градиентный спуск

4.1. Итерация (доказательство № 6)

Из дифференцируемости $f(w+h) = f(w) + \langle \nabla f(w), h\rangle + o(\|h\|)$. Убывание быстрее всего при $h \parallel -\nabla f$. При $h = -\eta \nabla f(w)$: $f(w+h) - f(w) \approx -\eta \|\nabla f\|^2 < 0$. Итерация:

$$w^{(k+1)} = w^{(k)} - \eta_k \nabla Q(w^{(k)}).$$

Для MSE: $w^{(k+1)} = w^{(k)} - \eta \frac{2}{\ell} X^T (X w^{(k)} - y)$.

4.2. Липшицев градиент и выбор шага

Если $\|\nabla f(x) - \nabla f(y)\| \le L\|x - y\|$, то (лемма о спуске)

$$f(y) \le f(x) + \langle \nabla f(x), y - x\rangle + \frac{L}{2}\|y - x\|^2 \;\Rightarrow\; f(w_{k+1}) \le f(w_k) - \eta\Big(1 - \frac{L\eta}{2}\Big)\|\nabla f(w_k)\|^2.$$

При $0 < \eta < 2/L$ значения не возрастают и (для выпуклой f) сходятся к минимуму. Для дважды дифференцируемой функции $L = \sup_w \lambda_{\max}(H(w))$. Для MSE $L = \frac{2}{\ell}\lambda_{\max}(X^T X) = \frac{2}{\ell}\sigma^2_{\max}(X)$.

4.3. Скорость и обусловленность (квадратичный случай)

Для $Q(w) = \frac{1}{2}(w - w^*)^T H (w - w^*) + \text{const}$ ошибка $e_k = w_k - w^*$ подчиняется

$$e_{k+1} = (I - \eta H) e_k \;\Rightarrow\; e_k = (I - \eta H)^k e_0.$$

В собственном базисе H каждая координата умножается на $(1 - \eta\lambda_i)$. Сходимость $\iff |1 - \eta\lambda_i| < 1$ для всех i $\iff \eta < 2/\lambda_{\max}$. Лучший постоянный шаг $\eta^* = \frac{2}{\lambda_{\max} + \lambda_{\min}}$ даёт

$$\|e_k\| \le \Big(\frac{\kappa - 1}{\kappa + 1}\Big)^k \|e_0\|, \qquad \kappa = \kappa(H) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Число итераций до точности ε: $k \approx \frac{\kappa}{2}\ln\frac{1}{\varepsilon}$. При $\kappa = 10^8$ — сотни миллионов шагов. Геометрически: линии уровня — эллипсы с отношением осей $\sqrt{\kappa}$ («овраг»), и GD зигзагом идёт поперёк оврага.

4.4. Критерии остановки и их недостатки

Критерий	Недостаток
$\|\nabla Q(w_k)\| < \varepsilon$	зависит от масштаба Q; для MAE (субградиент) может не выполниться никогда
$\|w_{k+1} - w_k\| < \varepsilon$	маленький шаг даёт ложную остановку; при «овраге» веса меняются медленно вдали от минимума
$\|Q_{k+1} - Q_k\| < \varepsilon$	на плато останавливается рано
максимум итераций	не гарантирует точность

5. Стохастические методы

5.1. SGD и mini-batch

$Q(w) = \frac{1}{\ell}\sum_i q_i(w)$. На шаге выбираем случайный объект i_k: $g_k = \nabla q_{i_k}(w_k)$, $w_{k+1} = w_k - \eta_k g_k$.

- **Несмещённость:** $\mathbb{E}[g_k \mid w_k] = \frac{1}{\ell}\sum_i \nabla q_i(w_k) = \nabla Q(w_k)$.
- **Mini-batch** из B объектов без возвращения: $g_{\mathcal{B}} = \frac{1}{B}\sum_{i\in\mathcal{B}} \nabla q_i$, дисперсия

$$D(g_{\mathcal{B}} \mid w) = \frac{\ell - B}{B(\ell-1)}\, D(g \mid w) \approx \frac{1}{B} D(g \mid w).$$

Плюсы: шаг дешевле в ℓ/B раз, шум помогает выйти из плоских областей. Минусы: из-за дисперсии при постоянном шаге метод колеблется около минимума и не сходится точно.

5.2. Затухающий шаг

Условия Роббинса–Монро:

$$\sum_k \eta_k = \infty, \qquad \sum_k \eta_k^2 < \infty.$$

Первое — чтобы дойти до минимума из любой точки, второе — чтобы погасить шум. Им удовлетворяет $\eta_k = \frac{C}{k + k_0}$: гармонический ряд расходится, а $\sum 1/k^2$ сходится. k_0 не даёт первым шагам быть огромными.

5.3. Momentum (метод тяжёлого шарика)

$$v_k = \beta v_{k-1} + \nabla Q(w_k), \qquad w_{k+1} = w_k - \eta v_k, \quad \beta \in [0, 1).$$

$v_k = \sum_{j \le k} \beta^{k-j} g_j$ — экспоненциально взвешенная сумма градиентов. Вдоль «дна оврага» градиенты сонаправлены и складываются (эффективный шаг $\approx \frac{\eta}{1-\beta}$), поперёк — меняют знак и гасятся. На квадратичной функции при оптимальных η, β скорость $\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ вместо $\frac{\kappa-1}{\kappa+1}$.

5.4. AdaGrad и RMSProp

Покоординатно (g — компонента градиента):

$$\text{AdaGrad:} \quad G_k = G_{k-1} + g_k^2, \qquad w_{k+1} = w_k - \frac{\eta}{\sqrt{G_k} + \epsilon}\, g_k;$$

$$\text{RMSProp:} \quad v_k = \beta v_{k-1} + (1-\beta) g_k^2, \qquad w_{k+1} = w_k - \frac{\eta}{\sqrt{v_k} + \epsilon}\, g_k.$$

Обе нормируют шаг по каждой координате на «типичный масштаб» её градиента — это диагональное предобуславливание, лечащее разный масштаб признаков. Отличие: в AdaGrad G_k только растёт, и шаг монотонно затухает (хорошо для разреженных признаков, плохо для долгого обучения). В RMSProp — экспоненциальное среднее, шаг не умирает.

5.5. Adam

$$m_k = \beta_1 m_{k-1} + (1-\beta_1) g_k, \qquad v_k = \beta_2 v_{k-1} + (1-\beta_2) g_k^2,$$

$$\hat m_k = \frac{m_k}{1-\beta_1^k}, \qquad \hat v_k = \frac{v_k}{1-\beta_2^k}, \qquad w_{k+1} = w_k - \eta \frac{\hat m_k}{\sqrt{\hat v_k} + \epsilon}.$$

Коррекция смещения. При $m_0 = 0$: $m_k = (1-\beta_1)\sum_{j=1}^{k} \beta_1^{k-j} g_j$. Если $\mathbb{E} g_j = \mathbb{E} g$, то

$$\mathbb{E} m_k = (1-\beta_1)\frac{1-\beta_1^k}{1-\beta_1}\mathbb{E} g = (1-\beta_1^k)\,\mathbb{E} g,$$

поэтому деление на $1-\beta_1^k$ убирает смещение к нулю на первых шагах. Adam = Momentum (направление) + RMSProp (масштаб). Типичные значения: $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$.

6. Обусловленность и масштабирование

Определение. Для симметричной $H \succ 0$: $\kappa(H) = \frac{\lambda_{\max}}{\lambda_{\min}}$; в общем случае $\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$. Если $\lambda_{\min} = 0$, то $\kappa = \infty$.

Связь с признаками. Для MSE $\kappa(H) = \kappa(X^T X) = \kappa(X)^2$: собственные числа $X^T X$ — квадраты сингулярных чисел X. Почти линейная зависимость столбцов ($Xv \approx 0$, $\|v\| = 1$) даёт $\sigma_{\min} \approx 0$ и $\kappa \gg 1$.

Почему масштаб портит κ. Пример: два центрированных некоррелированных признака со стандартными отклонениями s_1, s_2. Тогда $\frac{1}{\ell} X^T X = \operatorname{diag}(s_1^2, s_2^2)$, $\kappa = (s_1/s_2)^2$. При $s_1 = 1000$, $s_2 = 1$ получаем $\kappa = 10^6$. Без центрирования хуже: признак с большим средним (`YearBuilt` ≈ 1965) почти коллинеарен столбцу единиц свободного члена:

$$x \approx 1965 \cdot \mathbf{1} + \text{малые отклонения} \;\Rightarrow\; \sigma_{\min}(X) \text{ мало}.$$

Стандартизация $x \mapsto (x - \bar{x})/s$ делает $\frac{1}{\ell} X^T X$ корреляционной матрицей (с единицами на диагонали) и ортогонализует признаки относительно свободного члена. Остаётся только «настоящая» обусловленность — из корреляций признаков. Прогнозы MSE-модели от этого не меняются: это перепараметризация $w \mapsto (w_j s_j)$, но рельеф для GD становится «круглым».

7. Метрика качества

$$\mathrm{RMSE} = \sqrt{\frac{1}{m} \sum_{j=1}^{m} (\hat{y}_j - y_j)^2}.$$

RMSE в единицах цели; минимизация RMSE эквивалентна минимизации MSE (корень монотонен), но оптимизируют MSE — проще производная. Для цели $\ln y$: $\mathrm{RMSE} = 0{,}2$ означает типичную относительную ошибку $\approx 20\,\%$.

8. Вопросы для самопроверки

1. Сформулируйте вероятностную постановку обучения с учителем; теоретический и эмпирический функционалы и их связь.
2. Выведите градиент и гессиан MSE, MAE, Huber, Log-cosh в матричной форме. Где производные не существуют?
3. Докажите, что оптимальный ответ для квадратичной потери — условное среднее, для абсолютной — условная медиана, для квантильной — условный квантиль.
4. Выведите $w^* = (X^T X)^{-1} X^T y$.
5. Выведите итерацию GD. Почему шаг должен быть меньше $2/L$?
6. Как число обусловленности влияет на скорость GD? Выведите множитель $\frac{\kappa - 1}{\kappa + 1}$.
7. Основной недостаток полного GD; SGD и mini-batch, их плюсы и минусы; формула дисперсии mini-batch.
8. Критерии остановки и их недостатки. Правило обновления Momentum.
9. AdaGrad против RMSProp. Правило Adam и смысл коррекции смещения.
10. Почему без масштабирования $\kappa(H)$ огромна и как стандартизация это исправляет?