Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Методические указания к лабораторной работе №6 по дисциплине ОАД

Разработали:
Старший преподаватель
Маслеников К.Ю.
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

1 ЗАДАНИЕ 3
2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ 4
2.1 Математическое описание регуляризации 4
2.2 Расширение программной реализации 4
2.3 Инженерия признаков и L_1-регуляризация 5
2.3.1 Формирование расширенного признакового пространства 5
2.3.2 Реализация линейной модели с L_1-регуляризацией 6
2.3.3 Сравнение с Lasso библиотеки scikit-learn 6
2.3.4 Анализ отбора признаков 7
2.4 L_2-регуляризация и анализ оптимизации 8
2.4.1 Аналитическое решение линейной регрессии 8
2.4.2 Аналитическая линейная регрессия с L_2-регуляризацией 8
2.4.3 Сравнение с Ridge-регрессией библиотеки scikit-learn 9
2.4.4 Исследование влияния L_2-регуляризации на оптимизацию 9

1 ЗАДАНИЕ

Лабораторная работа является продолжением ЛР5.

Необходимо использовать набор данных, подготовленный в ЛР5, либо выбрать новый набор данных для задачи регрессии, содержащий не менее 10 000 объектов.

В работе необходимо реализовать и исследовать аналитические решения линейной регрессии, L_1- и L_2-регуляризацию, влияние L_2-регуляризации на процесс градиентной оптимизации, а также применение L_1-регуляризации для отбора признаков.

Лекционные и дополнительные материалы, соответствующие данной лабораторной работе, размещены на диске[1].

Результаты работы оформить в виде ноутбука. Приведённая ниже структура включает основные этапы, которые должны быть представлены в работе.

[1] https://disk.yandex.ru/d/LE1G4vmbrc4bBQ

2 СТРУКТУРА ЛАБОРАТОРНОЙ РАБОТЫ

2.1 Математическое описание регуляризации

Рассмотреть два вида регуляризации:

$$R_{L_1}(w) = \lambda \|w\|_1, \quad R_{L_2}(w) = \frac{\lambda}{2}\|w\|_2^2.$$

Для каждого регуляризатора необходимо:

– получить первую производную;

– получить вторую производную;

– указать точки, в которых соответствующие производные не существуют;

– представить математические выкладки в матрично-векторном виде в отдельных текстовых ячейках ноутбука с использованием TEX.

Для функционалов ошибки вида $Q(w)$ рассмотреть регуляризованный функционал

$$F(w) = Q(w) + R(w).$$

2.2 Расширение программной реализации

Расширить программную архитектуру, реализованную в предыдущей лабораторной работе, поддержкой L_1- и L_2-регуляризации.

Реализация должна позволять использовать выбранный функционал ошибки совместно с различными видами регуляризации.

2.3 Инженерия признаков и L_1-регуляризация

2.3.1 Формирование расширенного признакового пространства

Для выбранного набора данных провести предметно обусловленное конструирование признаков.

На основе смысла исходных признаков и особенностей предметной области сформировать не менее трёх новых признаков. Для каждого созданного признака необходимо привести его интерпретацию и обосновать целесообразность добавления в признаковое пространство.

После формирования новых признаков провести необходимую предварительную обработку набора данных и выполнить корреляционный анализ (Пирсон) полученного признакового пространства.

На основании результатов анализа исследовать возможность линеаризации зависимостей между признаками и целевой переменной.

Для как минимум трёх признаков, для которых наблюдаются выраженные нелинейные зависимости и для которых возможно подобрать подходящее преобразование, предложить преобразования, позволяющие получить более выраженное линейное представление зависимости.

После добавления линеаризованных признаков повторно провести корреляционный анализ (Пирсон) полученного признакового пространства.

При предметно обусловленном конструировании признаков и при линеаризации исходные признаки из набора данных не удалять. Иными словами, итоговое признаковое пространство должно содержать как исходные, так и все созданные признаки.

По завершении формирования расширенного признакового пространства привести набор данных к виду, пригодному для последующего обучения линейной модели.

2.3.2 Реализация линейной модели с L_1-регуляризацией

На расширенном признаковом пространстве самостоятельно реализовать обучение линейной модели методом GD с использованием MSE и L_1-регуляризации.

Рассмотреть два варианта собственной реализации:

– обучение с использованием L_1-регуляризации без дополнительной обработки малых коэффициентов;

– обучение с дополнительным принудительным занулением достаточно малых по модулю коэффициентов.

Во втором варианте самостоятельно выбрать и обосновать критерий зануления коэффициента. Например, коэффициент может быть занулён при выполнении условия

$$|w_j| < \varepsilon_w,$$

где $\varepsilon_w > 0$ — выбранное пороговое значение.

Коэффициент регуляризации λ подобрать по валидационной выборке. Для поиска рекомендуется использовать логарифмическую сетку, например

$$\lambda \in \left\{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1, 10\right\}.$$

При необходимости диапазон значений может быть изменён с учётом особенностей выбранного набора данных.

Другие используемые гиперпараметры также подобрать с использованием выбранной стратегии валидации.

2.3.3 Сравнение с Lasso библиотеки scikit-learn

На том же расширенном признаковом пространстве обучить модель Lasso библиотеки scikit-learn.

Коэффициент регуляризации библиотечной модели подобрать по валидационной выборке.

Сравнить три модели:

– собственную реализацию с L_1-регуляризацией без дополнительного зануления;

– собственную реализацию с дополнительным занулением малых коэффициентов;

– модель Lasso библиотеки scikit-learn.

Для каждой модели:

– вывести итоговые значения коэффициентов;

– оценить качество на тестовой выборке с использованием единой метрики, например RMSE;

– определить признаки, коэффициенты при которых были обнулены либо оказались достаточно малы.

2.3.4 Анализ отбора признаков

На основании полученных коэффициентов провести анализ результатов отбора признаков и сопоставить результаты собственной реализации L_1-регуляризации с моделью Lasso.

Проанализировать:

– какие исходные и созданные признаки были сохранены различными моделями;

– какие признаки получили малые или нулевые коэффициенты;

– насколько согласуются результаты отбора различных реализаций;

– как изменилась корреляционная структура признакового пространства после отбора;

– как сокращение признакового пространства повлияло на качество модели.

2.4 L_2-регуляризация и анализ оптимизации

Для последующих вычислительных экспериментов использовать набор данных с расширенным признаковым пространством, приведённый к виду, пригодному для обучения линейных моделей.

2.4.1 Аналитическое решение линейной регрессии

Самостоятельно реализовать аналитическое решение задачи минимизации MSE для линейной модели вида

$$w^* = \left(X^T X\right)^{-1} X^T y.$$

Для полученной модели:

– вывести найденные значения параметров;

– получить прогнозы на тестовой выборке;

– оценить качество модели с использованием выбранной метрики регрессии, например RMSE.

2.4.2 Аналитическая линейная регрессия с L_2-регуляризацией

Самостоятельно реализовать аналитическое решение задачи минимизации MSE для линейной модели с L_2-регуляризацией вида

$$w^* = \left(X^T X + \lambda I\right)^{-1} X^T y.$$

Коэффициент регуляризации λ подобрать по валидационной выборке с использованием выбранной стратегии поиска.

Для полученной модели:

– вывести найденные значения параметров;

– оценить качество на тестовой выборке;

– сопоставить полученные веса и качество модели с результатами линейной регрессии без регуляризации.

2.4.3 Сравнение с Ridge-регрессией библиотеки scikit-learn

Обучить модель Ridge библиотеки scikit-learn на том же наборе данных, подобрать коэффициент регуляризации по валидационной выборке и сравнить полученные результаты с собственной аналитической реализацией Ridge-регрессии.

В сравнении отразить:

– выбранные значения коэффициента регуляризации;
– полученные параметры моделей;
– качество моделей на тестовой выборке.

Сформулировать вывод о соответствии собственной реализации библиотечной модели и возможных причинах наблюдаемых различий.

2.4.4 Исследование влияния L_2-регуляризации на оптимизацию

Для исследования использовать те же функционалы ошибки, которые **были** выбраны в предыдущей лабораторной работе.

Дополнительно выбрать и реализовать один метод градиентной оптимизации из списка ниже, который **не был** использован в предыдущей лабораторной работе:

– GD;
– mini-batch SGD;
– Momentum;
– AdaGrad;
– RMSProp;
– Adam.

Для каждого функционала провести два вычислительных эксперимента:

– обучение без регуляризации;
– обучение с L_2-регуляризацией.

Коэффициент регуляризации λ, шаг обучения и остальные гиперпараметры оптимизатора подобрать по валидационной выборке с использованием выбранной стратегии поиска.

В качестве критерия сходимости использовать норму **полного градиента** оптимизируемого функционала:

$$\left\| \nabla F \left(w^{(k)} \right) \right\|_2 < \varepsilon,$$

где k — номер шага оптимизации, а $\varepsilon > 0$ — заранее выбранная точность.

Для всех вычислительных экспериментов использовать одно и то же значение ε.

Построить график зависимости нормы полного градиента от номера шага оптимизации:

$$k \longmapsto \left\| \nabla F \left(w^{(k)} \right) \right\|_2 .$$

На графике необходимо дополнительно отобразить горизонтальную линию $y = \varepsilon$, соответствующую выбранному критерию сходимости.

Построить график зависимости обусловленности от номера шага оптимизации:

$$k \longmapsto \kappa \left(H \left(w^{(k)} \right) \right) .$$

Если на отдельных шагах гессиан не существует или является вырожденным, соответствующие случаи необходимо учитывать при интерпретации результатов.

Построить график зависимости значения функционала ошибки от номера шага оптимизации:

$$k \longmapsto F \left(w^{(k)} \right) .$$

На каждом из построенных графиков совместно отобразить результаты оптимизации без регуляризации и с L_2-регуляризацией.

На основании полученных результатов проанализировать:

– изменение обусловленности задачи после добавления L_2-регуляризации;

– изменение характера и скорости сходимости выбранного метода оптимизации;

– различия в поведении регуляризации для разных функционалов ошибки.

После завершения подбора гиперпараметров обучить итоговые модели и оценить их качество на тестовой выборке.

Использовать ту же метрику качества, которая применялась в предыдущей лабораторной работе, например RMSE.

Для каждого функционала сравнить качество модели:

– без регуляризации;

– с L_2-регуляризацией.

Сформулировать выводы о влиянии регуляризации на качество модели.