ЛР6. Теория: переобучение, L_1 и L_2 регуляризация, аналитические решения

Лекции «Переобучение» и «Регуляризация», семинары «Обусловленность и псевдообратимость». Закрывает вопросы РК1 № 14–15 и доказательства № 5 и 7.

1. Переобучение и линейная зависимость признаков (доказательство № 5)

Утверждение. Если столбцы X линейно зависимы, то для любого решения w^* задачи обучения существует бесконечно много весов с теми же ответами на обучающей выборке.

Доказательство. Зависимость означает: $\exists v \neq 0$, $Xv = 0$. Для любого $C \in \mathbb{R}$ положим $w_C = w^* + Cv$. Тогда $Xw_C = Xw^* + CXv = Xw^*$. Ответы на обучении совпадают, поэтому любой функционал, зависящий от модели только через Xw, принимает одно и то же значение. При этом $\|w_C\|_2 \to \infty$ при $|C| \to \infty$.

Почему это плохо. На тесте $X_{test}w_C = X_{test}w^* + C\,X_{test}v$, и если $X_{test}v \neq 0$ (зависимость на новых данных нарушилась), ошибка растёт с $|C|$. Большие веса делают модель чувствительной к малым изменениям признаков. При **почти** линейной зависимости ($Xv \approx 0$) решение единственно, но неустойчиво: малый шум в y сильно меняет w^*.

В расширенном пространстве ЛР6 такие зависимости есть: `Age` + `YearBuilt` ≈ год продажи; `BuildingArea`, `log_BA`, `AreaPerRoom` сильно связаны.

2. Регуляризация: от условной задачи к безусловной

Регуляризатор — функция $R : \mathbb{R}^d \to \mathbb{R}_+$, ограничивающая «сложность» весов. Условная постановка:

$$Q(w) \to \min_w, \qquad R(w) \leq C.$$

Лагранжиан $\mathcal{L}(w, \lambda) = Q(w) + \lambda(R(w) - C)$. При фиксированном $\lambda \geq 0$ слагаемое $-\lambda C$ не зависит от w, поэтому

$$F(w) = Q(w) + \lambda R(w) \to \min_w .$$

Каждому C соответствует свой λ (множитель Лагранжа). $\lambda = 0$ — регуляризации нет; при $\lambda \to \infty$ все веса стремятся к нулю.

Три правила:

1. λ — **гиперпараметр**: по обучающей ошибке всегда «лучше» $\lambda = 0$, поэтому подбирают по валидации (логарифмическая сетка).
2. **Свободный член не штрафуется:** w_0 — точка отсчёта, а не чувствительность к признакам.
3. **Признаки масштабируют:** иначе штраф несопоставим для весов в разных единицах.

Примеры регуляризаторов: $\|w\|_1$ (Lasso), $\|w\|_2^2$ (Ridge), $\alpha\|w\|_1 + (1-\alpha)\|w\|_2^2$ (Elastic Net), $\|w\|_0$ — число ненулевых весов (невыпуклый, NP-трудный).

3. L_2-регуляризация (Ridge)

3.1. Производные

$$R(w) = \frac{\lambda}{2}\|w\|_2^2 = \frac{\lambda}{2} w^T w, \qquad dR = \lambda w^T dw \Rightarrow \nabla R = \lambda w, \qquad \nabla^2 R = \lambda I.$$

Дифференцируем всюду. Для $F = Q + R$: $\nabla F = \nabla Q + \lambda w$, $H_F = H_Q + \lambda I$.

3.2. Влияние на обусловленность (доказательство № 7)

Утверждение. Пусть $Q \in C^2$ выпуклый, H_Q симметрична и неотрицательно определена. Тогда L_2 -регуляризация уменьшает число обусловленности гессиана.

Доказательство. $H_Q = U\Lambda U^T$, U ортогональна, $\Lambda = \mathrm{diag}(\lambda_1 \geq \cdots \geq \lambda_d \geq 0)$. Тогда

$$H_F = U\Lambda U^T + \lambda U U^T = U(\Lambda + \lambda I)U^T,$$

то есть собственные векторы те же, а собственные числа сдвигаются: $\lambda_i \mapsto \lambda_i + \lambda$. Следовательно,

$$\kappa(H_F) = \frac{\lambda_1 + \lambda}{\lambda_d + \lambda}.$$

Функция $g(t) = \frac{a+t}{b+t}$ при $a > b \geq 0$ убывает: $g'(t) = \frac{b-a}{(b+t)^2} < 0$. Поэтому $\kappa(H_F) < \kappa(H_Q)$ при $\lambda > 0$, а при $\lambda_d = 0$ вместо $\kappa = \infty$ получаем конечное $\frac{\lambda_1+\lambda}{\lambda}$. ■

Геометрически: «овраг» с почти плоским направлением ($\lambda_d \approx 0$) превращается в чашу с кривизной не меньше λ, и GD сходится быстрее: множитель $\frac{\kappa-1}{\kappa+1}$ уменьшается.

3.3. Аналитическое решение

$$F(w) = \|Xw - y\|_2^2 + \lambda\|w\|_2^2, \qquad \nabla F = 2X^T(Xw - y) + 2\lambda w = 0 \;\Rightarrow\; w^* = (X^T X + \lambda I)^{-1} X^T y.$$

$X^T X + \lambda I \succ 0$ при $\lambda > 0$: $v^T(X^T X + \lambda I)v = \|Xv\|^2 + \lambda\|v\|^2 > 0$. Поэтому решение существует и единственно **всегда**, даже при вырожденной $X^T X$. Без штрафа на свободный член I заменяют на $P = \mathrm{diag}(0, 1, \ldots, 1)$.

Нормировка в формуле важна при сравнении с библиотеками:

Функционал	Решение
$\|Xw - y\|^2 + \lambda\|w\|^2$ (так в `sklearn.Ridge`, $\alpha = \lambda$)	$(X^T X + \lambda I)^{-1} X^T y$
$\frac{1}{2\ell}\|Xw - y\|^2 + \frac{\lambda}{2}\|w\|^2$ (лекция)	$(X^T X + \ell\lambda I)^{-1} X^T y$

3.4. Взгляд через SVD: сжатие

Пусть $X = U\Sigma V^T$, $\sigma_1 \geq \cdots \geq \sigma_d$. Тогда

$$w^*_{OLS} = \sum_i \frac{1}{\sigma_i}(u_i^T y)\, v_i, \qquad w^*_{Ridge} = \sum_i \frac{\sigma_i}{\sigma_i^2 + \lambda}(u_i^T y)\, v_i = \sum_i \underbrace{\frac{\sigma_i^2}{\sigma_i^2 + \lambda}}_{\in (0,1)} \frac{u_i^T y}{\sigma_i} v_i.$$

У OLS направления с малым σ_i получают огромный множитель $1/\sigma_i$ — так возникают большие неустойчивые веса. Ridge сжимает эти компоненты почти до нуля (множитель $\approx \sigma_i^2/\lambda$) и почти не трогает компоненты с большим σ_i. **Эффективное число параметров:**

$$\mathrm{df}(\lambda) = \sum_i \frac{\sigma_i^2}{\sigma_i^2 + \lambda} \in (0, d].$$

При $\lambda \to 0$ решение Ridge стремится к решению с минимальной нормой $X^{+}y$ (псевдообратная Мура–Пенроуза).

3.5. Байесовская интерпретация

Если $y \mid x, w \sim N(x^T w, \sigma^2)$ и априорно $w \sim N(0, \tau^2 I)$, то оценка максимума апостериорной вероятности

$$\hat{w}_{MAP} = \arg\min_w \frac{1}{2\sigma^2}\|Xw - y\|^2 + \frac{1}{2\tau^2}\|w\|^2$$

совпадает с Ridge при $\lambda = \sigma^2/\tau^2$. L_2-штраф — это априорная уверенность, что веса малы.

4. L_1-регуляризация (Lasso)

4.1. Производные

$$R(w) = \lambda \sum_j |w_j|, \qquad \partial_{w_j} R = \begin{cases} \lambda, & w_j > 0, \\ [-\lambda, \lambda], & w_j = 0, \\ -\lambda, & w_j < 0, \end{cases} \qquad \nabla^2 R = 0 \text{ почти всюду.}$$

Недифференцируем на гиперплоскостях $w_j = 0$ — там используют субградиент. Кривизны L_1 не добавляет: прямого улучшения обусловленности нет.

4.2. Почему L_1 зануляет веса

Сравним силы, тянущие вес к нулю: у L_2 — λw_j (слабеет при $w_j \to 0$, вес только уменьшается), у L_1 — $\lambda \operatorname{sign}(w_j)$ (постоянна по модулю и доводит вес до нуля). Геометрически: линии уровня Q касаются ромба $\{\|w\|_1 \le C\}$ чаще всего в **вершине**, где часть координат равна нулю. Шар $\{\|w\|_2 \le C\}$ вершин не имеет.

Коррелированные признаки ($x_1 \approx x_2$). Пока w_1, w_2 одного знака, $|w_1| + |w_2| = |w_1 + w_2|$, то есть штраф не зависит от распределения суммы между ними. При переходе к разным знакам штраф растёт (неравенство треугольника). Поэтому L_1 склонен переносить всю массу на один признак: $(w_1, w_2) \to (p, 0)$ или $(0, p)$. L_2, наоборот, делит поровну: при фиксированной сумме минимум $w_1^2 + w_2^2$ достигается при $w_1 = w_2$.

4.3. Проксимальный шаг и мягкий порог

Обычный субградиентный шаг почти никогда не попадает **точно** в ноль: вес колеблется около нуля с амплитудой $\sim \eta\lambda$. Проксимальный градиентный метод (ISTA) делает шаг по гладкой части и затем решает задачу для L_1 точно:

$$z = w_k - \eta \nabla Q(w_k), \qquad w_{k+1} = \arg\min_w \Big(\frac{1}{2\eta}\|w - z\|^2 + \lambda \|w\|_1 \Big).$$

Задача распадается по координатам. Условие оптимальности $0 \in w_j - z_j + \eta\lambda\, \partial|w_j|$ даёт **мягкий порог** (soft thresholding):

$$w_j = S_{\eta\lambda}(z_j) = \operatorname{sign}(z_j) \max\big(|z_j| - \eta\lambda,\ 0\big).$$

Если $|z_j| \le \eta\lambda$, вес ставится ровно в ноль. Отсюда обоснование критерия зануления в ЛР6: $\varepsilon_w = \eta\lambda$.

4.4. Условия оптимальности и $\lambda_{\max}$

Для $F(w) = \frac{1}{\ell}\|Xw - y\|^2 + \lambda\|w\|_1$ (признаки центрированы, свободный член отдельно) точка w^* оптимальна $\iff$ $0 \in \partial F(w^*)$:

$$\frac{2}{\ell}x_j^T(y - Xw^*) = \lambda\,\mathrm{sign}(w_j^*), \quad w_j^* \neq 0; \qquad \left|\frac{2}{\ell}x_j^T(y - Xw^*)\right| \leq \lambda, \quad w_j^* = 0.$$

Признак остаётся нулевым, пока его корреляция с остатком не превысит порог. Подставляя $w^* = 0$:

$$\lambda_{\max} = \frac{2}{\ell}\left\|X^T(y - \bar{y})\right\|_\infty,$$

и при $\lambda \geq \lambda_{\max}$ все веса нулевые. Это верхняя граница сетки поиска λ.

Связь с `sklearn.Lasso`. Lasso минимизирует $\frac{1}{2\ell}\|y - Xw\|^2 + \alpha\|w\|_1$. Это наш функционал, делённый на 2, с $\alpha = \lambda/2$.

4.5. Байесовская интерпретация

Априорное распределение Лапласа $p(w_j) \propto e^{-|w_j|/b}$ даёт MAP-оценку Lasso. Пик плотности в нуле — «веру» в то, что многие веса нулевые.

5. Сравнение L_1 и L_2

	L_2 **(Ridge)**	L_1 **(Lasso)**
Штраф	$\frac{\lambda}{2}\|w\|_2^2$	$\lambda\|w\|_1$
Градиент	λw	$\lambda\,\mathrm{sign}(w)$
Гессиан	λI — кривизна по всем направлениям	0 почти всюду
Обусловленность	гарантированно улучшается	только косвенно (если зануляет коррелированные признаки)
Разреженность	нет: веса малы, но ненулевые	да: отбор признаков
Коррелированные признаки	делит вес между ними	оставляет один
Аналитическое решение	$(X^TX + \lambda I)^{-1}X^Ty$	нет (координатный спуск, ISTA)
Дифференцируемость	всюду	нет при $w_j = 0$

6. Смещение и разброс

С ростом λ модель становится проще: **смещение растёт** (недообучение), **разброс падает** (меньше зависимость от конкретной выборки). Ошибка на валидации как функция λ обычно U-образна. Её минимум — выбранное λ^*. Поэтому λ ищут по логарифмической сетке $\{10^{-5}, \ldots, 10\}$: масштаб важнее точного значения.

7. Вопросы для самопроверки (РК1 № 14–15, доказательства № 5, 7)

1. Дайте определение регуляризатора. Сформулируйте условную задачу и приведите её к безусловной. Примеры регуляризаторов.
2. Почему L_1 зануляет веса, а L_2 — нет? Как они ведут себя при коррелированных признаках?
3. Докажите: при линейно зависимых признаках решений бесконечно много, и среди них есть сколь угодно большие по норме.
4. Докажите, что L_2 уменьшает число обусловленности гессиана. Запишите $\kappa(H_F)$.

5. Выведите $w^* = (X^T X + \lambda I)^{-1} X^T y$ и докажите, что матрица обратима при $\lambda > 0$.
6. Выведите мягкий порог как решение $\min_w \frac{1}{2\eta}(w - z)^2 + \lambda |w|$.
7. Найдите $\lambda_{\max}$, при котором Lasso зануляет все веса.
8. Как перевести наш λ в `alpha` для `Lasso` и `Ridge` из sklearn?