Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Конспект лекций по курсу ОАД

Разработал:
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

ВЕРОЯТНОСТНАЯ ПОСТАНОВКА ОБУЧЕНИЯ С УЧИТЕЛЕМ 3
1 ЛИНЕЙНЫЕ МОДЕЛИ 5
2 ЛИНЕЙНАЯ РЕГРЕССИЯ 8
3 ИЗМЕРЕНИЕ ОШИБКИ В ОБУЧЕНИИ С УЧИТЕЛЕМ 9
3.1 Измерение ошибки в задачах регрессии 12
4 ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ 25
5 ПЕРЕОБУЧЕНИЕ 28
6 РЕГУЛЯРИЗАЦИЯ 31
6.1 L_2-регуляризация 33
6.2 L_1-регуляризация 38
ЛИНЕЙНАЯ КЛАССИФИКАЦИЯ 43
7 БИНАРНАЯ КЛАССИФИКАЦИЯ 44
7.1 Метрики качества классификации 46
7.1.1 Матрица ошибок 46
7.1.2 Численные характеристики ROC-кривой и PR-кривой 53
7.2 Метод опорных векторов 60
7.2.1 Линейно разделимый случай 60
7.2.2 Линейно неразделимый случай 70
7.3 Бинарная кросс-энтропия 78
7.4 Сравнение функций потерь 87
8 МНОГОКЛАССОВАЯ И МНОГОМЕТОЧНАЯ КЛАССИФИКАЦИЯ 90
8.1 Многоклассовая классификация 90
8.1.1 Один против всех 90
8.1.2 Все против всех 91
8.1.3 Метрики качества многоклассовой классификации 92
8.2 Многометочная классификация 96
8.2.1 Независимая классификация 96
8.2.2 Цепочки классификаторов 97
8.2.3 Метрики качества многометочной классификации 98

ВЕРОЯТНОСТНАЯ ПОСТАНОВКА ОБУЧЕНИЯ С УЧИТЕЛЕМ

Обозначим через $\mathcal{X}$ пространство признаков, а через $\mathcal{Y}$ — пространство целевых значений. Элементы пространства $\mathcal{X}$ будем называть **объектами**, понимая под объектом его признаковое описание.

Будем считать, что существует некоторое истинное распределение

$$P^*_{X,Y}$$

на пространстве $\mathcal{X} \times \mathcal{Y}$. Это означает, что случайная пара (X, Y) распределена согласно $P^*_{X,Y}$:

$$(X, Y) \sim P^*_{X,Y}.$$

Данное распределение задаёт вероятностный закон, согласно которому возникают объекты и соответствующие им целевые значения.

Совместное распределение можно представить в виде произведения двух распределений:

$$P^*_{X,Y} = P^*_{Y|X} P^*_X,$$

где P^*_X описывает распределение объектов в пространстве признаков, а $P^*_{Y|X}$ описывает условное распределение целевой переменной Y при фиксированном признаковом описании объекта.

На практике распределение $P^*_{X,Y}$ неизвестно. Вместо него нам доступна выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{\ell}.$$

Её элементы рассматриваются как реализации случайных пар

$$(X_i, Y_i), \quad i = 1, \ldots, \ell.$$

Будем считать, что случайные пары (X_i, Y_i) независимы и имеют одно и то же распределение $P^*_{X,Y}$. В частности, каждая пара (x_i, y_i) является реализацией случайной пары (X_i, Y_i), распределённой согласно $P^*_{X,Y}$.

Определение. Моделью будем называть отображение

$$\alpha : \mathcal{X} \to \mathcal{Z},$$

где $\mathcal{Z}$ — пространство выходов модели.

Семейство моделей задаётся множеством отображений

$$\mathcal{A} \subseteq \{\alpha : \mathcal{X} \to \mathcal{Z}\}.$$

В общем случае пространство выходов модели $\mathcal{Z}$ не обязано совпадать с пространством целевых значений $\mathcal{Y}$. Например, в задаче бинарной классификации выходом модели может быть величина из отрезка $[0, 1]$, в то время как $\mathcal{Y}$ принимает дискретные значения. В этом случае выход модели можно преобразовать в класс с помощью порогового правила.

1 ЛИНЕЙНЫЕ МОДЕЛИ

Пусть $\mathcal{X} = \mathbb{R}^d$, тогда каждый объект имеет вид

$$x = (x_1, \ldots, x_d)^T \in \mathbb{R}^d,$$

где x_j — значение j-го признака объекта.

Определение. Линейной моделью называется отображение вида

$$\alpha(x) = w_0 + \sum_{j=1}^{d} w_j x_j = \langle w, x \rangle + w_0,$$

где $w \in \mathbb{R}^d$ — вектор весов, а $w_0 \in \mathbb{R}$ — свободный коэффициент. Вес w_j является коэффициентом при j-м признаке и определяет вклад этого признака в выход модели. Свободный коэффициент w_0 задаёт сдвиг выхода модели.

В более общем смысле будем относить к линейным моделям также модели, выход которых получается преобразованием значения линейной комбинации признаков.

Тогда семейство линейных моделей в простейшем скалярном случае задаётся множеством отображений

$$\mathcal{A}_{\text{lin}} = \left\{ \alpha : \mathcal{X} \to \mathcal{Z} \mid \alpha(x) = \varphi(\langle w, x \rangle + w_0),\ w \in \mathbb{R}^d,\ w_0 \in \mathbb{R} \right\},$$

где $\varphi : \mathbb{R} \to \mathcal{Z}$ — функция, преобразующая значение линейной комбинации признаков в выход модели.

Замечание. Линейная модель имеет такой вид, поскольку её выходное значение является линейной комбинацией признаков:

$$\alpha(x) = w_1 x_1 + \cdots + w_d x_d + w_0.$$

Параметры модели входят в эту формулу только в первой степени.

Рассмотрим геометрический смысл такой модели. В общем случае график линейной модели является гиперплоскостью в пространстве $\mathbb{R}^{d+1}$:

$$\alpha(x) = \langle w, x \rangle + w_0.$$

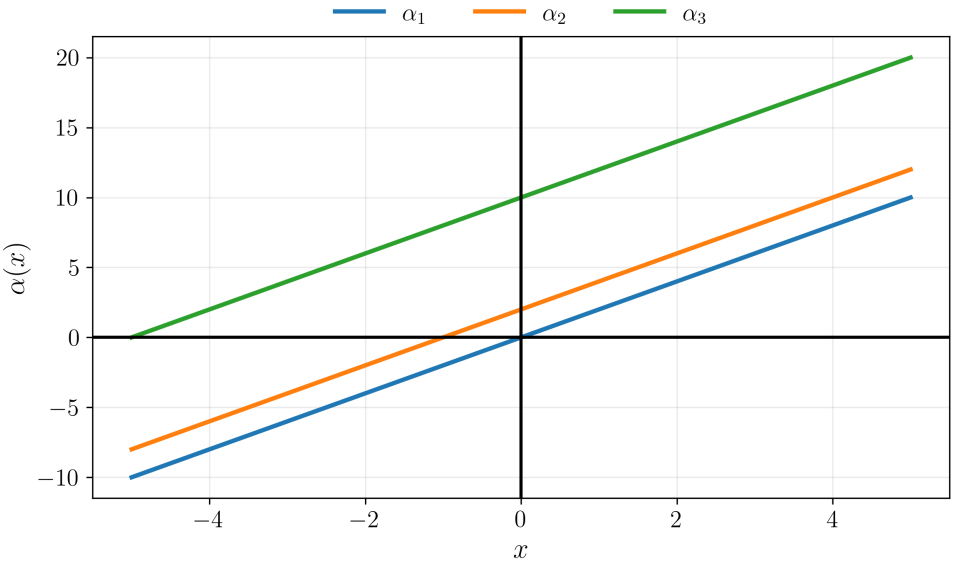


Рисунок 1 – Линейные модели $\alpha_1(x), \alpha_2(x)$ и $\alpha_3(x)$

Для наглядности разберём случай одного признака. Пусть объект описывается числом $x_1 \in \mathbb{R}$. Зафиксируем вес $w_1 = 2$ и рассмотрим три модели с разными свободными коэффициентами:

$$\alpha_1(x) = 2x, \qquad \alpha_2(x) = 2x + 2, \qquad \alpha_3(x) = 2x + 10.$$

Графиками этих моделей являются прямые на плоскости $(x, \alpha(x))$, изображённые на рисунке 1.

Как можно заметить, свободный коэффициент отвечает за смещение прямой. В частности, если положить признак равным нулю, то выходное значение модели определяется свободным коэффициентом:

$$\alpha(0) = w_0.$$

Поэтому w_0 можно понимать как точку отсчёта, относительно которой задаётся вклад остальных признаков.

Замечание. Строго говоря, из-за свободного коэффициента w_0 отображение

$$x \mapsto \langle w, x \rangle + w_0$$

является аффинным. Однако в машинном обучении модели такого вида традиционно называют линейными.

Упростим запись модели, добавив к признаковому описанию объекта $(d+1)$-й признак, равный единице. Тогда вес при нём будет равен свободному коэффициенту, а саму модель можно записать как

$$\alpha(x) = \langle w, x \rangle.$$

Тем не менее, при такой форме записи следует помнить, что в признаковом описании появился специальный единичный признак. Например, этот момент необходимо учитывать при использовании регуляризации.

2 ЛИНЕЙНАЯ РЕГРЕССИЯ

Рассмотрим задачу регрессии. В этом случае пространство целевых значений является вещественным:

$$\mathcal{Y} = \mathbb{R}.$$

Пусть также

$$\mathcal{X} = \mathbb{R}^d.$$

В качестве примера будем рассматривать задачу оценки стоимости квартиры. В этой задаче случайная пара (X, Y) имеет распределение $P^*_{X,Y}$. Здесь X — случайный вектор признаков, описывающих квартиру, например площадь, число комнат, этаж и другие характеристики, а Y — целевая случайная переменная, соответствующая стоимости квартиры.

Условное распределение $P^*_{Y|X=x}$ можно интерпретировать как распределение возможных стоимостей квартиры при фиксированном признаковом описании x.

При оценке стоимости конкретной квартиры её признаки x считаются известными. Поэтому непосредственно нас интересует поведение целевой переменной Y при условии $X = x$, то есть условное распределение $P^*_{Y|X=x}$.

В задаче линейной регрессии пространство выходов модели совпадает с пространством целевых значений:

$$\mathcal{Z} = \mathcal{Y} = \mathbb{R}.$$

Поэтому линейная регрессионная модель имеет вид

$$\alpha : \mathbb{R}^d \to \mathbb{R}, \qquad \alpha \in \mathcal{A}_{\text{lin}} \text{ с } \varphi(t) = t.$$

Однако обычная регрессионная модель не возвращает всё условное распределение. Она сопоставляет признаковому описанию x одно вещественное значение. Вопрос о том, как именно это значение должно соотноситься с условным распределением $P^*_{Y|X=x}$, будет рассмотрен далее.

3 ИЗМЕРЕНИЕ ОШИБКИ В ОБУЧЕНИИ С УЧИТЕЛЕМ

Пусть $x \in \mathcal{X}$ — признаковое описание объекта, тогда модель сопоставляет объекту x выходное значение $\alpha(x) \in \mathcal{Z}$.

Если истинное целевое значение для данного объекта равно $y \in \mathcal{Y}$, то необходимо определить, насколько выход модели $\alpha(x)$ отличается от y.

Определение. Функцией потерь будем называть отображение

$$L : \mathcal{Y} \times \mathcal{Z} \to \mathbb{R}_+.$$

Функция потерь задаёт численную меру несоответствия между истинным целевым значением y и выходом модели $\alpha(x)$. Чем больше значение $L(y, \alpha(x))$, тем больше это несоответствие для пары (x, y).

При условии $X = x$ целевая переменная Y в общем случае остаётся случайной и описывается условным распределением $P^*_{Y|X=x}$. Поэтому даже при фиксированном выходе модели ошибка $L(Y, \alpha(x))$ является случайной величиной относительно условного распределения $P^*_{Y|X=x}$.

Для произвольного $\alpha(x) \in \mathcal{Z}$ введём **локальную среднюю ошибку** при данном x:

$$m_{x,L}(\alpha(x)) = \mathbb{M}_{Y|X=x} L(Y, \alpha(x)).$$

Эта величина показывает среднюю ошибку выхода модели при признаковом описании x по возможным значениям целевой переменной Y.

Если бы условное распределение $P^*_{Y|X=x}$ было известно, то для данного x можно было бы выбрать модель, выход которой минимизирует локальную среднюю ошибку:

$$\alpha^*_x = \arg\min_{\alpha \in \mathcal{A}} m_{x,L}(\alpha(x)).$$

Таким образом, функция потерь определяет, какое значение из пространства выходов модели считается оптимальным относительно условного распределения целевой переменной.

Однако модель должна работать не только для одного признакового описания. Объекты сами являются случайными и распределены согласно P^*_X. Поэтому качество модели как функции на всём пространстве $\mathcal{X}$ определяется усреднением локальных средних ошибок по распределению объектов.

Введём **теоретический функционал ошибки**:

$$M_L(\alpha) = \mathbb{M}_X m_{X,L}(\alpha(X)).$$

Разворачивая определение $m_{X,L}$, получаем

$$M_L(\alpha) = \mathbb{M}_X \left[\mathbb{M}_{Y|X} L(Y, \alpha(X))\right].$$

Именно этот функционал выражает среднюю ошибку модели на данных, порождённых истинным распределением $P^*_{X,Y}$.

В идеале хотелось бы найти модель, минимизирующую теоретический функционал ошибки:

$$\alpha^* = \arg\min_{\alpha \in \mathcal{A}} M_L(\alpha).$$

Так как функционал $M_L(\alpha)$ является средним значением локальных ошибок, то его глобальный минимум в классе всех возможных отображений достигается такой функцией, которая почти для каждого x минимизирует локальную среднюю ошибку. Поэтому анализ конкретной функции потерь позволяет понять, какую характеристику условного распределения $P^*_{Y|X=x}$ восстанавливает идеальная модель.

В реальных задачах модель обычно выбирается из ограниченного семейства $\mathcal{A}$. Например, в линейной модели значения $\alpha(x)$ в разных точках связаны общими параметрами. Поэтому такая модель ищет наилучший компромисс внутри выбранного семейства моделей.

На практике распределения P^*_X и $P^*_{Y|X=x}$ неизвестны, поэтому величину $M_L(\alpha)$ нельзя вычислить напрямую. В связи с этим используется выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{\ell}.$$

По этой выборке определяется **эмпирический функционал ошибки**:

$$Q_L(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, \alpha(x_i)).$$

Именно этот функционал можно вычислить по имеющимся данным. Тогда задача обучения записывается в виде

$$\widehat{\alpha} = \arg\min_{\alpha \in \mathcal{A}} Q_L(\alpha, \mathcal{D}).$$

Переход от теоретического функционала $M_L(\alpha)$ к эмпирическому функционалу $Q_L(\alpha, \mathcal{D})$ можно обосновать законом больших чисел.

Рассмотрим фиксированную модель α, не зависящую от обучающей выборки. Положим

$$Z_i = L(Y_i, \alpha(X_i)), \qquad i = 1, \ldots, \ell.$$

Так как пары (X_i, Y_i) независимы и одинаково распределены, а модель α фиксирована, случайные величины Z_i также независимы и одинаково распределены.

Предположим, что случайная величина $L(Y, \alpha(X))$ имеет конечное математическое ожидание и конечную дисперсию. Тогда по следствию из закона больших чисел в форме Чебышёва

$$\frac{1}{\ell} \sum_{i=1}^{\ell} Z_i \xrightarrow{\mathbb{P}} \mathbb{M} Z_i \qquad \text{при } \ell \to \infty.$$

С учётом определения Z_i это означает, что для фиксированной модели α

$$Q_L(\alpha, \mathcal{D}) \xrightarrow{\mathbb{P}} M_L(\alpha).$$

Таким образом, эмпирический функционал ошибки является выборочным приближением теоретического функционала ошибки для заранее фиксированной модели.

Отметим, что это рассуждение не объясняет полностью процесс обучения, поскольку на практике модель выбирается по той же самой выборке:

$$\widehat{\alpha} = \arg\min_{\alpha \in \mathcal{A}} Q_L(\alpha, \mathcal{D}).$$

В этом случае модель $\widehat{\alpha}$ уже зависит от $\mathcal{D}$, поэтому сходимости для одной заранее фиксированной модели недостаточно. Возникает отдельный вопрос обобщающей способности модели, связанный со сложностью семейства $\mathcal{A}$. Этот вопрос будет рассмотрен при обсуждении переобучения и регуляризации.

3.1 Измерение ошибки в задачах регрессии

Пусть $\mathcal{X} = \mathbb{R}^d$ и $\mathcal{Y} = \mathcal{Z} = \mathbb{R}$. Рассмотрим несколько функций потерь вида $L(y, \alpha(x))$.

MSE и R^2.

Одной из наиболее распространённых функций потерь в задаче регрессии является квадратичная функция потерь:

$$L(y, \alpha(x)) = (\alpha(x) - y)^2 .$$

Она часто используется на практике благодаря своей гладкости.

Функционал ошибки, основанный на квадратичной функции потерь, называется средней квадратичной ошибкой (mean squared error, MSE):

$$Q_{\text{MSE}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\alpha(x_i) - y_i)^2 .$$

Однако значение MSE не всегда удобно интерпретировать напрямую, поскольку единицы измерения ошибки возводятся в квадрат. Например, если стоимость квартиры измеряется в рублях, то значение MSE измеряется в рублях в квадрате.

Чтобы вернуться к исходным единицам измерения целевой переменной, используют корень из средней квадратичной ошибки (root mean squared error, RMSE):

$$Q_{\text{RMSE}}(\alpha, \mathcal{D}) = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (\alpha(x_i) - y_i)^2}.$$

Значение RMSE уже измеряется в тех же единицах, что и целевая переменная.

При этом RMSE обычно используют именно как метрику качества, а не как основной функционал для оптимизации. При этом,

$$Q_{\text{RMSE}}(\alpha, \mathcal{D}) = \sqrt{Q_{\text{MSE}}(\alpha, \mathcal{D})}.$$

Функция квадратного корня монотонно возрастает, поэтому минимизация RMSE приводит к тому же минимуму, что и минимизация MSE.

Однако наличие корня усложняет дифференцирование. Поэтому на практике обычно оптимизируют MSE, а RMSE используют для интерпретации качества модели.

Другой метрикой, основанной на квадратичных ошибках, является коэффициент детерминации R^2:

$$R^2 = 1 - \frac{\sum_{i=1}^{\ell} (y_i - \alpha(x_i))^2}{\sum_{i=1}^{\ell} (y_i - \overline{y})^2}, \qquad \overline{y} = \frac{1}{\ell} \sum_{i=1}^{\ell} y_i$$

Числитель в формуле R^2 является суммой квадратов ошибок модели. Знаменатель является суммой квадратов отклонений целевых значений от среднего значения $\overline{y}$. Таким образом, коэффициент R^2 сравнивает рассматриваемую модель с простой базовой моделью, выход которой для всех объектов равен одному и тому же значению $\overline{y}$.

– Если $R^2 = 1$, то выход модели совпадает с целевыми значениями для всех объектов данной выборки.

– При $R^2 = 0$ модель по качеству совпадает с базовой моделью, выход которой всегда равен среднему значению $\overline{y}$.

– Если же $R^2 < 0$, то модель хуже базовой модели.

Метрика R^2 вычисляется относительно конкретной выборки. Поэтому сравнивать разные модели по R^2 корректно только тогда, когда значение этой метрики вычисляется на одной и той же выборке. Иначе знаменатель в формуле R^2 может быть разным, и сравнение будет некорректным.

Утверждение. Пусть $x \in \mathbb{R}^d$ фиксировано и известна плотность условного распределения $P^*_{Y|X=x}$. Тогда теоретически оптимальным значением выхода модели для квадратичной функции потерь является условное математическое ожидание:

$$\alpha^*(x) = \mathbb{M}[Y \mid X = x].$$

□ Пусть $p(y \mid x)$ — плотность условного распределения $P^*_{Y|X=x}$ и $\alpha = \alpha(x)$. Для квадратичной функции потерь локальная средняя ошибка имеет вид

$$m_{x,L}(\alpha) = \mathbb{M}_{Y|X=x}(Y - \alpha)^2.$$

Запишем это математическое ожидание в интегральной форме:

$$m_{x,L}(\alpha) = \int_{\mathbb{R}} (y-\alpha)^2 p(y \mid x)\, dy.$$

Найдём значение α, минимизирующее $m_{x,L}(\alpha)$. Дифференцируем по α:

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = \frac{d}{d\alpha} \int_{\mathbb{R}} (y-\alpha)^2 p(y \mid x)\, dy.$$

Получаем

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = \int_{\mathbb{R}} \frac{d}{d\alpha} (y-\alpha)^2 p(y \mid x)\, dy.$$

Так как

$$\frac{d}{d\alpha}(y-\alpha)^2 = 2(\alpha - y),$$

то

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = \int_{\mathbb{R}} 2(\alpha - y) p(y \mid x)\, dy.$$

Вынесем константу:

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = 2\left(\alpha \int_{\mathbb{R}} p(y \mid x)\, dy - \int_{\mathbb{R}} y p(y \mid x)\, dy\right).$$

Так как

$$\int_{\mathbb{R}} p(y \mid x)\, dy = 1, \qquad \int_{\mathbb{R}} y p(y \mid x)\, dy = \mathbb{M}[Y \mid X = x].$$

Имеем

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = 2\left(\alpha - \mathbb{M}[Y \mid X = x]\right).$$

По необходимому условию экстремума

$$2\left(\alpha - \mathbb{M}[Y \mid X = x]\right) = 0.$$

Следовательно,

$$\alpha = \mathbb{M}[Y \mid X = x].$$

Значит,

$$\alpha^*(x) = \mathbb{M}[Y \mid X = x].$$

■

Таким образом, обучаясь на MSE, модель стремится приблизить условное математическое ожидание распределения $P^*_{Y|X=x}$.

MAE.

Другой распространённой функцией потерь для задачи регрессии является абсолютная ошибка:

$$L(y, \alpha(x)) = |\alpha(x) - y| \,.$$

Функционал ошибки, основанный на абсолютной функции потерь, называется средней абсолютной ошибкой (mean absolute error, MAE):

$$Q_{\text{MAE}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} |\alpha(x_i) - y_i| \,.$$

Значение MAE измеряется в тех же единицах, что и целевая переменная. Поэтому оно интерпретируется напрямую.

Однако MAE сложнее использовать в задачах оптимизации. Функция $|\alpha(x) - y|$ не дифференцируема в точке $\alpha(x) = y$. Кроме того, её производная вне этой точки является постоянной:

$$\frac{d}{d\alpha(x)} |\alpha(x) - y| = \begin{cases} -1, & \alpha(x) < y, \\ 1, & \alpha(x) > y. \end{cases}$$

Такое поведение производной может быть слишком резким для оптимизации. Также вторая производная равна нулю почти всюду, поэтому она не содержит информации о кривизне функции потерь. В результате оптимизация MAE обычно менее удобна, чем оптимизация MSE.

Утверждение. Пусть $x \in \mathbb{R}^d$ фиксировано и известно условное распределение $P^*_{Y|X=x}$. Тогда теоретически оптимальным значением выхода модели для абсолютной функции потерь является условная медиана распределения $P^*_{Y|X=x}$:

$$\alpha^*(x) = \text{median}(Y \mid X = x).$$

□ Пусть $p(y \mid x)$ — плотность условного распределения $P^*_{Y|X=x}$ и $\alpha = \alpha(x)$. Локальная средняя ошибка для абсолютной функции потерь имеет вид

$$m_{x,L}(\alpha) = \mathbb{M}_{Y|X=x}|Y - \alpha|.$$

Запишем математическое ожидание в интегральной форме:

$$m_{x,L}(\alpha) = \int_{\mathbb{R}} |y - \alpha| p(y \mid x)\, dy.$$

Разобьём интеграл на две области: $y < \alpha$ и $y > \alpha$. Тогда

$$m_{x,L}(\alpha) = \int_{y<\alpha} (\alpha - y) p(y \mid x)\, dy + \int_{y>\alpha} (y - \alpha) p(y \mid x)\, dy.$$

Обозначим через

$$F_x(\alpha) = P(Y < \alpha \mid X = x)$$

условную функцию распределения.

Дифференцируем первую часть:

$$\frac{d}{d\alpha} \int_{y<\alpha} (\alpha - y) p(y \mid x)\, dy = \int_{y<\alpha} p(y \mid x)\, dy = F_x(\alpha).$$

Дифференцируем вторую часть:

$$\frac{d}{d\alpha} \int_{y>\alpha} (y - \alpha) p(y \mid x)\, dy = -\int_{y>\alpha} p(y \mid x)\, dy.$$

Имеем

$$\int_{y>\alpha} p(y \mid x)\, dy = 1 - F_x(\alpha).$$

Следовательно,

$$\frac{d}{d\alpha} \int_{y>\alpha} (y - \alpha) p(y \mid x)\, dy = -\left(1 - F_x(\alpha)\right).$$

Отсюда

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = F_x(\alpha) - \left(1 - F_x(\alpha)\right).$$

То есть

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = 2F_x(\alpha) - 1.$$

Для минимума необходимо

$$\frac{d}{d\alpha} m_{x,L}(\alpha) = 0.$$

Следовательно,

$$2F_x(\alpha) - 1 = 0,$$

и поэтому

$$F_x(\alpha) = \frac{1}{2}.$$

Значит, оптимальное значение $\alpha^*(x)$ является условной медианой распределения $P^*_{Y|X=x}$:

$$\alpha^*(x) = \text{median}(Y \mid X = x).$$

■

Таким образом, обучаясь на MAE, модель стремится приблизить условную медиану распределения $P^*_{Y|X=x}$.

Медиана обладает следующими основными свойствами. Во-первых, медиана делит распределение на две части: слева и справа от медианы находится не менее половины вероятностной массы. Во-вторых, медиана минимизирует среднее абсолютное отклонение. В-третьих, медиана более устойчива к выбросам, чем математическое ожидание.

Сравним MSE и MAE с точки зрения устойчивости к выбросам. Квадратичная ошибка штрафует отклонение $r = \alpha(x) - y$ как r^2, а абсолютная ошибка штрафует его как $|r|$. Поэтому при больших отклонениях MSE растёт значительно быстрее, чем MAE.

Например, рассмотрим набор значений

$$10,\ 11,\ 12,\ 13.$$

Его среднее значение и медиана равны 11.5. Если добавить выброс 1000, получим набор

$$10,\ 11,\ 12,\ 13,\ 1000.$$

Теперь среднее значение равно 209.2, а медиана равна 12. То есть среднее значение сильно сдвигается в сторону выброса, тогда как медиана изменяется значительно меньше.

Поэтому модели, обучаемые с MSE, могут сильнее смещаться в сторону объектов с большими ошибками, тогда как модели, обучаемые с MAE, обычно более устойчивы к выбросам.

Huber loss и Log-cosh.

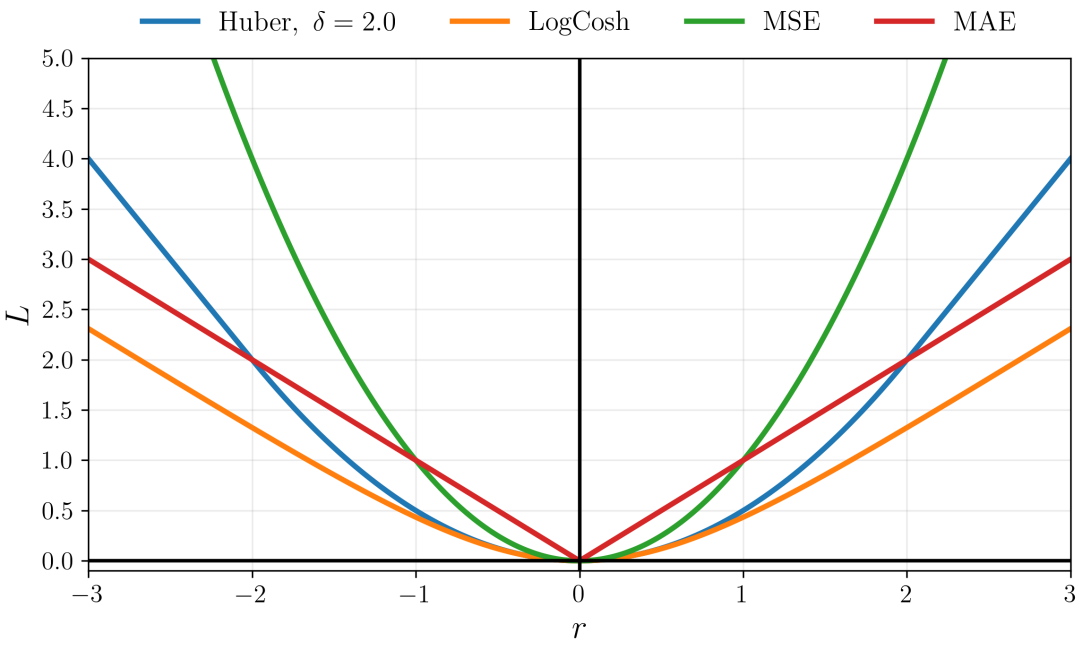


Рисунок 2 – Квадратичная, абсолютная, Huber и Log-cosh функции потерь

Функция потерь Хьюбера является промежуточным вариантом между квадратичной и абсолютной функциями потерь. Обозначим отклонение модели от истинного значения через

$$r = \alpha(x) - y.$$

Положим $\delta > 0$. Тогда функция потерь Хьюбера задаётся формулой

$$L_\delta(y, \alpha(x)) = \begin{cases} \dfrac{1}{2}r^2, & |r| \le \delta, \\ \delta\left(|r| - \dfrac{1}{2}\delta\right), & |r| > \delta. \end{cases}$$

График функции потерь Хьюбера приведён на рисунке 2.

Параметр δ задаёт границу между квадратичным и линейным поведением функции. Если отклонение $|r|$ меньше δ, то функция штрафует ошибку квадратично. Если же $|r|$ больше δ, штраф становится линейным.

Таким образом, параметр δ задаёт уровень устойчивости модели к большим отклонениям. Чем больше δ, тем более сильные ошибки всё ещё рассматриваются как обычные ошибки, а не как выбросы. При малых значениях δ функция

раньше переходит к линейному штрафу и становится ближе к абсолютной функции потерь.

Функционал ошибки, основанный на функции потерь Хьюбера, имеет вид

$$Q_{\text{Huber},\delta}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} L_\delta(y_i, \alpha(x_i)).$$

Функция потерь Хьюбера дифференцируема по r, но не имеет второй производной в точках стыковки $r = -\delta$ и $r = \delta$.

Другой сглаженной функцией потерь, сочетающей свойства квадратичной и абсолютной функций потерь, является Log-cosh:

$$L(y, \alpha(x)) = \log \cosh(r), \qquad \cosh(r) = \frac{e^r + e^{-r}}{2}.$$

Её график также приведён на рисунке 2.

Поведение функции $\log \cosh(r)$ можно описать следующим образом: при малых отклонениях, то есть при $r \to 0$, она ведёт себя как квадратичная функция потерь, а при больших отклонениях, то есть при $|r| \to \infty$, становится близкой к абсолютной функции потерь.

Функционал ошибки для Log-cosh задаётся формулой

$$Q_{\text{Log-cosh}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \log \cosh\left(\alpha(x_i) - y_i\right).$$

В отличие от функции потерь Хьюбера, Log-cosh является дважды дифференцируемой. Поэтому Log-cosh можно рассматривать как гладкий аналог функции потерь Хьюбера.

Квантильная функция потерь.

Пусть $\tau \in (0, 1)$ — заданный уровень квантиля. Квантильная функция потерь задаётся выражением

$$L_\tau(y, \alpha(x)) = \begin{cases} \tau\big(y - \alpha(x)\big), & y \geq \alpha(x), \\ (1 - \tau)\big(\alpha(x) - y\big), & y < \alpha(x). \end{cases}$$

Эта функция потерь является асимметричной. Параметр τ определяет, насколько по-разному штрафуются занижение и завышение выхода модели.

Если $\alpha(x) < y$, то модель занизила значение, и ошибка штрафуется с коэффициентом τ. Если $\alpha(x) > y$, то модель завысила значение, и ошибка штрафуется с коэффициентом $1 - \tau$. Поэтому при больших значениях τ сильнее штрафуется занижение выхода модели, а при малых значениях τ сильнее штрафуется его завышение.

Функционал ошибки, основанный на квантильной функции потерь, имеет вид

$$Q_\tau(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} L_\tau(y_i, \alpha(x_i)).$$

Квантильная функция потерь не дифференцируема в точке $y = \alpha(x)$. При $\alpha(x) \neq y$ её производная по $\alpha(x)$ равна

$$\frac{d}{d\alpha(x)} L_\tau(y, \alpha(x)) = \begin{cases} -\tau, & \alpha(x) < y, \\ 1 - \tau, & \alpha(x) > y. \end{cases}$$

Вторая производная равна нулю почти всюду, поэтому, как и в случае MAE, такая функция потерь не позволяет учитывать кривизну при оптимизации.

Утверждение. Пусть $x \in \mathbb{R}^d$ фиксировано и известно условное распределение $P^*_{Y|X=x}$. Тогда теоретически оптимальным значением выхода модели для квантильной функции потерь является условный квантиль уровня $\tau \in (0, 1)$ распределения $P^*_{Y|X=x}$:

$$\alpha^*(x) = q_\tau(Y \mid X = x).$$

□ Пусть $p(y \mid x)$ — плотность условного распределения $P^*_{Y|X=x}$, а $\alpha = \alpha(x)$. Локальная средняя ошибка для квантильной функции потерь имеет вид

$$m_{x,L}(\alpha) = \mathbb{M}_{Y|X=x} L_\tau(Y, \alpha).$$

Запишем математическое ожидание в интегральной форме:

$$m_{x,L}(\alpha) = \int_{\mathbb{R}} L_\tau(y, \alpha) p(y \mid x)\, dy.$$

По определению квантильной функции потерь получаем

$$m_{x,L}(\alpha) = (1 - \tau) \int_{y<\alpha} (\alpha - y) p(y \mid x)\, dy + \tau \int_{y>\alpha} (y - \alpha) p(y \mid x)\, dy.$$

Обозначим через

$$F_x(\alpha) = P(Y < \alpha \mid X = x)$$

условную функцию распределения.

Дифференцируем первую часть:

$$\frac{d}{d\alpha}\left[(1-\tau)\int_{y<\alpha}(\alpha - y)p(y \mid x)\,dy\right] = (1-\tau)\int_{y<\alpha} p(y \mid x)\,dy.$$

Следовательно,

$$\frac{d}{d\alpha}\left[(1-\tau)\int_{y<\alpha}(\alpha - y)p(y \mid x)\,dy\right] = (1-\tau)F_x(\alpha).$$

Дифференцируем вторую часть:

$$\frac{d}{d\alpha}\left[\tau\int_{y>\alpha}(y - \alpha)p(y \mid x)\,dy\right] = -\tau\int_{y>\alpha} p(y \mid x)\,dy.$$

Имеем

$$\int_{y>\alpha} p(y \mid x)\,dy = 1 - F_x(\alpha).$$

Значит,

$$\frac{d}{d\alpha}\left[\tau\int_{y>\alpha}(y - \alpha)p(y \mid x)\,dy\right] = -\tau\big(1 - F_x(\alpha)\big).$$

Отсюда производная локальной средней ошибки равна

$$\frac{d}{d\alpha}m_{x,L}(\alpha) = (1-\tau)F_x(\alpha) - \tau\big(1 - F_x(\alpha)\big).$$

Раскрывая скобки, получаем

$$\frac{d}{d\alpha}m_{x,L}(\alpha) = (1-\tau)F_x(\alpha) - \tau + \tau F_x(\alpha).$$

Следовательно,

$$\frac{d}{d\alpha}m_{x,L}(\alpha) = F_x(\alpha) - \tau.$$

Для минимума необходимо

$$\frac{d}{d\alpha}m_{x,L}(\alpha) = 0.$$

Поэтому

$$F_x(\alpha) - \tau = 0,$$

то есть

$$F_x(\alpha) = \tau.$$

Следовательно, оптимальное значение $\alpha^*(x)$ является условным квантилем уровня τ распределения $P^*_{Y|X=x}$:

$$\alpha^*(x) = q_\tau(Y \mid X = x).$$

■

Таким образом, обучаясь на квантильный функционал ошибки, модель стремится приблизить условный квантиль уровня τ распределения $P^*_{Y|X=x}$.

Заметим, что при $\tau = \frac{1}{2}$ квантиль уровня τ совпадает с медианой. Поэтому оптимальным значением выхода модели для квантильной функции потерь при $\tau = \frac{1}{2}$ является условная медиана распределения $P^*_{Y|X=x}$.

В этом случае квантильная функция потерь отличается от абсолютной функции потерь только постоянным множителем:

$$L_{0.5}(y, \alpha(x)) = \frac{1}{2}|y - \alpha(x)|.$$

Следовательно, квантильную функцию потерь можно рассматривать как асимметричное обобщение абсолютной функции потерь, позволяющее восстанавливать не только условную медиану, но и другие условные квантили распределения $P^*_{Y|X=x}$.

MSLE.

В некоторых задачах регрессии важно учитывать не абсолютное отклонение выхода модели от истинного значения, а отклонение в порядке величин. Для этого используют логарифмы целевых значений и выходов модели.

Функция потерь MSLE задаётся формулой

$$L(y, \alpha(x)) = (\log(\alpha(x) + 1) - \log(y + 1))^2 .$$

Соответствующий функционал ошибки называется средней квадратичной логарифмической ошибкой (mean squared logarithmic error, MSLE):

$$Q_{\text{MSLE}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left(\log(\alpha(x_i) + 1) - \log(y_i + 1)\right)^2 .$$

Так как в формуле используются логарифмы величин $\alpha(x) + 1$ и $y + 1$, данная функция потерь применяется прежде всего в задачах с неотрицательной целевой переменной:

$$y \geq 0, \qquad \alpha(x) \geq 0.$$

Добавление единицы позволяет корректно обрабатывать нулевые значения.

За счёт логарифмирования MSLE сильнее учитывает относительные различия между значениями, чем абсолютные отклонения. Поэтому такая функция потерь полезна, когда важен порядок величины выхода модели. Например, ошибка между 10 и 20 воспринимается похожим образом на ошибку между 100 и 200, поскольку в обоих случаях значения отличаются примерно в два раза.

Следует также учитывать, что MSLE несимметрична относительно одинаковых абсолютных отклонений. При фиксированном истинном значении y заниженное значение выхода модели обычно штрафуется сильнее, чем завышенное значение выхода модели на ту же абсолютную величину. Это связано с нелинейностью логарифма.

MAPE и SMAPE.

В задачах прогнозирования часто важно измерять не абсолютную, а относительную ошибку выхода модели. Для этого используется средняя абсолютная процентная ошибка (mean absolute percentage error, MAPE).

Функция потерь MAPE имеет вид

$$L(y, \alpha(x)) = \frac{|y - \alpha(x)|}{|y|}.$$

Соответствующий функционал ошибки задаётся формулой

$$Q_{\text{MAPE}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{|y_i - \alpha(x_i)|}{|y_i|}.$$

Если значение нужно выразить в процентах, то результат умножают на 100%.

MAPE показывает среднюю относительную ошибку выхода модели. Например, значение MAPE = 0.1 означает, что средняя абсолютная ошибка составляет примерно 10% от истинного значения.

Однако MAPE имеет существенное ограничение: она не определена при $y = 0$. Кроме того, при малых значениях y даже небольшое абсолютное отклонение может давать очень большую относительную ошибку. Поэтому MAPE следует применять осторожно, если в данных встречаются нулевые или близкие к нулю значения целевой переменной.

Для устранения асимметрии MAPE используют симметричную среднюю абсолютную процентную ошибку (symmetric mean absolute percentage error, SMAPE):

$$L(y, \alpha(x)) = \frac{2\,|y - \alpha(x)|}{(|y| + |\alpha(x)|)}.$$

Соответствующий функционал имеет вид

$$Q_{\text{SMAPE}}(\alpha, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{2\,|y_i - \alpha(x_i)|}{(|y_i| + |\alpha(x_i)|)}.$$

В отличие от MAPE, в SMAPE ошибка нормируется не только на истинное значение y, а на средний масштаб истинного значения и выхода модели. Поэтому SMAPE является симметричной по своим аргументам.

Из-за особенностей относительной нормировки, проблем при нулевых или малых значениях целевой переменной, а также менее удобных оптимизационных свойств MAPE и SMAPE чаще используют как метрики качества, а не как основные функции потерь для непосредственной оптимизации модели.

4 ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ

Рассмотрим задачу регрессии, в которой

$$\mathcal{X} = \mathbb{R}^d, \qquad \mathcal{Y} = \mathcal{Z} = \mathbb{R}, \qquad \alpha \in \mathcal{A}_{\text{lin}} \text{ с } \varphi(t) = t.$$

Пусть задана функция потерь $L(y, \alpha(x))$. Тогда задача обучения линейной модели сводится к минимизации эмпирического функционала ошибки:

$$Q_L(w, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} L\left(y_i, \langle w, x_i \rangle\right) \longrightarrow \min_w .$$

Чаще всего линейная регрессия обучается с использованием квадратичной функции потерь, поскольку для соответствующего функционала ошибки существует аналитическое решение. Получим его.

В этом случае функционал ошибки имеет вид

$$Q_{\text{MSE}}(w, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left(\langle w, x_i \rangle - y_i\right)^2 \longrightarrow \min_w .$$

Запишем функционал в матричном виде. Для этого введём матрицу объектов

$$X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_\ell^T \end{pmatrix} \in \mathbb{R}^{\ell \times d},$$

где каждый объект x_i^T вектор-строка. Тогда функционал MSE можно записать как

$$Q_{\text{MSE}}(w, \mathcal{D}) = \frac{1}{\ell} \|Xw - y\|_2^2 \longrightarrow \min_w .$$

где $w \in \mathbb{R}^d$ — вектор весов модели, а $y \in \mathbb{R}^\ell$ — вектор целевых значений. Поскольку множитель $\frac{1}{\ell}$ не влияет на положение минимума, далее будем минимизировать эквивалентный функционал

$$Q(w) = \|Xw - y\|_2^2 .$$

Перепишем его через скалярное произведение:

$$Q(w) = (Xw - y)^T (Xw - y).$$

Найдём дифференциал функционала $Q(w)$ по w:

$$d_w Q = d\left[(Xw - y)^T (Xw - y)\right].$$

Используя правило дифференцирования произведения, получаем

$$d_w Q = d(Xw - y)^T (Xw - y) + (Xw - y)^T d(Xw - y).$$

Заметим, что

$$d(Xw - y)^T (Xw - y) = dw^T\, X^T (Xw - y) = (Xw - y)^T X\, dw.$$

Так как

$$d(Xw - y) = X\, dw.$$

Следовательно,

$$d_w Q = (Xw - y)^T X\, dw + (Xw - y)^T X\, dw = 2(Xw - y)^T X\, dw.$$

Отсюда градиент функционала равен

$$\nabla_w Q(w) = 2\, X^T (Xw - y).$$

По необходимому условию экстремума приравниваем градиент к нулю:

$$2\, X^T (Xw - y) = 0.$$

Раскрывая скобки, получаем

$$X^T Xw - X^T y = 0.$$

Следовательно,

$$X^T Xw = X^T y.$$

Если матрица $X^T X$ обратима, то аналитическое решение имеет вид

$$w^* = (X^T X)^{-1} X^T y.$$

Наличие аналитического решения для оптимального вектора весов – это большое преимущество линейной регрессии с квадратичным функционалом, однако у такого подхода есть ряд ограничений. Во-первых, вычисление обратной матрицы может быть трудоёмким: для матрицы размера $d \times d$ эта операция в общем случае имеет кубическую вычислительную сложность по числу признаков.

Во-вторых, матрица $X^T X$ может быть вырожденной или плохо обусловленной. В этом случае обратная матрица либо не существует, либо её вычисление приводит к численно нестабильным результатам. Один из способов решения этой проблемы будет рассмотрен при обсуждении регуляризации.

Кроме того, аналитические решения довольно редки в машинном обучении. Если заменить MSE на другой функционал ошибки, то явной формулы для оптимального значения параметров может уже не существовать. Поэтому желательно иметь более общий подход, позволяющий обучать модель для широкого класса функционалов ошибки. Такой подход существует для почти всюду дифференцируемых функций и будет рассмотрен далее.

5 ПЕРЕОБУЧЕНИЕ

Ранее обсуждалось, что для фиксированной модели эмпирический функционал ошибки сходится по вероятности к теоретическому функционалу ошибки. Однако в задаче обучения модель не фиксирована заранее. Она выбирается по обучающей выборке. Поэтому модель может слишком хорошо подстроиться под конкретную обучающую выборку и потерять способность хорошо работать на новых объектах. Такое явление называется переобучением.

Будем рассматривать переобучение на примере линейной регрессии. Пусть $\mathcal{X} = \mathbb{R}^d$, $\mathcal{Y} = \mathcal{Z} = \mathbb{R}$ и $\alpha \in \mathcal{A}_{\text{lin}}$ при $\varphi(t) = t$.

Утверждение. Если признаки линейно зависимы, то для любого решения w^* задачи обучения существует бесконечно много векторов весов, дающих те же ответы на обучающей выборке.

□ Пусть задана обучающая выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{\ell},$$

и матрица объектов

$$X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_\ell^T \end{pmatrix} \in \mathbb{R}^{\ell \times d}.$$

Каждая строка этой матрицы соответствует одному объекту, а каждый столбец соответствует одному признаку.

Предположим, что признаки линейно зависимы. Это означает, что существует ненулевой вектор $v \in \mathbb{R}^d$, такой, что $Xv = 0$. Покомпонентно это означает, что для каждого объекта обучающей выборки выполнено

$$\langle v, x_i \rangle = 0, \qquad i = 1, \ldots, \ell.$$

Пусть вектор весов w^* является оптимальным решением задачи обучения на данной выборке. Построим семейство векторов весов, эквивалентных w^* на обучающей выборке.

Для произвольной константы $C \in \mathbb{R}$ рассмотрим вектор весов

$$w_C = w^* + Cv.$$

Тогда выходы модели на всей обучающей выборке имеют вид

$$Xw_C = X(w^* + Cv).$$

Раскроем скобки:

$$Xw_C = Xw^* + CXv.$$

Но по предположению $Xv = 0$. Следовательно,

$$Xw_C = Xw^*.$$

Значит, модели с весами w^* и w_C дают одинаковые ответы на всех объектах обучающей выборки.

Отсюда следует, что для любого функционала ошибки, зависящего от модели только через её ответы на обучающей выборке, будет выполнено

$$Q(w_C, \mathcal{D}) = Q(w^*, \mathcal{D}).$$

При этом норма вектора весов может становиться сколь угодно большой. Действительно, если увеличивать значение $|C|$, то вектор

$$w_C = w^* + Cv$$

будет всё дальше уходить вдоль направления v. Так как $v \neq 0$, величина $\|w_C\|_2$ может расти неограниченно.

■

Таким образом, при линейно зависимых признаках оптимизационная задача может иметь много решений с одинаковым качеством на обучающей выборке, но с сильно различающимися векторами весов. Среди этих решений могут быть решения с очень большими весами.

Рассмотрим поведение модели на тестовой выборке. Пусть тестовая выборка состоит из m объектов, а соответствующая матрица объектов обозначается через $X_{\text{test}} \in \mathbb{R}^{m \times d}$.

На обучающей выборке направление v невидимо для модели, поскольку $Xv = 0$. Однако это равенство может не выполняться на новых объектах.

Рассмотрим веса

$$w_C = w^* + Cv.$$

На обучающей выборке выходы модели не меняются:

$$Xw_C = Xw^*.$$

Но на тестовой выборке имеем

$$X_{\text{test}}w_C = X_{\text{test}}w^* + CX_{\text{test}}v.$$

Если $X_{\text{test}}v \neq 0$, то при большом $|C|$ слагаемое $CX_{\text{test}}v$ может быть значительным.

Обозначим тестовый вектор целевых значений через y_{test}. Тогда отклонение на тестовой выборке для весов w_C равно

$$r_{\text{test}}(C) = X_{\text{test}}w_C - y_{\text{test}}.$$

Подставляя выражение для w_C, получаем

$$r_{\text{test}}(C) = X_{\text{test}}w^* - y_{\text{test}} + CX_{\text{test}}v.$$

При большом $|C|$ последнее слагаемое может резко увеличить ошибку на тестовой выборке.

Таким образом, большие веса опасны не сами по себе, а потому, что они могут делать модель чувствительной к малым изменениям признаков. На обучающей выборке направление v могло быть невидимым, но на новых объектах эта компенсация может нарушиться.

В связи с этим возникает необходимость в подходе, позволяющем ограничивать сложность модели и не давать весам неограниченно расти вдоль плохо определённых направлений. Такой подход называется регуляризацией.

6 РЕГУЛЯРИЗАЦИЯ

Будем рассматривать регуляризацию на примере линейных моделей. Пусть

$$\mathcal{X} = \mathbb{R}^d, \qquad \mathcal{Y}, \mathcal{Z} \text{ заданы}, \qquad \alpha \in \mathcal{A}_{\text{lin}}.$$

Пусть также задан некоторый эмпирический функционал ошибки $Q(w, \mathcal{D})$.

Определение. Регуляризатором для вектора весов будем называть отображение

$$R : \mathbb{R}^d \to \mathbb{R}_+.$$

Тогда задачу условной оптимизации можно записать как

$$\begin{cases} Q(w, \mathcal{D}) \longrightarrow \min\limits_{w}, \\ R(w) \leq C, \end{cases}$$

где $C \geq 0$ — заданная константа.

То есть в условной постановке регуляризатор можно воспринимать как функцию от весов, значение которой ограничено сверху параметром C.

Запишем лагранжиан данной условной задачи:

$$\mathscr{L}(w, \mathcal{D}, \lambda) = Q(w, \mathcal{D}) + \lambda \left(R(w) - C\right) = Q(w, \mathcal{D}) + \lambda R(w) - \lambda C.$$

где $\lambda \geq 0$ — множитель Лагранжа.

Перейдём к безусловной задаче оптимизации. При фиксированном λ последнее слагаемое является константой, поэтому не влияет на точку минимума по w. Следовательно, минимизация лагранжиана по w эквивалентна минимизации функционала

$$Q(w, \mathcal{D}) + \lambda R(w).$$

Поэтому безусловную задачу оптимизации можно записать в виде

$$Q(w, \mathcal{D}) + \lambda R(w) \longrightarrow \min_{w},$$

где $\lambda \geq 0$ — коэффициент регуляризации.

Таким образом, коэффициент регуляризации λ можно понимать как множитель Лагранжа для некоторго неявного C.

Коэффициент λ позволяет управлять силой регуляризации. Если $\lambda = 0$, то регуляризация фактически отсутствует, и задача сводится к обычной минимизации эмпирического функционала ошибки. Если же значение λ слишком велико, то штраф за величину весов может стать доминирующим, и оптимальное решение будет иметь почти нулевые веса.

Поскольку регуляризация призвана ограничивать сложность модели и препятствовать необоснованному росту весов, естественно задавать регуляризатор через нормы вектора весов. Наиболее распространёнными являются два варианта:

$$R_{L_1}(w) = \|w\|_1 = \sum_{j=1}^{d} |w_j|,$$

$$R_{L_2}(w) = \|w\|_2^2 = \sum_{j=1}^{d} |w_j|^2.$$

Первый вариант называется L_1-регуляризацией, второй — L_2-регуляризацией.

Отметим, что в случае L_2-регуляризации обычно используется именно квадрат евклидовой нормы. Это делается для удобства оптимизации. Если использовать обычную евклидову норму, то в функционале появится квадратный корень, что усложнит дифференцирование.

Замечание 1. Коэффициент регуляризации λ является гиперпараметром. Это означает, что он не подбирается вместе с весами по обучающей выборке как обычный параметр модели. Если выбирать λ только по обучающей ошибке, то оптимальным почти всегда окажется значение $\lambda \approx 0$, поскольку слабая регуляризация позволяет модели лучше подстроиться под обучающую выборку. Однако, как обсуждалось ранее, такое поведение может приводить к потере обобщающей способности модели.

Замечание 2. Свободный член w_0 не включается в регуляризацию. Ранее отмечалось, что свободный член задаёт точку отсчёта модели. Его большое абсолютное значение не означает чрезмерной чувствительности модели к малым изменениям признаков.

Замечание 3. Перед обучением модели с регуляризацией необходимо масштабировать признаки. Если признаки имеют существенно разные масштабы, то один и тот же размер веса может соответствовать разному влиянию на выход

модели. В результате регуляризация будет штрафовать веса несопоставимым образом, и в задаче возникнут конкурирующие оптимизационные условия.

Выше в качестве примеров были приведены L_1- и L_2-регуляризации. Эти два вида регуляризации являются основными на практике, но имеют разный оптимизационный смысл. Рассмотрим их подробнее.

6.1 L_2-регуляризация

Утверждение. L_2-регуляризация делает рельеф функционала ошибки менее вытянутым и уменьшает коэффициент обусловленности его гессиана.

□ Пусть $Q(w) \in C^2$ — некоторый строго выпуклый функционал ошибки, гессиан которого имеет полный ранг. Применим к $Q(w)$ L_2-регуляризацию и обозначим полученный функционал через

$$F(w) = Q(w) + \frac{\lambda}{2}\|w\|_2^2.$$

Найдём градиент функционала F. Так как

$$\nabla_w \left(\frac{1}{2}\|w\|_2^2\right) = w,$$

получаем

$$\nabla_w F(w) = \nabla_w Q(w) + \lambda w.$$

Следовательно, гессиан функционала F равен

$$H_F = H_Q + \lambda I,$$

где H_Q — гессиан исходного функционала ошибки, а I — единичная матрица.

Так как функционал $Q(w)$ строго выпуклый, а его гессиан имеет полный ранг, то H_Q является симметричной положительно определённой матрицей и для неё существует спектральное разложение

$$H_Q = U\Lambda U^T,$$

где U — ортогональная матрица, а $\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$ — диагональная матрица собственных значений гессиана H_Q.

Преобразуем гессиан регуляризованного функционала:

$$H_F = H_Q + \lambda I.$$

Подставим спектральное разложение:

$$H_F = U\Lambda U^T + \lambda I.$$

Так как U ортогональна, то

$$I = UU^T.$$

Следовательно,

$$H_F = U\Lambda U^T + \lambda UU^T = U(\Lambda + \lambda I)U^T.$$

Значит, собственные значения гессиана H_F равны

$$\lambda_i + \lambda, \qquad i = 1, \ldots, d.$$

То есть L_2-регуляризация аддитивно сдвигает весь спектр гессиана.

Поскольку исходный гессиан H_Q положительно определён, то его коэффициент обусловленности задаётся как

$$\kappa(H_Q) = \frac{\lambda_{\max}}{\lambda_{\min}},$$

где

$$\lambda_{\max} = \max_i \lambda_i, \qquad \lambda_{\min} = \min_i \lambda_i.$$

Для регуляризованного функционала получаем

$$\kappa(H_F) = \frac{\lambda_{\max} + \lambda}{\lambda_{\min} + \lambda}.$$

При $\lambda > 0$ и $\lambda_{\max} > \lambda_{\min} > 0$ выполнено

$$\frac{\lambda_{\max} + \lambda}{\lambda_{\min} + \lambda} < \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Следовательно,

$$\kappa(H_F) < \kappa(H_Q).$$

Поскольку все собственные значения гессиана H_Q увеличиваются на λ, рельеф функционала F становится менее вытянутым: направления получают дополнительную кривизну.

■

Таким образом, L_2-регуляризация уменьшает коэффициент обусловленности гессиана функционала и тем самым улучшает геометрию задачи для градиентных методов.

Покажем теперь, как это улучшение рельефа связано с почти линейной зависимостью признаков. Для этого рассмотрим задачу регрессии с функционалом MSE.

Пусть

$$\mathcal{Y} = \mathcal{Z} = \mathbb{R}, \qquad \varphi(t) = t.$$

Для линейной регрессии с квадратичным функционалом ошибки имеем

$$Q(w) = \frac{1}{2\ell}\|Xw - y\|_2^2 \longrightarrow \min_w.$$

Добавим L_2-регуляризацию:

$$F(w) = \frac{1}{2\ell}\|Xw - y\|_2^2 + \frac{\lambda}{2}\|w\|_2^2 \longrightarrow \min_w.$$

Найдём градиент функционала F. Для MSE известно, что

$$\nabla_w \left(\frac{1}{2\ell}\|Xw - y\|_2^2 \right) = \frac{1}{\ell} X^T (Xw - y).$$

Для регуляризатора имеем

$$\nabla_w \left(\frac{\lambda}{2}\|w\|_2^2 \right) = \lambda w.$$

Следовательно,

$$\nabla_w F(w) = \frac{1}{\ell} X^T (Xw - y) + \lambda w.$$

Теперь найдём гессиан. Дифференциал первого слагаемого градиента равен

$$d_w \left[\frac{1}{\ell} X^T (Xw - y) \right] = \frac{1}{\ell} X^T X \, dw.$$

Дифференциал второго слагаемого равен

$$d_w(\lambda w) = \lambda \, dw.$$

Следовательно,

$$H_F = \frac{1}{\ell} X^T X + \lambda I = H_Q + \lambda I.$$

Пусть признаки почти линейно зависимы. Это означает, что существует вектор $v \in \mathbb{R}^d$ такой, что $\|v\|_2 = 1$ и $Xv \approx 0$. Тогда

$$\frac{1}{\ell} X^T X v = \frac{1}{\ell} X^T (Xv) \approx 0.$$

Следовательно, столбцы гессиана H_Q почти линейно зависимы.

В случае точной линейной зависимости $Xv = 0$ получаем $H_Q v = 0$. То есть у гессиана H_Q существует собственное значение, равное нулю.

В случае же почти линейной зависимости гессиан может оставаться положительно определённым, однако у него появляется очень малое собственное значение:

$$\lambda_i \approx 0.$$

Поэтому матрица H_Q становится плохо обусловленной:

$$\kappa(H_Q) \gg 1.$$

Геометрически это означает, что у рельефа функционала ошибки появляется сильно вытянутое, почти плоское направление.

По доказанному выше утверждению собственные значения гессиана получают прибавку λ:

$$\lambda_i \mapsto \lambda_i + \lambda.$$

Поэтому почти нулевые собственные значения перестают быть почти нулевыми:

$$\lambda_i + \lambda \geq \lambda.$$

Следовательно, регуляризованный функционал имеет менее вытянутый рельеф, что улучшает условия сходимости градиентных методов.

Ранее было получено аналитическое решение для оптимального вектора весов в линейной регрессии с квадратичной функцией потерь. В случае L_2-регуляризации формула получается аналогичным образом.

Для функционала

$$F(w) = \frac{1}{2\ell}\|Xw - y\|_2^2 + \frac{\lambda}{2}\|w\|_2^2$$

получаем

$$w^* = (X^T X + \lambda I)^{-1} X^T y.$$

Прежде матрица $X^T X$ могла быть вырожденной или плохо обусловленной. В таком случае обращение этой матрицы либо невозможно, либо численно неустойчиво. Добавление слагаемого λI смягчает эту проблему. Матрица $X^T X + \lambda I$ становится положительно определённой при ненулевой регуляризации, и задача получает единственное устойчивое решение.

Отметим, что почти линейная зависимость в исходной матрице признаков может приводить к почти линейной зависимости столбцов гессиана и для других функционалов ошибки. В данном случае был рассмотрен самый явный случай.

Таким образом, использование L_2-регуляризации помогает сразу в нескольких ситуациях. Во-первых, она препятствует искусственному наращиванию весов и тем самым снижает риск переобучения. Во-вторых, она улучшает рельеф функционала ошибки при скрытых почти линейных зависимостях признаков и тем самым способствует более устойчивой работе градиентных методов.

6.2 L_1-регуляризация

После предварительной обработки входных данных и возможного построения новых признаков размерность признакового описания может существенно увеличиться. При этом матрица признаков может содержать неинформативные признаки, а также сильно коррелированные признаки.

Как было показано ранее, приближённые линейные зависимости между признаками могут приводить к нестабильности обучения. Кроме того, большая размерность признакового пространства замедляет как процесс обучения модели, так и последующее вычисление её выходов.

Использование L_1-регуляризации может приводить к обнулению части весов, тем самым делая модель более разреженной. Разреженность модели полезна по двум основным причинам. Во-первых, она ускоряет работу модели, поскольку выход модели начинает зависеть только от части признаков. Во-вторых, она позволяет занулять веса при признаках, которые являются неинформативными с точки зрения оптимизации.

Покажем, почему L_1-регуляризация способна занулять веса чаще, чем L_2-регуляризация.

Для сравнения рассмотрим регуляризационные слагаемые

$$\frac{\lambda}{2}\|w\|_2^2 \text{ и } \lambda\|w\|_1.$$

Для L_2-регуляризации имеем

$$\nabla_w \left(\frac{\lambda}{2}\|w\|_2^2\right) = \lambda w.$$

Для L_1-регуляризации производная по координатам имеет вид

$$\partial_{w_j}(\lambda\|w\|_1) = \begin{cases} \lambda, & w_j > 0, \\ \lambda[-1,1], & w_j = 0, \\ -\lambda, & w_j < 0. \end{cases}$$

Поскольку функция недифференцируема в нуле, в этой точке используется субградиент. Вне нулевых координат это можно записать в векторном виде:

$$\partial_w \left(\lambda \|w\|_1\right) = \lambda \operatorname{sign}(w).$$

Как можно увидеть, производная L_2-регуляризации зависит от значения веса. Если

$$w_j \to 0, \implies \lambda w_j \to 0.$$

Поэтому в окрестности нуля L_2-регуляризация действует всё слабее. Она уменьшает веса, но обычно не зануляет их точно.

В то же время производная L_1-регуляризации вне нуля не зависит от величины веса. Для любого ненулевого w_j регуляризационное слагаемое действует с постоянной по модулю силой:

$$\left|\lambda \operatorname{sign}(w_j)\right| = \lambda.$$

Поэтому L_1-регуляризация способна доводить малые веса до нуля.

На практике точное зануление зависит от используемого численного метода. В обычном градиентном спуске вес может попасть лишь в малую окрестность нуля. Поэтому часто используются специальные процедуры, например проксимальные шаги или условия вида $|w_j| < C_k$, где C_k — некоторая динамически изменяющаяся величина оптимизации. При выполнении такого условия вес зануляется явно.

Таким образом, если признак является неинформативным с точки зрения оптимизатора и в результате оптимизации его вес оказывается небольшим по модулю, то L_1-регуляризация в большинстве случаев занулит этот вес.

Теперь рассмотрим поведение L_1-регуляризации при почти линейно зависимых признаках.

Пусть

$$x_1 \approx x_2.$$

Также пусть оптимизируется функционал ошибки с L_1-регуляризацией. Предположим, что в процессе оптимизации значение функционала уже практически стабилизировалось, однако веса w_1 и w_2 при почти линейно зависимых признаках ещё могут перераспределяться.

Напомним, что для двух весов L_1-регуляризатор имеет вид

$$R_{L_1}(w_1, w_2) = |w_1| + |w_2|.$$

Пусть за один шаг оптимизации веса изменяются следующим образом:

$$w_1 \mapsto w_1 + \Delta,$$

$$w_2 \mapsto w_2 - \Delta.$$

Рассмотрим поведение L_1-регуляризации при таком изменении весов. Пусть

$$p = w_1 + w_2.$$

Тогда сумма весов не меняется:

$$(w_1 + \Delta) + (w_2 - \Delta) = w_1 + w_2 = p.$$

Сначала рассмотрим случай, когда веса одного знака. Тогда

$$|w_1| + |w_2| = |w_1 + w_2| = |p|.$$

Если после такого изменения веса всё ещё остаются одного знака, то

$$|w_1 + \Delta| + |w_2 - \Delta| = |(w_1 + \Delta) + (w_2 - \Delta)|.$$

Следовательно,

$$|w_1 + \Delta| + |w_2 - \Delta| = |p|.$$

То есть пока веса остаются одного знака, значение L_1-регуляризатора не изменяется.

Теперь рассмотрим ситуацию, когда при дальнейшем изменении веса становятся разных знаков. Тогда по неравенству треугольника имеем

$$|w_1 + \Delta| + |w_2 - \Delta| > |(w_1 + \Delta) + (w_2 - \Delta)|.$$

Поскольку сумма равна p, получаем

$$|w_1 + \Delta| + |w_2 - \Delta| > |p|.$$

Следовательно, после перехода весов к разным знакам значение L_1-регуляризатора начинает возрастать.

Таким образом, пока два веса одного знака и их сумма фиксирована, L_1-норма не меняется. Но если дальнейшее изменение весов приводит к появлению противоположных знаков, то L_1-норма становится больше.

Следовательно, если два признака почти линейно зависимы, то L_1-регуляризация может занулить один из связанных весов, а второй увеличить на соответствующую величину, сохранив общий вклад пары признаков. Иными словами, L_1-регуляризация может перекинуть всю массу в один из двух похожих признаков:

$$(w_1, w_2) \quad \longrightarrow \quad (p, 0)$$

или

$$(w_1, w_2) \quad \longrightarrow \quad (0, p).$$

В обоих случаях сумма весов остаётся равной p, но один из весов становится нулевым.

Таким образом, L_1-регуляризация помогает сразу в нескольких ситуациях. Во-первых, она препятствует наращиванию весов. Во-вторых, она может зануллять часть весов, оставляя только признаки, которые являются информативными с точки зрения оптимизации. В-третьих, при почти линейно зависимых признаках она может оставить только один признак из группы похожих признаков.

Однако необходимо отметить отличие L_1-регуляризации от L_2-регуляризации. L_2-регуляризация добавляет к гессиану слагаемое λI и тем самым гарантированно добавляет кривизну во все направления. Для L_1-регуляризации такого эффекта нет.

Улучшение рельефа может произойти только косвенно. Если L_1-регуляризация занулит вес при одном из почти линейно зависимых признаков, то этот признак фактически перестанет участвовать в модели. Тогда активное множество признаков уменьшится, и почти линейная зависимость может исчезнуть.

Но такое улучшение **не** гарантируется. Если L_1-регуляризация не занулит веса почти линейно зависимых признаков, то соответствующая почти линейная зависимость сохранится, а вместе с ней сохранятся и связанные с ней проблемы рельефа функционала.

ЛИНЕЙНАЯ КЛАССИФИКАЦИЯ

В задачах классификации целевая переменная принимает значения из конечного множества классов.

Принято выделять три основных варианта классификации: бинарную классификацию (binary classification), многоклассовую классификацию (multiclass classification) и многометочную классификацию (multilabel classification).

В задаче бинарной классификации каждый объект относится к одному из двух классов. В многоклассовой классификации классов больше двух, при этом каждый объект имеет ровно одну метку класса. В многометочной классификации один объект может одновременно принадлежать нескольким классам.

Два последних варианта можно рассматривать как обобщения бинарной классификации. В данной главе сначала будет рассмотрена постановка задачи бинарной классификации и методы её решения. Затем будет обсуждаться сведение многоклассовой и многометочной классификации к набору бинарных задач.

Отметим, что для многоклассовой и многометочной классификации существуют и самостоятельные методы решения. Однако в данной главе эти задачи будут рассматриваться именно через сведение к бинарной классификации.

7 БИНАРНАЯ КЛАССИФИКАЦИЯ

Рассмотрим задачу бинарной классификации. Пусть

$$\mathcal{X} = \mathbb{R}^d, \qquad \mathcal{Y} = \{0, 1\}.$$

Будем считать, что класс 1 называется положительным. Соответственно, класс 0 называется отрицательным.

Пусть также задано пространство выходов модели $\mathcal{Z}$, а модель $\alpha \in \mathcal{A}_{\text{lin}}$ задана с некоторой функцией φ.

Введём отображение

$$\delta : \mathcal{Z} \to \mathcal{Y},$$

которое переводит выход модели в целевое значение.

Тогда **классификатором** будем называть $\delta \circ \alpha$ и записывать как

$$\alpha_\delta(x) = \delta(\alpha(x)).$$

Порогом будем называть гиперпараметр $\tau \in \mathcal{Z}$, который задаёт границу на шкале числовых выходов модели. По разные стороны этой границы объектам сопоставляются разные классы.

В задаче бинарной классификации отображение δ часто зависит от порогового параметра. В этом случае будем обозначать его через δ_τ.

Например, если $\mathcal{Z} = \mathbb{R}$, то отображение δ_τ можно задать следующим образом

$$\delta_\tau(z) = \begin{cases} 1, & z - \tau \geq 0, \\ 0, & z - \tau < 0. \end{cases}$$

Поскольку после применения δ_τ классификатор возвращает бинарное значение класса, естественно рассмотреть индикатор ошибки классификации

$$\mathbb{I}\left(y, \alpha_{\delta_\tau}(x)\right) = \left[y \neq \alpha_{\delta_\tau}(x)\right].$$

Этот индикатор равен 1, если классификатор ошибся на объекте x, и равен 0, если ответ был правильным.

Тогда функционал ошибки, соответствующий индикатору ошибки классификации, имеет вид

$$Q_{\mathbb{I}}(\alpha_{\delta_\tau}, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left[y_i \neq \alpha_{\delta_\tau}(x_i) \right] \to \min_w .$$

Этот функционал называется долей ошибок (error rate), поскольку он показывает, на какой доле объектов обучающей выборки классификатор дал неправильный ответ.

Однако данный функционал является дискретным относительно параметров модели. Поэтому оптимизировать его напрямую градиентными методами не представляется возможным. Кроме того, такой функционал может иметь много глобальных минимумов, поскольку разные значения параметров могут приводить к одному и тому же значению функционала.

Перейдём к функционалу, пригодному для градиентной оптимизации. Для этого оценим индикатор ошибки классификации сверху другой, почти всюду дифференцируемой функцией потерь. В качестве такой функции будем использовать $\widetilde{L}$, для которой

$$\mathbb{I}\left(y, \alpha_{\delta_\tau}(x)\right) \leq \widetilde{L}(y, \alpha(x)).$$

В этом случае для функционала ошибки получаем верхнюю оценку:

$$Q_{\mathbb{I}}(\alpha_{\delta_\tau}, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbb{I}\left(y_i, \alpha_{\delta_\tau}(x_i)\right) \leq \frac{1}{\ell} \sum_{i=1}^{\ell} \widetilde{L}(y_i, \alpha(x_i)) \to \min_w .$$

Таким образом, вместо дискретного функционала доли ошибок рассматривается оптимизация его верхней оценки. Поскольку функция $\widetilde{L}$ является почти всюду дифференцируемой по параметрам модели, полученный функционал можно минимизировать градиентными методами.

Возможные варианты таких верхних оценок будут рассмотрены далее в рамках вероятностной и геометрической постановок задачи бинарной классификации.

7.1 Метрики качества классификации

После обучения модели и задания отображения δ возникает необходимость оценить качество полученного классификатора. Рассмотрим несколько подходов к его оценке.

Accuracy.

Наиболее простой метрикой качества является доля правильных ответов (accuracy):

$$\text{accuracy}(\alpha_{\delta_\tau}, \mathcal{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left[y_i = \alpha_{\delta_\tau}(x_i) \right].$$

Данная метрика показывает, на какой доле объектов обучающей выборки классификатор дал правильный ответ.

Однако доля правильных ответов имеет существенный недостаток. Рассмотрим пример. Пусть в выборке содержится 950 отрицательных объектов и 50 положительных объектов. Предположим, что классификатор всегда относит объект к отрицательному классу: $\alpha_{\delta_\tau}(x) \equiv 0$. Тогда он правильно классифицирует все отрицательные объекты и ошибается на всех положительных объектах. Поэтому

$$\text{accuracy}(\alpha_{\delta_\tau}, \mathcal{D}) = \frac{950}{1000} = 0.95.$$

Таким образом, высокая доля правильных ответов сама по себе не всегда означает, что классификатор хорошо решает задачу. В частности, при сильном дисбалансе классов данная метрика может вводить в заблуждение. Поэтому вместе с accuracy необходимо анализировать соотношение классов в выборке.

7.1.1 Матрица ошибок

Неустойчивость доли правильных ответов к дисбалансу классов мотивирует введение более устойчивых метрик качества. Для их определения введём матрицу ошибок.

Поясним, как читать матрицу, представленную в таблице 1. По столбцам расположены истинные классы объектов, а по строкам — ответы классификатора.

Таблица 1 – Матрица ошибок для задачи бинарной классификации

	$y = 1$	$y = 0$
$\alpha_{\delta_\tau}(x) = 1$	True Positive (TP)	False Positive (FP)
$\alpha_{\delta_\tau}(x) = 0$	False Negative (FN)	True Negative (TN)

Величина TP равна числу правильно классифицированных положительных объектов. Величина FP равна числу отрицательных объектов, ошибочно отнесённых к положительному классу. Величина TN равна числу правильно классифицированных отрицательных объектов. Величина FN равна числу положительных объектов, ошибочно отнесённых к отрицательному классу.

Отметим, что суммы по столбцам соответствуют числу объектов соответствующих классов. В частности, $TP + FN$ равно числу положительных объектов в выборке, а $FP + TN$ равно числу отрицательных объектов в выборке.

Сумма всех элементов матрицы ошибок равна общему числу объектов

$$TP + TN + FP + FN = \ell.$$

Следовательно, долю правильных ответов можно выразить через элементы матрицы ошибок:

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

Precision и Recall.

Определим две более информативные метрики качества.

– Точность (precision):

$$\text{precision} = \frac{TP}{TP + FP}.$$

– Полнота (recall):

$$\text{recall} = \frac{TP}{TP + FN}.$$

Точность показывает, какая доля объектов, выделенных классификатором как положительные, действительно является положительными. Полнота, в свою очередь, показывает, какая часть положительных объектов была выделена классификатором.

Рассмотрим пример задачи классификации мошеннических транзакций (fraud detection). Пусть $y = 1$ означает, что транзакция является мошеннической, а $y = 0$ означает, что транзакция не является мошеннической. Необходимо блокировать только те транзакции, которые классификатор относит к положительному классу.

Если классификатор имеет высокую точность, то практически все заблокированные транзакции будут мошенническими. Однако число блокировок при этом может быть незначительным. Если классификатор имеет высокую полноту, то будут заблокированы практически все мошеннические транзакции. Однако вместе с этим может возрасти число ошибочных блокировок.

Следовательно, в зависимости от условий задачи необходимо регулировать соотношение между точностью и полнотой. Для этого используется порог τ. Если выбрать порог большим, то классификатор будет относить к положительному классу меньшее число объектов. Это обычно приводит к более высокой точности и более низкой полноте. По ходу уменьшения величины порога классификатор начинает относить к положительному классу больше объектов. Поэтому полнота неубывает, а точность, как правило, снижается из-за увеличения числа ложноположительных ответов.

Величина порога подбирается по валидационной выборке в соответствии с условиями конкретной задачи.

Дополним предыдущий пример. Пусть дана валидационная выборка, состоящая из пяти объектов:

$$\begin{aligned}
\alpha(x_1) &= 0.2, \quad y_1 = 0,\\
\alpha(x_2) &= 0.4, \quad y_2 = 1,\\
\alpha(x_3) &= 0.1, \quad y_3 = 0,\\
\alpha(x_4) &= 0.7, \quad y_4 = 1,\\
\alpha(x_5) &= 0.05, \quad y_5 = 1,
\end{aligned}$$

где $\alpha(x_i)$ — значение выхода модели на объекте x_i, а y_i — истинное целевое значение.

Пусть для задачи классификации мошеннических транзакций заданы следующие условия:

$$\begin{cases} \text{precision} \geq 0.9, \\ \text{recall} \to \max . \end{cases}$$

То есть необходимо среди порогов, обеспечивающих точность не меньше 0.9, выбрать тот, который даёт наибольшую полноту.

Подберём порог для заданных условий. Отсортируем объекты по невозрастанию значения выхода модели. Далее для каждого рассматриваемого значения τ вычислим точность и полноту. Результаты вычислений приведены в таблице 2.

Таблица 2 – Зависимость точности и полноты от значения порога

τ	Объекты, отнесённые к классу 1	precision	recall
0.7	x_4	1	$\frac{1}{3}$
0.4	x_4, x_2	1	$\frac{2}{3}$
0.2	x_4, x_2, x_1	$\frac{2}{3}$	$\frac{2}{3}$
0.1	x_4, x_2, x_1, x_3	$\frac{2}{4}$	$\frac{2}{3}$
0.05	x_4, x_2, x_1, x_3, x_5	$\frac{3}{5}$	1

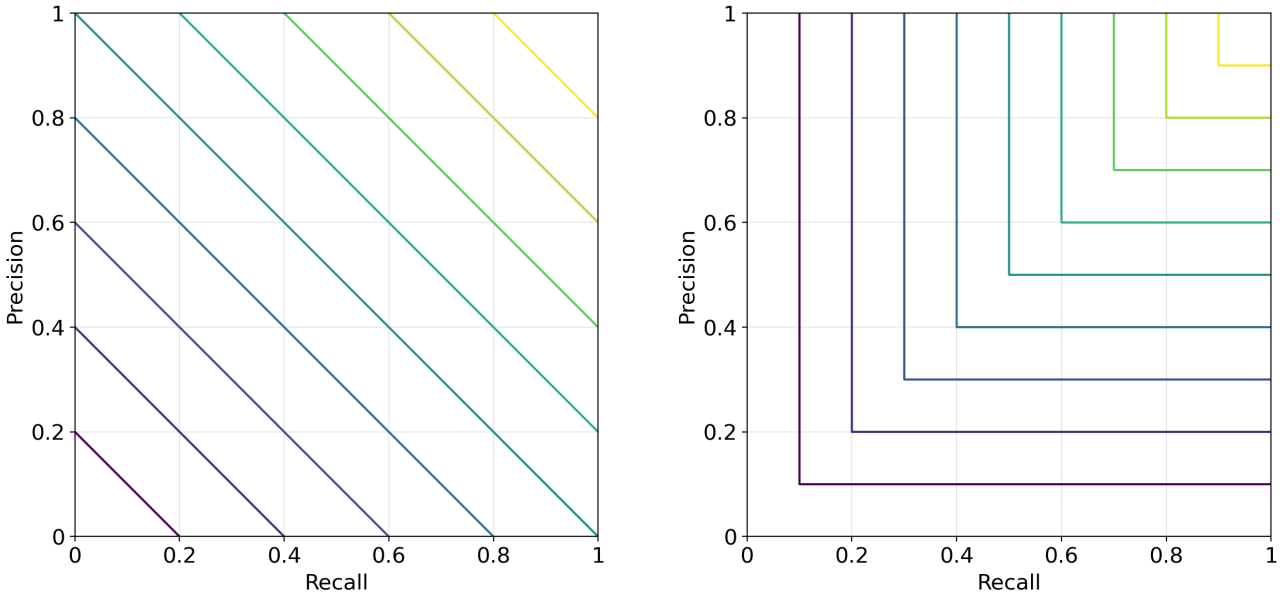
Нетрудно заметить, что при заданных условиях оптимальным является порог $\tau = 0.4$.

Точность и полнота описывают разные аспекты качества классификатора. Поэтому при сравнении классификаторов без заранее заданных условий может возникнуть ситуация, в которой не очевидно, какой классификатор лучше. Для получения одной численной характеристики вводятся агрегированные величины. Рассмотрим несколько способов объединения точности и полноты.

Далее будем обозначать

$$P = \text{precision}, \qquad R = \text{recall} .$$

Среднее арифметическое.



а) среднее арифметическое б) минимум

Рисунок 3 – Линии уровня среднего арифметического и минимума

Самой очевидной функцией агрегации является среднее арифметическое:

$$A(P, R) = \frac{P + R}{2}.$$

Линии уровня величины A изображены на рисунке 3 (а).

Агрегация средним арифметическим имеет несколько существенных недостатков. Как можно заметить из линий уровня, величина A принимает одинаковые значения как при близких значениях точности и полноты, так и при их существенном различии. Более того, данная величина не обращается в ноль, если только одна из величин P или R равна нулю. Поэтому среднее арифметическое обычно не используют как агрегированную метрику точности и полноты.

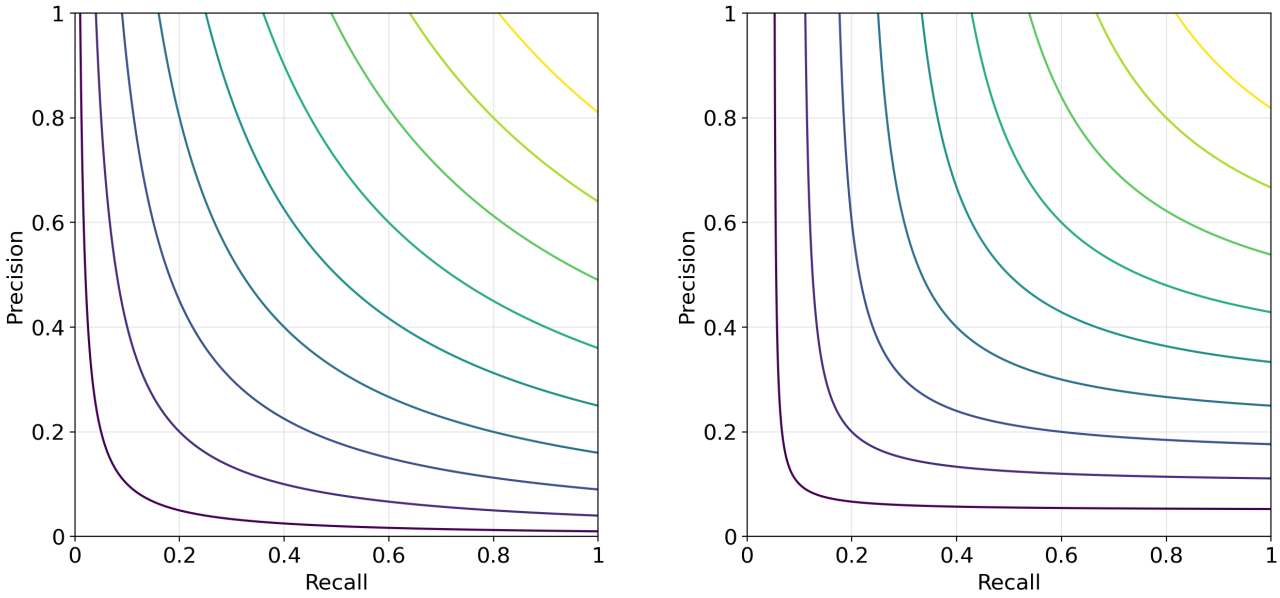
Минимум.

Другим способом агрегации является выбор минимального значения между точностью и полнотой:

$$\mathrm{Min}(P, R) = \min(P, R).$$

Линии уровня этой величины изображены на рисунке 3 (б).

Функция минимума является достаточно *жёсткой* величиной, поскольку полностью игнорирует большую из двух величин. Поэтому она может быть



а) среднее геометрическое б) среднее гармоническое

Рисунок 4 – Линии уровня среднего геометрического и среднего гармонического

применима в тех случаях, когда заданы достаточно *жёсткие* требования одновременно к точности и полноте.

Среднее геометрическое.

Более *мягким* решением является среднее геометрическое:

$$G(P, R) = \sqrt{PR}.$$

Линии уровня этой величины изображены на рисунке 4 (а).

Как можно заметить из рисунка, среднее геометрическое более сбалансированно учитывает изменения точности и полноты. Однако оно может слишком *мягко* агрегировать малые значения одной из величин. Иными словами, если точность или полнота принимает малое значение, то величина G всё ещё может оставаться достаточно большой.

Среднее гармоническое.

Среднее гармоническое является более *жёсткой* версией среднего геометрического:

$$F_1(P, R) = \frac{2PR}{P + R}.$$

Линии уровня среднего гармонического изображены на рисунке 4 (б).

Действительно, как можно заметить из рисунка, линии уровня среднего гармонического имеют большую кривизну. Поэтому среднее гармоническое чувствительнее к дисбалансу величин.

Установим связь между рассмотренными агрегирующими величинами. Для любой пары $P, R \in [0, 1]$ справедливо неравенство

$$\mathrm{Min}(P, R) \leq F_1(P, R) \leq G(P, R) \leq A(P, R).$$

То есть среднее гармоническое является более *мягким* методом агрегации по сравнению с минимумом и более консервативным методом агрегации по сравнению со средним геометрическим. Вследствие этого именно среднее гармоническое часто используют для объединения точности и полноты в одну величину.

Взвешенное среднее гармоническое.

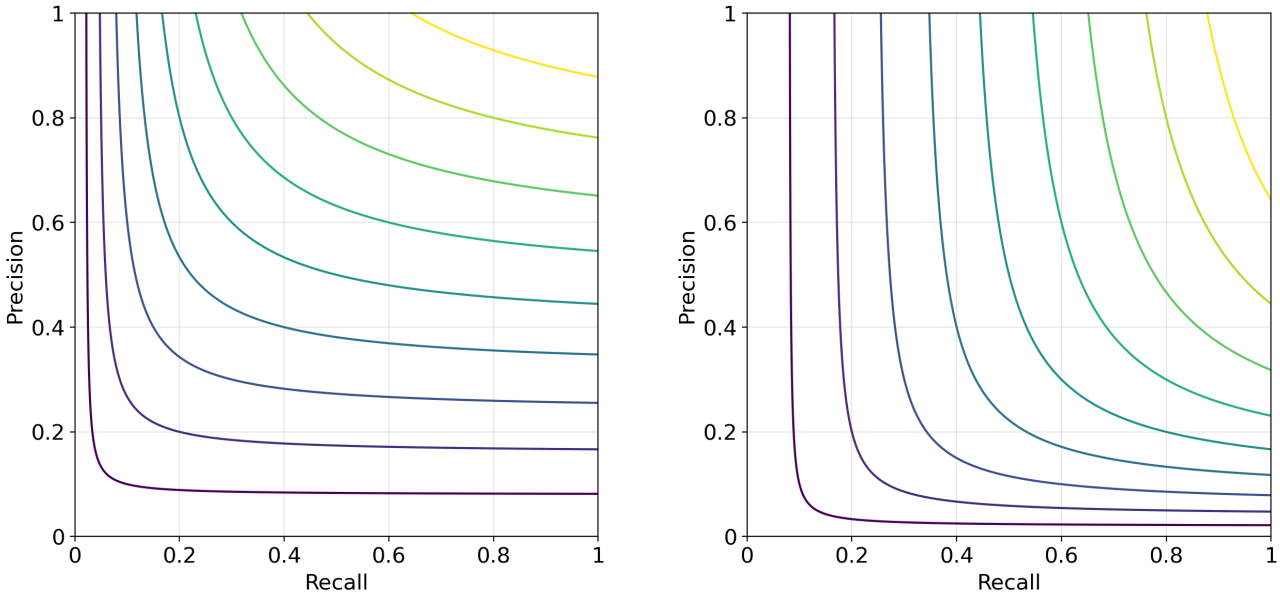
При использовании среднего гармонического может возникнуть необходимость *мягко* сместить величину F в сторону точности или полноты, сохранив при этом общий консервативный подход. Для этого используется взвешенное среднее гармоническое:

$$F_\beta(P, R) = (1 + \beta^2)\frac{PR}{\beta^2 P + R},$$

где $\beta > 0$ — параметр, задающий баланс между точностью и полнотой.

Рассмотрим линии уровня величины F_β при $\beta = 0.5$ и $\beta = 2$, изображённые на рисунке 5 (а) и рисунке 5 (б) соответственно.

При $\beta = 0.5$ величина F_β отдаёт больший приоритет точности. То есть линии уровня допускают меньшие значения полноты только при достаточно больших значениях точности. Аналогично, при $\beta = 2$ величина F_β отдаёт больший приоритет полноте.



а) F_β при $\beta = 0.5$ б) F_β при $\beta = 2$

Рисунок 5 – Линии уровня взвешенного среднего гармонического

7.1.2 Численные характеристики ROC-кривой и PR-кривой

Ранее введённые метрики качества характеризуют качество работы классификатора при фиксированном значении порога τ. Однако в большинстве задач возникает необходимость оценить качество классификатора в целом, а значение порога подобрать позже в соответствии с условиями конкретной задачи.

Рассмотрим два основных подхода к такой оценке.

ROC-кривая.

Наиболее распространённой метрикой такого вида является площадь под ROC-кривой (AUC-ROC). Для её определения введём две величины, зависящие от порога τ.

– True Positive Rate (TPR):

$$\mathrm{TPR}(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)}.$$

– False Positive Rate (FPR):

$$\mathrm{FPR}(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)}.$$

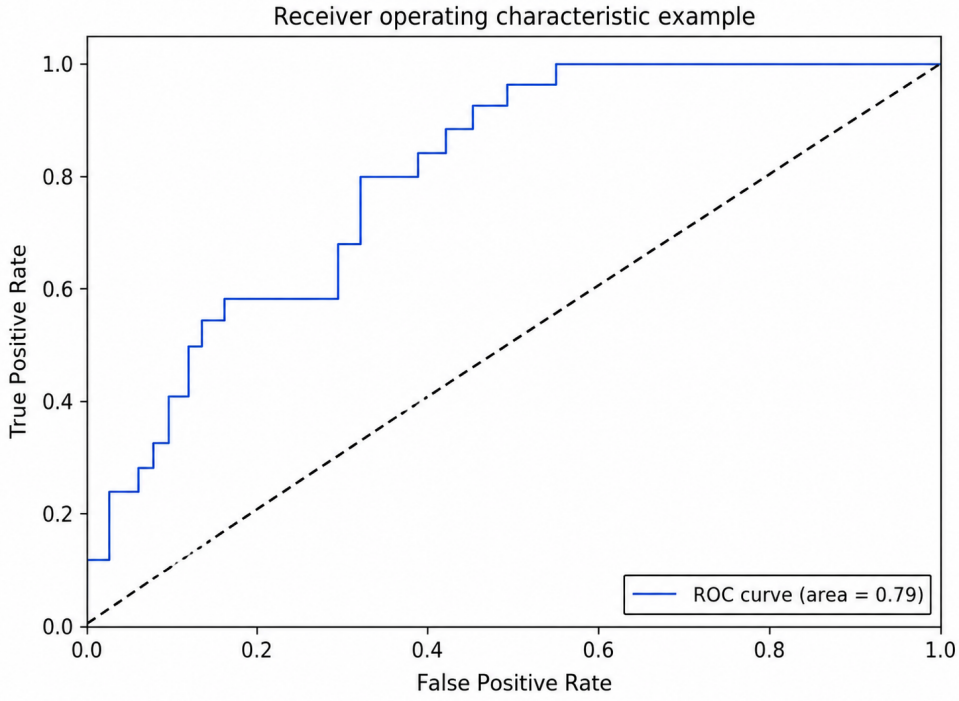


Рисунок 6 – Пример ROC-кривой

Величина $\mathrm{TPR}(\tau)$ показывает, какая доля положительных объектов была верно классифицирована при пороге τ. Величина $\mathrm{FPR}(\tau)$, в свою очередь, показывает, какая доля отрицательных объектов была ошибочно отнесена к положительному классу.

Рассмотрим плоскость, в которой по оси абсцисс отложена величина FPR, а по оси ординат — величина TPR. Каждый возможный выбор порога τ соответствует точке на этой плоскости. Пример ROC-кривой представлен на рисунке 6.

Поясним алгоритм построения ROC-кривой. Сначала все выходы модели $\alpha(x_i)$ сортируются в порядке невозрастания. Для более удобной интерпретации добавляется точка $(0, 0)$, соответствующая ситуации, в которой классификатор не относит ни один объект к положительному классу.

Далее для каждого рассматриваемого порога τ вычисляются соответствующие значения величин $\mathrm{TPR}(\tau)$ и $\mathrm{FPR}(\tau)$. Точка $(1, 1)$ достигается при $\tau = \min_i \alpha(x_i)$. Таким образом, ROC-кривая является кривой с концами в точках $(0, 0)$ и $(1, 1)$.

Площадь под ROC-кривой принимает значения от 0 до 1. Если классификатор безошибочно решает задачу, то площадь под ROC-кривой равна 1, а график ROC-кривой содержит точку $(0, 1)$.

Отметим, что ROC-кривая может быть неустойчива к дисбалансу классов. Пусть в выборке содержится 10 положительных объектов и 10000 отрицательных объектов. Рассмотрим классификатор, который при некотором значении порога имеет характеристики

$$TP = 9, \qquad FP = 100.$$

Очевидно, что данный классификатор плохо решает задачу, поскольку вместе с 9 верно найденными положительными объектами он ошибочно относит к положительному классу ещё 100 отрицательных объектов. Однако для данного порога имеем

$$\text{TPR} = \frac{9}{10} = 0.9, \qquad \text{FPR} = \frac{100}{10000} = 0.01.$$

Следовательно, на ROC-плоскости получаем точку $(0.01, 0.9)$, которая находится достаточно близко к точке, соответствующей идеальному классификатору.

Таким образом, при работе с ROC-кривой необходимо также анализировать соотношение классов в выборке.

PR-кривая.

PR-кривая (Precision-Recall curve) устроена схожим образом. Рассмотрим плоскость, в которой по оси абсцисс отложена величина $\text{recall}(\tau)$, а по оси ординат — величина $\text{precision}(\tau)$. Каждый возможный выбор порога τ также соответствует точке на этой плоскости. Пример PR-кривой представлен на рисунке 7.

В качестве численной характеристики PR-кривой часто используют величину AP (Average Precision). Для её определения отсортируем выходы модели $\alpha(x_i)$ по невозрастанию:

$$\alpha(x_{(1)}) \geq \alpha(x_{(2)}) \geq \cdots \geq \alpha(x_{(\ell)}),$$

где $x_{(k)}$ — объект, находящийся на k-й позиции после сортировки, а $y_{(k)}$ — соответствующее истинное целевое значение.

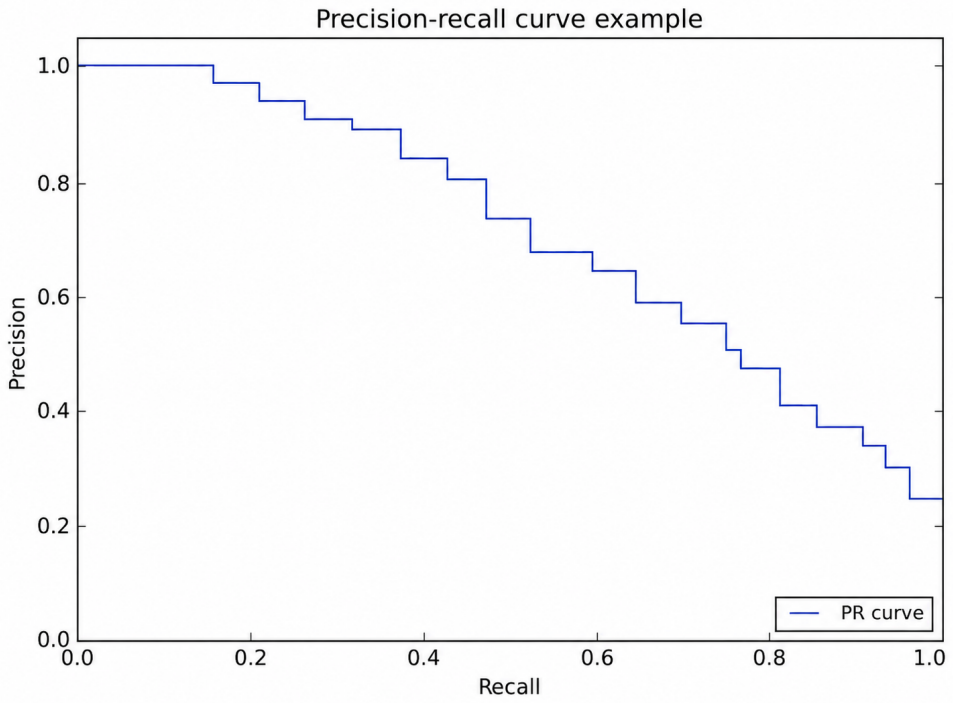


Рисунок 7 – Пример PR-кривой

Обозначим через ℓ_+ число положительных объектов в выборке:

$$\ell_+ = \sum_{i=1}^{\ell} [y_i = 1].$$

Пусть среди первых k объектов накоплено

$$TP_k = \sum_{j=1}^{k} [y_{(j)} = 1].$$

Тогда

$$\text{precision}\,@k = \frac{TP_k}{k}, \qquad \text{recall}\,@k = \frac{TP_k}{\ell_+}.$$

Введём величину AP:

$$\text{AP} = \sum_{k=1}^{\ell} \text{precision}\,@k\,(\text{recall}\,@k - \text{recall}\,@(k-1)), \qquad \text{recall}\,@0 = 0.$$

Данную величину можно интерпретировать как сумму вкладов по изменениям полноты.

Раскроем изменение полноты:

$$\text{recall}\,@k - \text{recall}\,@(k-1) = \frac{TP_k}{\ell_+} - \frac{TP_{k-1}}{\ell_+} = \frac{TP_k - TP_{k-1}}{\ell_+}.$$

Заметим, что при переходе от позиции $k-1$ к позиции k число истинно положительных ответов увеличивается на единицу только тогда, когда k-й объект является положительным:

$$TP_k - TP_{k-1} = [y_{(k)} = 1].$$

Следовательно,

$$\text{AP} = \frac{1}{\ell_+} \sum_{k=1}^{\ell} [y_{(k)} = 1]\,\text{precision}\,@k.$$

Таким образом, величина AP является характеристикой PR-кривой и усредняет значения precision в позициях, на которых в отсортированном списке находятся положительные объекты.

В то же время PR-кривая более устойчива к дисбалансу классов. Вернёмся к примеру, рассмотренному ранее для ROC-кривой. Для

$$TP = 9, \qquad FP = 100$$

имеем

$$\text{recall} = \frac{9}{10}, \qquad \text{precision} = \frac{9}{109}.$$

То есть PR-кривая в данном случае даёт более разумную оценку качества.

В заключение обсуждения метрик бинарной классификации приведём пример расчёта AUC-ROC и AP. Пусть дана валидационная выборка, состоящая из шести объектов:

$$\begin{aligned}
&\alpha(x_1) = 0.2, \quad y_1 = 0,\\
&\alpha(x_2) = 0.4, \quad y_2 = 1,\\
&\alpha(x_3) = 0.1, \quad y_3 = 0,\\
&\alpha(x_4) = 0.7, \quad y_4 = 1,\\
&\alpha(x_5) = 0.05, \quad y_5 = 1,\\
&\alpha(x_6) = 0.4, \quad y_6 = 0,
\end{aligned}$$

где $\alpha(x_i)$ — значение выхода модели на объекте x_i, а y_i — истинное целевое значение.

Отсортируем выходные значения модели по невозрастанию. Сначала построим ROC-кривую. Для каждого значения τ вычислим величины FPR и TPR. Результаты вычислений приведены в таблице 3.

Таблица 3 – Зависимость TPR и FPR от значения порога

τ	Объекты, отнесённые к классу 1	FPR	TPR
0.7	x_4	0	$\frac{1}{3}$
0.4	x_4, x_2, x_6	$\frac{1}{3}$	$\frac{2}{3}$
0.2	x_4, x_2, x_6, x_1	$\frac{2}{3}$	$\frac{2}{3}$
0.1	x_4, x_2, x_6, x_1, x_3	1	$\frac{2}{3}$
0.05	$x_4, x_2, x_6, x_1, x_3, x_5$	1	1

Теперь построим ROC-кривую по полученным точкам. Результат построения кривой изображён на рисунке 8 (а). Вычислим площадь под ROC-кривой методом трапеций.

Для этого разобьём площадь на две части точкой FPR = $\frac{1}{3}$. Площадь слева от этой точки по формуле трапеции равна

$$\frac{1}{2}\left(\frac{1}{3}+\frac{2}{3}\right)\cdot\frac{1}{3}=\frac{1}{6}.$$

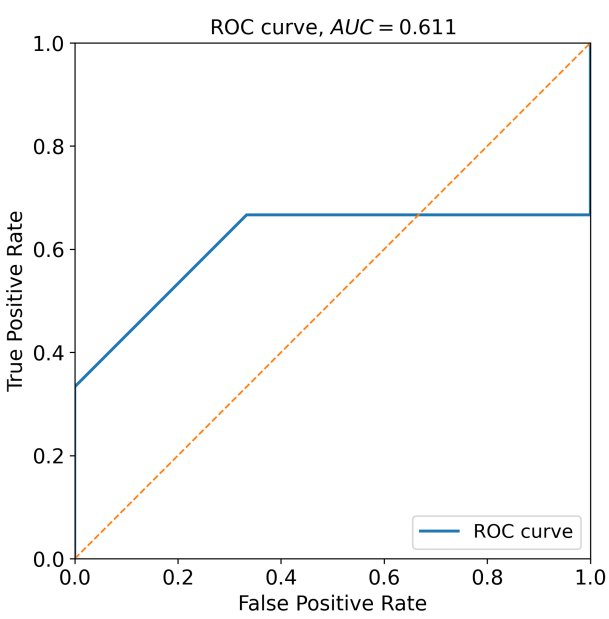
Площадь справа от этой точки равна площади квадрата:

$$\frac{2}{3}\cdot\frac{2}{3}=\frac{4}{9}.$$

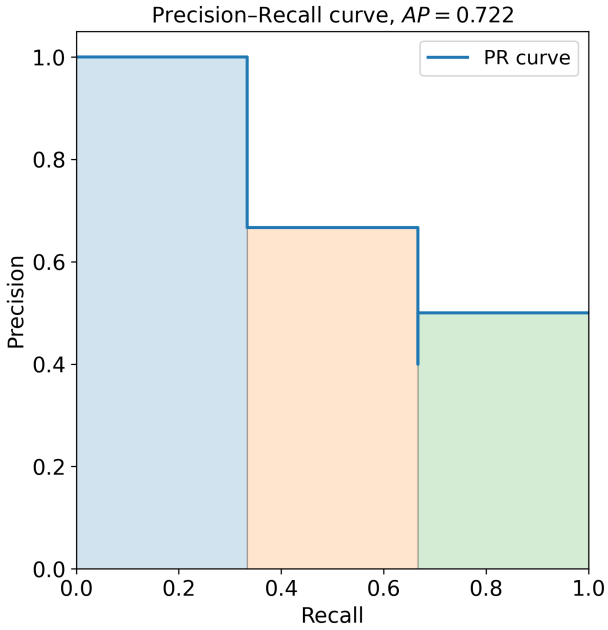
Следовательно,

$$\text{AUC-ROC}=\frac{1}{6}+\frac{4}{9}=\frac{11}{18}\approx 0.611.$$

Перейдём к построению PR-кривой. Для каждого значения τ вычислим точность и полноту. Результаты вычислений приведены в таблице 4.



а) ROC-кривая



б) PR-кривая

Рисунок 8 – ROC-кривая и PR-кривая при различных значениях порога

Таблица 4 – Зависимость точности и полноты от значения порога

τ	Объекты, отнесённые к классу 1	precision	recall
0.7	x_4	1	$\frac{1}{3}$
0.4	x_4, x_2, x_6	$\frac{2}{3}$	$\frac{2}{3}$
0.2	x_4, x_2, x_6, x_1	$\frac{2}{4}$	$\frac{2}{3}$
0.1	x_4, x_2, x_6, x_1, x_3	$\frac{2}{5}$	$\frac{2}{3}$
0.05	$x_4, x_2, x_6, x_1, x_3, x_5$	$\frac{3}{6}$	1

Будем строить данную кривую в ступенчатой дискретной форме по полученным точкам. Результат построения кривой изображён на рисунке 8 (б).

Теперь вычислим величину AP. Для этого просуммируем площади всех прямоугольников.

Таким образом,

$$\mathrm{AP} = 1 \cdot \frac{1}{3} + \frac{2}{3} \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{1}{3} = \frac{13}{18} \approx 0.722.$$

7.2 Метод опорных векторов

В данном подразделе рассмотрим геометрическую постановку бинарной классификации. Для этого в рамках данного подраздела переобозначим целевые значения по правилу $y \leftarrow 2y - 1$. То есть далее будем считать, что $y \in \{-1, +1\}$.

Поскольку линейная модель задаёт гиперплоскость, естественно использовать её для разделения объектов выборки.

Пусть $\mathcal{Z} = \mathbb{R}$ и $\varphi(t) = t$, а отображение δ_τ задано как $\delta_\tau(z) = \text{sign}(z - \tau)$. Тогда классификатор будем записывать в виде

$$\alpha_{\delta_\tau}(x) = \text{sign}\left(\langle w, x\rangle + w_0\right).$$

Здесь w является вектором нормали к гиперплоскости, а знак величины $\langle w, x\rangle + w_0$ определяет, по какую сторону от разделяющей гиперплоскости расположен объект.

Будем считать, что при $\langle w, x\rangle + w_0 = 0$ объект относится к положительному классу, то есть $\text{sign}(0) = +1$.

7.2.1 Линейно разделимый случай

Введём величину, называемую **отступом** (margin) на объекте x_i:

$$M_i = y_i\left(\langle w, x_i\rangle + w_0\right).$$

Знак отступа определяет корректность классификации. Если $M_i > 0$, то объект классифицирован правильно. Если $M_i < 0$, то классификация объекта является ошибочной. Величина $M_i = 0$ соответствует граничному случаю, при котором объект лежит на разделяющей гиперплоскости.

В то же время величину $|M_i|$ при фиксированных параметрах w, w_0 можно интерпретировать как степень уверенности модели в своём ответе на объекте x_i.

Выборка называется линейно разделимой, если существуют такие параметры w^*, w_0^*, что

$$y_i\left(\langle w^*, x_i\rangle + w_0^*\right) > 0, \qquad i = 1, \ldots, \ell.$$

Из аналитической геометрии известна формула расстояния от произвольной точки x_0 до гиперплоскости, задаваемой классификатором:

$$\rho(x_0, \alpha) = \frac{|\langle w, x_0 \rangle + w_0|}{\|w\|}.$$

Далее будем использовать её ориентированный аналог:

$$\widetilde{\rho}(x_i, \alpha) = \frac{y_i \left(\langle w, x_i \rangle + w_0\right)}{\|w\|} = \frac{M_i}{\|w\|}.$$

Для линейно разделимой выборки каждый объект классифицирован правильно, поэтому на объектах обучающей выборки величины $\widetilde{\rho}(x_i, \alpha)$ и $\rho(x_i, \alpha)$ совпадают.

Для улучшения обобщающей способности классификатора естественно максимизировать минимальное значение ориентированного расстояния $\widetilde{\rho}(x_i, \alpha)$ на объектах обучающей выборки. Таким образом, получаем задачу

$$\max_{w, w_0} \frac{\min\limits_{1 \le i \le \ell} y_i \left(\langle w, x_i \rangle + w_0\right)}{\|w\|}.$$

Заметим, что если одновременно умножить параметры w и w_0 на одну и ту же положительную константу, то классификатор не изменится. Действительно, для любого $c > 0$

$$\operatorname{sign}\left(\langle cw, x \rangle + cw_0\right) = \operatorname{sign}\left(\langle w, x \rangle + w_0\right).$$

Воспользуемся этим и преобразуем числитель. Поскольку $M_i > 0$ для любого i, обозначим $m = \min_i M_i$ и поделим параметры w и w_0 на величину m:

$$\min_i y_i \left(\left\langle \frac{w}{m}, x_i \right\rangle + \frac{w_0}{m}\right) = \frac{1}{m} \min_i y_i \left(\langle w, x_i \rangle + w_0\right) = \frac{m}{m} = 1.$$

Переобозначая нормированные параметры снова через w, w_0, получаем

$$\frac{\min\limits_i y_i \left(\langle w, x_i \rangle + w_0\right)}{\|w\|} = \frac{1}{\|w\|}.$$

Следовательно, максимизация минимального значения ориентированного расстояния эквивалентна минимизации нормы вектора w.

Таким образом, получаем прямую задачу метода опорных векторов для **линейно разделимого случая** (hard-margin support vector machine):

$$\begin{cases} \dfrac{1}{2}\|w\|^2 \to \min\limits_{w,w_0}, \\ y_i\left(\langle w, x_i\rangle + w_0\right) \geq 1, \qquad i = 1, \ldots, \ell. \end{cases}$$

Ограничения $y_i\left(\langle w, x_i\rangle + w_0\right) \geq 1$ означают, что отступ каждого объекта не меньше единицы. В оптимальном решении при наличии объектов обоих классов равенство достигается хотя бы на одном объекте каждого класса. Формально это будет показано далее с помощью условий Каруша–Куна–Таккера.

Замечание. Число 1 в условии $\min_i y_i\left(\langle w, x_i\rangle + w_0\right) = 1$ не имеет самостоятельного геометрического смысла. Вместо единицы можно было бы выбрать любую константу $\kappa > 0$. Выбор единицы позволяет упростить дальнейшие формулы.

Рассмотрим три параллельные гиперплоскости:

$$H_0: \qquad \langle w, x\rangle + w_0 = 0,$$

$$H_+: \qquad \langle w, x\rangle + w_0 = 1,$$

$$H_-: \qquad \langle w, x\rangle + w_0 = -1.$$

Гиперплоскость H_0 является границей принятия решения.

Для объекта положительного класса $y_i = +1$ ограничение прямой задачи принимает вид

$$\langle w, x_i\rangle + w_0 \geq 1.$$

Следовательно, все положительные объекты расположены на гиперплоскости H_+ или в полупространстве за ней.

Для объекта отрицательного класса $y_i = -1$ имеем

$$-\left(\langle w, x_i\rangle + w_0\right) \geq 1,$$

откуда

$$\langle w, x_i\rangle + w_0 \leq -1.$$

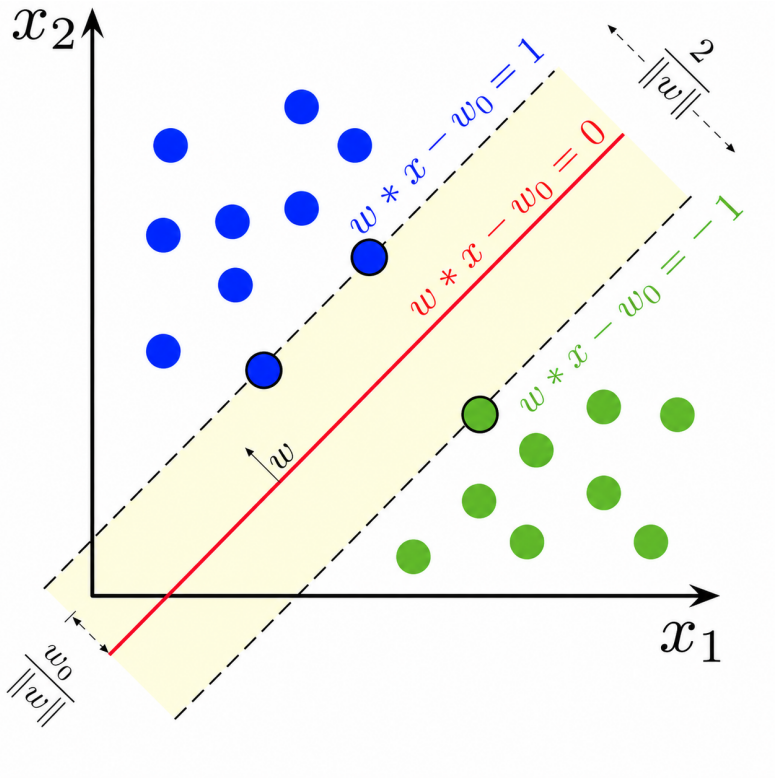


Рисунок 9 – Пример разделяющей гиперплоскости в $\mathbb{R}^2$

Следовательно, все отрицательные объекты расположены на гиперплоскости H_- или в полупространстве за ней.

Область

$$-1 < \langle w, x \rangle + w_0 < 1$$

будем называть **разделяющей полосой**.

Отметим, что в линейно разделимом случае ни один объект обучающей выборки не находится внутри данной полосы.

Расстояние от центральной гиперплоскости H_0 до каждой из границ полосы равно $\frac{1}{\|w\|}$. Следовательно, полная ширина разделяющей полосы равна $\frac{2}{\|w\|}$.

Таким образом, минимизация величины $\frac{1}{2}\|w\|^2$ эквивалентна максимизации ширины разделяющей полосы.

Для наглядности рассмотрим пример, изображённый на рисунке 9. Как можно заметить, в качестве H_+ выступает прямая $\langle w, x \rangle + w_0 = 1$, проходящая через две синие точки. На этой прямой и в полупространстве за ней располагаются объекты положительного класса. Аналогично, прямая $\langle w, x \rangle + w_0 = -1$ задаёт границу соответствующего полупространства для отрицательных объектов.

Полученная ранее прямая задача является выпуклой задачей квадратичного программирования и может решаться численно непосредственно. Однако для дальнейшего анализа удобно перейти к двойственной задаче.

Применим теорему Каруша–Куна–Таккера к данной задаче. Функционал $\frac{1}{2}\|w\|^2$ является выпуклым, а ограничения

$$1 - y_i\left(\langle w, x_i\rangle + w_0\right) \leq 0$$

являются аффинными и, следовательно, выпуклыми.

Кроме того, выполняется условие регулярности Слейтера. Действительно, поскольку выборка линейно разделима, существуют параметры w, w_0, для которых

$$y_i\left(\langle w, x_i\rangle + w_0\right) > 0$$

для любого i. Умножая эти параметры на достаточно большую положительную константу, можно добиться выполнения строгих неравенств

$$y_i\left(\langle w, x_i\rangle + w_0\right) > 1, \qquad i = 1, \ldots, \ell.$$

Следовательно, условия Каруша–Куна–Таккера являются необходимыми и достаточными условиями оптимальности. Поэтому в оптимальной точке существуют множители $\lambda_i \geq 0$, для которых выполняются соответствующие условия.

Лагранжиан исходной задачи имеет вид

$$\mathscr{L}(w, w_0, \lambda) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^{\ell} \lambda_i \left[1 - y_i\left(\langle w, x_i\rangle + w_0\right)\right].$$

Тогда система условий Каруша–Куна–Таккера принимает вид

$$\begin{cases} \nabla_w \mathscr{L}(w, w_0, \lambda) = 0, & \text{стационарность по } w, \\ \dfrac{\partial \mathscr{L}(w, w_0, \lambda)}{\partial w_0} = 0, & \text{стационарность по } w_0, \\ 1 - y_i\left(\langle w, x_i\rangle + w_0\right) \le 0, \quad i = 1, \ldots, \ell, & \text{прямая допустимость}, \\ \lambda_i \ge 0, \quad i = 1, \ldots, \ell, & \text{двойственная допустимость}, \\ \lambda_i\left[1 - y_i\left(\langle w, x_i\rangle + w_0\right)\right] = 0, \quad i = 1, \ldots, \ell, & \text{дополняющая нежёсткость}. \end{cases}$$

Преобразуем лагранжиан задачи:

$$\mathscr{L}(w, w_0, \lambda) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^{\ell} \lambda_i - \sum_{i=1}^{\ell} \lambda_i y_i \langle w, x_i\rangle - w_0 \sum_{i=1}^{\ell} \lambda_i y_i.$$

Используя линейность скалярного произведения, получаем

$$\sum_{i=1}^{\ell} \lambda_i y_i \langle w, x_i\rangle = \left\langle w, \sum_{i=1}^{\ell} \lambda_i y_i x_i \right\rangle.$$

Поэтому лагранжиан можно записать как

$$\mathscr{L}(w, w_0, \lambda) = \frac{1}{2}\|w\|^2 - \left\langle w, \sum_{i=1}^{\ell} \lambda_i y_i x_i \right\rangle + \sum_{i=1}^{\ell} \lambda_i - w_0 \sum_{i=1}^{\ell} \lambda_i y_i.$$

Поскольку прямая задача является выпуклой, ограничения аффинны и выполнено условие Слейтера, оптимальные значения прямой и двойственной задач совпадают.

Двойственная функция определяется как

$$q(\lambda) = \inf_{w, w_0} \mathscr{L}(w, w_0, \lambda).$$

Сначала найдём инфимум лагранжиана по w. Условие стационарности имеет вид

$$\nabla_w \mathscr{L}(w, w_0, \lambda) = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0.$$

Следовательно,

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i.$$

Теперь найдём инфимум лагранжиана по w_0. Условие стационарности имеет вид

$$\frac{\partial \mathscr{L}}{\partial w_0} = -\sum_{i=1}^{\ell} \lambda_i y_i = 0.$$

Следовательно,

$$\sum_{i=1}^{\ell} \lambda_i y_i = 0.$$

Если данное условие не выполняется, то лагранжиан не ограничен снизу по переменной w_0. Поэтому конечное значение двойственной функции возможно только при выполнении равенства $\sum_{i=1}^{\ell} \lambda_i y_i = 0$.

Обозначим

$$s = \sum_{i=1}^{\ell} \lambda_i y_i x_i.$$

При выполнении условия

$$\sum_{i=1}^{\ell} \lambda_i y_i = 0$$

лагранжиан принимает вид

$$\mathscr{L}(w, \lambda) = \frac{1}{2}\|w\|^2 - \langle w, s\rangle + \sum_{i=1}^{\ell} \lambda_i.$$

Дополняя первые два слагаемых до полного квадрата, получаем

$$\begin{aligned}\frac{1}{2}\|w\|^2 - \langle w, s\rangle &= \frac{1}{2}\left(\|w\|^2 - 2\langle w, s\rangle\right) \\ &= \frac{1}{2}\left(\|w - s\|^2 - \|s\|^2\right) \\ &= \frac{1}{2}\|w - s\|^2 - \frac{1}{2}\|s\|^2.\end{aligned}$$

Следовательно,

$$q(\lambda) = \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2}\left\|\sum_{i=1}^{\ell} \lambda_i y_i x_i\right\|^2.$$

Раскроем квадрат нормы:

$$\left\|\sum_{i=1}^{\ell}\lambda_i y_i x_i\right\|^2 = \left\langle \sum_{i=1}^{\ell}\lambda_i y_i x_i, \sum_{j=1}^{\ell}\lambda_j y_j x_j \right\rangle = \sum_{i=1}^{\ell}\sum_{j=1}^{\ell}\lambda_i\lambda_j y_i y_j \langle x_i, x_j\rangle.$$

Поэтому двойственная функция имеет вид

$$q(\lambda) = \sum_{i=1}^{\ell}\lambda_i - \frac{1}{2}\sum_{i=1}^{\ell}\sum_{j=1}^{\ell}\lambda_i\lambda_j y_i y_j \langle x_i, x_j\rangle.$$

Двойственная задача заключается в максимизации функции $q(\lambda)$:

$$\begin{cases} \displaystyle\sum_{i=1}^{\ell}\lambda_i - \frac{1}{2}\sum_{i=1}^{\ell}\sum_{j=1}^{\ell}\lambda_i\lambda_j y_i y_j \langle x_i, x_j\rangle \to \max_{\lambda}, \\ \lambda_i \geq 0, \qquad i = 1, \ldots, \ell, \\ \displaystyle\sum_{i=1}^{\ell}\lambda_i y_i = 0. \end{cases}$$

Введём матрицу Q, элементы которой задаются формулой

$$Q_{ij} = y_i y_j \langle x_i, x_j\rangle.$$

Матрица Q является неотрицательно определённой. Действительно, для любого вектора $c \in \mathbb{R}^{\ell}$

$$c^T Q c = \sum_{i=1}^{\ell}\sum_{j=1}^{\ell} c_i c_j y_i y_j \langle x_i, x_j\rangle = \left\langle \sum_{i=1}^{\ell} c_i y_i x_i, \sum_{j=1}^{\ell} c_j y_j x_j \right\rangle = \left\|\sum_{i=1}^{\ell} c_i y_i x_i\right\|^2 \geq 0$$

В матричной форме двойственная целевая функция записывается как

$$q(\lambda) = \mathbf{1}^T\lambda - \frac{1}{2}\lambda^T Q\lambda,$$

где $\mathbf{1}$ — вектор, состоящий из единиц.

Так как матрица Q неотрицательно определена, функция $q(\lambda)$ является вогнутой. Поэтому максимизация $q(\lambda)$ при линейных ограничениях представляет собой выпуклую задачу оптимизации.

Отметим, что использование двойственной постановки при некоторых условиях может быть более удобным с точки зрения оптимизации. Кроме того, признаки объектов входят в двойственную функцию только в форме скалярных произведений. Это в дальнейшем позволит перейти к ядерной форме метода опорных векторов.

Рассмотрим условие дополняющей нежёсткости:

$$\lambda_i \left[y_i \left(\langle w, x_i\rangle + w_0\right) - 1\right] = 0.$$

Если объект расположен строго за границей разделяющей полосы, то

$$y_i \left(\langle w, x_i\rangle + w_0\right) > 1.$$

В этом случае второй множитель в условии дополняющей нежёсткости положителен, поэтому обязательно $\lambda_i = 0$.

Если же $\lambda_i > 0$, то из условия дополняющей нежёсткости следует

$$y_i \left(\langle w, x_i\rangle + w_0\right) = 1.$$

Следовательно, такой объект лежит на одной из границ разделяющей полосы.

Объект x_i, для которого оптимальный двойственный коэффициент удовлетворяет условию $\lambda_i > 0$, будем называть **опорным вектором**. Множество индексов опорных векторов обозначим через $SV = \{i \mid \lambda_i > 0\}$.

Из условия стационарности имеем

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i.$$

Для всех неопорных объектов $\lambda_i = 0$, поэтому

$$w = \sum_{i \in SV} \lambda_i y_i x_i.$$

Таким образом, вектор нормали к разделяющей гиперплоскости определяется только опорными векторами. Объекты, расположенные строго за границами разделяющей полосы, не входят в данное представление.

Именно поэтому рассматриваемый метод называется методом опорных векторов.

Замечание. Из условия $\lambda_i > 0$ обязательно следует, что объект лежит на границе разделяющей полосы. Обратное утверждение в вырожденных случаях может не выполняться: объект может лежать на границе, но иметь $\lambda_i = 0$, если соответствующее ограничение является избыточным. Например, такая ситуация возможна при наличии совпадающих объектов.

Вернёмся к примеру, изображённому на рисунке 9. Нетрудно заметить, что в нём опорными векторами являются лежащие на границах разделяющей полосы два синих и один зелёный объекты.

Осталось определить свободный коэффициент w_0. Пусть x_k является опорным вектором, то есть $\lambda_k > 0$. Тогда

$$y_k \left(\langle w, x_k \rangle + w_0 \right) = 1.$$

Так как $y_k \in \{-1, +1\}$, получаем

$$\langle w, x_k \rangle + w_0 = y_k.$$

Следовательно,

$$w_0 = y_k - \langle w, x_k \rangle.$$

В точном оптимальном решении любой опорный вектор даёт одно и то же значение свободного коэффициента w_0, поскольку все соответствующие равенства выполняются одновременно для одних и тех же параметров w, w_0.

7.2.2 Линейно неразделимый случай

Рассмотрим теперь общий случай, когда выборку невозможно идеально разделить гиперплоскостью.

Выборка называется линейно неразделимой, если для любых параметров w, w_0 найдётся хотя бы один объект x_i, для которого

$$y_i\left(\langle w, x_i\rangle + w_0\right) \leq 0.$$

В таком случае допустимое множество задачи с жёстким отступом пусто.

Для того чтобы сделать допустимое множество непустым, для каждого объекта введём переменную $\xi_i \geq 0$ и заменим ограничение отступа на

$$y_i\left(\langle w, x_i\rangle + w_0\right) \geq 1 - \xi_i.$$

Чем больше значение ξ_i, тем сильнее разрешается нарушить исходное ограничение.

При минимально допустимом значении ξ_i возможны следующие случаи:

– если $\xi_i = 0$, то $M_i \geq 1$;

– если $0 < \xi_i < 1$, то объект классифицирован правильно, но находится внутри разделяющей полосы;

– если $\xi_i = 1$, то $M_i = 0$, то есть объект лежит на разделяющей гиперплоскости;

– если $\xi_i > 1$, то $M_i < 0$, то есть объект классифицирован неправильно.

Однако если разрешить произвольные значения ξ_i, то ограничения потеряют смысл, поскольку переменные ξ_i можно будет выбрать сколь угодно большими. Для предотвращения такой ситуации добавим к целевой функции слагаемое, учитывающее суммарную величину нарушений:

$$C\sum_{i=1}^{\ell}\xi_i,$$

где $C > 0$ — гиперпараметр, регулирующий влияние нарушений ограничений.

Тогда прямая задача метода опорных векторов для **линейно неразделимого случая** (soft-margin support vector machine) имеет вид

$$\begin{cases} \dfrac{1}{2}\|w\|^2 + C\sum\limits_{i=1}^{\ell}\xi_i \to \min\limits_{w,w_0,\xi}, \\ y_i\left(\langle w, x_i\rangle + w_0\right) \geq 1 - \xi_i, \qquad i = 1,\ldots,\ell, \\ \xi_i \geq 0, \qquad i = 1,\ldots,\ell. \end{cases}$$

Отметим, что слагаемые функционала отражают две конкурирующие тенденции. Величина $\frac{1}{2}\|w\|^2$ стремится увеличить ширину разделяющей полосы, в то время как слагаемое $C\sum_{i=1}^{\ell}\xi_i$ препятствует нарушению ограничений.

При больших значениях C нарушения ограничений оказывают более существенное влияние на значение целевого функционала. При малых значениях C допускаются более значительные нарушения в обмен на уменьшение нормы w, то есть на увеличение ширины разделяющей полосы.

Перепишем ограничения на переменные ξ_i в виде

$$\begin{cases} \xi_i \geq 1 - y_i\left(\langle w, x_i\rangle + w_0\right), \\ \xi_i \geq 0. \end{cases}$$

Поскольку переменные ξ_i входят в функционал с положительным коэффициентом C, в оптимальном решении они принимают минимально допустимые значения:

$$\xi_i = \max\left\{0,\ 1 - y_i\left(\langle w, x_i\rangle + w_0\right)\right\}.$$

Подставляя данное выражение в функционал исходной задачи, получаем безусловную задачу оптимизации:

$$\frac{1}{2}\|w\|^2 + C\sum_{i=1}^{\ell}\max\left\{0,\ 1 - y_i\left(\langle w, x_i\rangle + w_0\right)\right\} \to \min_{w,w_0}.$$

Данная задача показывает, что метод опорных векторов использует почти всюду дифференцируемую по параметрам модели верхнюю оценку индикатора

ошибки классификации (**hinge loss**):

$$\widetilde{L}_{\text{hinge}}\left(y, \alpha(x)\right) = \max\left\{0,\ 1 - y\alpha(x)\right\}.$$

Действительно, если объект классифицирован неверно, то $y_i\alpha(x_i) \leq 0$, а значение индикатора ошибки классификации равно единице. При этом

$$\max\left\{0,\ 1 - y_i\alpha(x_i)\right\} \geq 1.$$

Если объект классифицирован правильно, то значение индикатора ошибки классификации равно нулю, в то время как

$$\max\left\{0,\ 1 - y_i\alpha(x_i)\right\} \geq 0.$$

Перейдём к двойственной задаче оптимизации. Для этого вернёмся к условной постановке с переменными ξ_i и применим теорему Каруша–Куна–Таккера.

Целевой функционал является выпуклым, а ограничения

$$1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right) \leq 0, \qquad -\xi_i \leq 0$$

являются аффинными.

Кроме того, для данной задачи выполняется условие регулярности Слейтера. Например, можно выбрать

$$w = 0, \qquad w_0 = 0, \qquad \xi_i = 2, \qquad i = 1, \ldots, \ell.$$

Тогда

$$1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right) = -1 < 0$$

и

$$-\xi_i = -2 < 0.$$

Следовательно, существует строго допустимая точка.

Поэтому оптимальные значения прямой и двойственной задач совпадают, а условия Каруша–Куна–Таккера являются необходимыми и достаточными условиями оптимальности.

Для ограничений

$$1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right) \le 0$$

введём множители $\lambda_i \ge 0$, а для ограничений $-\xi_i \le 0$ — множители $\mu_i \ge 0$.

Лагранжиан задачи имеет вид

$$\begin{aligned}\mathscr{L}(w, w_0, \xi, \lambda, \mu) = \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{\ell}\xi_i \\ + \sum_{i=1}^{\ell}\lambda_i\left[1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right)\right] \\ - \sum_{i=1}^{\ell}\mu_i\xi_i.\end{aligned}$$

Раскрывая скобки и используя линейность скалярного произведения, получаем

$$\begin{aligned}\mathscr{L}(w, w_0, \xi, \lambda, \mu) = \frac{1}{2}\|w\|^2 - \left\langle w, \sum_{i=1}^{\ell}\lambda_i y_i x_i\right\rangle \\ + \sum_{i=1}^{\ell}\lambda_i - w_0\sum_{i=1}^{\ell}\lambda_i y_i \\ + \sum_{i=1}^{\ell}\xi_i\left(C - \lambda_i - \mu_i\right).\end{aligned}$$

Система условий Каруша–Куна–Таккера имеет вид

$$\begin{cases} \nabla_w \mathscr{L}(w, w_0, \xi, \lambda, \mu) = 0, & \text{стационарность по } w, \\ \dfrac{\partial \mathscr{L}(w, w_0, \xi, \lambda, \mu)}{\partial w_0} = 0, & \text{стационарность по } w_0, \\ \dfrac{\partial \mathscr{L}(w, w_0, \xi, \lambda, \mu)}{\partial \xi_i} = 0, \quad i = 1, \ldots, \ell, & \text{стационарность по } \xi_i, \\ 1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right) \le 0, \quad i = 1, \ldots, \ell, & \\ -\xi_i \le 0, \quad i = 1, \ldots, \ell, & \text{прямая допустимость}, \\ \lambda_i \ge 0, \quad i = 1, \ldots, \ell, & \\ \mu_i \ge 0, \quad i = 1, \ldots, \ell, & \text{двойственная допустимость}, \\ \lambda_i\left[1 - \xi_i - y_i\left(\langle w, x_i\rangle + w_0\right)\right] = 0, \quad i = 1, \ldots, \ell, & \\ \mu_i \xi_i = 0, \quad i = 1, \ldots, \ell. & \text{дополняющая нежёсткость}, \end{cases}$$

Получим условия стационарности по w и w_0. Имеем

$$\nabla_w \mathscr{L} = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0, \qquad \frac{\partial \mathscr{L}}{\partial w_0} = -\sum_{i=1}^{\ell} \lambda_i y_i = 0.$$

Следовательно,

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i, \qquad \sum_{i=1}^{\ell} \lambda_i y_i = 0.$$

Теперь получим условие стационарности по ξ_i:

$$\frac{\partial \mathscr{L}}{\partial \xi_i} = C - \lambda_i - \mu_i = 0.$$

Следовательно,

$$\lambda_i + \mu_i = C.$$

Так как $\lambda_i \ge 0$ и $\mu_i \ge 0$, получаем

$$0 \le \lambda_i \le C, \qquad i = 1, \ldots, \ell.$$

При выполнении условий стационарности слагаемые, содержащие w_0 и ξ_i, обращаются в нуль, поэтому лагранжиан принимает вид

$$\mathscr{L}(w, \lambda) = \frac{1}{2}\|w\|^2 - \left\langle w, \sum_{i=1}^{\ell} \lambda_i y_i x_i \right\rangle + \sum_{i=1}^{\ell} \lambda_i.$$

Двойственная функция определяется как

$$q(\lambda, \mu) = \inf_{w, w_0, \xi} \mathscr{L}(w, w_0, \xi, \lambda, \mu).$$

В результате

$$\begin{aligned} q(\lambda) &= \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2}\left\| \sum_{i=1}^{\ell} \lambda_i y_i x_i \right\|^2 \\ &= \sum_{i=1}^{\ell} \lambda_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle. \end{aligned}$$

Таким образом, в линейно неразделимом случае выражение для двойственной функции $q(\lambda)$ совпадает с выражением, полученным в линейно разделимом случае.

Двойственная задача имеет вид

$$\begin{cases} \displaystyle\sum_{i=1}^{\ell} \lambda_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \to \max_{\lambda}, \\ 0 \le \lambda_i \le C, \qquad i = 1, \ldots, \ell, \\ \displaystyle\sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

Подобно задаче для линейно разделимого случая, данная задача также является выпуклой задачей оптимизации.

В отличие от линейно разделимого случая, в данной задаче множители Лагранжа λ_i естественно разбиваются на три группы.

Случай $\lambda_i = 0$.

Из условия

$$C - \lambda_i - \mu_i = 0$$

получаем

$$\mu_i = C > 0.$$

Тогда из условия дополняющей нежёсткости

$$\mu_i \xi_i = 0$$

следует

$$\xi_i = 0.$$

Вместе с условием прямой допустимости это даёт

$$M_i \geq 1.$$

Таким образом, объект располагается на границе разделяющей полосы или за ней. В невырожденном случае такой объект находится строго за границей разделяющей полосы.

Случай $0 < \lambda_i < C$**.**

Тогда

$$\mu_i = C - \lambda_i > 0.$$

Из условия

$$\mu_i \xi_i = 0$$

следует

$$\xi_i = 0.$$

Поскольку $\lambda_i > 0$, первое условие дополняющей нежёсткости даёт

$$1 - \xi_i - M_i = 0.$$

Следовательно,

$$M_i = 1.$$

То есть такие объекты лежат точно на границах разделяющей полосы.

Случай $\lambda_i = C$**.**

При этом

$$\mu_i = 0.$$

Поэтому переменная ξ_i может быть положительной.

Поскольку $\lambda_i > 0$, из первого условия дополняющей нежёсткости следует

$$M_i = 1 - \xi_i.$$

Поэтому возможны следующие случаи:

– объект лежит на границе разделяющей полосы при $\xi_i = 0$;
– объект находится внутри разделяющей полосы при $0 < \xi_i < 1$;
– объект лежит на разделяющей гиперплоскости при $\xi_i = 1$;
– объект классифицирован неправильно при $\xi_i > 1$.

Поскольку условие стационарности по w не изменилось, определение опорных векторов также остаётся прежним. Однако в линейно неразделимом случае опорными являются не только объекты, расположенные на границах разделяющей полосы. Объекты внутри полосы и ошибочно классифицированные объекты также могут иметь $\lambda_i > 0$.

Свободный коэффициент w_0 в невырожденном случае восстанавливается по объектам, для которых

$$0 < \lambda_i < C.$$

Для таких объектов $\xi_i = 0$ и

$$y_i\left(\langle w, x_i\rangle + w_0\right) = 1.$$

Следовательно,

$$w_0 = y_i - \langle w, x_i\rangle.$$

Отметим, что по объекту с $\lambda_i = C$ данную формулу в общем случае использовать нельзя, поскольку для такого объекта может выполняться $\xi_i > 0$. В этом случае

$$y_i\left(\langle w, x_i\rangle + w_0\right) = 1 - \xi_i,$$

а не единица.

7.3 Бинарная кросс-энтропия

Рассмотрим вероятностную постановку бинарной классификации. Пусть выборка имеет вид

$$\{(x, y_i)\}_{i=1}^{\ell}, \qquad y_i \in \{0, 1\}.$$

Поскольку каждый объект имеет одинаковое признаковое описание, модель должна возвращать на них одно и то же значение. Естественно потребовать

$$\arg\min_{\alpha(x)} \frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, \alpha(x)) = \hat{p}_\ell, \qquad \hat{p}_\ell = \frac{1}{\ell} \sum_{i=1}^{\ell} y_i.$$

Иными словами, оптимальным выходным значением модели является доля объектов положительного класса.

Поскольку $\mathcal{Y} = \{0, 1\}$, условное распределение целевой переменной при фиксированном x имеет вид

$$P^*_{Y|X=x} = \text{Ber}\left(P^*(Y = 1 \mid X = x)\right).$$

Пусть $Y_1, \ldots, Y_\ell$ являются независимыми реализациями данного условного распределения и

$$\hat{p}_\ell = \frac{1}{\ell} \sum_{i=1}^{\ell} Y_i.$$

Тогда по следствию из закона больших чисел в форме Чебышёва

$$\hat{p}_\ell \xrightarrow{\mathbb{P}} \mathbb{M}[Y \mid X = x] = P^*(Y = 1 \mid X = x) \qquad \text{при } \ell \to \infty.$$

Следовательно, доля положительных объектов является выборочной оценкой условной вероятности положительного класса $P^*(Y = 1 \mid X = x)$. Поэтому в вероятностной постановке бинарной классификации будем рассматривать модели, выход которых является оценкой этой величины.

Поскольку условное распределение Бернулли полностью определяется вероятностью положительного класса, оценка величины $P^*(Y = 1 \mid X = x)$ эквивалентна оценке всего условного распределения $P^*_{Y|X=x}$.

Положим $\mathcal{Z} = [0, 1]$, зафиксируем отображение δ_τ и зададим φ как некоторое вероятностное преобразование, которое переводит вещественное число

в пространство параметров соответствующего вероятностного распределения. Тогда выход модели имеет вид

$$\alpha(x) = P_\alpha(Y = 1 \mid X = x).$$

Определение. Функция потерь позволяет корректно оценивать условную вероятность, если для любого фиксированного объекта x выполнено

$$\arg \min_{\alpha(x)\in[0,1]} m_{x,L}(\alpha(x)) = \arg \min_{\alpha(x)\in[0,1]} \mathbb{M}_{Y|X=x} L(Y, \alpha(x)) = P^*(Y = 1 \mid X = x).$$

Ранее рассматривалась выборка с одинаковыми признаковыми описаниями. Однако в реальных данных признаковые описания объектов, как правило, не совпадают. Рассмотрим теперь выборку, в которой $x_1 \approx x_2 \approx \cdots \approx x_\ell$, и существует объект x_c такой, что

$$\|x_i - x_c\| \le \varepsilon, \qquad i = 1, \ldots, \ell.$$

Будем считать, что модель является липшицевой с константой $C_\alpha > 0$. Тогда

$$|\alpha(x_i) - \alpha(x_c)| \le C_\alpha \|x_i - x_c\| \le C_\alpha \varepsilon.$$

Обозначим

$$\Delta_i = \alpha(x_i) - \alpha(x_c).$$

Следовательно,

$$\alpha(x_i) = \alpha(x_c) + \Delta_i, \qquad |\Delta_i| \le C_\alpha \varepsilon.$$

Пусть функция потерь дифференцируема по второму аргументу в точке $\alpha(x_c)$. Используем формулу Тейлора для разложения средней ошибки по второму

аргументу функции потерь в окрестности точки $\alpha(x_c)$ до второго члена:

$$\frac{1}{\ell}\sum_{i=1}^{\ell} L(y_i, \alpha(x_i)) = \frac{1}{\ell}\sum_{i=1}^{\ell} L(y_i, \alpha(x_c) + \Delta_i)$$
$$= \frac{1}{\ell}\sum_{i=1}^{\ell}\left[L(y_i, \alpha(x_c)) + \left.\frac{\partial L(y_i, z)}{\partial z}\right|_{z=\alpha(x_c)} \Delta_i + o(\Delta_i)\right]$$
$$= \frac{1}{\ell}\sum_{i=1}^{\ell} L(y_i, \alpha(x_c)) + \frac{1}{\ell}\sum_{i=1}^{\ell}\left.\frac{\partial L(y_i, z)}{\partial z}\right|_{z=\alpha(x_c)} \Delta_i$$
$$+ \frac{1}{\ell}\sum_{i=1}^{\ell} o(\Delta_i).$$

Поскольку производная в точке $\alpha(x_c)$ конечна, а $\Delta_i = O(\varepsilon)$, линейное слагаемое имеет порядок $O(\varepsilon)$, а остаточное слагаемое — порядок $o(\varepsilon)$. Следовательно,

$$\frac{1}{\ell}\sum_{i=1}^{\ell} L(y_i, \alpha(x_i)) = \frac{1}{\ell}\sum_{i=1}^{\ell} L(y_i, \alpha(x_c)) + O(\varepsilon).$$

Таким образом, в достаточно малом шаре значения модели на объектах $x_1, \ldots, x_\ell$ можно приближённо заменить одним общим значением $\alpha(x_c)$. Тем самым задача приближённо сводится к ранее рассмотренному случаю одного объекта с различными целевыми значениями $y_1, \ldots, y_\ell$.

Тогда при достаточно малом радиусе шара и большом числе наблюдений доля объектов положительного класса в нём в силу закона больших чисел и предположения о близости условных распределений приближённо оценивает $P^*(Y = 1 \mid X = x_c)$.

Ранее в задаче регрессии были рассмотрены квадратичная и абсолютная функции потерь. Проверим, позволяют ли они корректно оценивать условную вероятность.

Утверждение. Квадратичная функция потерь позволяет корректно оценивать условную вероятность.

□ Пусть x фиксирован и $P^*_{Y|X=x} = \mathrm{Ber}\,(P^*(Y = 1 \mid X = x))$. Для квадратичной функции потерь локальная средняя ошибка имеет вид

$$m_{x,L}(\alpha(x)) = \mathbb{M}_{Y|X=x}\,(Y - \alpha(x))^2\,.$$

Раскрывая условное математическое ожидание по двум возможным значениям Y, получаем

$$\begin{aligned} m_{x,L}(\alpha(x)) &= P^*(Y = 1 \mid X = x)\,(1 - \alpha(x))^2 + P^*(Y = 0 \mid X = x)\alpha(x)^2 \\ &= P^*(Y = 1 \mid X = x)\left(1 - 2\alpha(x) + \alpha(x)^2\right) \\ &\quad + (1 - P^*(Y = 1 \mid X = x))\,\alpha(x)^2 \\ &= P^*(Y = 1 \mid X = x) - 2P^*(Y = 1 \mid X = x)\alpha(x) + \alpha(x)^2. \end{aligned}$$

Возьмём производную по $\alpha(x)$:

$$\frac{d}{d\alpha(x)} m_{x,L}(\alpha(x)) = -2P^*(Y = 1 \mid X = x) + 2\alpha(x).$$

По необходимому условию экстремума

$$-2P^*(Y = 1 \mid X = x) + 2\alpha(x) = 0.$$

В результате,

$$\alpha^*(x) = P^*(Y = 1 \mid X = x).$$

■

Следовательно, квадратичная функция потерь позволяет корректно оценивать условную вероятность. Однако в задаче классификации она может оказаться менее удобной с точки зрения оптимизации, поскольку градиент по параметрам модели может быстро затухать, затрудняя обучение.

Утверждение. Абсолютная функция потерь **не** позволяет корректно оценивать условную вероятность.

□ Пусть x фиксирован и $P^*_{Y|X=x} = \mathrm{Ber}\,(P^*(Y = 1 \mid X = x))$. Для абсолютной функции потерь локальная средняя ошибка имеет вид

$$m_{x,L}(\alpha(x)) = \mathbb{M}_{Y|X=x}\,|Y - \alpha(x)|\,.$$

Распишем условное математическое ожидание по двум возможным значениям Y:

$$m_{x,L}(\alpha(x)) = P^*(Y = 1 \mid X = x)|1 - \alpha(x)| + P^*(Y = 0 \mid X = x)|\alpha(x)|.$$

Поскольку $\alpha(x) \in [0,1]$, имеем $|1-\alpha(x)| = 1-\alpha(x)$ и $|\alpha(x)| = \alpha(x)$. Получаем,

$$\begin{aligned} m_{x,L}(\alpha(x)) &= P^*(Y=1 \mid X=x)\,(1-\alpha(x)) \\ &\quad + (1-P^*(Y=1 \mid X=x))\,\alpha(x) \\ &= P^*(Y=1 \mid X=x) - P^*(Y=1 \mid X=x)\alpha(x) \\ &\quad + \alpha(x) - P^*(Y=1 \mid X=x)\alpha(x) \\ &= P^*(Y=1 \mid X=x) + (1-2P^*(Y=1 \mid X=x))\,\alpha(x). \end{aligned}$$

Следовательно, полученное выражение является линейной функцией относительно $\alpha(x)$. Рассмотрим три случая.

– Если $P^*(Y=1 \mid X=x) < \frac{1}{2}$, то $1-2P^*(Y=1 \mid X=x) > 0$. Поэтому локальная средняя ошибка возрастает по $\alpha(x)$, и минимум достигается при $\alpha(x) = 0$.

– Если $P^*(Y=1 \mid X=x) > \frac{1}{2}$, то $1-2P^*(Y=1 \mid X=x) < 0$. Поэтому локальная средняя ошибка убывает по $\alpha(x)$, и минимум достигается при $\alpha(x) = 1$.

– Если $P^*(Y=1 \mid X=x) = \frac{1}{2}$, то $1-2P^*(Y=1 \mid X=x) = 0$. В этом случае локальная средняя ошибка не зависит от $\alpha(x)$, поэтому минимум достигается при любом $\alpha(x) \in [0,1]$.

Из рассмотренных случаев следует, что в общем случае минимум локальной средней ошибки **не** достигается при

$$\alpha(x) = P^*(Y=1 \mid X=x).$$

■

Следовательно, абсолютная функция потерь **не** позволяет корректно оценивать условную вероятность.

Таким образом, функции потерь, традиционно применяемые в задаче регрессии, могут иметь ограничения при использовании в задаче классификации. В связи с этим возникает необходимость введения более подходящей функции потерь.

Поскольку $P^*_{Y|X=x} = \mathrm{Ber}\,(P^*(Y=1 \mid X=x))$, естественно рассмотреть правдоподобие произвольной выборки. Тогда функция правдоподобия и соот-

ветствующая ей задача оптимизации имеют вид

$$\mathcal{L}(\alpha, \mathcal{D}) = \prod_{i=1}^{\ell} \alpha(x_i)^{y_i} \, (1 - \alpha(x_i))^{1-y_i} \to \max_w .$$

Прологарифмируем функцию правдоподобия и перейдём к эквивалентной задаче минимизации отрицательного логарифма:

$$-\log \mathcal{L}(\alpha, \mathcal{D}) = -\sum_{i=1}^{\ell} \left[y_i \log \alpha(x_i) + (1 - y_i) \log \left(1 - \alpha(x_i)\right) \right] \to \min_w .$$

Таким образом, минимизация отрицательного логарифма правдоподобия приводит к функции потерь, называемой **бинарной кросс-энтропией** (binary cross-entropy):

$$L_{\text{BCE}}(y, \alpha(x)) = -y \log \alpha(x) - (1 - y) \log \left(1 - \alpha(x)\right) .$$

Тогда соответствующий функционал ошибки имеет вид

$$Q_{\text{BCE}}(\alpha, \mathcal{D}) = -\frac{1}{\ell} \sum_{i=1}^{\ell} \left[y_i \log \alpha(x_i) + (1 - y_i) \log \left(1 - \alpha(x_i)\right) \right] .$$

Утверждение. Минимизация кросс-энтропии эквивалентна минимизации дивергенции Кульбака–Лейблера между истинным и модельным условными распределениями. Кросс-энтропийная функция потерь позволяет корректно оценивать условную вероятность.

□ Пусть x фиксирован и $P^*_{Y|X=x} = \text{Ber}\left(P^*(Y = 1 \mid X = x)\right)$. Для кросс-энтропийной функции потерь локальная средняя ошибка имеет вид

$$\begin{aligned} m_{x, L_{\text{BCE}}}(\alpha(x)) &= \mathbb{M}_{Y|X=x} L_{\text{BCE}}(Y, \alpha(x)) \\ &= \mathbb{M}_{Y|X=x} \left[-Y \log \alpha(x) - (1 - Y) \log \left(1 - \alpha(x)\right) \right] . \end{aligned}$$

Обозначим через $P_{\alpha, Y|X=x} = \text{Ber}\left(\alpha(x)\right)$ условное распределение, порождённое моделью α.

По определению кросс-энтропии:

$$\text{CE}\left(P^*_{Y|X=x} \| P_{\alpha, Y|X=x} \right) = \mathbb{M}_{Y|X=x} \left[-Y \log \alpha(x) - (1 - Y) \log \left(1 - \alpha(x)\right) \right]$$

Для кросс-энтропии справедливо разложение:

$$\mathrm{CE}\left(P^*_{Y|X=x} \| P_{\alpha,Y|X=x}\right) = H\left(P^*_{Y|X=x}\right) + D_{\mathrm{KL}}\left(P^*_{Y|X=x} \| P_{\alpha,Y|X=x}\right),$$

где H — энтропия, а D_{KL} — дивергенция Кульбака–Лейблера.

Поскольку $H\left(P^*_{Y|X=x}\right)$ не зависит от распределения модели, минимизация кросс-энтропии по $\alpha(x)$ эквивалентна минимизации дивергенции Кульбака–Лейблера:

$$\arg\min_{\alpha(x)\in[0,1]} \mathrm{CE}\left(P^*_{Y|X=x} \| P_{\alpha,Y|X=x}\right) = \arg\min_{\alpha(x)\in[0,1]} D_{\mathrm{KL}}\left(P^*_{Y|X=x} \| P_{\alpha,Y|X=x}\right).$$

По неравенству Гиббса дивергенция Кульбака–Лейблера неотрицательна, причём обращается в нуль тогда и только тогда, когда распределения совпадают. Следовательно, минимум достигается при

$$P_{\alpha,Y|X=x} = P^*_{Y|X=x}.$$

Поскольку оба распределения являются бернуллиевскими, равенство распределений эквивалентно равенству их параметров:

$$\alpha(x) = P^*(Y = 1 \mid X = x).$$

■

Таким образом, при минимизации кросс-энтропийной функции потерь модельное распределение $P_{\alpha,Y|X=x}$ приближается к истинному условному распределению $P^*_{Y|X=x}$. Следовательно, кросс-энтропийная функция потерь позволяет корректно оценивать условную вероятность.

Покажем теперь, что кросс-энтропийная функция потерь с точностью до постоянного множителя является верхней оценкой индикатора ошибки классификации.

Если объект классифицирован верно, то значение индикатора ошибки классификации равно нулю. В то же время кросс-энтропийная функция потерь неотрицательна.

Если же объект классифицирован неверно, то рассмотрим два случая.

– Пусть $y = 1$. Ошибка классификации означает, что $\alpha(x) < \frac{1}{2}$. Тогда

$$L_{\text{BCE}}(1, \alpha(x)) = -\log \alpha(x) \geq -\log \frac{1}{2} = \log 2.$$

– Пусть $y = 0$. Ошибка классификации означает, что $\alpha(x) \geq \frac{1}{2}$. Следовательно, $1 - \alpha(x) \leq \frac{1}{2}$, поэтому

$$L_{\text{BCE}}(0, \alpha(x)) = -\log (1 - \alpha(x)) \geq -\log \frac{1}{2} = \log 2.$$

Таким образом, при любой ошибке классификации

$$L_{\text{BCE}}(y, \alpha(x)) \geq \log 2.$$

Обозначим через $\widetilde{L}_{\text{BCE}}(y, \alpha(x))$ кросс-энтропийную функцию потерь с логарифмом по основанию 2:

$$\widetilde{L}_{\text{BCE}}(y, \alpha(x)) = \frac{1}{\log 2} L_{\text{BCE}}(y, \alpha(x)).$$

При неверной классификации индикатор ошибки классификации принимает значение, равное единице. Следовательно,

$$1 \leq \frac{1}{\log 2} L_{\text{BCE}}(y, \alpha(x)) = \widetilde{L}_{\text{BCE}}(y, \alpha(x)).$$

Поскольку множитель $\frac{1}{\log 2}$ является положительной константой, изменение основания логарифма не влияет на решение задачи минимизации.

Преобразуем кросс-энтропийную функцию потерь:

$$\begin{aligned} L_{\text{BCE}}(y, \alpha(x)) &= -y \log \alpha(x) - (1 - y) \log (1 - \alpha(x)) \\ &= -y \log \frac{\alpha(x)}{1 - \alpha(x)} - \log (1 - \alpha(x)) \,. \end{aligned}$$

Тогда **логитом** будем называть величину

$$z(x) = \log \frac{\alpha(x)}{1 - \alpha(x)}.$$

Логит представляет собой логарифм шансов положительного класса, то есть логарифм отношения вероятности положительного класса к вероятности отрицательного класса (log-odds), и принимает значения на всей вещественной прямой. Поэтому $z(x)$ естественно интерпретировать как значение вещественной части модели, которое затем преобразуется в вероятность $\alpha(x) = \varphi(z(x))$.

Знак $z(x)$ указывает, какой из классов является более вероятным, а величина $|z(x)|$ характеризует выраженность преимущества одного класса над другим в шкале логарифма отношения шансов:

$$z(x) > 0 \iff \alpha(x) > \frac{1}{2}, \qquad z(x) < 0 \iff \alpha(x) < \frac{1}{2},$$

$$z(x) = 0 \iff \alpha(x) = \frac{1}{2}.$$

Экспоненцируя равенство, определяющее логит, получаем

$$e^{z(x)} = \frac{\alpha(x)}{1 - \alpha(x)}.$$

Разрешая это равенство относительно $\alpha(x)$, имеем

$$e^{z(x)}\,(1 - \alpha(x)) = \alpha(x),$$
$$e^{z(x)} = \alpha(x)\left(1 + e^{z(x)}\right).$$

Следовательно,

$$\alpha(x) = \frac{e^{z(x)}}{1 + e^{z(x)}} = \frac{1}{1 + e^{-z(x)}} = \varphi(z(x)).$$

Полученное преобразование называется **сигмоидальной функцией**:

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Таким образом, при параметризации вероятности через логит преобразование φ естественным образом принимает вид сигмоидальной функции. Поэтому в задачах бинарной классификации сигмоида наиболее часто используется совместно с кросс-энтропийной функцией потерь.

Рассмотрим полученное ранее выражение для бинарной кросс-энтропии:

$$L_{\text{BCE}}(y, \alpha(x)) = -y \log \frac{\alpha(x)}{1 - \alpha(x)} - \log\left(1 - \alpha(x)\right).$$

Подставляя $\alpha(x) = \sigma(z(x))$, получаем

$$L_{\text{BCE}}(y, \sigma(z(x))) = -y \log \frac{\sigma(z(x))}{1 - \sigma(z(x))} - \log\left(1 - \sigma(z(x))\right).$$

Поскольку

$$\frac{\sigma(z(x))}{1 - \sigma(z(x))} = e^{z(x)}, \qquad 1 - \sigma(z(x)) = \frac{1}{1 + e^{z(x)}},$$

получаем

$$\begin{aligned} L_{\text{BCE}}(y, \sigma(z(x))) &= -y \log e^{z(x)} - \log \frac{1}{1 + e^{z(x)}} \\ &= -yz(x) + \log\left(1 + e^{z(x)}\right). \end{aligned}$$

Таким образом, бинарная кросс-энтропия, записанная как функция логита, принимает вид

$$L_{\log}(y, z) = \log\left(1 + e^{z}\right) - yz.$$

Эту функцию называют **логистической** функцией потерь. Полученная эквивалентная форма удобна для представления функции потерь через отступ и её сопоставления с другими функциями потерь классификации.

7.4 Сравнение функций потерь

В данном подразделе сопоставим логистическую функцию потерь и функцию потерь метода опорных векторов, рассмотрев их зависимость от отступа. Для этого переобозначим целевые значения по правилу $y \leftarrow 2y - 1$. То есть далее будем считать, что $y \in \{-1, +1\}$.

С учётом введённого переобозначения представим логистическую функцию потерь в соответствующей форме. Рассмотрим два возможных значения y.

– При $y = +1$, что соответствует исходному значению $y = 1$, получаем

$$L_{\log}(1, z) = \log\left(1 + e^{z}\right) - z = \log\left(e^{-z}\left(1 + e^{z}\right)\right) = \log\left(1 + e^{-z}\right).$$

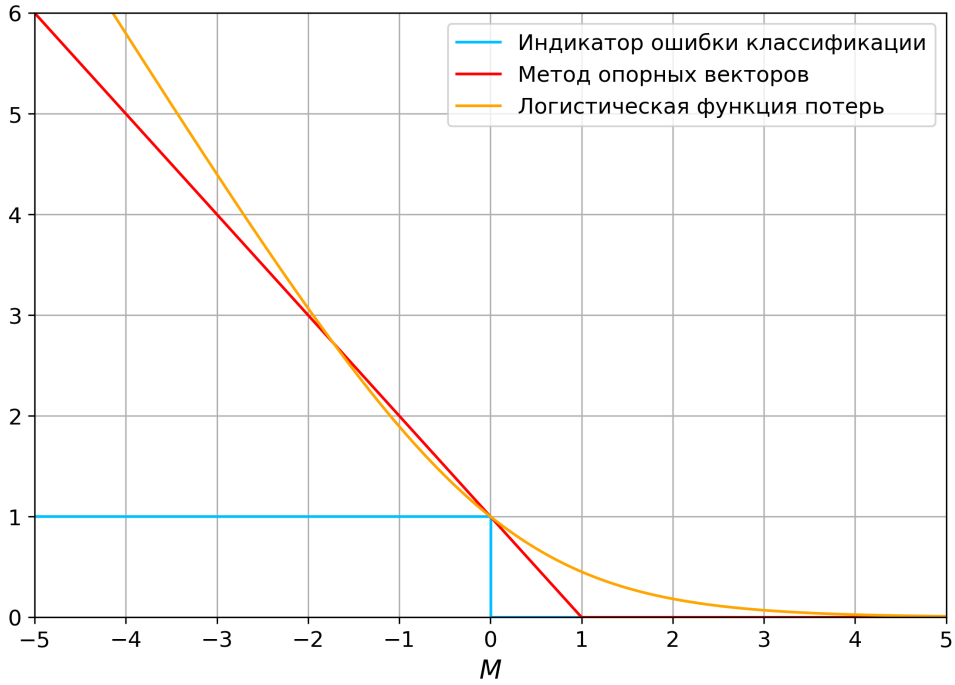


Рисунок 10 – Зависимость индикатора ошибки классификации и функций потерь от отступа

– При $y = -1$, что соответствует исходному значению $y = 0$, имеем

$$L_{\log}(-1, z) = \log\left(1 + e^{z}\right).$$

Следовательно, оба случая можно записать в единой форме:

$$L_{\log}(y, z) = \log\left(1 + e^{-yz}\right).$$

Обозначим через $\widetilde{L}_{\log}$ логистическую функцию потерь с логарифмом по основанию 2. Тогда обе рассматриваемые функции потерь, представленные как функции отступа, имеют вид

$$\widetilde{L}_{\log}(M) = \log_2\left(1 + e^{-M}\right), \qquad \widetilde{L}_{\text{hinge}}(M) = \max\{0,\ 1 - M\}.$$

Рассмотрим графики этих функций, изображённые на рисунке 10. Как можно заметить, с ростом положительного отступа значения обеих функций стремятся к нулю. При этом функция потерь метода опорных векторов обращается в нуль при $M \geq 1$, тогда как логистическая функция потерь остаётся

положительной при любом конечном значении отступа и продолжает убывать с его увеличением.

Таким образом, объекты, для которых достигнут необходимый положительный отступ, перестают влиять на дальнейшую оптимизацию функции потерь метода опорных векторов. При использовании логистической функции потерь увеличение отступа продолжает уменьшать её значение и для уже правильно классифицированных объектов. В некоторых задачах это различие может приводить к тому, что метод опорных векторов демонстрирует лучшие значения метрик качества классификации.

8 МНОГОКЛАССОВАЯ И МНОГОМЕТОЧНАЯ КЛАССИФИКАЦИЯ

8.1 Многоклассовая классификация

Рассмотрим задачу многоклассовой классификации. Пусть

$$\mathcal{X} = \mathbb{R}^d, \qquad \mathcal{Y} = \{1, \ldots, K\},$$

где $K \in \mathbb{N}$ — число классов.

Иными словами, каждый объект может относиться только к одному из K классов.

Пусть также заданы пространство выходов модели $\mathcal{Z}$, модель $\alpha \in \mathcal{A}_{\text{lin}}$ с некоторой функцией φ и некоторое отображение δ.

Существует множество подходов к сведению многоклассовой классификации к серии бинарных задач. В данном подразделе рассмотрим два наиболее известных подхода: один против всех (one-versus-all) и все против всех (all-versus-all).

8.1.1 Один против всех

Обучим K моделей на задачу бинарной классификации. Каждая из K моделей учится отличать соответствующий ей класс от всех остальных классов.

Пусть $\alpha_k(x)$ — модель, обученная отличать k-й класс от остальных. Зададим отображение δ как оператор $\arg\max$.

Тогда итоговый классификатор имеет вид

$$\alpha_\delta(x) = \arg \max_{k \in \{1,\ldots,K\}} \alpha_k(x).$$

Ограничение данного подхода заключается в том, что обучается K моделей, качество каждой из которых влияет на итоговое решение. Так, переобучение хотя бы одной модели может исказить результат классификатора.

В то же время модели могут иметь разные масштабы выходных значений. В таком случае их сопоставление является некорректным. Эта проблема особенно

актуальна для метода опорных векторов, в котором параметры различных моделей могут иметь разные масштабы.

8.1.2 Все против всех

Теперь обучим C_K^2 моделей на задачу бинарной классификации. Обозначим через $\alpha^{jm}(x)$, где $1 \leq j < m \leq K$, модель, обученную отличать j-й класс от m-го.

Каждая такая модель обучается по соответствующей подвыборке

$$\{(x_i, y_i) \mid y_i \in \{j, m\}\},$$

в которой объекты принадлежат только классам j и m.

Зададим некоторые отображения δ_τ для каждой модели $\alpha^{jm}(x)$. Отображение δ для итогового классификатора положим равным $\arg\max$.

Тогда итоговый классификатор имеет вид

$$\alpha_\delta(x) = \arg \max_{k \in \{1,\ldots,K\}} \sum_{1 \leq j < m \leq K} \left[\alpha_{\delta_\tau}^{jm}(x) = k\right].$$

То есть итоговым ответом становится класс, получивший наибольшее число голосов.

В отличие от предыдущего подхода, масштаб выходных значений моделей не влияет на итоговый результат, поскольку при голосовании используются ответы соответствующих классификаторов.

Однако число обучаемых моделей существенно возрастает. Это увеличивает вычислительные затраты и число моделей, подверженных переобучению, ошибки которых могут исказить ответ итогового классификатора.

8.1.3 Метрики качества многоклассовой классификации

Метрики качества многоклассовой классификации, подобно самой задаче, как правило, также строятся посредством сведения к рассмотренным ранее метрикам качества бинарной классификации. Выделяют два подхода к такому сведению.

Для этого представим многоклассовую задачу как K бинарных задач. Для каждой из этих задач можно вычислить метрики качества бинарной классификации. Для этого обобщим матрицу ошибок на K классов.

Таблица 5 – Матрица ошибок для задачи многоклассовой классификации

	$y = 1$	$y = 2$	$\cdots$	$y = K$
$\alpha_\delta(x) = 1$	C_{11}	C_{12}	$\cdots$	C_{1K}
$\alpha_\delta(x) = 2$	C_{21}	C_{22}	$\cdots$	C_{2K}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$\alpha_\delta(x) = K$	C_{K1}	C_{K2}	$\cdots$	C_{KK}

В таблице 5 через C_{ij} обозначено число объектов истинного класса j, отнесённых классификатором к классу i.

Поясним, как читать матрицу, представленную в таблице 5. Обозначим через TP_k, FP_k, TN_k и FN_k соответствующие величины матрицы ошибок для k-го класса относительно остальных классов. Тогда

$$TP_k = C_{kk}, \qquad FP_k = \sum_{j \neq k} C_{kj},$$

$$FN_k = \sum_{i \neq k} C_{ik}, \qquad TN_k = \sum_{i \neq k} \sum_{j \neq k} C_{ij}.$$

Для любого фиксированного класса k сумма этих величин равна числу объектов выборки:

$$TP_k + FP_k + FN_k + TN_k = \ell.$$

Микро-усреднение.

При микро-усреднении характеристики сначала усредняются по классам, а затем вычисляется соответствующая двухклассовая метрика. Например, полнота вычисляется как

$$\text{recall}_{\text{micro}} = \frac{\overline{TP}}{\overline{TP} + \overline{FN}}, \qquad \overline{TP} = \frac{1}{K}\sum_{k=1}^{K} TP_k, \qquad \overline{FN} = \frac{1}{K}\sum_{k=1}^{K} FN_k.$$

Макро-усреднение.

При макро-усреднении сначала вычисляется итоговая метрика для каждого класса, а затем полученные значения усредняются. Например, для полноты получаем

$$\text{recall}_{\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} \text{recall}_k, \qquad \text{recall}_k = \frac{TP_k}{TP_k + FN_k}.$$

Отметим, что микро-усреднение имеет существенный недостаток. Рассмотрим пример.

Пусть $K = 3$, причём первый класс содержит 90 объектов, а второй и третий классы содержат по 5 объектов. Пусть также классификатор правильно определил все объекты первого класса, но из второго и третьего классов распознал только по одному объекту, а остальные объекты отнёс к первому классу.

Тогда матрица ошибок имеет вид, представленный в таблице 6. По этой матрице вычислим полноту обоими подходами.

Таблица 6 – Матрица ошибок
для трёх классов

	$y = 1$	$y = 2$	$y = 3$
$\alpha_\delta(x) = 1$	90	4	4
$\alpha_\delta(x) = 2$	0	1	0
$\alpha_\delta(x) = 3$	0	0	1

– При микро-усреднении:

$$\text{recall}_{\text{micro}} = \frac{92}{92 + 8} = 0.92.$$

– При макро-усреднении:

$$\text{recall}_{\text{macro}} = \frac{1 + \frac{1}{5} + \frac{1}{5}}{3} \approx 0.467.$$

Следовательно, если некоторый класс имеет очень маленькую мощность, то при микро-усреднении он практически никак не влияет на результат, поскольку его вклад в средние значения TP, FP, FN и TN является незначительным.

В случае же макро-усреднения сначала вычисляются величины, которые уже не чувствительны к соотношению размеров классов, если используются, например, точность или полнота. Поэтому каждый класс вносит одинаковый вклад в итоговую метрику.

Утверждение. В задаче многоклассовой классификации метрики $\text{recall}_{\text{micro}}$, $\text{precision}_{\text{micro}}$ и $F_{1,\text{micro}}$ совпадают с долей верных ответов:

$$\text{precision}_{\text{micro}} = \text{recall}_{\text{micro}} = F_{1,\text{micro}} = \text{accuracy}\,.$$

□ Обозначим через V число верно классифицированных объектов, а через E — число ошибок. Тогда

$$V + E = \ell.$$

Каждый верно классифицированный объект увеличивает на единицу значение TP_k соответствующего ему класса. Поэтому

$$\sum_{k=1}^{K} TP_k = V.$$

Каждая ошибка состоит в том, что объект истинного класса j отнесён к некоторому классу $i \neq j$. Такая ошибка одновременно увеличивает на единицу значение FP_i и на единицу значение FN_j. Следовательно,

$$\sum_{k=1}^{K} FP_k = E, \qquad \sum_{k=1}^{K} FN_k = E.$$

Тогда

$$\begin{aligned}\text{precision}_{\text{micro}} &= \frac{\sum\limits_{k=1}^{K} TP_k}{\sum\limits_{k=1}^{K} TP_k + \sum\limits_{k=1}^{K} FP_k} \\ &= \frac{V}{V+E} = \frac{V}{\ell}.\end{aligned}$$

Аналогично,

$$\begin{aligned}\text{recall}_{\text{micro}} &= \frac{\sum\limits_{k=1}^{K} TP_k}{\sum\limits_{k=1}^{K} TP_k + \sum\limits_{k=1}^{K} FN_k} \\ &= \frac{V}{V+E} = \frac{V}{\ell}.\end{aligned}$$

Поскольку данные величины равны, получаем

$$F_{1,\text{micro}} = \frac{2\,\text{precision}_{\text{micro}}\,\text{recall}_{\text{micro}}}{\text{precision}_{\text{micro}} + \text{recall}_{\text{micro}}} = \frac{V}{\ell}.$$

Доля верных ответов в задаче многоклассовой классификации определяется как

$$\text{accuracy} = \frac{\sum\limits_{k=1}^{K} TP_k}{\ell} = \frac{V}{\ell}.$$

Следовательно,

$$\text{precision}_{\text{micro}} = \text{recall}_{\text{micro}} = F_{1,\text{micro}} = \text{accuracy} = \frac{V}{\ell}.$$

■

Таким образом, достаточно вычислить долю верных ответов, чтобы иметь представление об основных метриках микро-усреднения.

Дополнительно отметим, что метрики качества многоклассовой классификации, как правило, не зависят от общего порога τ. Данные метрики для рассмотренных в пунктах 8.1.1 и 8.1.2 подходов вычисляются для итогового классификатора, отображение δ которого не зависит от такого порога.

8.2 Многометочная классификация

Рассмотрим теперь задачу многометочной классификации. Пусть

$$\mathcal{X} = \mathbb{R}^d \qquad \mathcal{Y} = \{0, 1\}^K,$$

где $K \in \mathbb{N}$ — число классов.

Иными словами, каждому объекту $x \in \mathcal{X}$ соответствует булев вектор

$$y = (y_1, \ldots, y_K)^T \in \mathcal{Y},$$

задающий принадлежность объекта соответствующим классам.

Пусть также задано пространство выходов модели $\mathcal{Z}$, а модель $\alpha \in \mathcal{A}_{\text{lin}}$ задана с некоторой функцией φ.

Подобно задаче многоклассовой классификации рассмотрим два наиболее известных подхода к решению задачи многометочной классификации.

8.2.1 Независимая классификация

Будем определять принадлежность объекта к каждому классу независимо и обучим K моделей на задачу бинарной классификации.

Обозначим через $\alpha_k(x)$ модель, обученную определять принадлежность объекта к k-му классу, и зададим отображение δ_τ, соответствующее данной модели. Тогда соответствующий классификатор будем обозначать через $\alpha^k_{\delta_\tau}$.

Итоговый классификатор зададим как вектор классификаторов:

$$\alpha_M(x) = \begin{pmatrix} \alpha^1_{\delta_\tau}(x) \\ \vdots \\ \alpha^K_{\delta_\tau}(x) \end{pmatrix}.$$

Отметим, что каждый классификатор $\alpha^k_{\delta_\tau}$ может иметь собственное отображение δ и собственный порог τ. В данном случае используется упрощённое обозначение.

Основным ограничением данного подхода является отсутствие связей между отдельными классами. В некоторых задачах такие связи могут иметь

место. Так, например, в медицинских задачах многие заболевания являются тесно связанными.

8.2.2 Цепочки классификаторов

Зададим некоторую перестановку $\pi = (\pi_1, \ldots, \pi_K)$. Обозначим через $\alpha_{\pi_k}(x)$ модель, обученную на k-м шаге.

Обучающая выборка на шаге k имеет вид

$$\left\{\left(\left(x_i, y_{i,\pi_1}, \ldots, y_{i,\pi_{k-1}}\right), y_{i,\pi_k}\right)\right\}_{i=1}^{\ell}.$$

Первую модель обучим на выборке

$$\left\{\left(x_i, y_{i,\pi_1}\right)\right\}_{i=1}^{\ell}.$$

Следующую модель обучим на расширенной выборке, в которой к признакам добавлен столбец целевых значений первого шага. Далее процесс продолжается аналогичным образом.

Следовательно, при обучении каждая модель использует в качестве дополнительных признаков истинные значения классов, расположенных перед ней в цепочке.

Для каждой модели зададим отображение δ_τ и обозначим через $\alpha_{\delta_\tau}^{\pi_k}$ классификатор на шаге k. Тогда последовательность классификаторов имеет вид

$$\begin{aligned}
&\alpha_{\delta_\tau}^{\pi_1}(x),\\
&\alpha_{\delta_\tau}^{\pi_2}\left(x, \alpha_{\delta_\tau}^{\pi_1}(x)\right),\\
&\vdots\\
&\alpha_{\delta_\tau}^{\pi_K}\left(x, \alpha_{\delta_\tau}^{\pi_1}(x), \ldots, \alpha_{\delta_\tau}^{\pi_{K-1}}(x)\right).
\end{aligned}$$

Итоговый классификатор α_M^π зададим как вектор

$$\alpha_M^\pi(x) = \begin{pmatrix} \alpha_{\delta_\tau}^1(x) \\ \vdots \\ \alpha_{\delta_\tau}^K(x) \end{pmatrix},$$

где $\alpha^k_{\delta_\tau}$ — классификатор, определяющий принадлежность объекта к k-му классу.

Таким образом, данный подход позволяет учитывать зависимости между отдельными классами. Однако последовательная природа метода одновременно является его ограничением: ошибка модели, расположенной в начале цепочки, может повлиять на входные признаки последующих моделей и тем самым исказить их ответы.

В то же время результат итогового классификатора зависит от порядка обучения. Обычно эту проблему решают построением набора цепочек, соответствующих различным перестановкам.

8.2.3 Метрики качества многометочной классификации

В многометочной классификации метрики, как правило, зависят от выбранных порогов, поскольку итоговый классификатор является вектором бинарных классификаторов и каждая его координата может иметь собственное пороговое значение. Далее будем считать, что пороги фиксированы.

Обозначим итоговый классификатор через $\alpha_M(x)$. Для оценки различия между булевыми векторами y и $\alpha_M(x)$ введём расстояние Хемминга:

$$d_H\left(y, \alpha_M(x)\right) = \sum_{k=1}^{K} \left(y_k \oplus \alpha_{M,k}(x)\right),$$

где $\oplus$ — сложение по модулю 2, а $\alpha_{M,k}(x)$ — k-я координата ответа итогового классификатора.

Тогда метрика Хемминга задаётся как

$$\text{Hamming} = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{d_H\left(y_i, \alpha_M(x_i)\right)}{K}.$$

Данная величина показывает среднюю по объектам выборки долю классов, факт принадлежности к которым определён классификатором неверно.

Рассмотрим далее введённые ранее метрики бинарной классификации и обобщим их на задачу многометочной классификации.

– Доля верных ответов:

$$\text{accuracy} = \frac{1}{\ell}\sum_{i=1}^{\ell}\text{accuracy}_i, \qquad \text{accuracy}_i = \frac{\sum\limits_{k=1}^{K}\big(y_{ik} \wedge \alpha_{M,k}(x_i)\big)}{\sum\limits_{k=1}^{K}\big(y_{ik} \vee \alpha_{M,k}(x_i)\big)}.$$

– Точность:

$$\text{precision} = \frac{1}{\ell}\sum_{i=1}^{\ell}\text{precision}_i, \qquad \text{precision}_i = \frac{\sum\limits_{k=1}^{K}\big(y_{ik} \wedge \alpha_{M,k}(x_i)\big)}{\sum\limits_{k=1}^{K}\alpha_{M,k}(x_i)}.$$

– Полнота:

$$\text{recall} = \frac{1}{\ell}\sum_{i=1}^{\ell}\text{recall}_i, \qquad \text{recall}_i = \frac{\sum\limits_{k=1}^{K}\big(y_{ik} \wedge \alpha_{M,k}(x_i)\big)}{\sum\limits_{k=1}^{K}y_{ik}}.$$

Отметим, что подходы к построению метрик качества многоклассовой классификации, рассмотренные в пункте 8.1.3, могут быть перенесены и на задачу многометочной классификации.

Однако полученные таким образом метрики характеризуют качество итогового классификатора с иной точки зрения, чем рассмотренные ранее метрики многометочной классификации. Покажем это на примере.

Пусть выборка состоит из двух объектов и двух классов:

$$y_1 = (1,1)^T, \;\; \alpha_M(x_1) = (1,0)^T,$$
$$y_2 = (1,0)^T, \;\; \alpha_M(x_2) = (1,0)^T.$$

Полнота многометочной классификации равна

$$\text{recall} = \frac{1}{2}\left(\frac{\sum\limits_{k=1}^{2}\left(y_{1k} \wedge \alpha_{M,k}(x_1)\right)}{\sum\limits_{k=1}^{2} y_{1k}} + \frac{\sum\limits_{k=1}^{2}\left(y_{2k} \wedge \alpha_{M,k}(x_2)\right)}{\sum\limits_{k=1}^{2} y_{2k}}\right).$$

Для первого объекта верно определён один из двух классов, а для второго — единственный соответствующий ему класс. Поэтому

$$\text{recall} = \frac{1}{2}\left(\frac{1}{2} + 1\right) = \frac{3}{4}.$$

Теперь вычислим полноту с макро-усреднением:

$$\text{recall}_{\text{macro}} = \frac{1}{2}\left(\frac{2}{2} + \frac{0}{1}\right) = \frac{1}{2}.$$

Первая дробь соответствует первому классу: оба принадлежащих ему объекта классифицированы верно. Вторая дробь соответствует второму классу: единственный принадлежащий ему объект не был отнесён к этому классу.

Тем самым,

$$\text{recall} = \frac{3}{4}, \qquad \text{recall}_{\text{macro}} = \frac{1}{2}.$$

Таким образом, макро-усреднённая полнота характеризует среднее качество распознавания отдельных классов, придавая каждому классу одинаковый вес. Многометочная полнота, в свою очередь, характеризует качество покрытия множества классов каждого объекта.