Архитектура Данных: От Трубопровода до Линз Аналитики



Акт I: Трубопровод

Надежный перенос сырья.
Оркестрация через Airflow, журнальный CDC, обеспечение идемпотентности и смещение парадигмы в сторону ELT.

Акт II: Фильтры

Непрерывный контроль.
Измерение метрик качества по ГОСТ 25012, техническое профилирование, дедупликация и Data Governance.

Акт III: Линзы

Извлечение смыслов.
Аналитический SQL, многомерные агрегации (ROLLUP/CUBE) и оконные функции без потери детализации.

Gemini Notebook



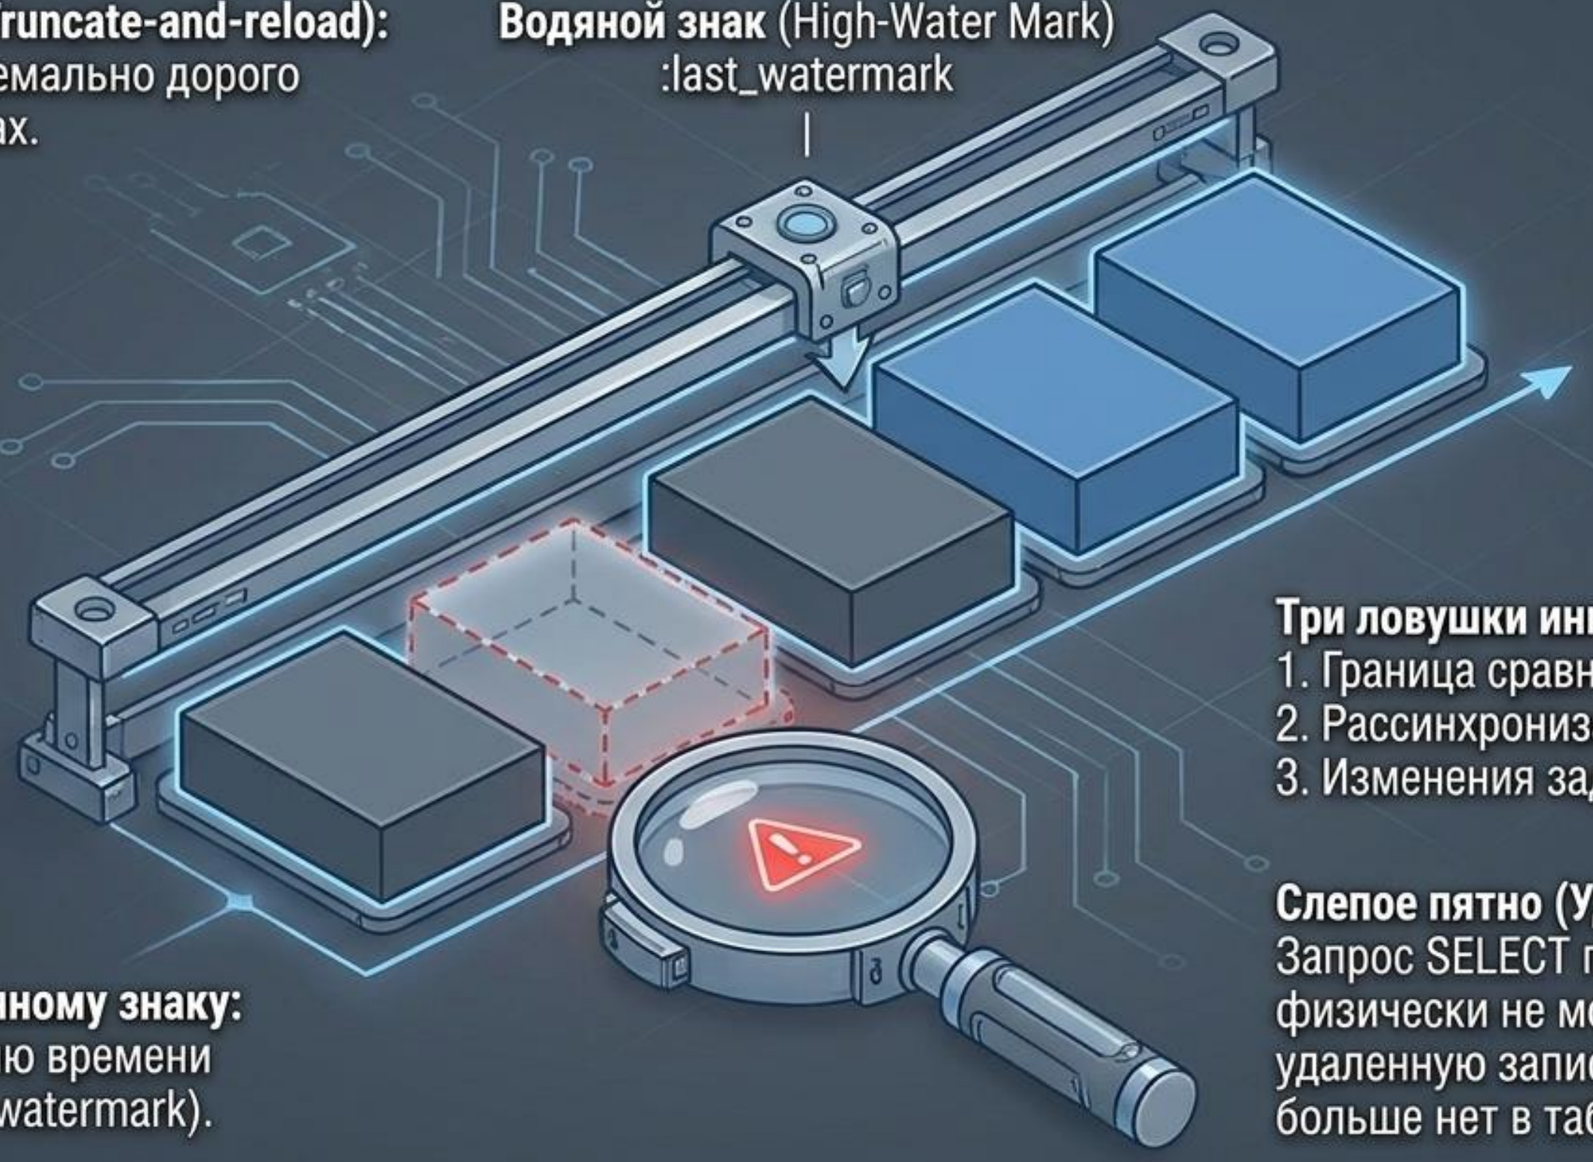
Критерий	Классический ETL	Современный ELT
Где преобразование:	На отдельном внешнем сервере	Внутри целевого хранилища
Порядок этапов:	Extract → Transform → Load	Extract → Load → Transform
Сырые данные:	Обычно удаляются после трансформации	Сохраняются в Data Lake для переобработки
Драйвер перехода:	Ограничения старых СУБД	Дешевое хранение и мощь MPP-движков (ClickHouse)

Gemini Notebook

Инкрементальная загрузка и ее слепое пятно

Полная загрузка (Truncate-and-reload):
Надежно, но экстремально дорого на больших объемах.

Водяной знак (High-Water Mark)
:last_watermark



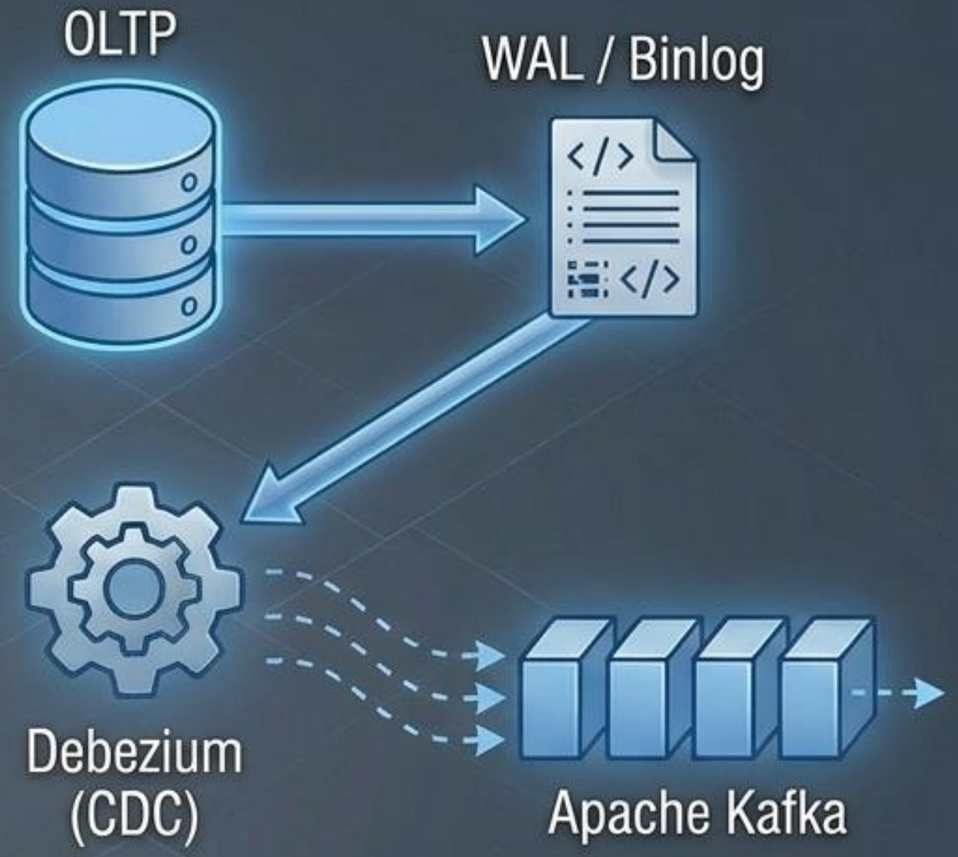
Три ловушки инкремента:
1. Граница сравнения (строгое > vs >=).
2. Рассинхронизация часовых поясов.
3. Изменения задним числом.

Слепое пятно (Удаления):
Запрос SELECT по метке времени физически не может поймать удаленную запись, так как ее больше нет в таблице источника.

Инкремент по водяному знаку:
Отбор строк по полю времени (updated_at > :last_watermark).

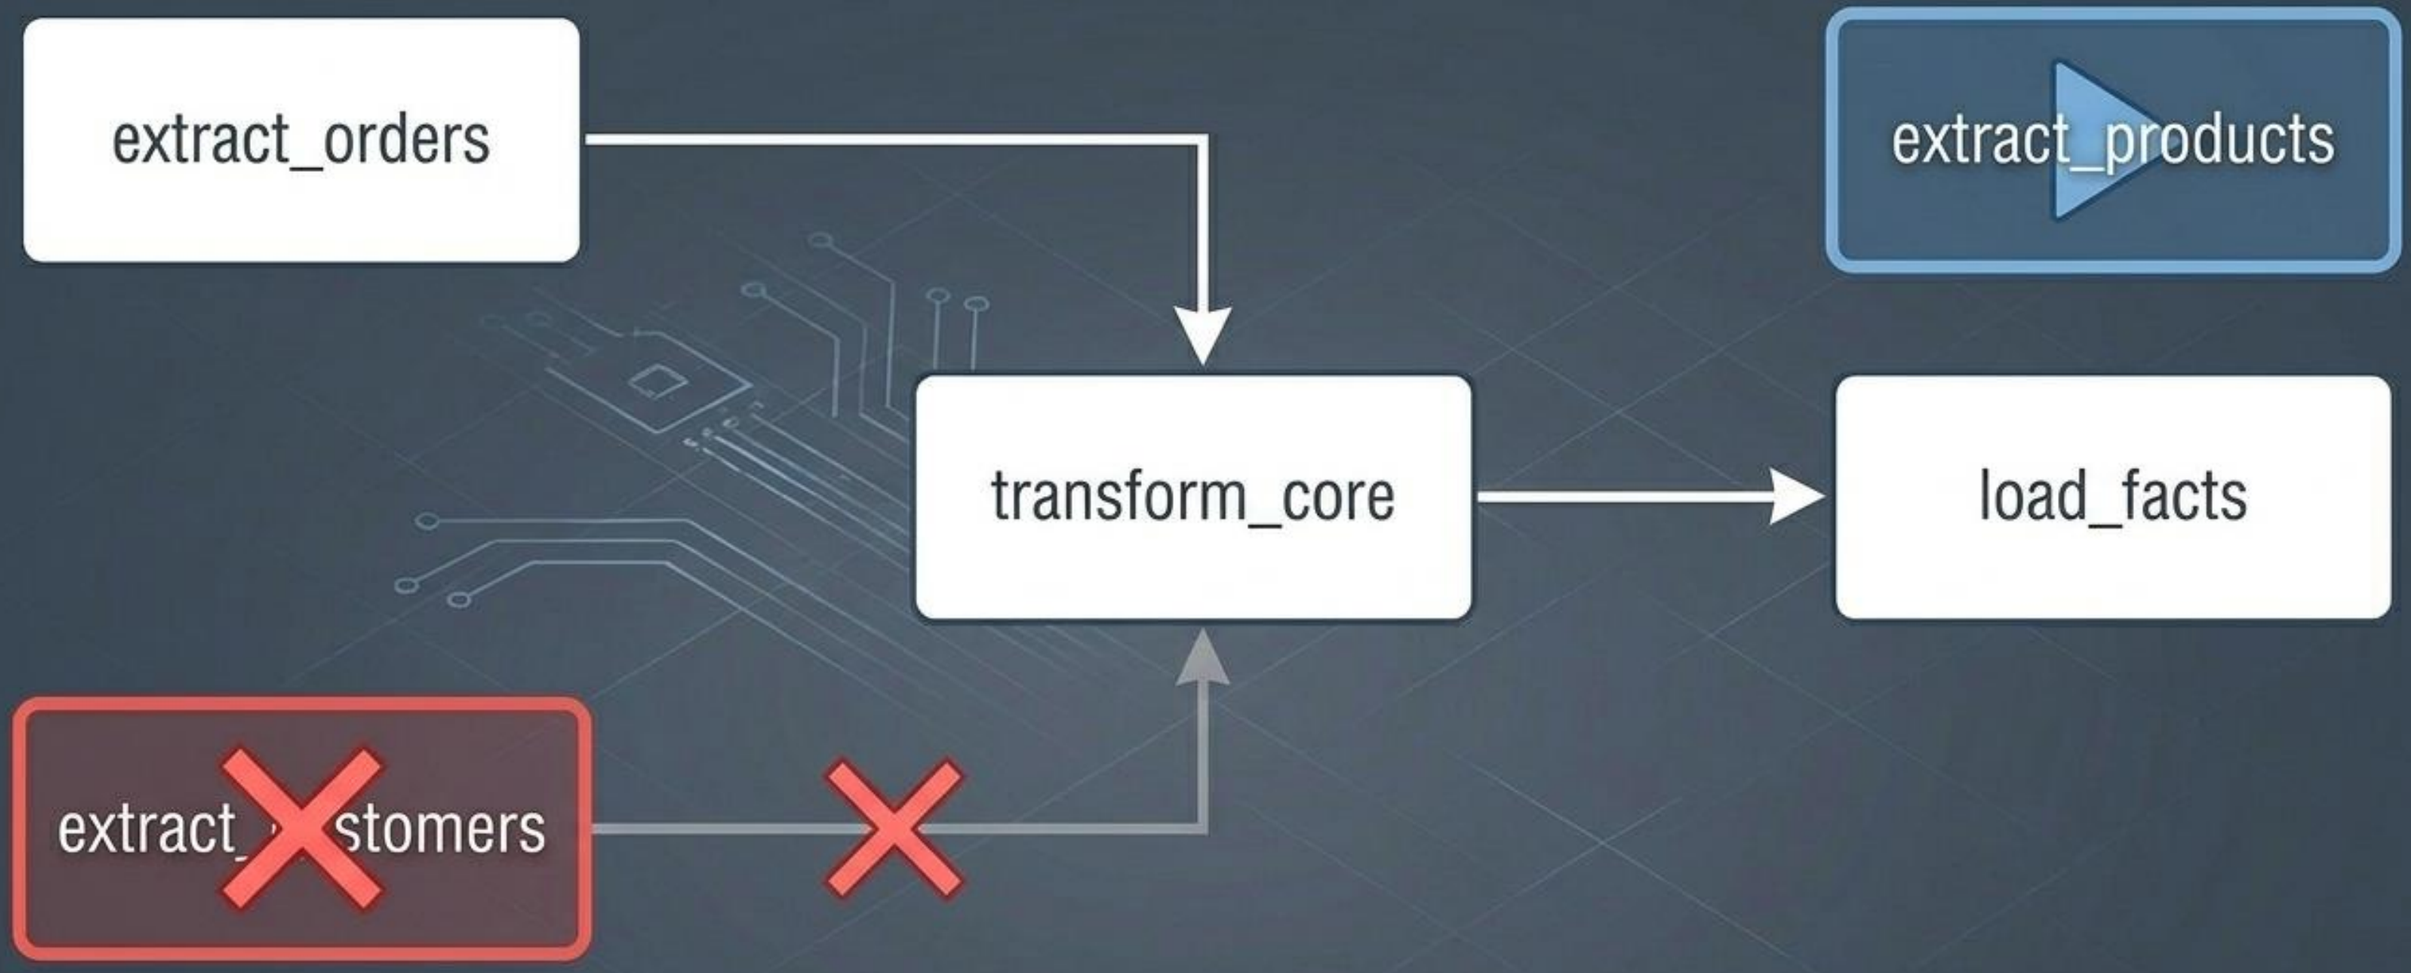
Gemini Notebook

Метод	Вторжение в источник	Видимость удалений	Нагрузка
По столбцу времени	Нет	Не видит	Низкая
Триггерный	Изменение схемы	Видит	Высокая (каждая транзакция)
Снимковый (Diff)	Нет	Видит	Высокая (сравнение массивов)
Журнальный (WAL/binlog)	Нет	Видит ВСЕ	Минимальная



Мост к реальному времени:
Журнальный CDC превращает пакетный извлекающий ETL в непрерывный поток событий (Streaming).

Gemini Notebook



DAG (Направленный ациклический граф):
Вершины — задачи, ребра — зависимости.
Ацикличность гарантирует существование финальной точки конвейера.

Оркестрация (Apache Airflow):
Читает код DAG, соблюдает порядок и управляет запуском.
Сам не преобразует данные, а дирижирует процессами.

Параллелизм:
Задачи, не имеющие общих путей в графе (как extract_products), автоматически выполняются параллельно.

Gemini Notebook



Проблема:
Падение сети на середине.
При перезапуске часть данных грузится второй раз.

Идемпотентность:
Свойство операции давать идентичный результат при любом числе повторных запусков.

Решение (UPSERT / MERGE):
Если ключ есть — обнови (UPDATE), если нет — вставь (INSERT).

Следствие:
Безопасный перезапуск упавших задач и backfill (заполнение за прошлые дни) без риска задублировать витрину.

Gemini Notebook

Цена грязных данных: Правило 1–10–100

Экспоненциальный рост стоимости дефекта на каждом этапе конвейера.



Garbage In, Garbage Out:

Идеально написанный аналитический SQL-запрос поверх мусорных данных выдаст математически точный мусор.

Gemini Notebook

Измерение качества (ГОСТ Р ИСО/МЭК 25012)

Качество данных измеримо. «Плохие данные» — это не метрика.



Полнота. Доля заполненных значений (отсутствие NULL в обязательных полях).



Точность. Соответствие реальности (корректные даты, реалистичные суммы).



Согласованность. Непротиворечивость (сумма заказа = сумме всех его позиций).



Актуальность. Отражение текущего состояния (действующий тариф, а не архивный).



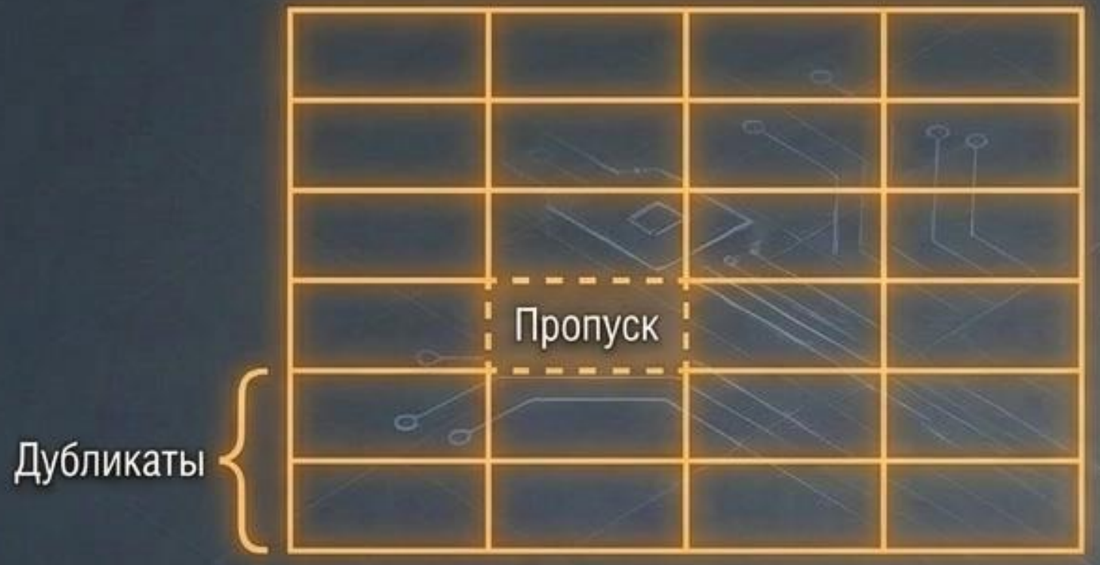
Уникальность. Отсутствие неоправданных дублей одного реального объекта.



Доступность. Данные не заблокированы правами и доступны по требованию.

Gemini Notebook

Профилирование и Очистка





Три вектора профилирования:
Структура (типы),
Содержание (распределения),
Связи (ключи).

Выбросы (Outliers):
Наблюдения, резко отклоняющиеся от массы.
Слепое удаление опасно: выброс может быть мошеннической транзакцией.

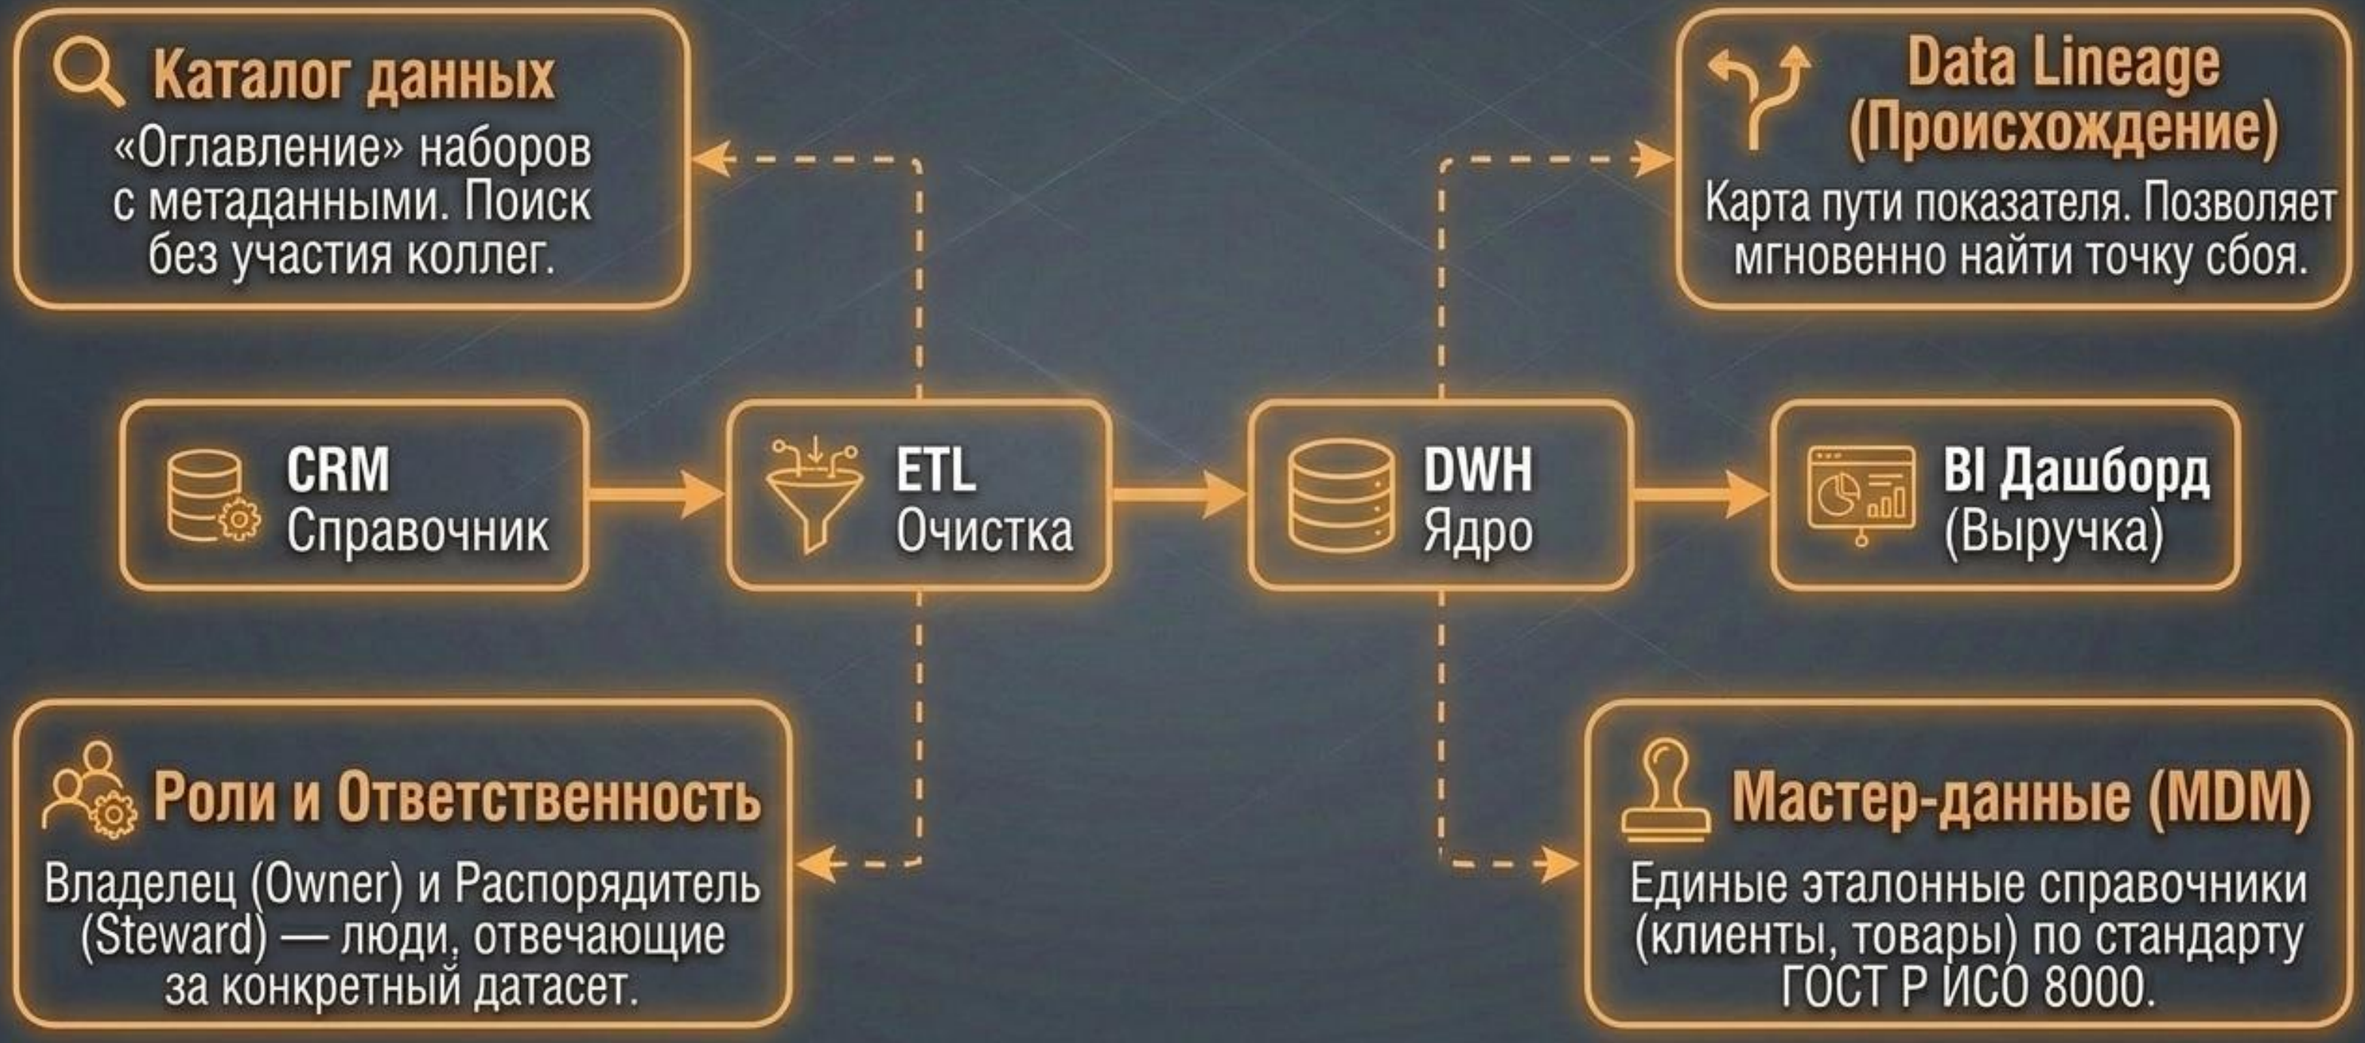
Обработка пропусков:
Выбросить строку/признак ИЛИ импутировать (константа, медиана).

Разрешение сущностей (Entity Resolution):
В отличие от дедупликации, сводит разные написания («ООО Ромашка» и «Ромашка, ООО») в один реальный объект.

Gemini Notebook

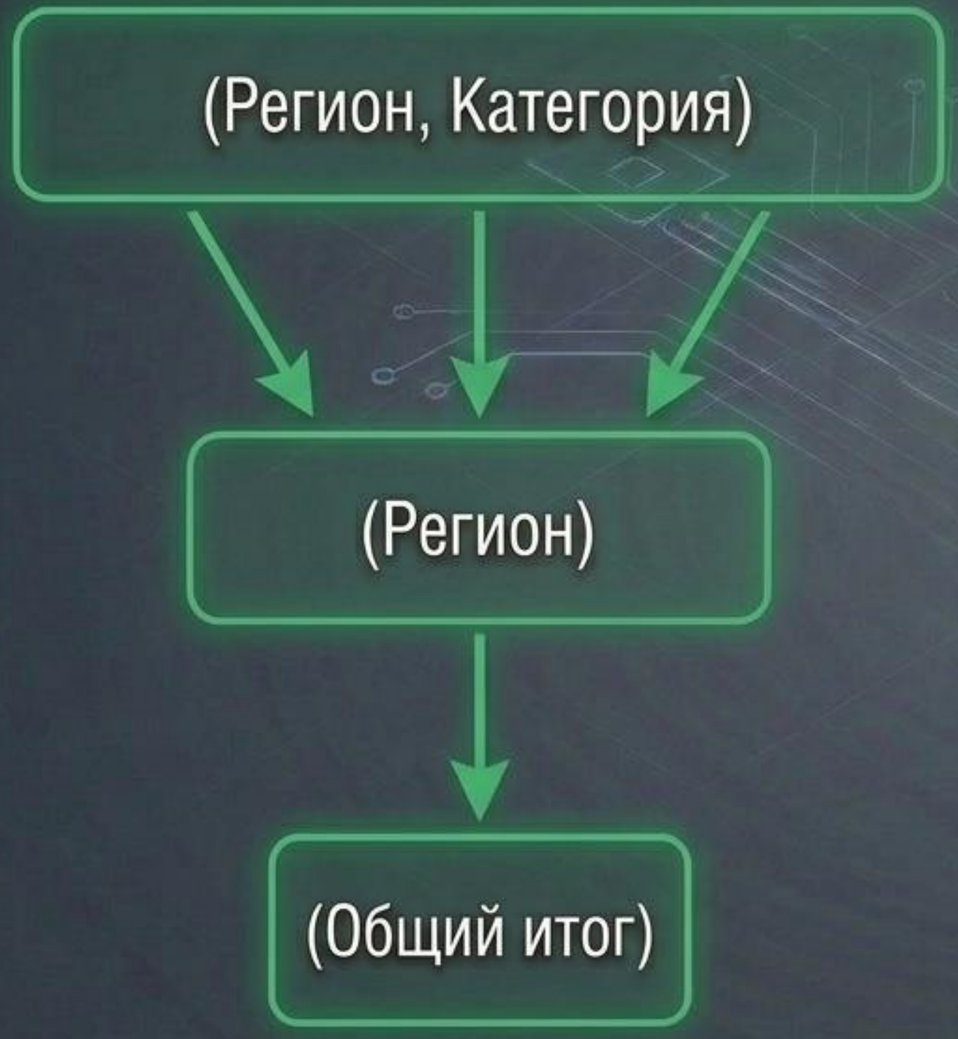
Управление данными (Data Governance)

Разовая очистка деградирует за недели. Качество необходимо удерживать системно.



Gemini Notebook

Аналитический SQL: Расширенные группировки




```
SELECT region, category, SUM(amount)
FROM sales
GROUP BY ROLLUP (region, category);
```

GROUPING SETS:
Вычисление детальных итогов, подытогов и общего итога одним проходом, без десятков UNION ALL.

ROLLUP:
Сворачивает естественные иерархии сверху вниз (Год → Месяц).

CUBE:
Строит итоги по всем возможным сочетаниям измерений.

Gemini Notebook

Анатомия оконной функции

Как посчитать агрегат, не теряя исходную детализацию строки.

compression



passthrough with addition



GROUP BY

Схлопывает детализацию. Исходные строки уничтожаются, остается только агрегат.

Оконная функция

Сохраняет строки независимыми. Вычисляет агрегат по группе («окну») и привязывает результат к каждой текущей строке.

Syntax

SUM(amount) OVER (PARTITION BY region)

Функции ранжирования

ROW_NUMBER(): 1, 2, 3, 4
RANK(): 1, 2, 2, 4 (с пропуском)
DENSE_RANK(): 1, 2, 2, 3 (без пропуска)

Gemini Notebook

Рамка окна и Рекурсия

Рамка окна (Window Frame):



- ORDER BY внутри окна не просто сортирует — он по умолчанию включает рамку от начала до текущей строки (Нарастающий итог).
- Скользящее среднее: Рамка ROWS BETWEEN 2 PRECEDING AND CURRENT ROW создает окно из 3 строк, скользящее по набору данных.
- LAG / LEAD: Доступ к предыдущей или следующей строке без тяжелых JOIN.

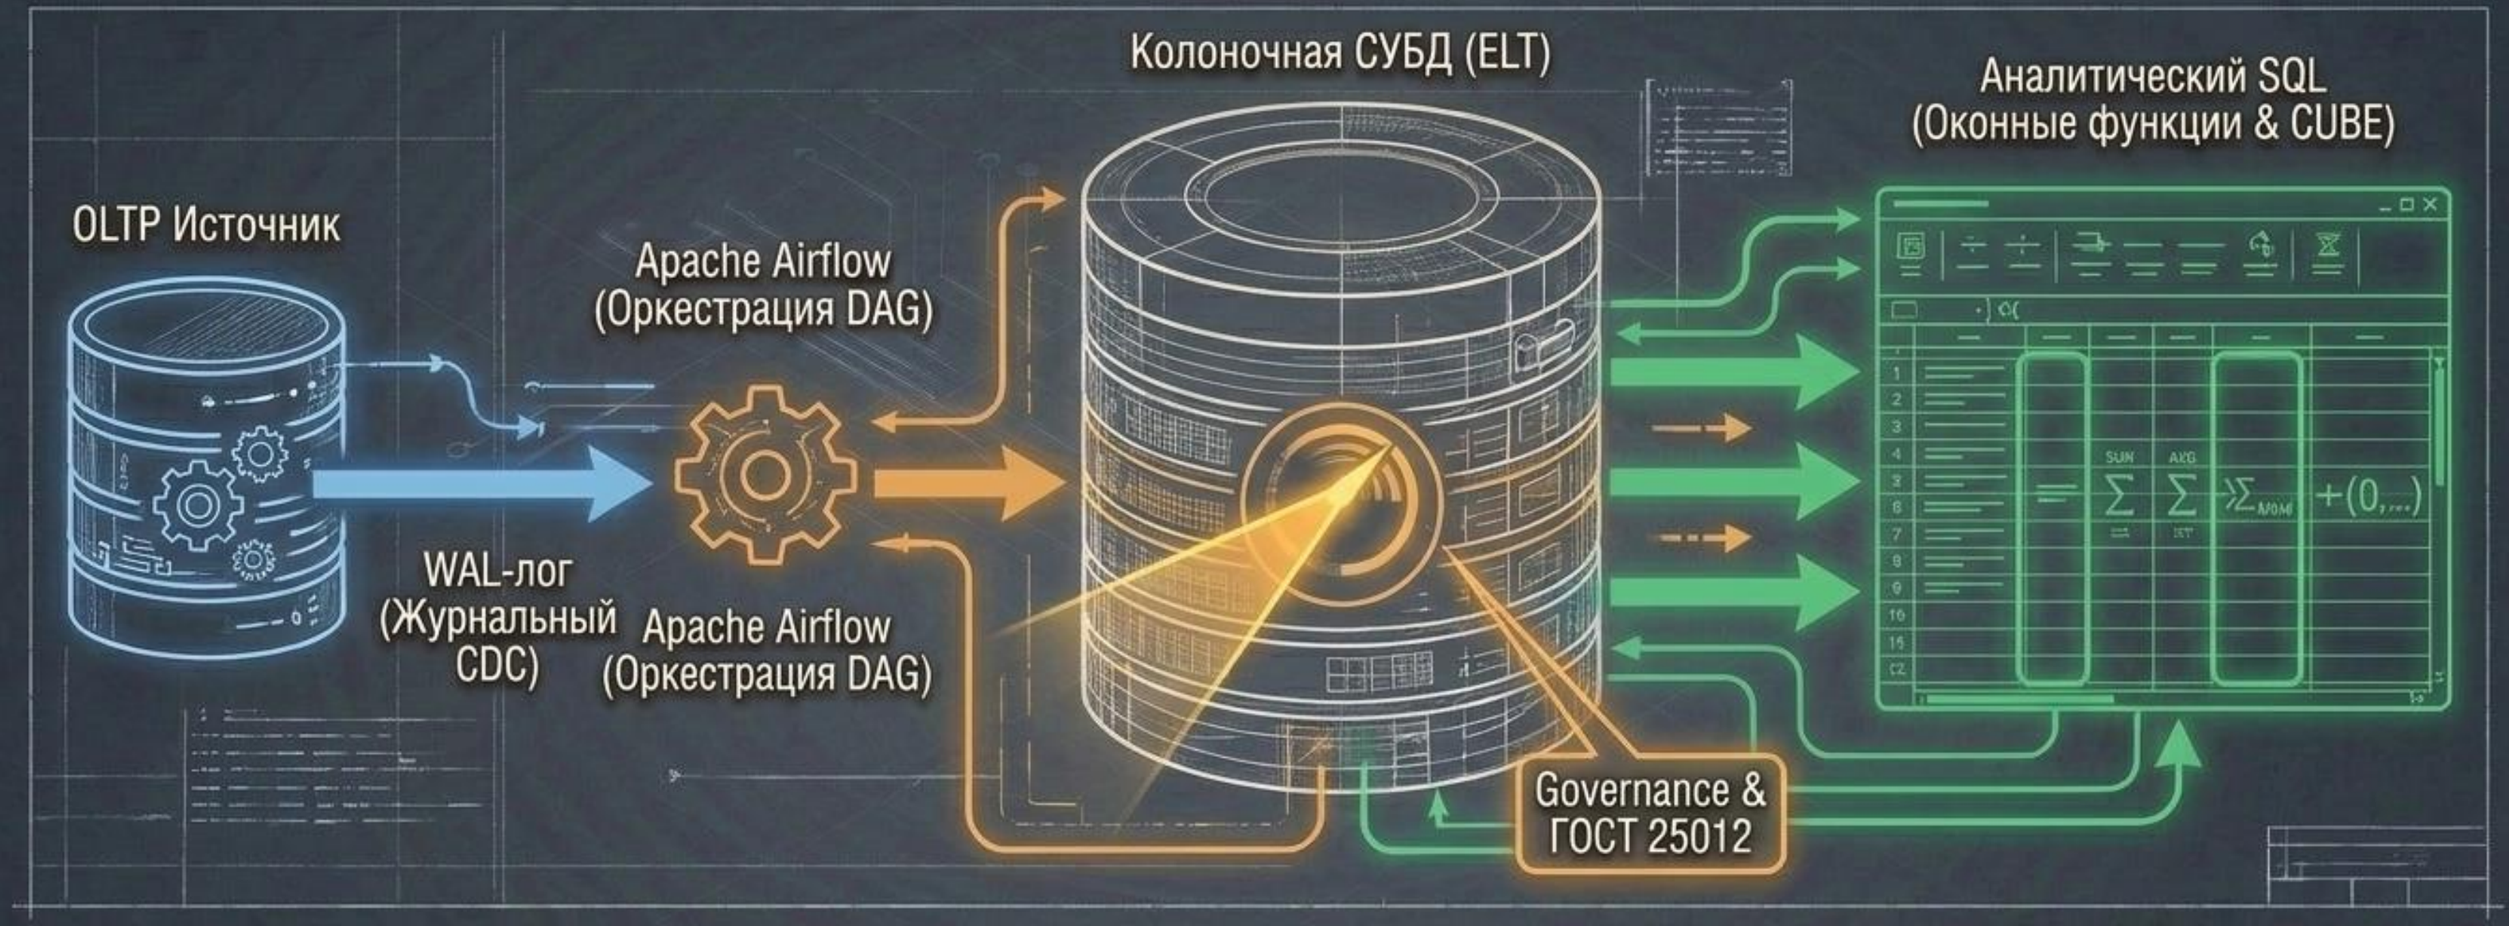
Рекурсивные CTE (WITH RECURSIVE):



- Запрос ссылается на самого себя. Идеально для обхода несбалансированных «рваных» иерархий (оргструктура) на любую неизвестную глубину.

Gemini Notebook

Единая экосистема аналитики: Синтез



Аналитика реального времени — это не изолированные инструменты, а единый сквозной конвейер.

«Идеальный конвейер, аккуратно загрузивший мусор — это по-прежнему мусор, только загруженный вовремя.»

Конечный результат:
ELT обеспечивает масштаб, журнальный CDC дает актуальность, Governance гарантирует доверие, а SQL извлекает бизнес-смысл.
Мгновенно. Безошибочно. Идемпотентно.

Gemini Notebook