Архитектура аналитических систем

# Оперативный анализ данных: От хаоса к системе



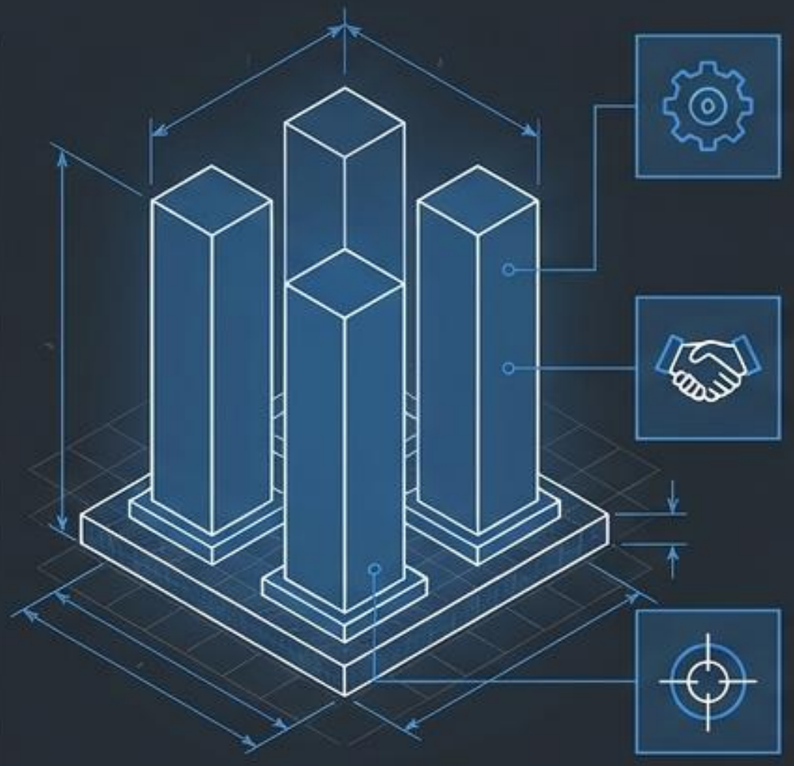
Полное руководство по проектированию DWH: Инфраструктура, Моделирование, Архитектура и Управление изменениями

Gemini Notebook

# Хранилища рушатся не из-за кода

Технически идеальная загрузка не спасет,
если нет системы.





Метаданные:
Чтобы не потерять смысл
(Кто отвечает за поле
«Маржа»?).

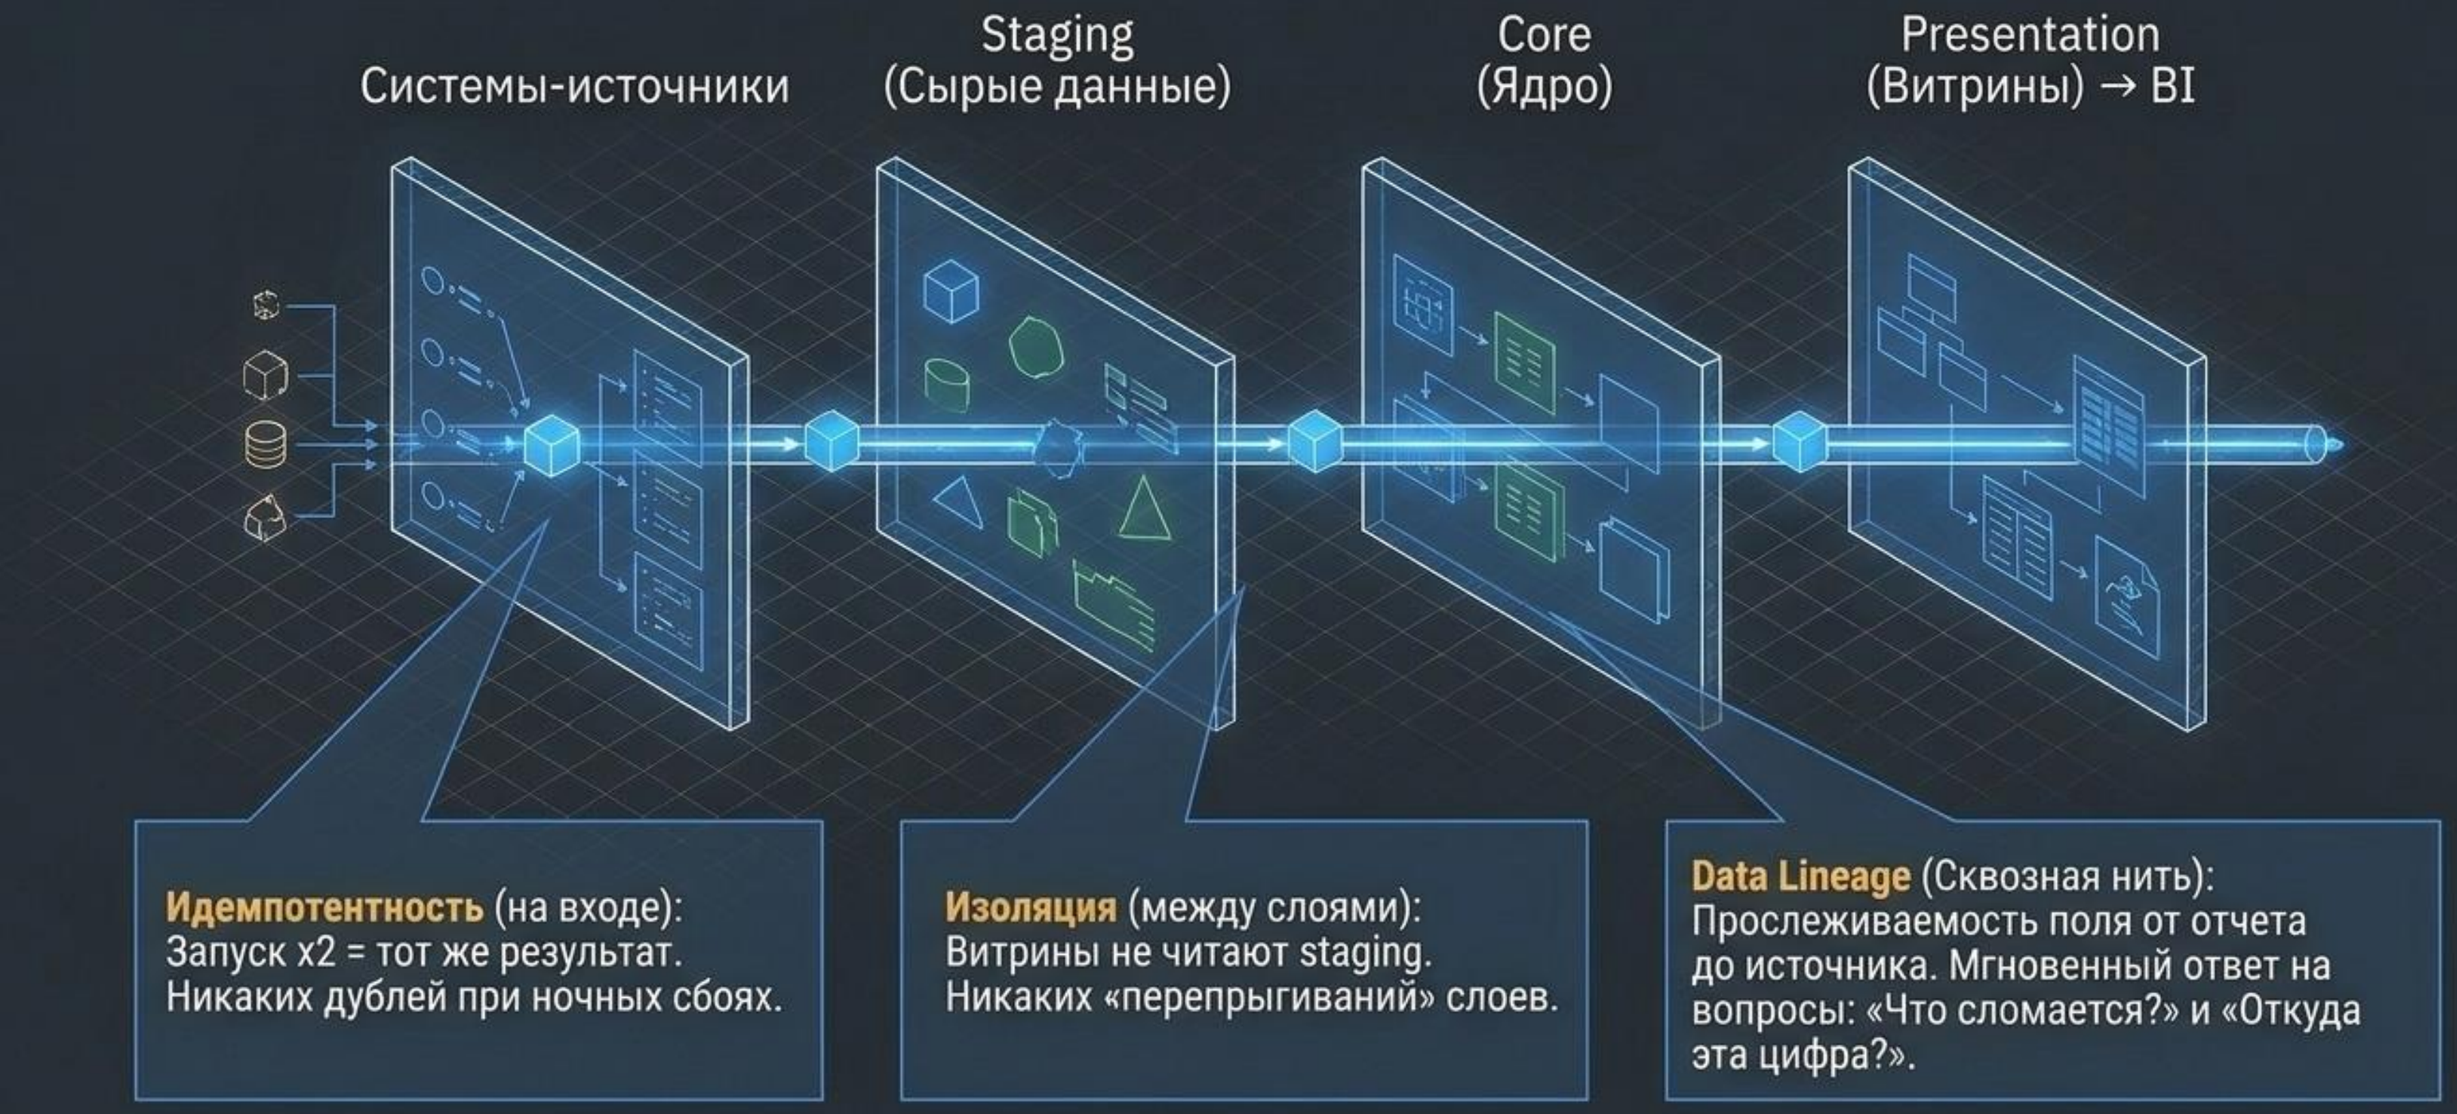
Границы ответственности:
Чтобы знать, кто отвечает
за качество
(Инженер доставляет,
Владелец определяет,
Аналитик интерпретирует).

Измеримые требования:
Чтобы знать, как система
должна работать (SLA).

Архитектура — это договор между бизнесом и технологиями,
закрепленный документально (ГОСТ 34.601-90).

Gemini Notebook

# Жесткие правила конвейера данных




Gemini Notebook

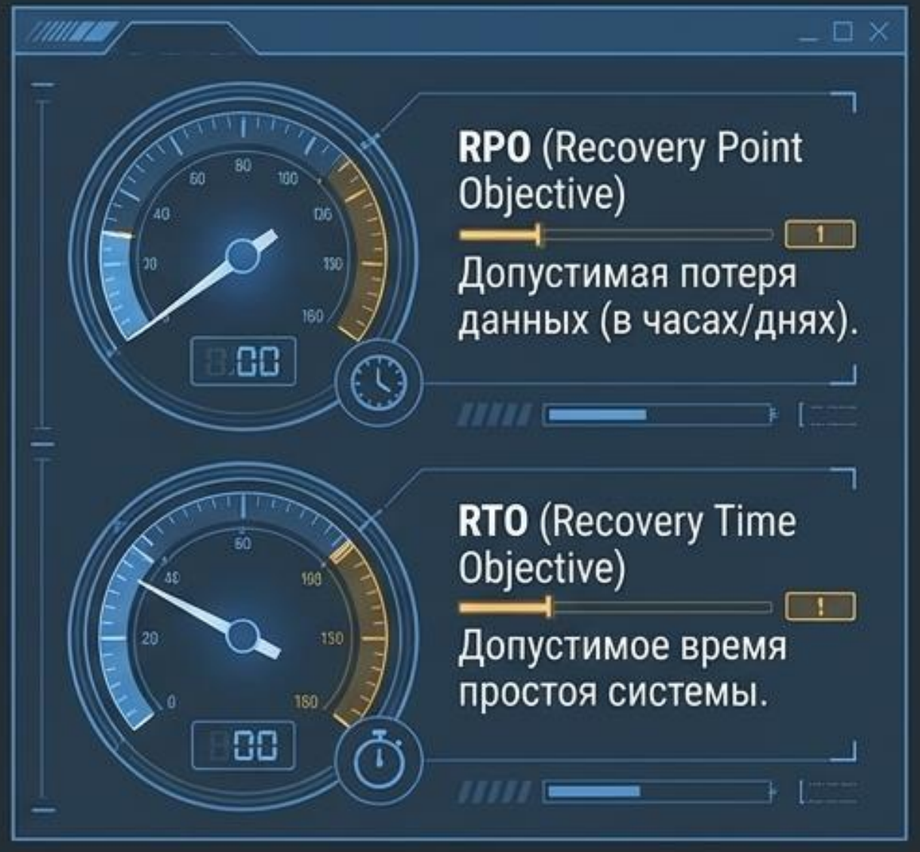
# Невидимый клей DWH: Метаданные и Метрики




**Технические:**
Структуры, индексы (Создаются СУБД автоматически).

**Бизнес-метаданные:**
Смысл показателя, владелец. (Пишет человек. Их отсутствие = смерть доверия к цифрам).

**Операционные:**
Время загрузки, ошибки. (Пишет система. Делают тихие сбои заметными).



**RPO** (Recovery Point Objective)
Допустимая потеря данных (в часах/днях).

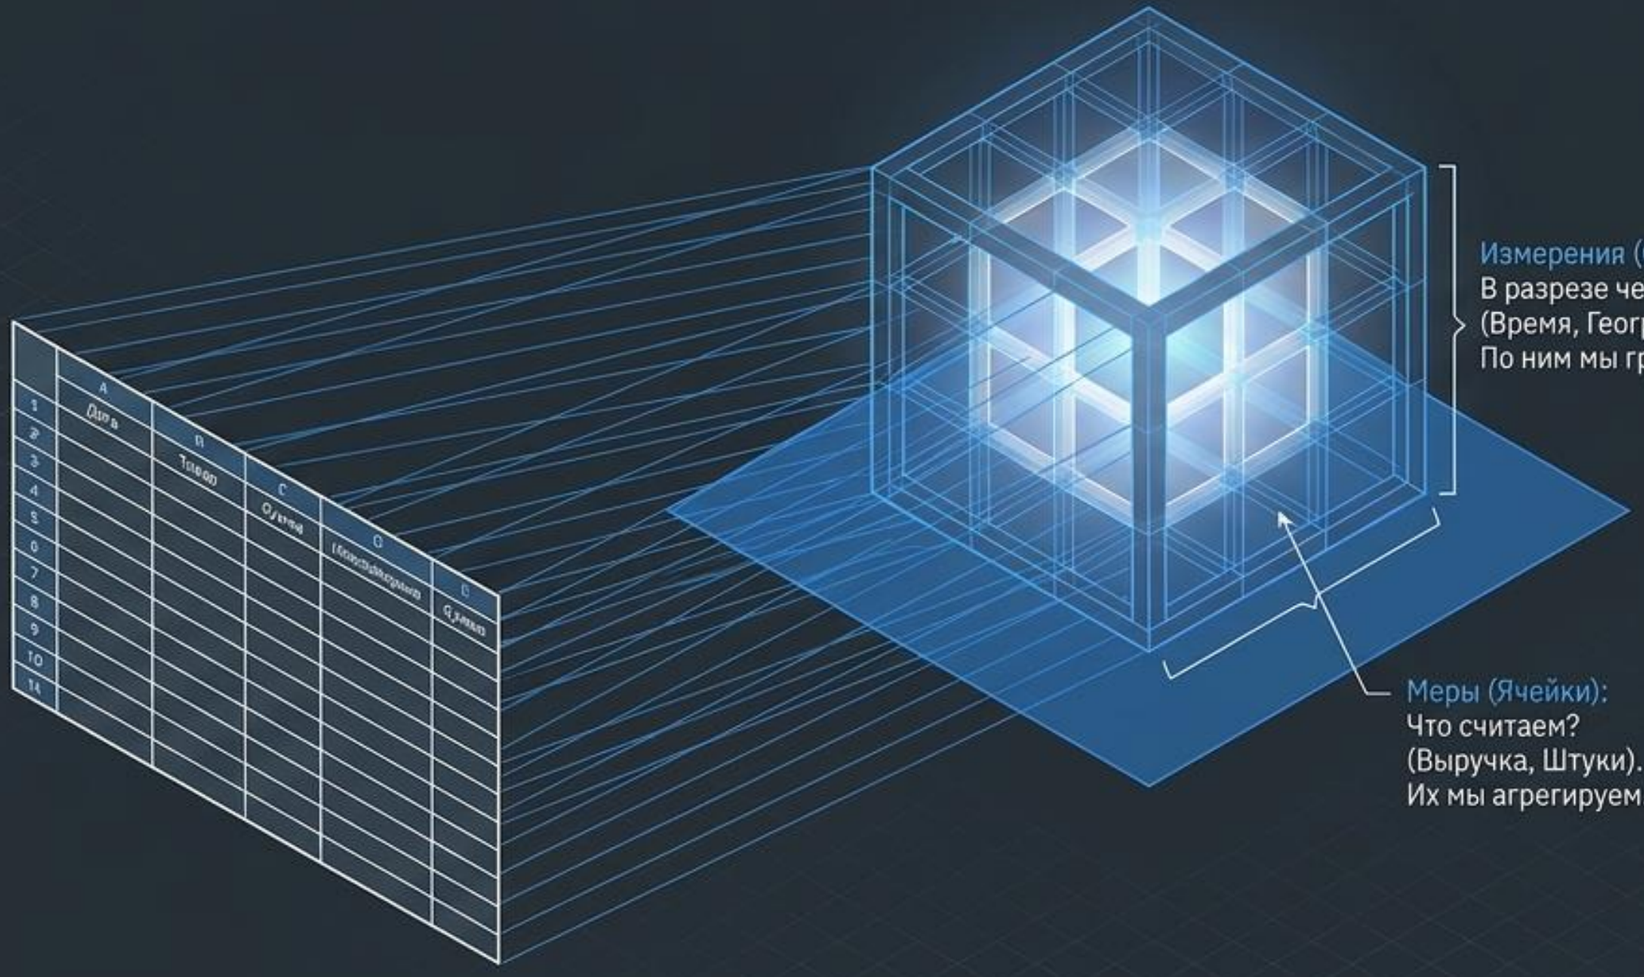
**RTO** (Recovery Time Objective)
Допустимое время простоя системы.

**Нефункциональное требование** обязано быть **измеримым.**
Не «система работает быстро», а «95% запросов < 5 сек при 50 юзерах».

Gemini Notebook

# OLAP-Куб: Как мыслит бизнес

Многомерная модель подсмотрена у пользователей.
Базовая формула: «Показатель в разрезе признаков».



**Измерения (Оси):**
В разрезе чего?
(Время, География, Товар).
По ним мы группируем.

**Меры (Ячейки):**
Что считаем?
(Выручка, Штуки).
Их мы агрегируем.

**Разреженность (Sparsity):**
50к товаров × 500 магазинов × 365 дней = ~9 млрд ячеек.

Но в реальности заполнено ~2%.

**Вывод:**
Куб — это логическая абстракция для мышления, а не формат хранения на диске.

Gemini Notebook

# Гранулярность (Зерно): Самое важное решение

Что означает одна строка в таблице фактов?






Детализацию, которая не была сохранена, восстановить невозможно. Агрегат из деталей получается всегда, детали из агрегата — никогда.

Правило Кимбалла: Зерно объявляется ДО проектирования измерений и мер.
Смешение зерен в одной таблице = двойной счет.

Gemini Notebook

# Анатомия Мер: Что можно складывать?

**Аддитивные:** Складываем по всем измерениям (Выручка, Штуки, Себестоимость).



**Полуаддитивные:** Складываем по всему, кроме времени (Остаток на складе, Баланс). Берем последнее или среднее.



**Неаддитивные:** Не складываем вообще (Цена, Рентабельность, Средний чек).



## Ошибка: Усреднение средних

Сложение неаддитивных мер дает искажение на 20%+.

$$\frac{\sum(\text{Средний Чек})}{N} = \text{Искажение}$$

**Решение:** Не хранить относительные величины в готовом виде. Хранить числитель и знаменатель, а делить только в момент запроса.

Gemini Notebook

# Физическое воплощение: Схема «Звезда»

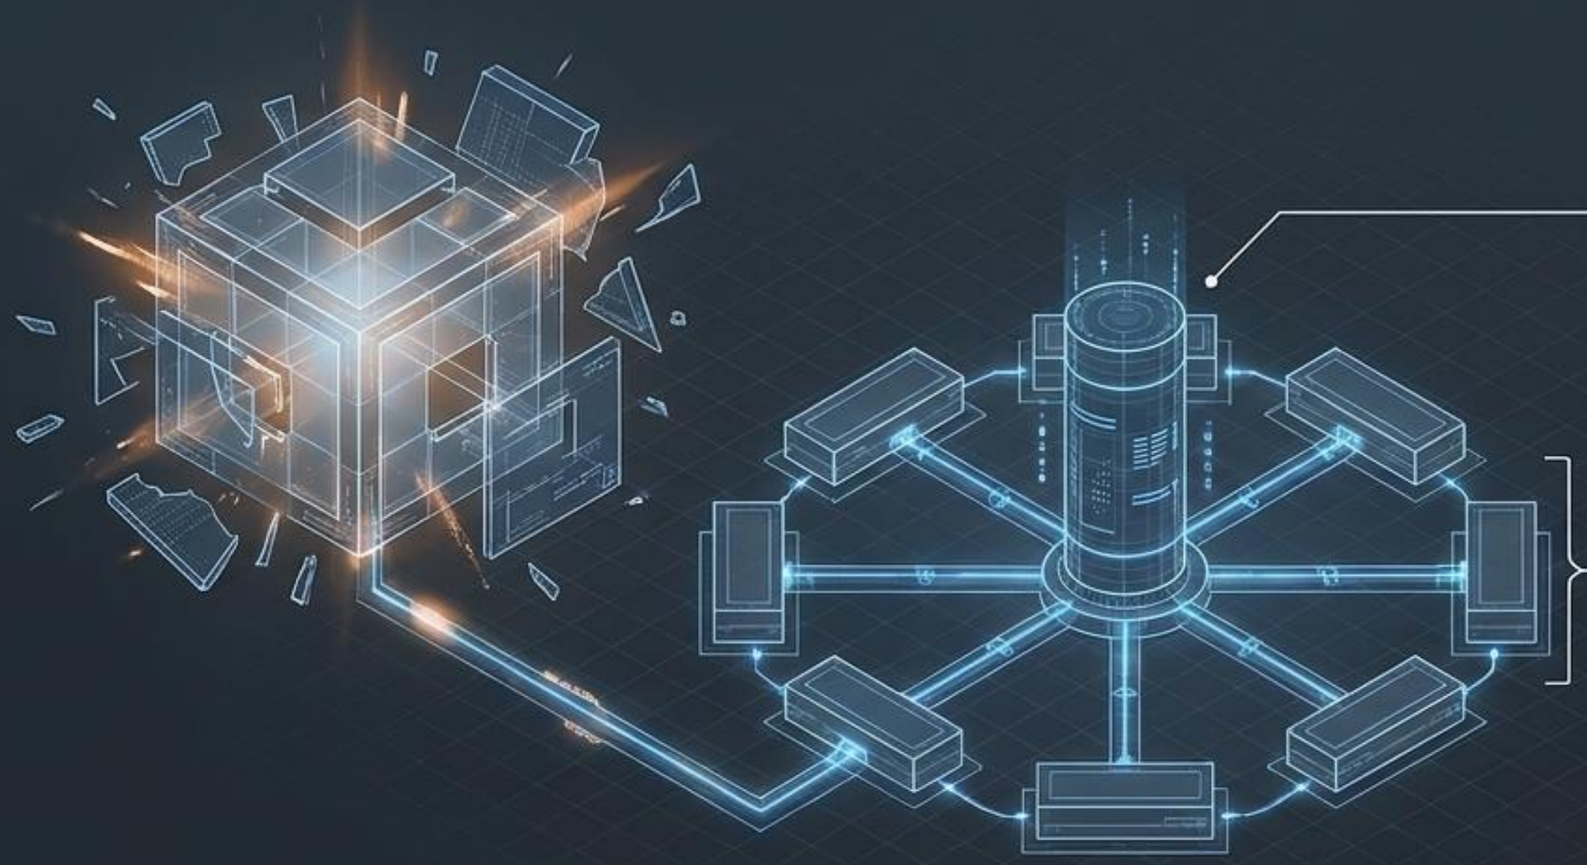


**Таблица фактов (Fact):**

В центре. Длинная и узкая (сотни миллионов строк). Хранит только ключи и меры.

**Таблицы измерений (Dim):**

По краям. Короткие и широкие. Вся иерархия (Категория → Подкатегория → Товар) денормализована в одной таблице.

Денормализация измерений — это не ошибка, а фича.

Мы платим мегабайтами за избыточность → — экономим часы вычислений на JOIN → – получаем абсолютную понятность для бизнес-пользователя.

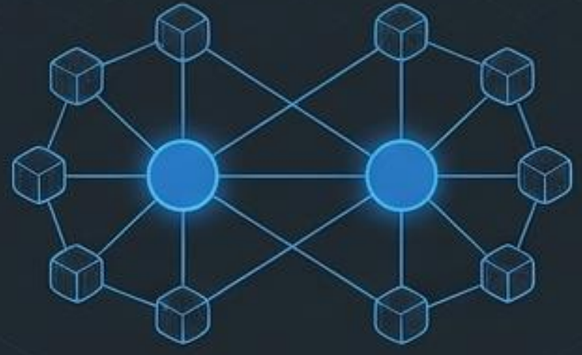
Gemini Notebook

# Вариации архитектуры и Типы фактов

## Эволюция Схем



**Снежинка (Snowflake):** Измерения нормализованы. Экономит место, но убивает скорость чтения. Применять точечно.



**Созвездие (Galaxy):** Несколько таблиц фактов (Продажи, Остатки) делят общие (конформные) измерения.

## 3 Типа Таблиц Фактов




**Транзакционная:** Одно событие = одна строка (Продажа). Меры аддитивны. Никогда не обновляется.




**Периодический снимок:** Состояние на дату (Остатки склада). Меры полуаддитивны.

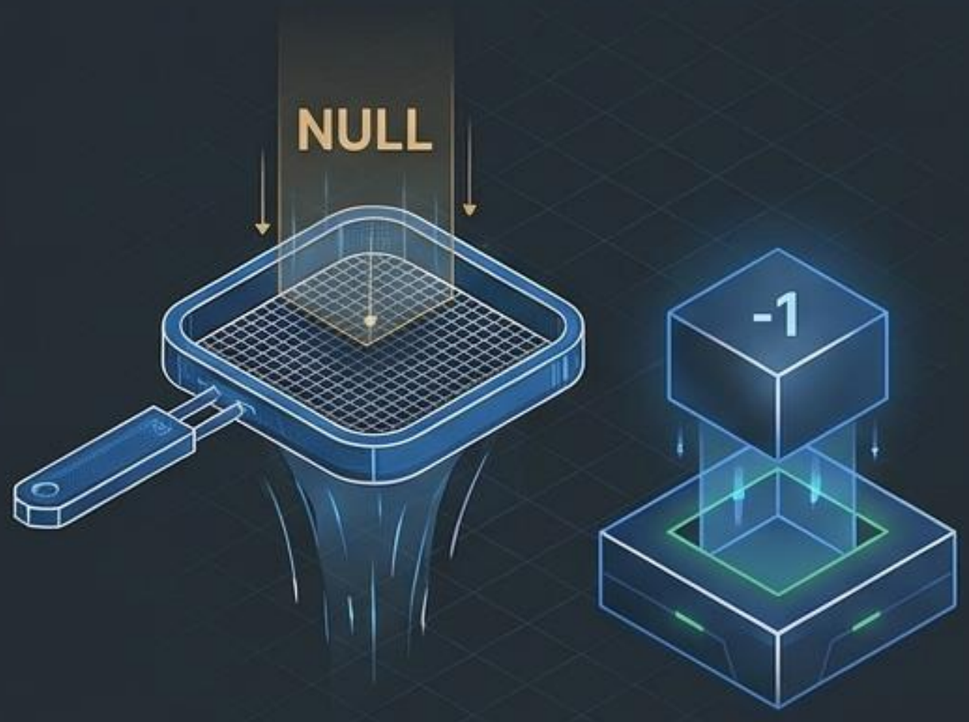



**Накапливающийся снимок:** Процесс с вехами (Статусы заказа: создан → оплачен → доставлен). Единственный тип фактов, который регулярно обновляется.

Gemini Notebook

# Якорь Хранилища: Суррогатные ключи

Искусственный ID (число),
генерируемый самим DWH,
не имеющий бизнес-смысла.







**Зачем нужен? (Отказ от натуральных ключей):**

- 1. Хранение истории (объект один — версий много).
- 2. Защита от переиспользования кодов в источнике.
- 3. Скорость соединений (JOIN чисел быстрее строк).

**Обработка неизвестных значений (Магия NULL)**

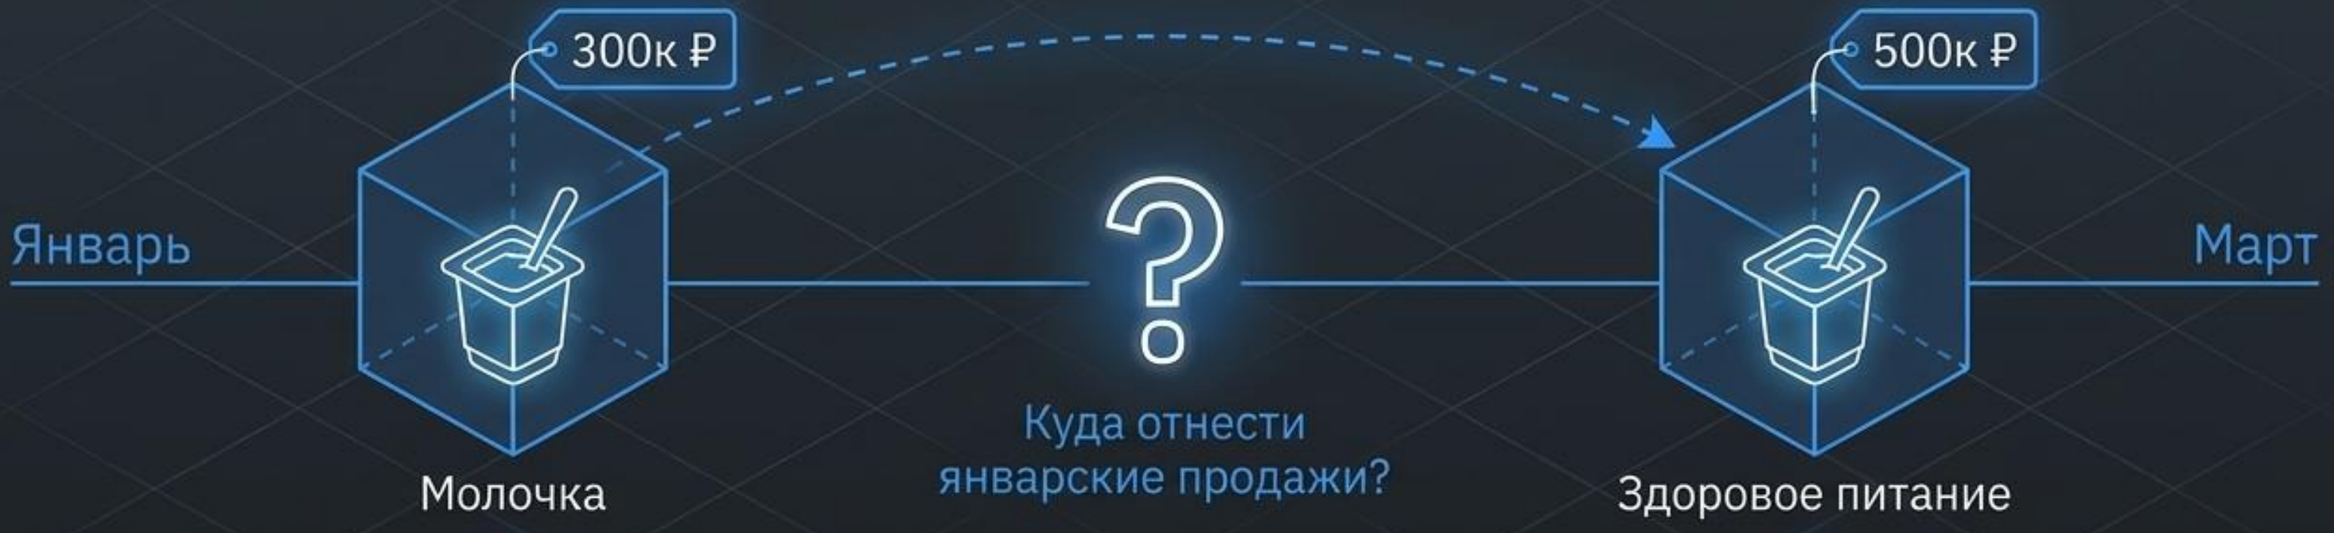
Никогда не используем NULL (теряет строки при соединениях).

В измерениях заводим служебные суррогатные строки:
-1 (Неизвестно), -2 (Неприменимо). Отчеты остаются полными.

Gemini Notebook

# Парадокс Времени: Меняющиеся измерения

Проблема: Факты неизменны, но атрибуты меняются.



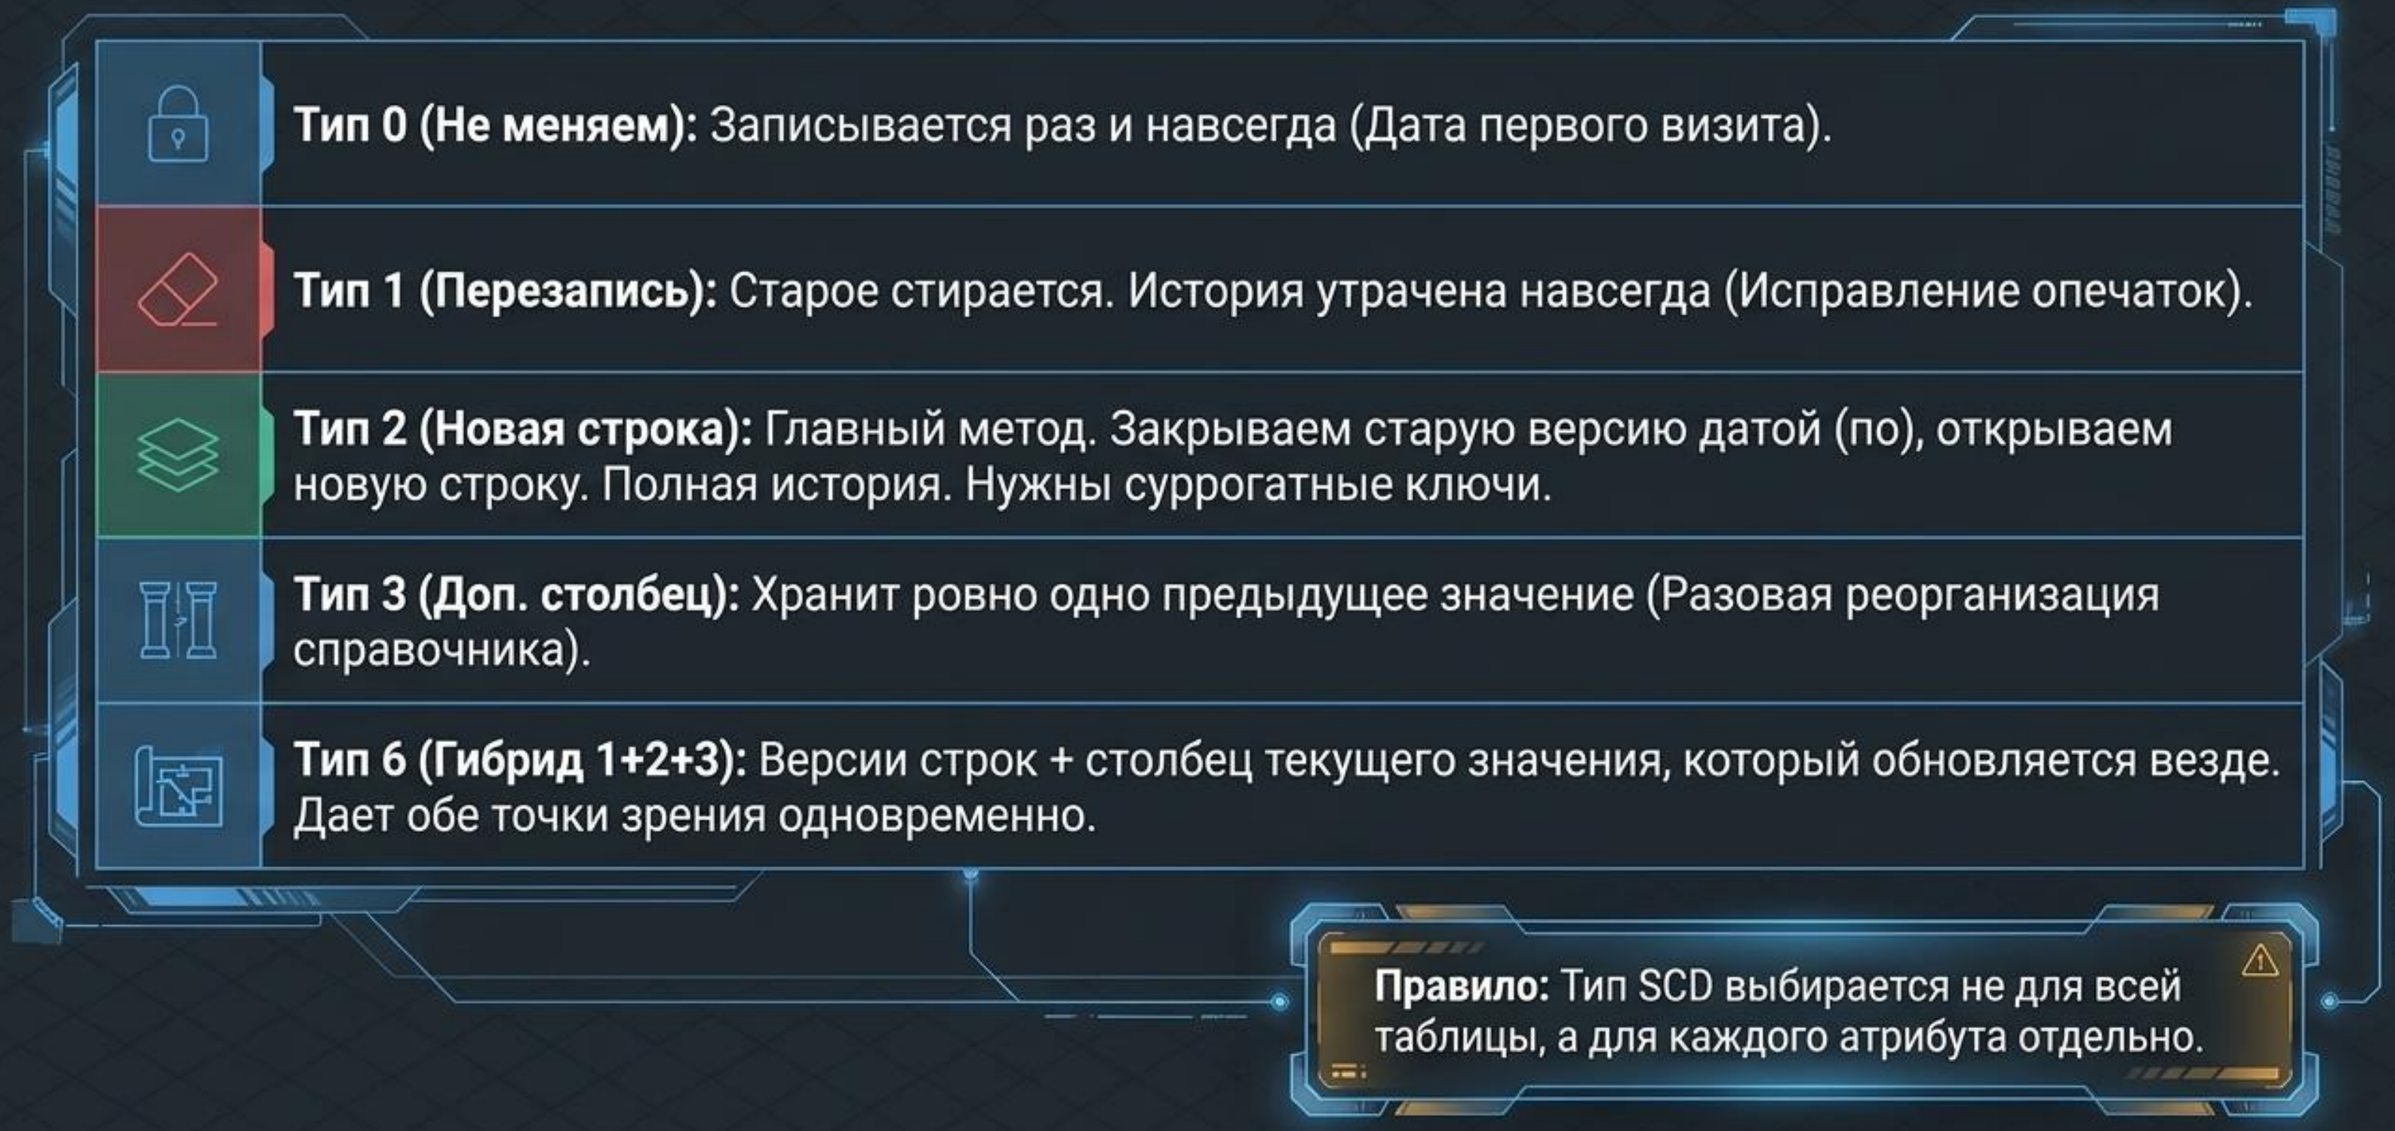

**Точка зрения А (Финансист):**
300к в «Молочке» (Историческая правда на момент сделки).

**Точка зрения Б (Категорийщик):**
300к в «Здоровом питании» (Оценка в текущей оргструктуре).

**Вывод:** Выбор сохранения истории — не техническое, а смысловое решение. Его принимает владелец данных.

Gemini Notebook

# Арсенал SCD: 5 способов управления временем



**Тип 0 (Не меняем):** Записывается раз и навсегда (Дата первого визита).

**Тип 1 (Перезапись):** Старое стирается. История утрачена навсегда (Исправление опечаток).

**Тип 2 (Новая строка):** Главный метод. Закрываем старую версию датой (по), открываем новую строку. Полная история. Нужны суррогатные ключи.

**Тип 3 (Доп. столбец):** Хранит ровно одно предыдущее значение (Разовая реорганизация справочника).

**Тип 6 (Гибрид 1+2+3):** Версии строк + столбец текущего значения, который обновляется везде. Дает обе точки зрения одновременно.

**Правило:** Тип SCD выбирается не для всей таблицы, а для каждого атрибута отдельно.

Gemini Notebook

# Мастер-План: Матрица Шины Кимбалла

Мы не строим корпоративную монстр-модель сразу. Мы заранее договариваемся об общих (конформных) измерениях и строим по одной витрине.



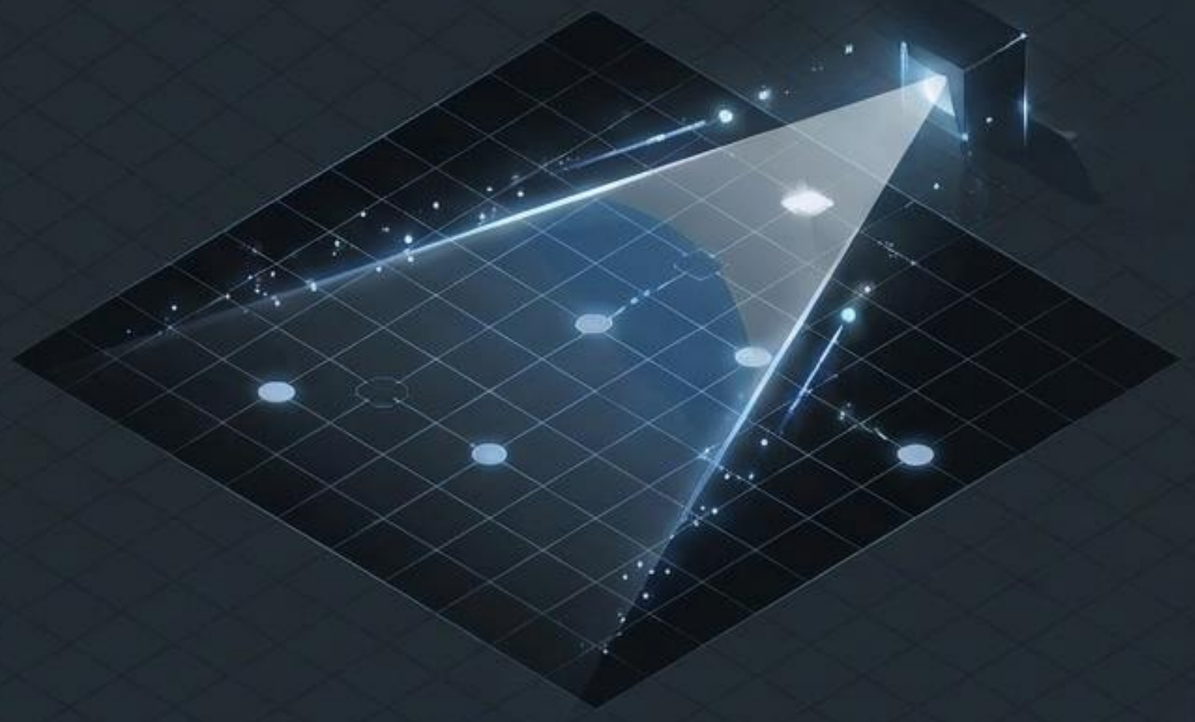

## 4 Шага Проектирования Витрины:

1. Выбрать бизнес-процесс (Моделируем реальность, а не текущий отчет!)
2. Объявить зерно
3. Определить измерения
4. Определить меры (Всегда в последнюю очередь!)

Gemini Notebook

# Анализ Непроизошедшего: Магия Аналитики

Концепция: Безфактовая таблица (только ключи измерений, нет мер).



## Вид 1: Регистрация событий

Студент пришел на лекцию. Показ баннера. (Считаем просто количество строк).

## Вид 2: Таблица Покрытия

**Вопрос:** Какой товар участвовал в акции, но не продался ни разу?
**Проблема:** Отсутствие продажи = отсутствие строки в базе фактов.
**Решение:** Таблица Покрытия фиксирует то, что могло произойти.

**Уравнение аналитики:** Ответ = (Множество возможного) минус (Множество состоявшегося). Без этой таблицы такие инсайты невозможны.

Gemini Notebook

# Синтез: 7 фатальных ошибок (и как мы их избегаем)

| | |
|---|---|
| ✓ | **Проектирование от отчета, а не от процесса** → Модель описывает реальный бизнес, а не желания конкретного менеджера. |
| ✓ | **Смешение зерен в одной таблице** → Приводит к двойному счету. Зерно всегда должно быть единым. |
| ✓ | **Хранение средних значений** → Неаддитивные меры искажают итог. Считаем деление только при запросе. |
| ✓ | **Использование NULL в ключах** → Применяем суррогатные строки «-1 (Неизвестно)» во избежание потери данных. |
| ✓ | **Слепая нормализация измерений** → Используем схему «Звезда» для скорости JOIN-ов и понятности. |
| ✓ | **SCD Тип 1 вместо Типа 2** → Утрата истории. Выбор SCD всегда согласовываем с владельцем данных. |
| ✓ | **Отсутствие бизнес-метаданных** → Без единого определения показателя, цифрам просто не поверят. |

Правильное хранилище данных — это не написание SQL-кода.
Это формализация правды об организации.

Gemini Notebook