1 ВОПРОСЫ БЕЗ ДОКАЗАТЕЛЬСТВА

1. Перечислите основные семантические типы признаков. Перечислите не менее трёх способов обработки пропусков для каждого основного типа признаков. Поясните их преимущества и недостатки.

2. Дайте определение выброса. Перечислите не менее трёх способов обнаружения и обработки выбросов. Поясните принцип их работы, преимущества и особенности применения.

3. Перечислите основные семантические типы признаков. Поясните принцип работы One-Hot Encoding, Frequency Encoding и Target Encoding. Укажите недостатки этих методов.

4. Перечислите основные семантические типы признаков. Поясните, почему перед подачей в линейную модель признаки необходимо масштабировать. Перечислите и поясните пять основных видов масштабирования признаков.

5. Сформулируйте вероятностную постановку задачи обучения с учителем.

6. Дайте определения теоретического и эмпирического функционалов ошибки. Установите связь между ними.

7. Дайте определения MSE и RMSE. Запишите их формулы и поясните их свойства. Дайте определение коэффициента детерминации R^2, запишите его формулу и поясните смысл его значений.

8. Дайте определения MAE и квантильной функции потерь. Запишите их формулы и поясните их свойства и особенности.

9. Дайте определение гиперпараметра модели. Поясните принципы работы стратегий подбора гиперпараметров и кросс-валидации. Укажите их преимущества и недостатки.

10. Укажите основной недостаток классического градиентного спуска. Поясните принцип работы SGD, укажите его преимущества и недостатки. Поясните принцип работы Mini-Batch SGD.

11. Перечислите критерии остановки градиентного спуска и поясните их недостатки. Поясните принцип работы метода инерции (Momentum). Запишите правило обновления параметров и охарактеризуйте специфику метода.

12. Поясните принцип работы методов AdaGrad и RMSProp. Запишите правила обновления параметров, охарактеризуйте специфику методов и укажите их основные различия.

13. Поясните принцип работы метода Adam. Запишите правило обновления параметров и охарактеризуйте специфику метода.

14. Дайте определение регуляризатора. Сформулируйте условную задачу оптимизации и приведите её к безусловной форме. Приведите примеры регуляризаторов.

15. Дайте определение регуляризатора. Поясните необходимость применения L_1-регуляризации, её влияние на оптимизацию и отличия от L_2-регуляризации.

16. Перечислите четыре свойства хранилища данных и раскройте содержание каждого.

17. Назовите слои хранилища и укажите назначение каждого. Чем промежуточная зона отличается от оперативного склада данных?

18. Изложите существо подходов Инмона и Кимбалла. Приведите не менее шести критериев их сопоставления.

19. Перечислите виды метаданных и укажите источник формирования каждого вида. Какой вид метаданных отсутствует наиболее часто и каковы последствия этого?

20. Дайте определение гиперкуба. Почему куб называют логической моделью? Сформулируйте правило разграничения мер и измерений. Почему тип данных не определяет роль поля?

21. Дайте определение гранулярности. Сформулируйте принцип невосстановимости детализации.

22. Перечислите классы мер по признаку аддитивности и приведите по два примера на каждый класс.

23. Перечислите виды иерархий и приведите пример каждого. В чём различие несбалансированной и «рваной» иерархии?

24. Опишите состав таблицы фактов и таблицы измерения в схеме «звезда». Чем определяется зерно таблицы фактов? Сопоставьте схемы «звезда» и «снежинка». Что представляет собой схема «созвездие»?

25. В чём состоит задача обработки медленно меняющихся измерений? Почему она не имеет технически предпочтительного решения? Кто принимает решение о способе хранения истории атрибута и где это решение фиксируется?

26. Дайте определение агрегата и предагрегации. Рассчитайте число возможных агрегатов для куба с указанным составом измерений и уровней иерархий.

27. Сопоставьте три технологии ХД не менее чем по шести критериям.

28. В чём состоит различие среза и вырезания? Сформулируйте его через понятие размерности. Каково практическое назначение вращения, если данные при его выполнении не изменяются?

29. Назовите этапы ETL и задачи каждого.

30. Сравните методы CDC. В чём преимущество журнального CDC? Что такое DAG и зачем нужна оркестрация?

2 ВОПРОСЫ С ДОКАЗАТЕЛЬСТВОМ

1. Сформулируйте и докажите утверждение о теоретически оптимальном значении выхода модели для квадратичной функции потерь.
2. Сформулируйте и докажите утверждение о теоретически оптимальном значении выхода модели для абсолютной функции потерь.
3. Сформулируйте и докажите утверждение о теоретически оптимальном значении выхода модели для квантильной функции потерь.
4. Сформулируйте постановку задачи обучения линейной регрессии в матричном виде и выведите формулу аналитического решения для квадратичной функции потерь.
5. Сформулируйте и докажите утверждение о влиянии линейной зависимости признаков на множество решений задачи обучения линейной модели.
6. Выведите формулу одной итерации градиентного спуска.
7. Сформулируйте и докажите утверждение о влиянии L_2-регуляризации на рельеф функционала ошибки и коэффициент обусловленности его гессиана.

3 ЗАДАЧИ

Все примеры задач разобраны в файле семинаров в разделе 6 «Матрично-векторное дифференцирование».