Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Конспект математических семинаров по курсу ОАД

Разработал:
Рубинштейн И.А.

Москва, 2026 г.

СОДЕРЖАНИЕ

ЛИНЕЙНАЯ АЛГЕБРА 4
1 ПРОСТРАНСТВА 5
1.1 Линейные пространства 5
1.2 Метрические и нормированные пространства 7
1.3 Евклидова структура 11
1.4 Аффинное пространство 17
2 ОБРАТИМОСТЬ И СПЕКТРАЛЬНАЯ СТРУКТУРА 20
2.1 Ранг матрицы 20
2.2 Обратимость матрицы 21
2.3 Определитель 23
2.4 Спектр матрицы 27
2.5 Спектральное разложение 28
2.6 Сингулярное разложение 31
2.7 Почти линейная зависимость 39
3 МАТРИЧНЫЕ НОРМЫ 41
3.1 Норма Фробениуса 41
3.2 Индуцированная норма 43
4 ОБУСЛОВЛЕННОСТЬ И ПСЕВДООБРАТИМОСТЬ 48
4.1 Обусловленность 49
4.2 Псевдообратимость 50
МАТЕМАТИЧЕСКИЙ АНАЛИЗ 57
5 ДИФФЕРЕНЦИАЛЬНОЕ ИСЧИСЛЕНИЕ В $\mathbb{R}^n$ 58
5.1 Топология пространства $\mathbb{R}^n$ 58
5.2 Дифференцируемость функции в точке 61
5.3 Дифференцируемость отображения в точке 68
5.4 Производные высших порядков 76
5.5 Спектральная структура матрицы Гессе 78
6 МАТРИЧНО-ВЕКТОРНОЕ ДИФФЕРЕНЦИРОВАНИЕ 85
6.1 Пространство матриц 85
6.2 Основные типы дифференцирования 89
6.2.1 $\mathbb{R} \to \mathbb{R}$ 90
6.2.2 $\mathbb{R} \to \mathbb{R}^m$ 90
6.2.3 $\mathbb{R} \to \mathbb{R}^{m \times n}$ 91

6.2.4 $\mathbb{R}^n \to \mathbb{R}$ 92
6.2.5 $\mathbb{R}^n \to \mathbb{R}^m$ 94
6.2.6 $\mathbb{R}^n \to \mathbb{R}^{p\times q}$ 96
6.2.7 Задачи с векторным аргументом 99
6.2.8 $\mathbb{R}^{m\times n} \to \mathbb{R}$ 107
6.2.9 $\mathbb{R}^{m\times n} \to \mathbb{R}^p$ 110
6.2.10 $\mathbb{R}^{m\times n} \to \mathbb{R}^{p\times q}$ 111
6.2.11 Задачи с матричным аргументом 114
7 БЕЗУСЛОВНАЯ И УСЛОВНАЯ ОПТИМИЗАЦИЯ 124
7.1 Безусловная оптимизация 124
7.1.1 Градиентные методы 128
7.2 Условная оптимизация 139
7.2.1 Метод множителей Лагранжа 140
7.2.2 Условия Каруша–Куна–Таккера 148
7.2.3 Двойственная задача 152
7.2.4 Выпуклая условная оптимизация 155

ЛИНЕЙНАЯ АЛГЕБРА

В данной главе рассматриваются основные понятия линейной алгебры для конечномерных пространств над полем вещественных чисел. Сначала вводятся линейные, метрические, нормированные, евклидовы и аффинные пространства, затем рассматриваются ранг и обратимость матриц, спектральное и сингулярное разложения, после чего вводятся матричные нормы, коэффициент обусловленности и псевдообратная матрица.

1 ПРОСТРАНСТВА

В начале рассмотрим основные типы пространств, с которыми будем работать далее, преимущественно ограничиваясь пространством $\mathbb{R}^n$ над полем $\mathbb{R}$.

1.1 Линейные пространства

Определение. Линейным, или векторным, пространством над полем $\mathbb{R}$ называется множество V, на котором определены две операции: сложение элементов пространства и умножение элемента пространства на скаляр из $\mathbb{R}$.

Для пространства $\mathbb{R}^n$ данные операции имеют вид

$$+ : \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}^n, \qquad (x, y) \mapsto x + y,$$

и

$$\cdot : \mathbb{R} \times \mathbb{R}^n \to \mathbb{R}^n, \qquad (\lambda, x) \mapsto \lambda x.$$

При этом для $\forall\, x, y, z \in \mathbb{R}^n$ и $\forall\, \alpha, \beta \in \mathbb{R}$ выполняются следующие аксиомы:

– Замкнутость относительно сложения: $x + y \in \mathbb{R}^n$.

– Коммутативность сложения: $x + y = y + x$.

– Ассоциативность сложения: $(x + y) + z = x + (y + z)$.

– Существование нулевого элемента: $\exists\, 0 \in \mathbb{R}^n :\ x + 0 = x$.

– Существование обратного элемента относительно сложения: $\exists\, (-x) \in \mathbb{R}^n :\ x + (-x) = 0$.

– Замкнутость относительно умножения на скаляр: $\alpha x \in \mathbb{R}^n$.

– Согласованность с единицей поля: $1x = x$.

– Ассоциативность умножения на скаляры: $\alpha(\beta x) = (\alpha\beta)x$.

– Дистрибутивность относительно сложения векторов: $\alpha(x+y) = \alpha x + \alpha y$.

– Дистрибутивность относительно сложения скаляров: $(\alpha+\beta)x = \alpha x + \beta x$.

Таким образом, пространство $\mathbb{R}^n$ с обычными операциями сложения и умножения на вещественное число является линейным пространством над полем $\mathbb{R}$.

Определение. Линейной комбинацией векторов $x_1, \ldots, x_k \in \mathbb{R}^n$ называется выражение

$$\alpha_1 x_1 + \cdots + \alpha_k x_k, \qquad \alpha_1, \ldots, \alpha_k \in \mathbb{R}.$$

Векторы $x_1, \ldots, x_k$ называются линейно зависимыми, если

$$\exists\, \alpha_1, \ldots, \alpha_k \in \mathbb{R}: \qquad \sum_{i=1}^{k} \alpha_i x_i = 0, \qquad \exists\, i \in \{1, \ldots, k\}:\ \alpha_i \neq 0.$$

Векторы $x_1, \ldots, x_k$ называются линейно независимыми, если

$$\sum_{i=1}^{k} \alpha_i x_i = 0 \quad \Longrightarrow \quad \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0.$$

Определение. Базисом пространства $\mathbb{R}^n$ будем называть систему линейно независимых векторов $e_1, \ldots, e_n$, порождающих всё пространство, то есть такую, что любой вектор $x \in \mathbb{R}^n$ единственным образом представляется в виде

$$x = x_1 e_1 + \cdots + x_n e_n.$$

Коэффициенты $x_1, \ldots, x_n$ называются координатами вектора x в данном базисе.

Далее, если не сказано обратное, будем работать в стандартном базисе пространства $\mathbb{R}^n$:

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \qquad e_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \qquad \ldots, \qquad e_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}.$$

В таком случае координатное представление вектора имеет привычный вид

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}.$$

Определение. Отображение $L : \mathbb{R}^n \to \mathbb{R}^m$ называется линейным, если оно сохраняет операции линейного пространства, то есть для любых $x, y \in \mathbb{R}^n$ и

$\alpha \in \mathbb{R}$ выполняются два свойства:

$$L(x + y) = L(x) + L(y), \qquad L(\alpha x) = \alpha L(x).$$

Таким образом, линейное отображение преобразует элементы пространства, не нарушая его линейную структуру.

1.2 Метрические и нормированные пространства

Линейная структура задаёт операции сложения векторов и умножения их на скаляры, но не определяет понятие расстояния, для введения которого рассмотрим метрическое пространство.

Определение. Метрическим пространством называется пара (X, ρ), где X — непустое множество, а $\rho : X \times X \to \mathbb{R}$ — функция, называемая метрикой, такая, что для $\forall\, x, y, z \in X$ выполняются следующие аксиомы:

– Неотрицательность: $\rho(x, y) \geq 0$, причём $\rho(x, y) = 0 \iff x = y$.

– Симметричность: $\rho(x, y) = \rho(y, x)$.

– Неравенство треугольника:

$$\rho(x, z) \leq \rho(x, y) + \rho(y, z).$$

Метрика позволяет измерять расстояние между элементами пространства. Для линейных пространств можно дополнительно ввести структуру, позволяющую определять длину отдельного вектора.

Определение. Нормированным пространством называется пара $(V, \|\cdot\|)$, где V — линейное пространство, а $\|\cdot\|: V \to \mathbb{R}_+$ — функция, называемая нормой, такая, что для $\forall\, x, y \in V$ и $\forall\, \alpha \in \mathbb{R}$ выполняются следующие аксиомы:

– Неотрицательность: $\|x\| \geq 0$, причём $\|x\| = 0 \iff x = 0$.

– Однородность: $\|\alpha x\| = |\alpha| \|x\|$.

– Неравенство треугольника:

$$\|x + y\| \leq \|x\| + \|y\|.$$

Норма задаёт длину вектора, однако через неё естественным образом можно определить и расстояние между двумя векторами.

Утверждение. Всякое нормированное пространство является метрическим относительно метрики $\rho(x, y) = \|x - y\|$.

□ Из неотрицательности нормы следует

$$\rho(x, y) = \|x - y\| \geq 0.$$

Кроме того,

$$\rho(x, y) = 0 \quad \Longleftrightarrow \quad \|x - y\| = 0 \quad \Longleftrightarrow \quad x - y = 0 \quad \Longleftrightarrow \quad x = y.$$

Проверим симметричность. Имеем

$$\rho(x, y) = \|x - y\| = \|-(y - x)\| = |-1|\|y - x\| = \|y - x\| = \rho(y, x).$$

Наконец, для любых $x, y, z \in V$ имеем $x - z = (x - y) + (y - z)$. Следовательно, по неравенству треугольника для нормы

$$\rho(x, z) = \|x - z\| = \|(x - y) + (y - z)\| \leq \|x - y\| + \|y - z\| = \rho(x, y) + \rho(y, z).$$

■

Рассмотрим основные нормы в пространстве $\mathbb{R}^n$.

Для $p \geq 1$ определим p-норму как

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}.$$

При $p = 1$ получаем норму

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|.$$

При $p = 2$ получаем евклидову норму

$$\|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}.$$

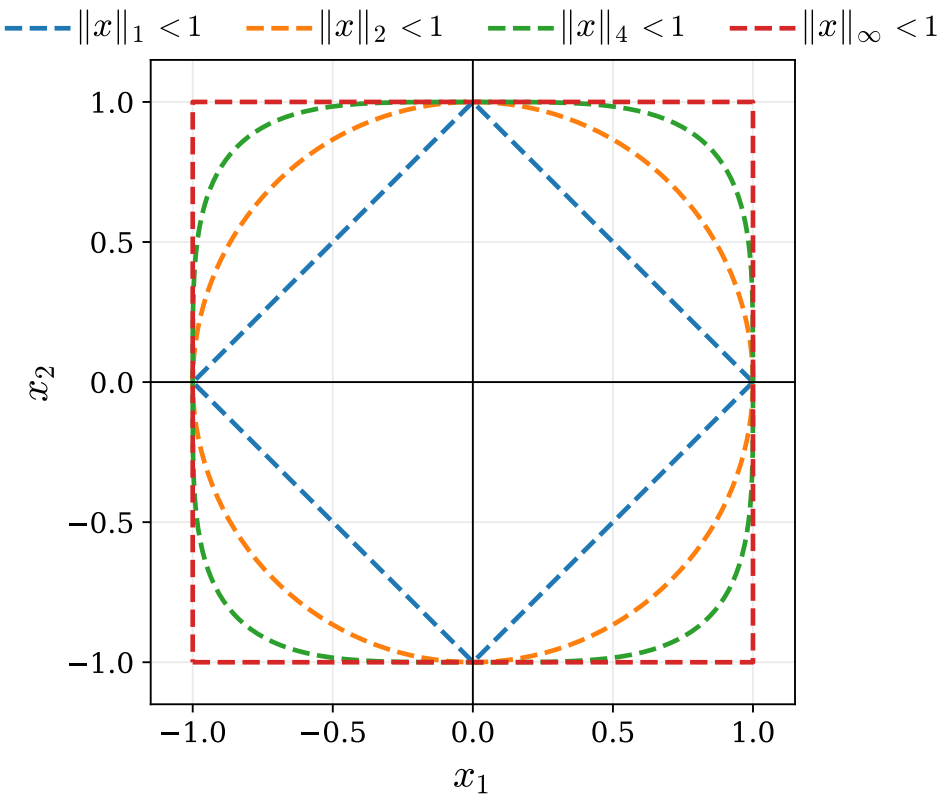


Рисунок 1 – Единичные шары в $\mathbb{R}^2$ для норм $\|\cdot\|_1$, $\|\cdot\|_2$, $\|\cdot\|_4$ и $\|\cdot\|_\infty$.

Отдельно определим бесконечную норму:

$$\|x\|_\infty = \max_{i=1,\ldots,n} |x_i|.$$

Далее, если не сказано обратное, для нормированного пространства будем использовать метрику, индуцированную нормой:

$$\rho(x, y) = \|x - y\|.$$

Определение. Открытым шаром радиуса $r > 0$ с центром в точке a метрического пространства (X, ρ) называется множество

$$B_r(a) = \{x \in X \mid \rho(x, a) < r\}.$$

Рассмотрим в $\mathbb{R}^2$ открытые единичные шары с центром в нуле для нескольких значений p, изображённые на рисунке 1.

Для нормы $\|\cdot\|_1$ имеем

$$B_1^{(1)}(0) = \left\{x \in \mathbb{R}^2 \;\middle|\; |x_1| + |x_2| < 1\right\}.$$

Граница данного шара имеет форму ромба.

Для евклидовой нормы

$$B_1^{(2)}(0) = \left\{x \in \mathbb{R}^2 \;\middle|\; x_1^2 + x_2^2 < 1\right\},$$

то есть получаем привычный круг.

При $p = 4$ имеем

$$B_1^{(4)}(0) = \left\{x \in \mathbb{R}^2 \;\middle|\; |x_1|^4 + |x_2|^4 < 1\right\}.$$

Его граница принимает форму скруглённого квадрата.

Наконец, для бесконечной нормы

$$B_1^{(\infty)}(0) = \left\{x \in \mathbb{R}^2 \;\middle|\; \max(|x_1|, |x_2|) < 1\right\},$$

то есть единичный шар представляет собой внутренность квадрата

$$-1 < x_1 < 1, \qquad -1 < x_2 < 1.$$

Таким образом, при переходе от $p = 1$ к $p = 2$, затем к $p = 4$ и далее к $p = \infty$ форма единичного шара постепенно изменяется от ромба к кругу, затем к скруглённому квадрату и, наконец, к квадрату.

1.3 Евклидова структура

Норма позволяет определять длины векторов и расстояния между ними. Для описания геометрических отношений между векторами, в частности углов и ортогональности, введём дополнительную структуру на линейном пространстве $\mathbb{R}^n$.

Определение. Скалярным произведением на $\mathbb{R}^n$ называется отображение

$$\langle \cdot, \cdot \rangle : \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R},$$

такое, что для $\forall\, x, y, z \in \mathbb{R}^n$ и $\forall\, \alpha, \beta \in \mathbb{R}$ выполняются следующие аксиомы:

– Линейность:

$$\langle \alpha x + \beta y, z \rangle = \alpha \langle x, z \rangle + \beta \langle y, z \rangle.$$

– Симметричность:

$$\langle x, y \rangle = \langle y, x \rangle.$$

– Неотрицательность:

$$\langle x, x \rangle \geq 0, \text{ причём } \langle x, x \rangle = 0 \iff x = 0.$$

Линейное пространство над $\mathbb{R}$ с заданным скалярным произведением называется евклидовым пространством.

В стандартном базисе $\mathbb{R}^n$ скалярное произведение будем задавать в виде

$$\langle x, y \rangle = x^T y = \sum_{i=1}^{n} x_i y_i.$$

Скалярное произведение непосредственно связано с введённой ранее евклидовой нормой:

$$\|x\|_2 = \sqrt{\langle x, x \rangle}.$$

Таким образом, евклидова норма является нормой, индуцированной стандартным скалярным произведением.

Теорема (неравенство Коши–Буняковского–Шварца). Для любых $x, y \in V$ справедливо неравенство:

$$|\langle x, y\rangle| \le \|x\|\|y\|.$$

□ Если $x = 0$ или $y = 0$, то неравенство выполняется тривиально. Пусть далее $x \neq 0$ и $y \neq 0$.

Для любого $t \in \mathbb{R}$ по неотрицательности нормы имеем

$$\|x - ty\|^2 \ge 0.$$

Раскроем норму через скалярное произведение:

$$\begin{aligned}\|x - ty\|^2 &= \langle x - ty, x - ty\rangle \\ &= \langle x, x\rangle - 2t\langle x, y\rangle + t^2\langle y, y\rangle \\ &= \|x\|^2 - 2t\langle x, y\rangle + t^2\|y\|^2.\end{aligned}$$

Полученное выражение является квадратным трёхчленом относительно t, неотрицательным для любого $t \in \mathbb{R}$. Следовательно, его дискриминант неположителен:

$$D = 4\langle x, y\rangle^2 - 4\|x\|^2\|y\|^2 \le 0.$$

Отсюда

$$\langle x, y\rangle^2 \le \|x\|^2\|y\|^2,$$

следовательно,

$$|\langle x, y\rangle| \le \|x\|\|y\|.$$

■

Следствие. Равенство $|\langle x, y\rangle| = \|x\|\|y\|$ достигается тогда и только тогда, когда векторы x и y линейно зависимы.

□ Если $x = 0$ или $y = 0$, то векторы линейно зависимы и равенство выполняется.

Пусть $x \neq 0$ и $y \neq 0$. Если в неравенстве Коши–Буняковского–Шварца достигается равенство, то

$$\langle x, y\rangle^2 = \|x\|^2\|y\|^2,$$

поэтому дискриминант рассмотренного выше квадратного трёхчлена равен нулю:

$$D = 4\langle x, y\rangle^2 - 4\|x\|^2\|y\|^2 = 0.$$

Следовательно, существует $t \in \mathbb{R}$, для которого

$$\|x - ty\|^2 = 0.$$

Тогда

$$x - ty = 0,$$

то есть

$$x = ty.$$

Следовательно, x и y линейно зависимы.

Обратно, пусть x и y линейно зависимы. Тогда для некоторого $t \in \mathbb{R}$

$$x = ty.$$

Следовательно,

$$|\langle x, y\rangle| = |\langle ty, y\rangle| = |t|\|y\|^2,$$

а также

$$\|x\|\|y\| = \|ty\|\|y\| = |t|\|y\|^2.$$

Таким образом,

$$|\langle x, y\rangle| = \|x\|\|y\|.$$

■

Определение. Векторы $x, y \in \mathbb{R}^n$ называются ортогональными, если

$$\langle x, y\rangle = 0.$$

Определение. Базис $e_1, \ldots, e_n$ называется ортонормированным, если его векторы попарно ортогональны и имеют единичную норму:

$$\langle e_i, e_j\rangle = 0, \qquad i \neq j,$$

и

$$\|e_i\|_2 = 1, \qquad i = 1, \ldots, n.$$

Эквивалентно данные условия можно записать в виде

$$\langle e_i, e_j \rangle = \delta_{ij},$$

где $\delta_{ij} = 1$ при $i = j$ и $\delta_{ij} = 0$ при $i \neq j$.

Стандартный базис пространства $\mathbb{R}^n$, введённый ранее, является ортонормированным относительно заданного скалярного произведения.

Далее при рассмотрении замены базиса будем ограничиваться ортонормированными базисами.

Пусть $B = (e_1, \ldots, e_n)$ — старый ортонормированный базис, а $B' = (e'_1, \ldots, e'_n)$ — новый ортонормированный базис.

Запишем координаты новых базисных векторов в старом базисе в виде столбцов матрицы U:

$$U = \begin{pmatrix} | & | & & | \\ [e'_1]_B & [e'_2]_B & \cdots & [e'_n]_B \\ | & | & & | \end{pmatrix}.$$

Если один и тот же вектор x имеет координаты x_{old} в базисе B и x_{new} в базисе B', то

$$x = x_{\text{new},1} e'_1 + \cdots + x_{\text{new},n} e'_n.$$

Следовательно, в старых координатах

$$x_{\text{old}} = U x_{\text{new}}.$$

Поскольку столбцы U образуют ортонормированный базис, получаем $U^T U = I$.

Действительно, обозначим столбцы матрицы U через $u_1, \ldots, u_n$:

$$U = \begin{pmatrix} | & | & & | \\ u_1 & u_2 & \cdots & u_n \\ | & | & & | \end{pmatrix}.$$

Тогда элемент матрицы $U^T U$ с индексами i, j имеет вид

$$(U^T U)_{ij} = u_i^T u_j = \langle u_i, u_j \rangle.$$

Так как столбцы ортонормированы,

$$\langle u_i, u_j \rangle = \delta_{ij}.$$

Следовательно,

$$U^T U = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} = I.$$

Отсюда сразу получаем формулу перехода в новый базис. Умножим равенство

$$x_{\text{old}} = U x_{\text{new}}$$

слева на U^T:

$$U^T x_{\text{old}} = U^T U x_{\text{new}} = I x_{\text{new}} = x_{\text{new}}.$$

Следовательно,

$$x_{\text{new}} = U^T x_{\text{old}}.$$

Покажем также, что выполняется равенство

$$U U^T = I.$$

Для любого столбца u_j матрицы U вследствие ортонормированности имеем

$$U^T u_j = e_j,$$

где e_j — j-й стандартный базисный вектор. Следовательно,

$$U U^T u_j = U e_j = u_j.$$

Таким образом, оператор UU^T оставляет неизменным каждый из базисных векторов $u_1, \ldots, u_n$. Поскольку данные векторы образуют базис $\mathbb{R}^n$, получаем

$$UU^T = I.$$

Тем самым для матрицы перехода между ортонормированными базисами выполняется

$$U^T U = UU^T = I.$$

Определение. Квадратная матрица U, удовлетворяющая условию

$$U^T U = UU^T = I,$$

называется **ортогональной**.

Для дальнейшего рассмотрения нам будут важны два ключевых свойства ортогональных матриц.

Во-первых, ортогональное преобразование сохраняет скалярное произведение.

Пусть $x, y \in \mathbb{R}^n$. Тогда

$$\langle Ux, Uy \rangle = (Ux)^T (Uy) = x^T U^T U y = x^T I y = x^T y = \langle x, y \rangle.$$

Во-вторых, ортогональное преобразование сохраняет евклидову норму.

$$\|Ux\|_2 = \sqrt{\langle Ux, Ux \rangle} = \sqrt{\langle x, x \rangle} = \|x\|_2.$$

Вернёмся к линейным отображениям общего вида. После выбора стандартных базисов линейное отображение $L : \mathbb{R}^n \to \mathbb{R}^m$ может быть представлено в матричном виде как

$$L(x) = Ax, \qquad A \in \mathbb{R}^{m \times n}.$$

Геометрически линейное преобразование может приводить к повороту, отражению, проекции, растяжению, сжатию вектора, а также к комбинациям данных эффектов.

Например, рассмотрим в $\mathbb{R}^2$ матрицу

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}.$$

Для произвольного вектора $x = (x_1, x_2)^T$ получаем

$$L(x) = Ax = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2x_1 \\ 0.5x_2 \end{pmatrix}.$$

Таким образом, данное преобразование растягивает вектор вдоль первого координатного направления в два раза и одновременно сжимает вдоль второго координатного направления в два раза.

1.4 Аффинное пространство

До настоящего момента мы рассматривали элементы $\mathbb{R}^n$ как векторы. Для описания положения точек в пространстве введём аффинную структуру.

Определение. Аффинным пространством $\mathcal{A}$, ассоциированным с линейным пространством V, называется непустое множество точек $\mathcal{A}$, на котором задано действие

$$\mathcal{A} \times V \to \mathcal{A}, \qquad (P, v) \mapsto P + v,$$

такое, что выполняются следующие аксиомы:

– Для $\forall\, P \in \mathcal{A}$ и $\forall\, u, v \in V$

$$(P + u) + v = P + (u + v).$$

– Для $\forall\, P, Q \in \mathcal{A}$ $\exists!\, v \in V$:

$$Q = P + v.$$

Этот единственный вектор обозначается через

$$v = \overrightarrow{PQ} = Q - P.$$

Таким образом, в аффинном пространстве определена операция сложения точки и вектора, результатом которой является новая точка. В то же время операция сложения двух точек в общем случае не определена.

Определение. Аффинным репером называется система

$$\mathcal{R} = (O; e_1, \ldots, e_n),$$

где $O \in \mathcal{A}$ — выбранное начало отсчёта, а $e_1, \ldots, e_n$ — базис ассоциированного линейного пространства V.

Тогда для любой точки $P \in \mathcal{A}$ существует единственный набор координат $x_1, \ldots, x_n$ такой, что

$$P = O + x_1 e_1 + \cdots + x_n e_n.$$

Иными словами,

$$\overrightarrow{OP} = x_1 e_1 + \cdots + x_n e_n.$$

Далее будем использовать введённый ранее стандартный ортонормированный базис пространства $\mathbb{R}^n$ и выберем в качестве точки отсчёта O точку с нулевыми координатами.

Тем самым получаем стандартную декартову систему координат. После такого выбора точку P будем координатно отождествлять с её радиус-вектором

$$\overrightarrow{OP} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}.$$

Далее будем считать, что работаем в аффинном евклидовом пространстве со стандартным декартовым репером и заданным скалярным произведением.

Определение. Аффинное преобразование в выбранных координатах задаётся отображением

$$F(x) = Ax + b, \qquad A \in \mathbb{R}^{m \times n},\ b \in \mathbb{R}^m.$$

Определение. Аффинной комбинацией точек $P_1, \ldots, P_k$ называется выражение

$$\sum_{i=1}^{k} \lambda_i P_i, \qquad \sum_{i=1}^{k} \lambda_i = 1,$$

где $\lambda_1, \ldots, \lambda_k \in \mathbb{R}$.

Аффинное преобразование сохраняет аффинные комбинации, то есть

$$F\left(\sum_{i=1}^{k} \lambda_i P_i\right) = \sum_{i=1}^{k} \lambda_i F(P_i), \qquad \sum_{i=1}^{k} \lambda_i = 1.$$

Рассмотрим геометрический смысл данного свойства на примере прямой. Пусть на плоскости заданы две точки P и Q. Прямая, проходящая через данные точки, задаётся их аффинной комбинацией

$$P(t) = (1 - t)P + tQ, \qquad t \in \mathbb{R}.$$

Действительно, коэффициенты данной комбинации удовлетворяют условию

$$(1 - t) + t = 1.$$

Перепишем уравнение прямой в привычной параметрической форме:

$$P(t) = (1 - t)P + tQ = P - tP + tQ = P + t(Q - P).$$

Введём направляющий вектор $v = Q - P$. Тогда

$$P(t) = P + tv.$$

Применим к данной прямой произвольное аффинное преобразование $F(x)$:

$$F(P(t)) = A(P + tv) + b = AP + tAv + b = (AP + b) + tAv = F(P) + tAv.$$

Таким образом, линейная часть A преобразует направляющий вектор v в направляющий вектор Av, а аддитивная часть b позволяет дополнительно сдвигать преобразуемые точки пространства.

Геометрически аффинное преобразование дополняет линейное преобразование возможностью аддитивного сдвига.

2 ОБРАТИМОСТЬ И СПЕКТРАЛЬНАЯ СТРУКТУРА

В данном разделе рассмотрим ранг матрицы, условия её обратимости, а затем перейдём к спектральной структуре линейных преобразований и сингулярному разложению.

2.1 Ранг матрицы

Определение. Рангом матрицы $A \in \mathbb{R}^{m\times n}$ называется максимальное число линейно независимых её столбцов. Эквивалентно ранг можно определять как максимальное число линейно независимых строк матрицы.

Ранг матрицы A будем обозначать через

$$\operatorname{rank} A.$$

В дальнейшем будем использовать без доказательства следующие свойства ранга матрицы.

Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad B \in \mathbb{R}^{n\times k}.$$

– Ранг матрицы совпадает с рангом транспонированной матрицы:

$$\operatorname{rank} A = \operatorname{rank} A^T.$$

– Ранг матрицы не превосходит меньшей из её размерностей:

$$\operatorname{rank} A \leq \min(m, n).$$

Если достигается равенство

$$\operatorname{rank} A = \min(m, n),$$

то матрица A называется **полноранговой**.

– Ранг произведения матриц не превосходит ранга каждого из сомножителей:

$$\operatorname{rank}(AB) \le \min\bigl(\operatorname{rank} A, \operatorname{rank} B\bigr).$$

2.2 Обратимость матрицы

Определение. Матрица $A \in \mathbb{R}^{n\times n}$ называется обратимой, если существует матрица $A^{-1} \in \mathbb{R}^{n\times n}$, такая что

$$A^{-1}A = AA^{-1} = I.$$

Матрица A^{-1} называется **обратной** к A.

Утверждение. Обратная матрица, если она существует, единственна.

□ Пусть существуют две обратные матрицы B и C:

$$AB = BA = I, \qquad AC = CA = I.$$

Тогда

$$B = BI = B(AC) = (BA)C = IC = C.$$

■

Теорема. Пусть $A, L, R \in \mathbb{R}^{n\times n}$. Тогда

$$AR = I \quad \Longrightarrow \quad RA = I, \qquad R = A^{-1}, \qquad A = R^{-1},$$

и

$$LA = I \quad \Longrightarrow \quad AL = I, \qquad L = A^{-1}, \qquad A = L^{-1}.$$

□ Из свойства ранга произведения

$$n = \operatorname{rank} I = \operatorname{rank}(AR) \le \operatorname{rank} A \le n.$$

Следовательно, $\operatorname{rank} A = n$, то есть столбцы A линейно независимы.

Рассмотрим

$$A(RA - I) = ARA - A = (AR)A - A = IA - A = 0.$$

Обозначим $C = RA - I = (c_1, \ldots, c_n)$. Тогда

$$AC = (Ac_1, \ldots, Ac_n) = 0 \quad \Longrightarrow \quad Ac_i = 0, \qquad i = 1, \ldots, n.$$

Так как столбцы A линейно независимы, из $Ac_i = 0$ следует $c_i = 0$. Следовательно, $C = 0$, то есть $RA = I$.

Таким образом,

$$AR = RA = I.$$

По определению обратимой матрицы получаем

$$R = A^{-1}, \qquad A = R^{-1}.$$

Вторая часть утверждения доказывается аналогично.

■

Следствие. Пусть для $A \in \mathbb{R}^{n\times n}$ существуют левая и правая обратные матрицы L и R соответственно. Тогда

$$LA = I, \qquad AR = I \quad \Longrightarrow \quad L = R.$$

Доказательство полностью следует из теоремы о том, что для квадратной матрицы существование односторонней обратной влечёт обычную обратимость, и утверждения о единственности обратной матрицы.

Теорема. Пусть $A \in \mathbb{R}^{n\times n}$. Тогда

$$A \text{ необратима} \quad \Longleftrightarrow \quad \operatorname{rank} A < n.$$

□ Пусть сначала A необратима. Предположим противное:

$$\operatorname{rank} A = n.$$

Тогда столбцы A линейно независимы и образуют базис $\mathbb{R}^n$. Следовательно, для каждого стандартного базисного вектора e_i существует вектор b_i, такой что

$$Ab_i = e_i.$$

Соберём эти векторы в матрицу $B = (b_1, \ldots, b_n)$. Тогда

$$AB = (Ab_1, \ldots, Ab_n) = (e_1, \ldots, e_n) = I.$$

Следовательно, A обратима. Получили противоречие с исходным предположением, что A необратима. Значит

$$A \text{ необратима} \quad \Longrightarrow \quad \operatorname{rank} A < n.$$

Теперь пусть $\operatorname{rank} A < n$. Предположим противное: A обратима. Тогда $A^{-1}A = I$.

По свойству ранга произведения

$$\operatorname{rank} I = \operatorname{rank}(A^{-1}A) \leq \operatorname{rank} A.$$

Но $\operatorname{rank} I = n$, поэтому $n \leq \operatorname{rank} A$, что противоречит условию $\operatorname{rank} A < n$. Следовательно,

$$\operatorname{rank} A < n \quad \Longrightarrow \quad A \text{ необратима}.$$

■

2.3 Определитель

Определение. Определителем квадратной матрицы называется отображение

$$\det : \mathbb{R}^{n\times n} \to \mathbb{R}, \qquad A \mapsto \det A.$$

Далее без доказательства будем использовать следующие свойства определителя:

– Если строки или столбцы квадратной матрицы A линейно зависимы, то

$$\det A = 0.$$

– Для квадратных матриц A и B выполняется мультипликативность определителя:

$$\det(AB) = \det A \det B.$$

– Если $R \in \mathbb{R}^{n\times n}$ является верхней или нижней треугольной матрицей, то её определитель равен произведению диагональных элементов:

$$\det R = \prod_{i=1}^{n} r_{ii}.$$

Определение. Квадратная матрица A называется вырожденной, если $\det A = 0$, и невырожденной, если $\det A \neq 0$.

Теорема. Для $A \in \mathbb{R}^{n\times n}$

$$\det A = 0 \quad \Longleftrightarrow \quad A \text{ необратима.}$$

□ Пусть сначала $\det A = 0$. Если бы A была обратима, то $AA^{-1} = I$. По мультипликативности определителя

$$\det A \det A^{-1} = \det I = 1,$$

что невозможно при $\det A = 0$. Следовательно,

$$\det A = 0 \quad \Longrightarrow \quad A \text{ необратима.}$$

Теперь пусть A необратима. Тогда по критерию обратимости через ранг

$$\operatorname{rank} A < n.$$

Следовательно, столбцы A линейно зависимы, поэтому по свойству определителя $\det A = 0$.

Значит

$$A \text{ необратима} \quad \Longrightarrow \quad \det A = 0.$$

■

Следствие. Для квадратных матриц A и B

$$AB \text{ обратима} \quad \Longleftrightarrow \quad A \text{ и } B \text{ обратимы.}$$

При этом

$$(AB)^{-1} = B^{-1}A^{-1}.$$

□ Если A и B обратимы, то

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = I.$$

Аналогично,

$$(B^{-1}A^{-1})(AB) = I.$$

Следовательно,

$$(AB)^{-1} = B^{-1}A^{-1}.$$

Обратно, если AB обратима, то $\det(AB) \neq 0$. По мультипликативности

$$\det A \det B \neq 0.$$

Следовательно,

$$\det A \neq 0, \qquad \det B \neq 0,$$

а значит обе матрицы обратимы.

■

Утверждение. Умножение матрицы слева или справа на обратимую матрицу не меняет её ранг.

□ Пусть P обратима. Тогда по свойству ранга произведения

$$\operatorname{rank}(PA) \leq \operatorname{rank} A.$$

Но $A = P^{-1}(PA)$, поэтому

$$\operatorname{rank} A = \operatorname{rank}\left(P^{-1}(PA)\right) \leq \operatorname{rank}(PA).$$

Следовательно,

$$\operatorname{rank}(PA) = \operatorname{rank} A.$$

Аналогично, если Q обратима, то

$$\operatorname{rank}(AQ) \leq \operatorname{rank} A.$$

Поскольку $A = (AQ)Q^{-1}$, имеем

$$\operatorname{rank} A \leq \operatorname{rank}(AQ).$$

Следовательно,

$$\operatorname{rank}(AQ) = \operatorname{rank} A.$$

■

Замечание. Для прямоугольной матрицы $A \in \mathbb{R}^{m\times n}$ двусторонней обратной в обычном смысле при $m \neq n$ не существует. Однако может существовать односторонняя обратная.

Если $m > n$ и $\operatorname{rank} A = n$, то существует левая обратная матрица L:

$$LA = I_n.$$

В частности, одну из таких матриц можно задать в виде

$$L = (A^T A)^{-1} A^T.$$

Если же $m < n$ и $\operatorname{rank} A = m$, то существует правая обратная матрица R:

$$AR = I_m.$$

Аналогично, правую обратную матрицу можно выбрать в виде

$$R = A^T (AA^T)^{-1}.$$

Отметим, что в общем случае односторонняя обратная матрица не единственна. Рассмотренные выше левая и правая обратные матрицы называются **каноническими** односторонними обратными.

2.4 Спектр матрицы

Определение. Вещественным спектром квадратной матрицы $A \in \mathbb{R}^{n\times n}$ называется множество

$$\operatorname{spec}_{\mathbb{R}}(A) = \{\lambda \in \mathbb{R} \mid A - \lambda I \text{ необратима}\}.$$

Например, для диагональной матрицы

$$A = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}$$

вещественный спектр состоит из значений, расположенных на её диагонали:

$$\operatorname{spec}_{\mathbb{R}}(A) = \{\lambda_1, \ldots, \lambda_n\}.$$

По критерию обратимости через определитель условие необратимости матрицы $A - \lambda I$ эквивалентно условию

$$\det(A - \lambda I) = 0.$$

Тем самым элементы вещественного спектра являются корнями многочлена, задаваемого определителем матрицы $A - \lambda I$.

Определение. Характеристическим многочленом матрицы A называется многочлен

$$\chi_A(\lambda) = \det(A - \lambda I).$$

Таким образом,

$$\lambda \in \operatorname{spec}_{\mathbb{R}}(A) \quad \Longleftrightarrow \quad \chi_A(\lambda) = 0.$$

Поскольку определитель матрицы $A - \lambda I$ задаёт многочлен по λ степени не выше n, число различных вещественных элементов спектра удовлетворяет оценке

$$\left|\operatorname{spec}_{\mathbb{R}}(A)\right| \leq n.$$

Утверждение. Для $A \in \mathbb{R}^{n\times n}$

$$0 \in \operatorname{spec}_{\mathbb{R}}(A) \quad \Longleftrightarrow \quad A \text{ необратима.}$$

□ По определению спектра

$$0 \in \operatorname{spec}_{\mathbb{R}}(A) \quad \Longleftrightarrow \quad A - 0I \text{ необратима} \quad \Longleftrightarrow \quad A \text{ необратима.}$$

■

Определение. Число $\lambda \in \mathbb{R}$ называется собственным значением матрицы $A \in \mathbb{R}^{n\times n}$, если существует ненулевой вектор $v \in \mathbb{R}^n$, такой что

$$Av = \lambda v.$$

Такой вектор v называется собственным вектором матрицы A, соответствующим собственному значению λ.

Геометрически собственный вектор задаёт направление, которое линейное преобразование не переводит в другое направление, а лишь масштабирует в λ раз. При $\lambda < 0$ направление дополнительно меняет ориентацию на противоположную.

2.5 Спектральное разложение

Теорема (спектральная теорема). Пусть

$$A \in \mathbb{R}^{n\times n}, \qquad A = A^T.$$

Тогда существует ортогональная матрица $Q = (q_1, \ldots, q_n)$ и диагональная матрица $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$, такие что

$$A = Q\Lambda Q^T.$$

При этом $q_1, \ldots, q_n$ образуют ортонормированный базис собственных векторов A, а $\lambda_1, \ldots, \lambda_n$ являются соответствующими собственными значениями.

Рассмотрим геометрический смысл данного разложения. Пусть $x \in \mathbb{R}^n$ задан в исходном базисе своими координатами:

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}.$$

Так как $Q = (q_1, \ldots, q_n)$, имеем

$$Q^T x = \begin{pmatrix} q_1^T x \\ \vdots \\ q_n^T x \end{pmatrix} = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{pmatrix}.$$

Поскольку $q_1, \ldots, q_n$ образуют ортонормированный собственный базис, величины $\alpha_i = q_i^T x$ являются координатами вектора x в этом базисе. Следовательно, действие Q^T переводит координаты вектора x из исходного базиса в собственный. Далее

$$\Lambda Q^T x = \begin{pmatrix} \lambda_1 \alpha_1 \\ \vdots \\ \lambda_n \alpha_n \end{pmatrix}.$$

То есть каждая компонента вдоль собственного направления q_i независимо умножается на соответствующее собственное значение λ_i. Наконец,

$$Q \Lambda Q^T x = \sum_{i=1}^{n} \lambda_i \alpha_i q_i.$$

Следовательно,

$$Ax = \sum_{i=1}^{n} \lambda_i \alpha_i q_i.$$

Таким образом, спектральное разложение позволяет представить сложное смешанное действие линейного преобразования в более наглядной форме: перейти к собственному базису, в котором компоненты вектора изменяются независимо вдоль собственных направлений.

Рассмотрим пример. Пусть

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Собственные значения матрицы имеют вид

$$\lambda_1 = 3, \qquad \lambda_2 = 1.$$

Выберем соответствующие ортонормированные собственные векторы

$$q_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad q_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Тогда

$$Q = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

является матрицей поворота стандартного базиса на 45° против часовой стрелки, а

$$\Lambda = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}.$$

Получаем спектральное разложение

$$A = Q \Lambda Q^T.$$

Физически действие матрицы A на вектор x можно интерпретировать последовательно. Сначала матрица Q^T переводит координаты вектора x в собственный базис. Затем матрица Λ независимо масштабирует полученные компоненты: первая координата умножается на 3, а вторая остаётся неизменной. После этого матрица Q переводит полученный вектор обратно в исходный базис.

Пусть

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.$$

После перехода в собственный базис получаем

$$Q^T x = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix}.$$

Тогда

$$Ax = 3\alpha_1 q_1 + \alpha_2 q_2.$$

Таким образом, в собственном базисе действие матрицы сводится к независимому масштабированию компонент вектора вдоль собственных направлений.

2.6 Сингулярное разложение

Лемма. Для любой матрицы $A \in \mathbb{R}^{m\times n}$ матрица $A^T A \in \mathbb{R}^{n\times n}$ симметрична, а все её собственные значения неотрицательны.

□ Симметричность следует из равенства

$$(A^T A)^T = A^T (A^T)^T = A^T A.$$

Пусть $v \neq 0$ является собственным вектором $A^T A$, соответствующим собственному значению λ:

$$A^T A v = \lambda v.$$

Умножим равенство слева на v^T:

$$v^T A^T A v = \lambda v^T v.$$

Левая часть имеет вид

$$v^T A^T A v = (Av)^T Av = \|Av\|_2^2 \geq 0.$$

Следовательно,

$$\lambda \|v\|_2^2 = \|Av\|_2^2 \geq 0.$$

Поскольку $v \neq 0$, его евклидова норма положительна, то есть $\|v\|_2^2 > 0$. Следовательно, из равенства $\lambda\|v\|_2^2 = \|Av\|_2^2 \geq 0$ получаем $\lambda \geq 0$.

■

Пусть теперь

$$A \in \mathbb{R}^{m\times n}, \qquad p = \min(m, n).$$

Рассмотрим матрицу

$$A^T A \in \mathbb{R}^{n\times n}.$$

Она симметрична, поэтому по спектральной теореме существует ортонормированный базис её собственных векторов. Упорядочим собственные значения по невозрастанию:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0.$$

Определение. Сингулярными значениями матрицы A называются числа

$$\sigma_i = \sqrt{\lambda_i}, \qquad i = 1, \ldots, p.$$

Обычно их располагают в порядке

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_p \geq 0.$$

Определение. Ортонормированные собственные векторы v_i матрицы $A^T A$, удовлетворяющие равенству

$$A^T A v_i = \sigma_i^2 v_i,$$

называются правыми сингулярными векторами матрицы A.

Если $\sigma_i > 0$, определим

$$u_i = \frac{A v_i}{\sigma_i}.$$

Тогда непосредственно

$$A v_i = \sigma_i u_i.$$

Покажем, что полученный вектор u_i является собственным вектором матрицы AA^T. По определению u_i получаем

$$AA^T u_i = AA^T \frac{A v_i}{\sigma_i} = \frac{A(A^T A v_i)}{\sigma_i} = \frac{A(\sigma_i^2 v_i)}{\sigma_i} = \sigma_i A v_i = \sigma_i^2 u_i.$$

Следовательно, u_i является левым сингулярным вектором матрицы A.

Если же $\sigma_i = 0$, то $A^T A v_i = 0$. Следовательно,

$$\|Av_i\|_2^2 = v_i^T A^T A v_i = 0,$$

то есть

$$Av_i = 0.$$

Теорема (о сингулярных базисах). Для любой матрицы $A \in \mathbb{R}^{m\times n}$ существует разложение

$$A = U\Sigma V^T,$$

где

$$U \in \mathbb{R}^{m\times m}, \qquad V \in \mathbb{R}^{n\times n}$$

— ортогональные матрицы, составленные соответственно из левых и правых сингулярных векторов матрицы A, а

$$\Sigma \in \mathbb{R}^{m\times n}$$

— прямоугольная диагональная матрица, на диагонали которой расположены сингулярные значения

$$\sigma_1, \ldots, \sigma_p, \qquad p = \min(m, n).$$

Рассмотрим геометрический смысл сингулярного разложения. Пусть $x \in \mathbb{R}^n$ задан в исходном базисе своими координатами:

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}.$$

Так как $V = (v_1, \ldots, v_n)$, имеем

$$V^T x = \begin{pmatrix} v_1^T x \\ \vdots \\ v_n^T x \end{pmatrix} = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{pmatrix}.$$

При этом $v_1, \ldots, v_n$ образуют ортонормированный базис входного пространства, поэтому величины $\alpha_i = v_i^T x$ являются координатами вектора x в базисе правых сингулярных векторов. Следовательно, действие V^T переводит координаты вектора x из исходного базиса в правый сингулярный базис.

Далее действует прямоугольная диагональная матрица Σ. Положим $p = \min(m, n)$. Тогда ненулевые диагональные элементы Σ равны сингулярным значениям, поэтому

$$\Sigma V^T x = \begin{pmatrix} \sigma_1 \alpha_1 \\ \vdots \\ \sigma_p \alpha_p \\ 0 \\ \vdots \end{pmatrix} \in \mathbb{R}^m.$$

То есть каждая компонента независимо масштабируется в σ_i раз вдоль соответствующего правого сингулярного направления v_i, а при $\sigma_i = 0$ соответствующая компонента обнуляется.

Наконец, столбцы матрицы $U = (u_1, \ldots, u_m)$ образуют ортонормированный базис выходного пространства, поэтому матрица U переводит полученные координаты из базиса левых сингулярных векторов в исходный базис выходного пространства.:

$$U\Sigma V^T x = U \begin{pmatrix} \sigma_1 \alpha_1 \\ \vdots \\ \sigma_p \alpha_p \\ 0 \\ \vdots \end{pmatrix} = \sum_{i=1}^{p} \sigma_i \alpha_i u_i.$$

Следовательно,

$$Ax = \sum_{i=1}^{p} \sigma_i \alpha_i u_i.$$

Таким образом, в сингулярном разложении каждое правое сингулярное направление v_i переходит в левое сингулярное направление u_i, одновременно масштабируясь в σ_i раз.

Рассмотрим пример. Пусть

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{3\times 2}.$$

Сначала вычислим

$$A^T A = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}.$$

Собственные значения матрицы $A^T A$ равны

$$\lambda_1 = 9, \qquad \lambda_2 = 1.$$

Следовательно, сингулярные значения матрицы A имеют вид

$$\sigma_1 = 3, \qquad \sigma_2 = 1.$$

Выберем соответствующие ортонормированные собственные векторы матрицы $A^T A$:

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad v_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Это правые сингулярные векторы матрицы A. Поэтому

$$V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}.$$

Левые сингулярные векторы получим по формуле $u_i = Av_i/\sigma_i$. Для первого направления

$$Av_1 = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 0 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 3 \\ 3 \\ 0 \end{pmatrix}.$$

Так как $\sigma_1 = 3$, получаем

$$u_1 = \frac{Av_1}{3} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}.$$

Для второго направления

$$Av_2 = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 0 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}.$$

Так как $\sigma_2 = 1$, имеем

$$u_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}.$$

Дополним u_1, u_2 до ортонормированного базиса пространства $\mathbb{R}^3$, положив

$$u_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}.$$

Тогда

$$U = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Следовательно, сингулярное разложение имеет вид

$$A = U\Sigma V^T.$$

Физически действие матрицы A на вектор $x \in \mathbb{R}^2$ можно интерпретировать последовательно. Сначала матрица V^T переводит координаты вектора в базис правых сингулярных векторов. Затем матрица Σ умножает первую координату на 3, оставляя вторую неизменной, и переводит полученный вектор в пространство $\mathbb{R}^3$. После этого матрица U переводит полученные координаты из базиса левых сингулярных векторов в исходный базис выходного пространства.

Пусть

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.$$

После перехода в базис правых сингулярных векторов получаем

$$V^T x = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix}.$$

Тогда после масштабирования и перехода в базис левых сингулярных векторов

$$Ax = 3\alpha_1 u_1 + \alpha_2 u_2.$$

Важным преимуществом сингулярного разложения является его применимость к произвольной действительной матрице. При этом, в отличие от собственных значений, сингулярные значения σ_i описывают лишь величину изменения вдоль специальных направлений: растяжение, сжатие или обнуление. Изменение ориентации при этом определяется взаимным расположением правого и левого сингулярных базисов, то есть матрицами V и U.

Следствие. Пусть

$$A \in \mathbb{R}^{n \times n}, \qquad A = A^T.$$

Тогда сингулярные значения матрицы A равны модулям её собственных значений.

□ По спектральной теореме

$$A = Q \Lambda Q^T.$$

Так как $A = A^T$, имеем

$$A^T A = A^2.$$

Следовательно,

$$A^T A = Q \Lambda Q^T Q \Lambda Q^T = Q \Lambda^2 Q^T.$$

Поэтому собственные значения $A^T A$ равны

$$\lambda_1^2, \ldots, \lambda_n^2.$$

По определению сингулярных значений они имеют вид

$$|\lambda_1|, \ldots, |\lambda_n|.$$

Если упорядочить собственные значения так, что

$$|\lambda_1| \geq \cdots \geq |\lambda_n|,$$

а сингулярные значения стандартно упорядочить как

$$\sigma_1 \geq \cdots \geq \sigma_n,$$

то

$$\sigma_i = |\lambda_i|, \qquad i = 1, \ldots, n.$$

■

Следствие. Ранг матрицы равен числу её ненулевых сингулярных значений:

$$\operatorname{rank} A = \#\{i : \sigma_i > 0\}.$$

□ Пусть $A = U\Sigma V^T$ — сингулярное разложение матрицы A. Матрицы U и V^T ортогональны и, следовательно, обратимы. Как было доказано ранее, умножение слева или справа на обратимую матрицу ранг не меняет. Поэтому

$$\operatorname{rank} A = \operatorname{rank}\left(U\Sigma V^T\right) = \operatorname{rank}\Sigma.$$

Матрица Σ диагональна в прямоугольном смысле, поэтому её ранг равен числу ненулевых диагональных элементов. Следовательно,

$$\operatorname{rank}\Sigma = \#\{i : \sigma_i > 0\}.$$

■

2.7 Почти линейная зависимость

Полученная связь ранга с сингулярными значениями позволяет количественно описать ситуацию, когда столбцы матрицы не являются точно линейно зависимыми, но близки к этому состоянию.

Определение. Пусть

$$A = (a_1, \ldots, a_n) \in \mathbb{R}^{m \times n}, \qquad m \geq n.$$

Будем говорить, что столбцы A почти линейно зависимы, если существует вектор коэффициентов $v \in \mathbb{R}^n$, такой что $\|v\|_2 = 1$, для которого

$$\|Av\|_2 \leq \varepsilon$$

при некотором малом $\varepsilon > 0$.

Утверждение. Пусть

$$A \in \mathbb{R}^{m \times n}, \qquad m \geq n.$$

Если столбцы A почти линейно зависимы, то минимальное сингулярное значение A близко к нулю.

Иными словами,

$$\exists\, v: \quad \|v\|_2 = 1, \qquad \|Av\|_2 \leq \varepsilon \quad \Longrightarrow \quad \sigma_{\min}(A) \leq \varepsilon.$$

□ По сингулярному разложению

$$A = U\Sigma V^T.$$

Положим

$$z = V^T v.$$

Так как V ортогональна, она сохраняет евклидову норму:

$$\|z\|_2 = \|V^T v\|_2 = \|v\|_2 = 1.$$

Теперь

$$Av = U\Sigma V^T v = U\Sigma z.$$

Поскольку U также ортогональна,

$$\|Av\|_2 = \|U\Sigma z\|_2 = \|\Sigma z\|_2.$$

Тогда

$$\|\Sigma z\|_2^2 = \sum_{i=1}^{n} \sigma_i^2 z_i^2.$$

Обозначим $\sigma_{\min} = \min_i \sigma_i$. Тогда для каждого i выполняется $\sigma_i^2 \geq \sigma_{\min}^2$, поэтому

$$\|Av\|_2^2 = \sum_{i=1}^{n} \sigma_i^2 z_i^2 \geq \sigma_{\min}^2 \sum_{i=1}^{n} z_i^2.$$

Так как $\|z\|_2 = 1$, имеем

$$\sum_{i=1}^{n} z_i^2 = 1.$$

Следовательно,

$$\sigma_{\min}^2 \leq \|Av\|_2^2.$$

Так как сингулярные значения неотрицательны и по условию $\|Av\|_2 \leq \varepsilon$, получаем

$$\sigma_{\min} \leq \|Av\|_2 \leq \varepsilon.$$

■

Следствие. Пусть $A \in \mathbb{R}^{n\times n}$, $A = A^T$. Если столбцы A почти линейно зависимы, то у A существует собственное значение, модуль которого не превосходит ε.

Иными словами,

$$\exists\, v \in \mathbb{R}^n : \quad \|v\|_2 = 1, \qquad \|Av\|_2 \leq \varepsilon \quad \Longrightarrow \quad \exists\, \lambda_i \in \operatorname{spec}_{\mathbb{R}}(A) : \quad |\lambda_i| \leq \varepsilon.$$

3 МАТРИЧНЫЕ НОРМЫ

До настоящего момента норма рассматривалась для векторов пространства $\mathbb{R}^n$. Расширим данное понятие на пространство матриц.

Определение. Матричной нормой на пространстве $\mathbb{R}^{m\times n}$ называется отображение

$$\|\cdot\| : \mathbb{R}^{m\times n} \to \mathbb{R}_+,$$

такое, что для любых $A, B \in \mathbb{R}^{m\times n}$ и $\alpha \in \mathbb{R}$ выполняются следующие аксиомы:

– Неотрицательность: $\|A\| \geq 0$, причём $\|A\| = 0 \iff A = 0$.

– Однородность:

$$\|\alpha A\| = |\alpha|\|A\|.$$

– Неравенство треугольника:

$$\|A + B\| \leq \|A\| + \|B\|.$$

Отметим, что пространство $\mathbb{R}^n$ можно отождествить с пространством матриц $\mathbb{R}^{n\times 1}$. Поэтому данное определение согласуется с введённым ранее определением векторной нормы.

3.1 Норма Фробениуса

Определение. Следом квадратной матрицы называется отображение

$$\operatorname{tr} : \mathbb{R}^{n\times n} \to \mathbb{R},$$

задаваемое в виде

$$\operatorname{tr} A = \sum_{i=1}^{n} a_{ii}.$$

Далее без доказательства будем использовать следующие свойства следа:

– След матрицы совпадает со следом транспонированной матрицы:

$$\operatorname{tr}(A^T) = \operatorname{tr} A.$$

– Для согласованного произведения трёх матриц след инвариантен относительно циклической перестановки сомножителей:

$$\operatorname{tr}(ABC) = \operatorname{tr}(BCA) = \operatorname{tr}(CAB).$$

– След является линейным отображением:

$$\operatorname{tr}(\alpha A + \beta B) = \alpha \operatorname{tr} A + \beta \operatorname{tr} B.$$

В частности,

$$\operatorname{tr}(A + B) = \operatorname{tr} A + \operatorname{tr} B$$

и

$$\operatorname{tr}(\alpha A) = \alpha \operatorname{tr} A.$$

Определение. Нормой Фробениуса матрицы $A \in \mathbb{R}^{m\times n}$ называется величина

$$\|A\|_F = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}^2}.$$

Утверждение. Для любой матрицы $A \in \mathbb{R}^{m\times n}$ выполняется

$$\|A\|_F^2 = \operatorname{tr}(A^T A).$$

□ Рассмотрим диагональные элементы матрицы $A^T A$. Для каждого $j = 1, \ldots, n$ имеем

$$(A^T A)_{jj} = \sum_{i=1}^{m} (A^T)_{ji} A_{ij} = \sum_{i=1}^{m} a_{ij}^2.$$

Следовательно,

$$\operatorname{tr}(A^T A) = \sum_{j=1}^{n} (A^T A)_{jj} = \sum_{j=1}^{n}\sum_{i=1}^{m} a_{ij}^2 = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}^2 = \|A\|_F^2.$$

■

Утверждение. Пусть $A \in \mathbb{R}^{m\times n}$, а $\sigma_1, \ldots, \sigma_p$, где $p = \min(m, n)$, — её сингулярные значения. Тогда

$$\|A\|_F = \sqrt{\sum_{i=1}^{p} \sigma_i^2}.$$

□ Пусть

$$A = U\Sigma V^T.$$

Тогда

$$A^TA = (U\Sigma V^T)^T U\Sigma V^T = V\Sigma^T U^T U\Sigma V^T = V\Sigma^T (U^T U)\Sigma V^T = V\Sigma^T \Sigma V^T,$$

поскольку $U^T U = I$.

По доказанному выше равенству $\|A\|_F^2 = \mathrm{tr}(A^TA)$. Следовательно,

$$\|A\|_F^2 = \mathrm{tr}\left(V\Sigma^T\Sigma V^T\right) = \mathrm{tr}\left(\Sigma^T\Sigma V^T V\right) = \mathrm{tr}\left(\Sigma^T\Sigma I\right) = \mathrm{tr}\left(\Sigma^T\Sigma\right) = \sum_{i=1}^{p}\sigma_i^2,$$

При переходе использованы циклическое свойство следа и равенство $V^TV = I$.

Отсюда

$$\|A\|_F = \sqrt{\sum_{i=1}^{p}\sigma_i^2}.$$

■

3.2 Индуцированная норма

Рассмотрим другой способ задания матричной нормы, непосредственно связанный с действием линейного преобразования на векторы.

Пусть на пространствах $\mathbb{R}^n$ и $\mathbb{R}^m$ фиксированы векторные нормы, которые далее будем обозначать одинаково через $|\cdot|$.

Определение. Индуцированной матричной нормой для $A \in \mathbb{R}^{m\times n}$ называется величина

$$\|A\| = \sup_{x\neq 0}\frac{|Ax|}{|x|}.$$

Индуцированную норму можно интерпретировать как максимальный коэффициент растяжения вектора матрицей A относительно выбранной векторной нормы.

Утверждение. Пусть $|\cdot|_2$ — евклидова норма. Тогда соответствующая индуцированная норма матрицы имеет вид

$$\|A\|_2 = \sigma_{\max}(A).$$

□ Пусть $A = U\Sigma V^T$ — сингулярное разложение матрицы A. По определению индуцированной нормы

$$\|A\|_2 = \sup_{x \neq 0} \frac{|Ax|_2}{|x|_2}.$$

Положим $z = V^T x$. Поскольку V ортогональна,

$$|z|_2 = |V^T x|_2 = |x|_2.$$

Кроме того,

$$Ax = U\Sigma V^T x = U\Sigma z.$$

Так как U также ортогональна,

$$|Ax|_2 = |U\Sigma z|_2 = |\Sigma z|_2.$$

Следовательно,

$$\frac{|Ax|_2^2}{|x|_2^2} = \frac{|\Sigma z|_2^2}{|z|_2^2}.$$

Пусть $p = \min(m, n)$. Тогда

$$|\Sigma z|_2^2 = \sum_{i=1}^{p} \sigma_i^2 z_i^2.$$

Поскольку $\sigma_i \leq \sigma_{\max}$ для всех i,

$$\sum_{i=1}^{p} \sigma_i^2 z_i^2 \leq \sigma_{\max}^2 \sum_{i=1}^{n} z_i^2 = \sigma_{\max}^2 |z|_2^2.$$

Следовательно,

$$\frac{|Ax|_2}{|x|_2} \leq \sigma_{\max}.$$

При этом равенство достигается на правом сингулярном векторе, соответствующем $\sigma_{\max}$. Действительно, если $x = v_1$, то $Av_1 = \sigma_1 u_1$, поэтому

$$\frac{|Av_1|_2}{|v_1|_2} = \sigma_1 = \sigma_{\max}.$$

Отсюда

$$\|A\|_2 = \sigma_{\max}(A).$$

■

Утверждение. Для любой матрицы $A \in \mathbb{R}^{m\times n}$ выполняется

$$\|A\|_2 \le \|A\|_F.$$

□ Поскольку все сингулярные значения неотрицательны,

$$\sigma_{\max}^2 \le \sum_{i=1}^{p} \sigma_i^2, \qquad p = \min(m, n).$$

Извлекая квадратный корень, получаем

$$\sigma_{\max} \le \sqrt{\sum_{i=1}^{p} \sigma_i^2}.$$

Но

$$\|A\|_2 = \sigma_{\max}, \qquad \|A\|_F = \sqrt{\sum_{i=1}^{p} \sigma_i^2}.$$

Следовательно,

$$\|A\|_2 \le \|A\|_F.$$

■

Таким образом, норма Фробениуса также задаёт верхнюю оценку коэффициента растяжения вектора:

$$|Ax|_2 \le \|A\|_2 |x|_2 \le \|A\|_F |x|_2.$$

Однако наименьшей верхней гранью коэффициентов растяжения является именно индуцированная евклидова норма $\|A\|_2$.

Далее без доказательства приведём ещё два примера индуцированных норм:

– Для векторной нормы $|\cdot|_1$ соответствующая матричная норма имеет вид

$$\|A\|_1 = \max_{j=1,\dots,n} \sum_{i=1}^{m} |a_{ij}|,$$

то есть равна максимальной абсолютной сумме элементов по столбцам.

– Для векторной нормы $|\cdot|_\infty$ соответствующая матричная норма имеет вид

$$\|A\|_\infty = \max_{i=1,\dots,m} \sum_{j=1}^{n} |a_{ij}|,$$

то есть равна максимальной абсолютной сумме элементов по строкам.

Определение. Матричная норма называется субмультипликативной, если для любых матриц согласованных размеров

$$A \in \mathbb{R}^{m\times n}, \qquad B \in \mathbb{R}^{n\times k}$$

выполняется

$$\|AB\| \le \|A\|\|B\|.$$

Утверждение. Индуцированная матричная норма субмультипликативна.

□ Из определения индуцированной нормы для любого ненулевого вектора x имеем

$$\frac{|Ax|}{|x|} \le \|A\|.$$

Следовательно,

$$|Ax| \le \|A\||x|.$$

Данное неравенство также выполняется при $x = 0$.

Пусть теперь $A \in \mathbb{R}^{m\times n}$, $B \in \mathbb{R}^{n\times k}$, и $x \in \mathbb{R}^k$. Тогда

$$|ABx| = |A(Bx)| \le \|A\||Bx| \le \|A\|\|B\||x|.$$

Для любого ненулевого x получаем

$$\frac{|ABx|}{|x|} \le \|A\|\|B\|.$$

Следовательно,

$$\|AB\| = \sup_{x\neq 0} \frac{|ABx|}{|x|} \le \|A\|\|B\|.$$

■

Утверждение. Норма Фробениуса субмультипликативна.

□ Пусть $A \in \mathbb{R}^{m\times n}, B \in \mathbb{R}^{n\times k}$. Запишем столбцы B как $B = (b_1, \ldots, b_k)$. Тогда столбцы произведения AB имеют вид

$$AB = (Ab_1, \ldots, Ab_k).$$

По определению нормы Фробениуса через столбцы

$$\|AB\|_F^2 = \sum_{j=1}^{k} |Ab_j|_2^2.$$

Для индуцированной евклидовой нормы

$$|Ab_j|_2 \leq \|A\|_2 |b_j|_2.$$

Поэтому

$$\|AB\|_F^2 \leq \sum_{j=1}^{k} \|A\|_2^2 |b_j|_2^2.$$

Поскольку множитель $\|A\|_2^2$ не зависит от j, получаем

$$\|AB\|_F^2 \leq \|A\|_2^2 \sum_{j=1}^{k} |b_j|_2^2.$$

Но

$$\sum_{j=1}^{k} |b_j|_2^2 = \|B\|_F^2.$$

Следовательно,

$$\|AB\|_F \leq \|A\|_2 \|B\|_F.$$

Поскольку $\|A\|_2 \leq \|A\|_F$, получаем

$$\|AB\|_F \leq \|A\|_F \|B\|_F.$$

■

4 ОБУСЛОВЛЕННОСТЬ И ПСЕВДООБРАТИМОСТЬ

Утверждение. Пусть $A \in \mathbb{R}^{n\times n}$. Тогда

$$A \text{ обратима} \quad \Longleftrightarrow \quad \sigma_i > 0, \qquad i = 1, \ldots, n.$$

□ Как было показано ранее,

$$\operatorname{rank} A = \#\{i : \sigma_i > 0\}.$$

Для квадратной матрицы

$$A \text{ обратима} \quad \Longleftrightarrow \quad \operatorname{rank} A = n.$$

Следовательно,

$$A \text{ обратима} \quad \Longleftrightarrow \quad \operatorname{rank} A = n \quad \Longleftrightarrow \quad \sigma_i > 0 \text{ для всех } i = 1, \ldots, n.$$

■

Утверждение. Пусть $A \in \mathbb{R}^{n\times n}$ — обратимая матрица и $A = U\Sigma V^T$ — её сингулярное разложение. Тогда

$$A^{-1} = V\Sigma^{-1}U^T, \qquad \Sigma^{-1} = \operatorname{diag}\left(\frac{1}{\sigma_1}, \ldots, \frac{1}{\sigma_n}\right),$$

и

$$\sigma_{\max}(A^{-1}) = \frac{1}{\sigma_{\min}(A)}.$$

□ Поскольку A обратима, все её сингулярные значения положительны. Следовательно, матрица

$$\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_n)$$

также обратима, причём

$$\Sigma^{-1} = \operatorname{diag}\left(\frac{1}{\sigma_1}, \ldots, \frac{1}{\sigma_n}\right).$$

Используя правило обращения произведения, получаем

$$A^{-1} = (U\Sigma V^T)^{-1} = (V^T)^{-1}\Sigma^{-1}U^{-1}.$$

Так как U и V ортогональны,

$$U^{-1} = U^T, \qquad (V^T)^{-1} = V.$$

Следовательно,

$$A^{-1} = V\Sigma^{-1}U^T.$$

Отсюда сингулярные значения A^{-1} имеют вид $\frac{1}{\sigma_i(A)}$. Если

$$\sigma_1 \geq \cdots \geq \sigma_n > 0,$$

то после обращения порядок меняется:

$$\frac{1}{\sigma_1} \leq \cdots \leq \frac{1}{\sigma_n}.$$

Следовательно,

$$\sigma_{\max}(A^{-1}) = \frac{1}{\sigma_{\min}(A)}.$$

■

4.1 Обусловленность

Определение. Пусть $A \in \mathbb{R}^{n\times n}$ — обратимая матрица. Коэффициентом обусловленности матрицы A относительно индуцированной евклидовой нормы называется величина

$$\kappa(A) = \|A\|_2\|A^{-1}\|_2.$$

Поскольку

$$\|A\|_2 = \sigma_{\max}(A) \qquad \|A^{-1}\|_2 = \frac{1}{\sigma_{\min}(A)},$$

получаем

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

Таким образом, коэффициент обусловленности можно интерпретировать как отношение максимального коэффициента масштабирования к минимальному коэффициенту масштабирования.

Замечание. Матрица называется хорошо обусловленной, если $\kappa(A) \approx 1$. Иными словами, матрица почти не выделяет направлений, которые растягиваются или сжимаются существенно сильнее других.

Рассмотрим теперь обратимую матрицу $A \in \mathbb{R}^{n\times n}$, столбцы которой почти линейно зависимы. Как было показано ранее, в таком случае $\sigma_{\min}(A) \leq \varepsilon$. Следовательно,

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \geq \frac{\sigma_{\max}(A)}{\varepsilon}.$$

Поэтому при малом ε относительно $\sigma_{\max}(A)$ имеем

$$\kappa(A) \gg 1.$$

То есть существует направление, которое матрица сжимает существенно сильнее по сравнению с направлением максимального масштабирования.

4.2 Псевдообратимость

Ранее было показано, что для обратимой квадратной матрицы $A = U\Sigma V^T$ обратная имеет вид

$$A^{-1} = V\Sigma^{-1}U^T, \qquad \Sigma^{-1} = \operatorname{diag}\left(\frac{1}{\sigma_1}, \ldots, \frac{1}{\sigma_n}\right).$$

Если хотя бы одно сингулярное значение равно нулю, то матрица Σ^{-1} не определена и обычной обратной матрицы не существует. Обобщим данную конструкцию так, чтобы обращались только ненулевые сингулярные значения.

Определение. Пусть $A \in \mathbb{R}^{m\times n}$, $A = U\Sigma V^T$, и $p = \min(m, n)$. Псевдообратной матрицей Мура–Пенроуза называется матрица

$$A^+ = V\Sigma^+U^T,$$

где $\Sigma^+ \in \mathbb{R}^{n\times m}$ имеет транспонированную относительно Σ прямоугольную диагональную форму, а её диагональные элементы задаются как

$$\sigma_i^+ = \begin{cases} \dfrac{1}{\sigma_i}, & \sigma_i > 0, \\ 0, & \sigma_i = 0, \end{cases} \qquad i = 1, \ldots, p.$$

Поскольку псевдообратная матрица инвертирует ненулевые сингулярные значения, а нулевые остаются нулевыми, она существует **всегда**.

Рассмотрим несколько частных случаев:

– Пусть $A \in \mathbb{R}^{n\times n}$ обратима. Тогда все её сингулярные значения положительны, поэтому

$$\Sigma^+ = \Sigma^{-1}.$$

Следовательно,

$$A^+ = V\Sigma^+U^T = V\Sigma^{-1}U^T = A^{-1}.$$

Таким образом, для обратимой квадратной матрицы псевдообратная совпадает с обычной обратной.

– Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad m > n, \qquad \operatorname{rank} A = n.$$

Тогда все n сингулярных значений положительны. Имеем

$$A^+A = V\Sigma^+U^TU\Sigma V^T = V\Sigma^+(U^TU)\Sigma V^T = V\Sigma^+\Sigma V^T.$$

Так как A имеет полный столбцовый ранг, на диагональных позициях произведения $\Sigma^+\Sigma$ получаем

$$\frac{1}{\sigma_i}\sigma_i = 1, \qquad i = 1, \ldots, n.$$

Следовательно,

$$\Sigma^+\Sigma = I_n.$$

Поэтому

$$A^+A = VI_nV^T = VV^T = I_n.$$

Таким образом, A^+ является левой обратной к A.

– Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad m < n, \qquad \operatorname{rank} A = m.$$

Аналогично,

$$AA^+ = U\Sigma V^T V\Sigma^+ U^T = U\Sigma\Sigma^+ U^T.$$

Так как A имеет полный строчный ранг,

$$\Sigma\Sigma^+ = I_m.$$

Следовательно,

$$AA^+ = UI_m U^T = UU^T = I_m.$$

Таким образом, A^+ является правой обратной к A.

Поскольку понятие обратной матрицы было обобщено с помощью псевдообратной, естественно аналогичным образом расширить определение коэффициента обусловленности на прямоугольные полноранговые матрицы.

Определение. Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad \operatorname{rank} A = \min(m, n).$$

Коэффициентом обусловленности матрицы A называется величина

$$\kappa(A) = \|A\|_2 \|A^+\|_2.$$

Поскольку при полном ранге меньшей стороны сингулярные значения псевдообратной имеют вид

$$\frac{1}{\sigma_1}, \ldots, \frac{1}{\sigma_p}, \qquad p = \min(m, n),$$

получаем

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

Предыдущее определение коэффициента обусловленности для обратимой квадратной матрицы является частным случаем данного определения, поскольку для обратимой квадратной матрицы $A^+ = A^{-1}$.

Утверждение. Если

$$A \in \mathbb{R}^{m\times n}, \qquad m > n, \qquad \operatorname{rank} A = n,$$

то

$$\kappa(A^T A) = \kappa(A)^2.$$

Если же

$$A \in \mathbb{R}^{m\times n}, \qquad m < n, \qquad \operatorname{rank} A = m,$$

то

$$\kappa(AA^T) = \kappa(A)^2.$$

□ Рассмотрим первый случай. Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad m > n, \qquad \operatorname{rank} A = n.$$

Тогда все сингулярные значения положительны:

$$\sigma_1 \geq \cdots \geq \sigma_n > 0.$$

Пусть $A = U\Sigma V^T$. Тогда

$$A^T A = V\Sigma^T U^T U\Sigma V^T = V\Sigma^T\Sigma V^T.$$

Матрица $\Sigma^T\Sigma$ диагональна и имеет вид

$$\Sigma^T\Sigma = \operatorname{diag}(\sigma_1^2, \ldots, \sigma_n^2).$$

Следовательно, собственные значения симметричной матрицы $A^T A$ равны

$$\sigma_1^2, \ldots, \sigma_n^2.$$

Тогда

$$\sigma_i(A^T A) = \sigma_i(A)^2.$$

Так как все сингулярные значения неотрицательны, порядок при возведении в квадрат сохраняется. Поэтому

$$\sigma_{\max}(A^T A) = \sigma_{\max}(A)^2 \qquad \sigma_{\min}(A^T A) = \sigma_{\min}(A)^2.$$

По определению коэффициента обусловленности

$$\kappa(A^TA) = \frac{\sigma_{\max}(A^TA)}{\sigma_{\min}(A^TA)} = \frac{\sigma_{\max}(A)^2}{\sigma_{\min}(A)^2} = \left(\frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}\right)^2 = \kappa(A)^2.$$

Второй случай доказывается аналогично для матрицы AA^T.

■

Рассмотрим теперь две прямоугольные полноранговые матрицы

$$A \in \mathbb{R}^{m\times n}, \qquad m > n, \qquad \operatorname{rank} A = n,$$

и

$$B \in \mathbb{R}^{m\times n}, \qquad m < n, \qquad \operatorname{rank} B = m.$$

Как было показано ранее, для A существует каноническая левая обратная

$$L = (A^TA)^{-1}A^T, \qquad LA = I_n,$$

а для B существует каноническая правая обратная

$$R = B^T(BB^T)^{-1}, \qquad BR = I_m.$$

В обоих случаях построение канонической односторонней обратной требует формирования квадратной матрицы A^TA или BB^T. По доказанному выше утверждению

$$\kappa(A^TA) = \kappa(A)^2 \qquad \kappa(BB^T) = \kappa(B)^2.$$

Следовательно, при большой исходной обусловленности переход к данным квадратным матрицам ещё сильнее увеличивает разрыв между их крайними сингулярными значениями, что может существенно ухудшать численную устойчивость последующего обращения.

Утверждение. Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad m > n, \qquad \operatorname{rank} A = n,$$

и

$$B \in \mathbb{R}^{m\times n}, \qquad m < n, \qquad \operatorname{rank} B = m.$$

Тогда каноническая левая обратная к A совпадает с её псевдообратной:

$$(A^T A)^{-1} A^T = A^+.$$

Каноническая правая обратная к B также совпадает с её псевдообратной:

$$B^T (BB^T)^{-1} = B^+.$$

□ Докажем первое равенство. Пусть $A = U\Sigma V^T$ — сингулярное разложение матрицы A. Так как A имеет полный столбцовый ранг, все её сингулярные значения положительны:

$$\sigma_1, \ldots, \sigma_n > 0.$$

Тогда

$$A^T A = (V\Sigma^T U^T)(U\Sigma V^T) = V\Sigma^T (U^T U)\Sigma V^T = V\Sigma^T \Sigma V^T.$$

Поскольку

$$\Sigma^T \Sigma = \operatorname{diag}(\sigma_1^2, \ldots, \sigma_n^2),$$

имеем

$$(\Sigma^T \Sigma)^{-1} = \operatorname{diag}\left(\frac{1}{\sigma_1^2}, \ldots, \frac{1}{\sigma_n^2}\right).$$

Следовательно,

$$(A^T A)^{-1} = \left(V\Sigma^T \Sigma V^T\right)^{-1} = V(\Sigma^T \Sigma)^{-1} V^T.$$

Теперь умножим полученную матрицу на A^T:

$$(A^T A)^{-1} A^T = V(\Sigma^T \Sigma)^{-1} V^T V\Sigma^T U^T = V(\Sigma^T \Sigma)^{-1} \Sigma^T U^T.$$

На диагональных позициях произведения $(\Sigma^T \Sigma)^{-1}\Sigma^T$ получаем

$$\frac{1}{\sigma_i^2}\sigma_i = \frac{1}{\sigma_i},$$

а структурные нули остаются нулями. Следовательно,

$$(\Sigma^T\Sigma)^{-1}\Sigma^T = \Sigma^+.$$

Поэтому

$$(A^TA)^{-1}A^T = V\Sigma^+U^T = A^+.$$

Второе равенство доказывается аналогично.

■

Таким образом, псевдообратная задаёт эквивалентную форму канонических односторонних обратных, но при её непосредственном вычислении с использованием сингулярного разложения не требуется формировать матрицы вида A^TA или AA^T, обусловленность которых возводится в квадрат. Поэтому такой способ вычисления псевдообратной является более численно устойчивым.

МАТЕМАТИЧЕСКИЙ АНАЛИЗ

В данной главе рассматриваются основные понятия математического анализа и оптимизации в конечномерном пространстве $\mathbb{R}^n$ со стандартной евклидовой метрикой. Сначала рассматриваются общая теория дифференциального исчисления и матрично-векторное дифференцирование, затем безусловная и условная оптимизация.

5 ДИФФЕРЕНЦИАЛЬНОЕ ИСЧИСЛЕНИЕ В $\mathbb{R}^n$

5.1 Топология пространства $\mathbb{R}^n$

Далее, если не сказано обратное, через E будем обозначать произвольное подмножество пространства $\mathbb{R}^n$.

Определение. Окрестностью радиуса $r > 0$ точки $a \in \mathbb{R}^n$ называется множество

$$B_r(a) = \{x \in \mathbb{R}^n \mid \rho(x, a) < r\}.$$

Определение. Точка $a \in E$ называется **внутренней точкой** множества E, если существует её окрестность, целиком содержащаяся в E:

$$\exists\, r > 0 : \qquad B_r(a) \subseteq E.$$

Точка $a \in \mathbb{R}^n \setminus E$ называется **внешней точкой** множества E, если существует её окрестность, не содержащая точек E:

$$\exists\, r > 0 : \qquad B_r(a) \subseteq \mathbb{R}^n \setminus E.$$

Точка $a \in \mathbb{R}^n$ называется **граничной точкой** множества E, если любая её окрестность содержит как точки множества E, так и точки, не принадлежащие E:

$$\forall\, r > 0 : \qquad B_r(a) \cap E \neq \varnothing, \qquad B_r(a) \cap \left(\mathbb{R}^n \setminus E\right) \neq \varnothing.$$

Определение. Множество $E \subseteq \mathbb{R}^n$ называется **открытым**, если каждая его точка является внутренней, то есть

$$\forall\, a \in E \quad \exists\, r > 0 : \qquad B_r(a) \subseteq E.$$

Определение. Множество $E \subseteq \mathbb{R}^n$ называется **замкнутым**, если его дополнение $\mathbb{R}^n \setminus E$ является открытым.

Определение. Множество $E \subseteq \mathbb{R}^n$ называется **выпуклым**, если вместе с любыми двумя своими точками оно содержит весь соединяющий их отрезок, то

есть для любых $x, y \in E$ и любого $t \in [0, 1]$

$$(1 - t)x + ty \in E.$$

Определение. Проколотой окрестностью радиуса $r > 0$ точки $a \in \mathbb{R}^n$ называется множество

$$\overset{\circ}{B}_r(a) = B_r(a) \setminus \{a\}.$$

Определение. Точка $a \in \mathbb{R}^n$ называется **предельной точкой** множества E, если любая её проколотая окрестность содержит точку множества E, то есть

$$\forall\, r > 0 : \qquad \overset{\circ}{B}_r(a) \cap E \neq \varnothing.$$

Определение. Пусть $f : E \to \mathbb{R}^m$, точка $a \in \mathbb{R}^n$ является предельной точкой множества E, а $b \in \mathbb{R}^m$. Точка b называется **пределом функции** f при $x \to a$, если для любой окрестности $B_\varepsilon(b)$ существует проколотая окрестность $\overset{\circ}{B}_\delta(a)$ такая, что

$$\forall\, \varepsilon > 0 \quad \exists\, \delta = \delta(\varepsilon, a) > 0 : \qquad x \in E \cap \overset{\circ}{B}_\delta(a) \quad \Longrightarrow \quad f(x) \in B_\varepsilon(b).$$

В таком случае пишут

$$\lim_{x \to a} f(x) = b.$$

Определение. Пусть $f : E \to \mathbb{R}^m$ и $a \in E$ является предельной точкой множества E. Функция f называется **непрерывной в точке** a, если

$$\lim_{x \to a} f(x) = f(a).$$

В общем случае для произвольной точки $a \in E$ непрерывность в точке a задаётся условием

$$\forall\, \varepsilon > 0 \quad \exists\, \delta = \delta(\varepsilon, a) > 0 : \qquad x \in E \cap B_\delta(a) \quad \Longrightarrow \quad f(x) \in B_\varepsilon(f(a)).$$

Определение. Функция $f : E \to \mathbb{R}^m$ называется **равномерно непрерывной** на E, если

$$\forall\, \varepsilon > 0 \quad \exists\, \delta = \delta(\varepsilon) > 0 : \quad \forall\, x, y \in E : \quad \rho(x, y) < \delta \quad \Longrightarrow \quad \rho(f(x), f(y)) < \varepsilon.$$

Определение. Функция $f : E \to \mathbb{R}^m$ называется **липшицевой** на E, если существует число $L > 0$ такое, что для любых $x, y \in E$

$$\rho(f(x), f(y)) \leq L\rho(x, y).$$

Число L называется **константой Липшица** функции f.

Утверждение. Если функция липшицева на E, то она равномерно непрерывна на E. Если функция равномерно непрерывна на E, то она непрерывна в каждой точке E.

Иными словами,

$$\text{липшицевость} \implies \text{равномерная непрерывность} \implies \text{непрерывность}.$$

□ Пусть функция f является L-липшицевой. При $L > 0$ для произвольного $\varepsilon > 0$ выберем $\delta = \varepsilon/L$. Тогда из $\rho(x, y) < \delta$ следует

$$\rho(f(x), f(y)) \leq L\rho(x, y) < L\delta = \varepsilon.$$

Следовательно, функция f равномерно непрерывна.

Пусть теперь функция f равномерно непрерывна на E. Тогда для любого $\varepsilon > 0$ существует $\delta = \delta(\varepsilon) > 0$ такое, что для любых $x, y \in E$ из $\rho(x, y) < \delta$ следует $\rho(f(x), f(y)) < \varepsilon$. Зафиксировав произвольную точку $a \in E$ и положив $y = a$, получаем

$$\rho(x, a) < \delta \quad \implies \quad \rho(f(x), f(a)) < \varepsilon.$$

Следовательно, функция f непрерывна в точке a. Так как точка a была выбрана произвольно, функция непрерывна в каждой точке множества E.

■

Пример. Рассмотрим k-ю координатную функцию

$$p_k : \mathbb{R}^n \to \mathbb{R}, \qquad p_k(x) = x_k, \qquad k = 1, \ldots, n.$$

Для любых $x, y \in \mathbb{R}^n$ имеем

$$|p_k(x) - p_k(y)| = |x_k - y_k| \le \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2} = \|x - y\|_2 = \rho(x, y).$$

Следовательно, координатная функция p_k является 1-липшицевой, а значит равномерно непрерывной и, в частности, непрерывной.

5.2 Дифференцируемость функции в точке

Пусть $U \subseteq \mathbb{R}^n$ — открытое множество, $f : U \to \mathbb{R}$ и $a \in U$.

Определение. Частной производной функции f по переменной x_k в точке a называется предел

$$\frac{\partial f}{\partial x_k}(a) = \lim_{t \to 0} \frac{f(a + te_k) - f(a)}{t},$$

если он существует, где e_k — k-й вектор стандартного базиса пространства $\mathbb{R}^n$.

Определение. Пусть $v \in \mathbb{R}^n$, $v \neq 0$. Производной функции f по направлению v в точке a называется предел

$$\frac{\partial f}{\partial v}(a) = \lim_{t \to 0} \frac{f(a + tv) - f(a)}{t},$$

если он существует.

В частности, производная по координатному направлению совпадает с соответствующей частной производной:

$$\frac{\partial f}{\partial e_k}(a) = \frac{\partial f}{\partial x_k}(a).$$

Определение. Функция f называется **дифференцируемой в точке** a, если существует вектор $A \in \mathbb{R}^n$ и функция $\alpha : \mathbb{R}^n \to \mathbb{R}$, для которой

$$\alpha(0) = 0, \qquad \alpha(h) \to 0 \quad \text{при} \quad h \to 0,$$

такие что для всех достаточно малых $h \in \mathbb{R}^n$

$$f(a+h) = f(a) + \langle A, h\rangle + \alpha(h)\|h\|_2. \tag{1}$$

Линейный функционал

$$h \mapsto \langle A, h\rangle$$

называется **дифференциалом функции** f в точке a и обозначается через df_a.

Таким образом, формулу (1) можно записать в виде

$$f(a+h) = f(a) + df_a(h) + o(\|h\|_2), \qquad h \to 0.$$

Теорема. Если функция f дифференцируема в точке a, то для любого $v \in \mathbb{R}^n$, $v \neq 0$, существует производная функции f по направлению v, причём

$$\frac{\partial f}{\partial v}(a) = df_a(v).$$

□ Так как множество U открыто и $a \in U$, существует $r > 0$ такое, что

$$B_r(a) \subset U.$$

Положим

$$h = tv, \qquad |t| < \frac{r}{\|v\|_2}.$$

Тогда $a + tv \in U$, и по формуле (1)

$$f(a+tv) - f(a) = df_a(tv) + \alpha(tv)\|tv\|_2.$$

По линейности дифференциала $df_a(tv) = t\,df_a(v)$. Поэтому при $t \neq 0$

$$\frac{f(a+tv) - f(a)}{t} = df_a(v) + \alpha(tv)\frac{|t|}{t}\|v\|_2.$$

В силу непрерывности, при $t \to 0$ имеем $\alpha(tv) \to 0$. Следовательно,

$$\lim_{t\to 0} \frac{f(a+tv) - f(a)}{t} = df_a(v),$$

то есть

$$\frac{\partial f}{\partial v}(a) = df_a(v).$$

■

Следствие. Дифференциал df_a определяется однозначно.

Это следует из равенства производной по направлению и значения дифференциала на данном направлении.

Определение. Двойственным пространством к $\mathbb{R}^n$ называется пространство

$$(\mathbb{R}^n)^* = \{L : \mathbb{R}^n \to \mathbb{R} \mid L \text{ линейно}\}.$$

Определение. Базис $e^1, \ldots, e^n$ пространства $(\mathbb{R}^n)^*$ называется **двойственным** к базису $e_1, \ldots, e_n$ пространства $\mathbb{R}^n$, если

$$e^i(e_j) = \delta_{ij}, \qquad i, j = 1, \ldots, n,$$

где δ_{ij} — символ Кронекера:

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Теорема (Необходимое условие дифференцируемости). Если функция f дифференцируема в точке a, то она непрерывна в этой точке и имеет все частные производные, причём для любого $h \in \mathbb{R}^n$

$$df_a(h) = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) h_k.$$

□ Положим в формуле (1) $h = x - a$. Тогда при $x \to a$

$$f(x) = f(a) + df_a(x - a) + o(\|x - a\|_2).$$

Поскольку для некоторого $A \in \mathbb{R}^n$

$$df_a(x - a) = \langle A, x - a \rangle,$$

по неравенству Коши–Буняковского–Шварца

$$|df_a(x-a)| \le \|A\|_2 \|x-a\|_2 \to 0$$

при $x \to a$. Кроме того,

$$o(\|x-a\|_2) \to 0.$$

Следовательно,

$$\lim_{x \to a} f(x) = f(a),$$

то есть функция f непрерывна в точке a.

Далее для каждого $k = 1, \ldots, n$ по теореме о производной по направлению существует

$$\frac{\partial f}{\partial x_k}(a) = \frac{\partial f}{\partial e_k}(a) = df_a(e_k).$$

Для произвольного вектора

$$h = \sum_{k=1}^{n} h_k e_k$$

по линейности дифференциала получаем

$$df_a(h) = df_a\left(\sum_{k=1}^{n} h_k e_k\right) = \sum_{k=1}^{n} h_k df_a(e_k) = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) h_k.$$

■

Рассмотрим теперь координатную функцию

$$p_k : \mathbb{R}^n \to \mathbb{R}, \qquad p_k(x) = x_k.$$

Для произвольных $a, h \in \mathbb{R}^n$ имеем

$$p_k(a+h) = a_k + h_k = p_k(a) + h_k.$$

Следовательно, координатная функция p_k дифференцируема в любой точке, причём её дифференциал имеет вид

$$d(p_k)_a(h) = h_k.$$

Данный дифференциал не зависит от выбора точки a. Поэтому далее будем обозначать его через dx_k:

$$dx_k(h) = h_k.$$

Для стандартных базисных векторов e_j выполняется

$$dx_k(e_j) = (e_j)_k = \delta_{kj}.$$

Следовательно, линейные функционалы

$$dx_1, \ldots, dx_n$$

образуют базис пространства $(\mathbb{R}^n)^*$, двойственный стандартному базису $e_1, \ldots, e_n$ пространства $\mathbb{R}^n$.

Таким образом, дифференциал функции f в точке a можно разложить по двойственному базису:

$$df_a = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) dx_k.$$

Действительно, для любого $h \in \mathbb{R}^n$

$$df_a(h) = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) dx_k(h) = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) h_k.$$

Определение. Градиентом дифференцируемой функции f в точке a называется вектор

$$\nabla f(a) = \begin{pmatrix} \dfrac{\partial f}{\partial x_1}(a) \\ \vdots \\ \dfrac{\partial f}{\partial x_n}(a) \end{pmatrix}.$$

Тогда для любого $h \in \mathbb{R}^n$

$$df_a(h) = \sum_{k=1}^{n} \frac{\partial f}{\partial x_k}(a) h_k = \langle \nabla f(a), h \rangle.$$

Следовательно, формулу дифференцируемости можно записать в виде

$$f(a + h) = f(a) + \langle \nabla f(a), h \rangle + o(\|h\|_2), \qquad h \to 0.$$

Утверждение. Пусть функция f дифференцируема в точке a и $\nabla f(a) \neq 0$. Тогда для любого $v \in \mathbb{R}^n$ такого, что $\|v\|_2 = 1$,

$$\left|\frac{\partial f}{\partial v}(a)\right| \leq \|\nabla f(a)\|_2,$$

причём равенство достигается тогда и только тогда, когда

$$v = \pm\frac{\nabla f(a)}{\|\nabla f(a)\|_2}.$$

□ По теореме о производной по направлению

$$\frac{\partial f}{\partial v}(a) = df_a(v) = \langle \nabla f(a), v\rangle.$$

По неравенству Коши–Буняковского–Шварца

$$\left|\frac{\partial f}{\partial v}(a)\right| = |\langle \nabla f(a), v\rangle| \leq \|\nabla f(a)\|_2\|v\|_2 = \|\nabla f(a)\|_2.$$

Равенство в неравенстве Коши–Буняковского–Шварца достигается тогда и только тогда, когда векторы v и $\nabla f(a)$ линейно зависимы. Поскольку $\|v\|_2 = 1$, получаем

$$v = \pm\frac{\nabla f(a)}{\|\nabla f(a)\|_2}.$$

Для направления

$$v = \frac{\nabla f(a)}{\|\nabla f(a)\|_2}$$

имеем

$$\frac{\partial f}{\partial v}(a) = \left\langle \nabla f(a), \frac{\nabla f(a)}{\|\nabla f(a)\|_2}\right\rangle = \|\nabla f(a)\|_2.$$

Для противоположного направления

$$v = -\frac{\nabla f(a)}{\|\nabla f(a)\|_2}$$

получаем

$$\frac{\partial f}{\partial v}(a) = -\|\nabla f(a)\|_2.$$

■

Утверждение даёт характеристику градиента: ненулевой градиент направлен в сторону наибольшего роста функции, а его длина равна максимальной скорости роста.

Определение. Множеством уровня функции f, соответствующим значению $c \in \mathbb{R}$, называется множество

$$M_c = \{x \in U \mid f(x) = c\}.$$

Утверждение. Пусть функция f дифференцируема в точке $a \in M_c$. Рассмотрим последовательность точек $x^{(j)} \in M_c$, $x^{(j)} \neq a$, такую, что

$$x^{(j)} \to a,$$

и пусть для некоторого единичного вектора v

$$\frac{x^{(j)} - a}{\|x^{(j)} - a\|_2} \to v.$$

Тогда

$$\langle \nabla f(a), v \rangle = 0.$$

□ Так как $a, x^{(j)} \in M_c$, имеем

$$f(x^{(j)}) = f(a) = c.$$

По дифференцируемости функции f в точке a

$$f(x^{(j)}) - f(a) = \left\langle \nabla f(a), x^{(j)} - a \right\rangle + o\left(\|x^{(j)} - a\|_2\right).$$

Следовательно,

$$0 = \left\langle \nabla f(a), x^{(j)} - a \right\rangle + o\left(\|x^{(j)} - a\|_2\right).$$

Разделим равенство на $\|x^{(j)} - a\|_2$:

$$0 = \left\langle \nabla f(a), \frac{x^{(j)} - a}{\|x^{(j)} - a\|_2} \right\rangle + o(1).$$

При $j \to \infty$ имеем

$$\frac{x^{(j)} - a}{\|x^{(j)} - a\|_2} \to v, \qquad o(1) \to 0.$$

Поэтому

$$\langle \nabla f(a), v \rangle = 0.$$

■

Таким образом, градиент в точке a ортогонален направлениям множества уровня, проходящим через эту точку.

Теорема (Достаточное условие дифференцируемости). Если функция f имеет в некоторой окрестности точки a частные производные по всем переменным и все они непрерывны в точке a, то функция f дифференцируема в этой точке.

5.3 Дифференцируемость отображения в точке

Пусть $U \subseteq \mathbb{R}^n$ — открытое множество, $f : U \to \mathbb{R}^m$ и $a \in U$.

Определение. Отображение f называется **дифференцируемым в точке** a, если существуют линейное отображение

$$L_a : \mathbb{R}^n \to \mathbb{R}^m$$

и отображение $\alpha : \mathbb{R}^n \to \mathbb{R}^m$, для которого

$$\alpha(0) = 0, \qquad \alpha(h) \to 0 \quad \text{при} \quad h \to 0,$$

такие что для всех достаточно малых $h \in \mathbb{R}^n$

$$f(a + h) = f(a) + L_a(h) + \alpha(h)\|h\|_2.$$

Линейное отображение L_a называется **дифференциалом отображения** f в точке a и обозначается через df_a. Тогда формулу дифференцируемости можно записать в виде

$$f(a + h) = f(a) + df_a(h) + o(\|h\|_2), \qquad h \to 0.$$

Определение. Матрицей дифференциала отображения f в стандартных базисах называется матрица $J_f(a)$, определяемая равенством

$$df_a(h) = J_f(a)h$$

для любого $h \in \mathbb{R}^n$.

Матрица $J_f(a)$ называется **матрицей Якоби**, или **якобианом**, отображения f в точке a.

Если

$$f = \begin{pmatrix} f_1 \\ \vdots \\ f_m \end{pmatrix},$$

то матрица Якоби имеет вид

$$J_f(a) = \begin{pmatrix} \dfrac{\partial f_1}{\partial x_1}(a) & \cdots & \dfrac{\partial f_1}{\partial x_n}(a) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial f_m}{\partial x_1}(a) & \cdots & \dfrac{\partial f_m}{\partial x_n}(a) \end{pmatrix}.$$

Иными словами,

$$J_f(a) = \begin{pmatrix} \nabla f_1(a)^T \\ \vdots \\ \nabla f_m(a)^T \end{pmatrix}.$$

Пример. Рассмотрим отображение

$$f : \mathbb{R}^2 \to \mathbb{R}^2, \qquad f(x, y) = \begin{pmatrix} x + y \\ xy \end{pmatrix}.$$

Его матрица Якоби имеет вид

$$J_f(x, y) = \begin{pmatrix} 1 & 1 \\ y & x \end{pmatrix}.$$

В точке $a = (2, 1)^T$ получаем

$$J_f(a) = J_f(2, 1) = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}.$$

Утверждение. Пусть отображения f и g дифференцируемы в точке a, а $\lambda \in \mathbb{R}$. Тогда отображения $f + g$ и λf также дифференцируемы в точке a, причём

$$d(f + g)_a = df_a + dg_a$$

и

$$d(\lambda f)_a = \lambda\, df_a.$$

В матричной форме данные равенства имеют вид

$$J_{f+g}(a) = J_f(a) + J_g(a)$$

и

$$J_{\lambda f}(a) = \lambda J_f(a).$$

Теорема. Пусть $U \subseteq \mathbb{R}^n$ и $V \subseteq \mathbb{R}^m$ — открытые множества, отображение $f : U \to \mathbb{R}^m$ дифференцируемо в точке a, причём $f(U) \subseteq V$, а отображение $g : V \to \mathbb{R}^k$ дифференцируемо в точке $f(a)$. Тогда композиция

$$g \circ f : U \to \mathbb{R}^k$$

дифференцируема в точке a, причём

$$d(g \circ f)_a = dg_{f(a)} \circ df_a.$$

□ По определению дифференцируемости положим $b = f(a)$. Тогда

$$f(a + h) = f(a) + df_a(h) + \alpha(h)\|h\|_2, \qquad \alpha(h) \to 0 \quad \text{при} \quad h \to 0,$$

и

$$g(b + u) = g(b) + dg_b(u) + \beta(u)\|u\|_2, \qquad \beta(u) \to 0 \quad \text{при} \quad u \to 0.$$

Введём

$$\chi(h) = df_a(h) + \alpha(h)\|h\|_2.$$

Тогда

$$f(a+h) = b + \chi(h).$$

Поэтому

$$\begin{aligned} g(f(a+h)) &= g\big(b + \chi(h)\big) \\ &= g(b) + dg_b\big(\chi(h)\big) + \beta\big(\chi(h)\big)\|\chi(h)\|_2 \\ &= g(b) + dg_b\left(df_a(h) + \alpha(h)\|h\|_2\right) + \beta\big(\chi(h)\big)\|\chi(h)\|_2 \\ &= g(b) + dg_b\big(df_a(h)\big) + \|h\|_2 dg_b\big(\alpha(h)\big) + \beta\big(\chi(h)\big)\|\chi(h)\|_2 \\ &= g(f(a)) + \big(dg_b \circ df_a\big)(h) + \eta(h)\|h\|_2, \end{aligned}$$

где

$$\eta(h) = dg_b\big(\alpha(h)\big) + \beta\big(\chi(h)\big)\frac{\|\chi(h)\|_2}{\|h\|_2}.$$

Покажем, что

$$\eta(h) \to 0 \qquad \text{при} \qquad h \to 0.$$

Так как

$$\alpha(h) \to 0,$$

а отображение dg_b линейно и непрерывно, имеем

$$dg_b\big(\alpha(h)\big) \to 0.$$

Кроме того,

$$\chi(h) = df_a(h) + \alpha(h)\|h\|_2 \to 0,$$

поэтому

$$\beta\big(\chi(h)\big) \to 0.$$

Так как df_a является линейным отображением, существует $C > 0$ такое, что

$$\|df_a(h)\|_2 \le C\|h\|_2.$$

Следовательно,

$$\frac{\|\chi(h)\|_2}{\|h\|_2} = \frac{\|df_a(h) + \alpha(h)\|h\|_2\|_2}{\|h\|_2} \le \frac{\|df_a(h)\|_2}{\|h\|_2} + \|\alpha(h)\|_2 \le C + \|\alpha(h)\|_2.$$

Следовательно,

$$\eta(h) \to 0 \qquad \text{при} \qquad h \to 0.$$

Значит,

$$g(f(a+h)) = g(f(a)) + \big(dg_{f(a)} \circ df_a\big)(h) + o(\|h\|_2).$$

Следовательно, композиция $g \circ f$ дифференцируема в точке a и

$$d(g \circ f)_a = dg_{f(a)} \circ df_a.$$

■

Следствие 1. Для матриц Якоби композиции справедливо

$$J_{g\circ f}(a) = J_g(f(a))J_f(a),$$

где

$$\underset{k\times n}{J_{g\circ f}(a)} = \underset{k\times m}{J_g(f(a))}\,\underset{m\times n}{J_f(a)}.$$

При $k = 1$ имеем

$$J_g(b) = \left(\frac{\partial g}{\partial y_1}(b) \quad \cdots \quad \frac{\partial g}{\partial y_m}(b)\right),$$

а

$$J_f(a) = \begin{pmatrix} \dfrac{\partial f_1}{\partial x_1}(a) & \cdots & \dfrac{\partial f_1}{\partial x_n}(a) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial f_m}{\partial x_1}(a) & \cdots & \dfrac{\partial f_m}{\partial x_n}(a) \end{pmatrix}.$$

Следовательно,

$$J_{g\circ f}(a) = \left(\frac{\partial (g\circ f)}{\partial x_1}(a) \quad \cdots \quad \frac{\partial (g\circ f)}{\partial x_n}(a)\right) = J_g(b)J_f(a).$$

Отсюда

$$\frac{\partial(g\circ f)}{\partial x_j}(a)=\sum_{i=1}^{m}\frac{\partial g}{\partial y_i}(b)\frac{\partial f_i}{\partial x_j}(a),\qquad j=1,\dots,n.$$

Следствие 2. Если функции $f, g : U \to \mathbb{R}$ дифференцируемы в точке a, то функции fg и $\dfrac{f}{g}$, при $g \neq 0$ на U, также дифференцируемы в точке a, причём

$$d(fg)_a = g(a)\,df_a + f(a)\,dg_a,$$

и

$$d\left(\frac{f}{g}\right)_a = \frac{g(a)\,df_a - f(a)\,dg_a}{g^2(a)}.$$

Теорема Лагранжа. Пусть функция $f : [x, y] \to \mathbb{R}$ непрерывна на отрезке $[x, y]$ и дифференцируема на интервале (x, y), где $x < y$. Тогда существует точка $\xi \in (x, y)$ такая, что

$$f(y) - f(x) = f'(\xi)(y - x).$$

Теорема (критерий Липшица). Пусть $U \subseteq \mathbb{R}^n$ — открытое выпуклое множество, а отображение $f : U \to \mathbb{R}^m$ дифференцируемо на U. Тогда для $L > 0$

$$f \text{ является } L\text{-липшицевым} \iff \|df_x\|_2 \le L \quad \text{для всех } x \in U.$$

□ Пусть сначала

$$\|df_x\|_2 \le L \qquad \text{для всех } x \in U.$$

Возьмём произвольные $x, y \in U$. Так как множество U выпукло,

$$x + t(y - x) \in U, \qquad t \in [0, 1].$$

Если $f(x) = f(y)$, то

$$\|f(y) - f(x)\|_2 = 0 \le L\|y - x\|_2.$$

Пусть далее $f(x) \neq f(y)$ и положим

$$u = \frac{f(y) - f(x)}{\|f(y) - f(x)\|_2}.$$

Рассмотрим функцию

$$\varphi(t) = \left\langle f\big(x + t(y - x)\big), u \right\rangle, \qquad t \in [0, 1].$$

По теореме Лагранжа существует $\xi \in (0, 1)$ такое, что

$$\varphi(1) - \varphi(0) = \varphi'(\xi).$$

Имеем

$$\begin{aligned} \varphi(1) - \varphi(0) &= \langle f(y) - f(x), u \rangle \\ &= \left\langle f(y) - f(x), \frac{f(y) - f(x)}{\|f(y) - f(x)\|_2} \right\rangle \\ &= \|f(y) - f(x)\|_2. \end{aligned}$$

По правилу дифференцирования композиции

$$\varphi'(t) = \left\langle df_{x+t(y-x)}(y - x), u \right\rangle.$$

Следовательно, по неравенству Коши–Буняковского–Шварца и определению индуцированной нормы

$$|\varphi'(t)| \leq \|df_{x+t(y-x)}(y - x)\|_2 \|u\|_2 \leq \|df_{x+t(y-x)}\|_2 \|y - x\|_2 \leq L\|y - x\|_2.$$

Поэтому

$$\|f(y) - f(x)\|_2 = |\varphi'(\xi)| \leq L\|y - x\|_2.$$

Так как точки $x, y \in U$ были выбраны произвольно, отображение f является L-липшицевым.

Обратно, пусть отображение f является L-липшицевым:

$$\|f(x) - f(y)\|_2 \leq L\|x - y\|_2$$

для любых $x, y \in U$.

Зафиксируем произвольную точку $a \in U$ и вектор $v \in \mathbb{R}^n$. Так как множество U открыто, для всех достаточно малых t точка $a + tv$ принадлежит U.

По липшицевости

$$\|f(a + tv) - f(a)\|_2 \leq L\|tv\|_2 = L|t|\|v\|_2.$$

При $t \neq 0$ получаем

$$\left\| \frac{f(a + tv) - f(a)}{t} \right\|_2 \leq L\|v\|_2.$$

По теореме о производной по направлению для дифференцируемого отображения

$$\frac{f(a + tv) - f(a)}{t} \to df_a(v) \qquad \text{при} \qquad t \to 0.$$

Следовательно,

$$\|df_a(v)\|_2 \leq L\|v\|_2.$$

По определению индуцированной нормы

$$\|df_a\|_2 \leq L.$$

Так как точка $a \in U$ была выбрана произвольно,

$$\|df_x\|_2 \leq L \qquad \text{для всех } x \in U.$$

■

5.4 Производные высших порядков

Пусть $U \subseteq \mathbb{R}^n$ — открытое множество, $f : U \to \mathbb{R}$ и $a \in U$.

Определение. Пусть функция f имеет в некоторой окрестности точки a частную производную порядка $k-1$

$$\frac{\partial^{k-1} f}{\partial x_{i_{k-1}} \cdots \partial x_{i_1}}$$

и эта функция имеет в точке a частную производную по переменной x_{i_k}. Тогда величина

$$\frac{\partial^k f}{\partial x_{i_k} \cdots \partial x_{i_1}}(a) = \frac{\partial}{\partial x_{i_k}} \left(\frac{\partial^{k-1} f}{\partial x_{i_{k-1}} \cdots \partial x_{i_1}}(x) \right) \Bigg|_{x=a}$$

называется **частной производной порядка** k функции f в точке a.

Замечание. Значение смешанной частной производной может зависеть от порядка дифференцирования.

Рассмотрим функцию

$$f(x,y) = \begin{cases} xy \dfrac{x^2 - y^2}{x^2 + y^2}, & x^2 + y^2 \neq 0, \\ 0, & x = y = 0. \end{cases}$$

Для неё

$$\frac{\partial^2 f}{\partial x \, \partial y}(0,0) = 1, \qquad \frac{\partial^2 f}{\partial y \, \partial x}(0,0) = -1.$$

Следовательно,

$$\frac{\partial^2 f}{\partial x \, \partial y}(0,0) \neq \frac{\partial^2 f}{\partial y \, \partial x}(0,0).$$

Теорема Шварца. Пусть $n = 2$ и смешанные частные производные

$$\frac{\partial^2 f}{\partial x \, \partial y}, \qquad \frac{\partial^2 f}{\partial y \, \partial x}$$

определены в некоторой окрестности точки (x_0, y_0) и непрерывны в этой точке. Тогда

$$\frac{\partial^2 f}{\partial x \, \partial y}(x_0, y_0) = \frac{\partial^2 f}{\partial y \, \partial x}(x_0, y_0).$$

Определение. Пусть $p \in \mathbb{N}$. Функция f принадлежит классу $C^p(U)$, если она имеет на U все частные производные порядка p и все они непрерывны на U.

Замечание. Для $p \geq 2$ справедливо включение

$$C^p(U) \subset C^{p-1}(U).$$

Класс бесконечно дифференцируемых функций определяется равенством

$$C^\infty(U) = \bigcap_{p=1}^{\infty} C^p(U).$$

Следствие 1. Если $f \in C^p(U)$, то все смешанные частные производные функции f порядка до p включительно не зависят от порядка дифференцирования.

Следствие 2. Сумма, произведение, частное, если оно определено, и композиция функций класса C^p являются функциями класса C^p.

Определение. Дифференциалом второго порядка функции f в точке a называется выражение

$$d^2 f_a(h,h) = \sum_{i=1}^{n} \sum_{j=1}^{n} \frac{\partial^2 f}{\partial x_i \partial x_j}(a) h_i h_j.$$

Определение. Матрицей Гессе, или гессианом, функции f в точке a называется матрица её частных производных второго порядка

$$H_f(a) = \begin{pmatrix} \dfrac{\partial^2 f}{\partial x_1^2}(a) & \cdots & \dfrac{\partial^2 f}{\partial x_n \partial x_1}(a) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f}{\partial x_1 \partial x_n}(a) & \cdots & \dfrac{\partial^2 f}{\partial x_n^2}(a) \end{pmatrix}.$$

При этом

$$d^2 f_a(h,h) = h^T H_f(a) h.$$

Пример. Для функции

$$f(x,y) = x^2 + xy + y^2$$

имеем

$$\frac{\partial^2 f}{\partial x^2} = 2, \qquad \frac{\partial^2 f}{\partial x \partial y} = 1, \qquad \frac{\partial^2 f}{\partial y \partial x} = 1, \qquad \frac{\partial^2 f}{\partial y^2} = 2.$$

Поэтому

$$H_f(x, y) = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Замечание. Если $f \in C^2(U)$, то по теореме Шварца смешанные частные производные второго порядка совпадают, поэтому матрица Гессе симметрична:

$$H_f(a)^T = H_f(a).$$

Утверждение. Если $f \in C^2(U)$, то в окрестности точки a справедлива формула Тейлора второго порядка

$$f(a + h) = f(a) + df_a(h) + \frac{1}{2} d^2 f_a(h, h) + o(\|h\|_2^2), \qquad h \to 0.$$

Эквивалентно,

$$f(a + h) = f(a) + \langle \nabla f(a), h \rangle + \frac{1}{2} h^T H_f(a) h + o(\|h\|_2^2), \qquad h \to 0.$$

5.5 Спектральная структура матрицы Гессе

Определение. Квадратная матрица $A \in \mathbb{R}^{n \times n}$ называется **положительно определённой**, если

$$x^T A x > 0$$

для любого $x \in \mathbb{R}^n$, $x \neq 0$.

Матрица A называется **неотрицательно определённой**, если

$$x^T A x \geq 0$$

для любого $x \in \mathbb{R}^n$.

Матрица A называется **неположительно определённой**, если

$$x^T A x \leq 0$$

для любого $x \in \mathbb{R}^n$.

Матрица A называется **отрицательно определённой**, если

$$x^T A x < 0$$

для любого $x \in \mathbb{R}^n$, $x \neq 0$.

Теорема (спектральный критерий определённости). Пусть $A \in \mathbb{R}^{n \times n}$ и $A = A^T$. Тогда:

$$A \text{ положительно определена} \iff \lambda_i > 0 \quad \text{для всех } i;$$

$$A \text{ неотрицательно определена} \iff \lambda_i \geq 0 \quad \text{для всех } i;$$

$$A \text{ неположительно определена} \iff \lambda_i \leq 0 \quad \text{для всех } i;$$

$$A \text{ отрицательно определена} \iff \lambda_i < 0 \quad \text{для всех } i,$$

где $\lambda_1, \ldots, \lambda_n$ — собственные значения матрицы A.

□ Рассмотрим случай положительной определённости. Так как матрица A симметрична, по спектральной теореме

$$A = Q \Lambda Q^T,$$

Для произвольного $x \in \mathbb{R}^n$ положим $y = Q^T x$. Тогда

$$x^T A x = x^T Q \Lambda Q^T x = y^T \Lambda y = \sum_{i=1}^{n} \lambda_i y_i^2.$$

Пусть сначала $\lambda_i > 0$ для всех i. Если $x \neq 0$, то из ортогональности Q следует, что $y \neq 0$. Поэтому

$$\sum_{i=1}^{n} \lambda_i y_i^2 > 0,$$

то есть

$$x^T A x > 0.$$

Следовательно, матрица A положительно определена.

Обратно, пусть матрица A положительно определена. Для собственного вектора $q_i \neq 0$, соответствующего собственному значению λ_i, имеем

$$Aq_i = \lambda_i q_i.$$

Тогда

$$q_i^T A q_i = \lambda_i \|q_i\|_2^2.$$

По положительной определённости

$$q_i^T A q_i > 0,$$

а поскольку $\|q_i\|_2^2 > 0$, получаем $\lambda_i > 0$.

Остальные случаи доказываются аналогично.

■

Определение. Пусть множество U выпукло. Функция $f : U \to \mathbb{R}$ называется **выпуклой**, если для любых $x, y \in U$ и $t \in [0, 1]$ выполняется

$$f\big((1-t)x + ty\big) \leq (1-t)f(x) + tf(y).$$

Функция f называется **вогнутой**, если для любых $x, y \in U$ и $t \in [0, 1]$ выполняется

$$f\big((1-t)x + ty\big) \geq (1-t)f(x) + tf(y).$$

Теорема (критерий выпуклости). Пусть U — открытое выпуклое множество и $f \in C^2(U)$. Тогда функция f выпукла на U тогда и только тогда, когда

$$h^T H_f(x) h \geq 0$$

для всех $x \in U$ и $h \in \mathbb{R}^n$.

Аналогично, функция f вогнута на U тогда и только тогда, когда

$$h^T H_f(x) h \leq 0$$

для всех $x \in U$ и $h \in \mathbb{R}^n$.

Определение. Пусть множество U выпукло. Функция $f : U \to \mathbb{R}$ называется **строго выпуклой**, если для любых $x, y \in U$, $x \neq y$, и $t \in (0, 1)$

выполняется

$$f\big((1-t)x+ty\big) < (1-t)f(x)+tf(y).$$

Функция f называется **строго вогнутой**, если для любых $x, y \in U$, $x \neq y$, и $t \in (0,1)$ выполняется

$$f\big((1-t)x+ty\big) > (1-t)f(x)+tf(y).$$

Теорема (критерий строгой выпуклости). Пусть U — открытое выпуклое множество и $f \in C^2(U)$. Тогда

$$f \text{ строго выпукла на } U \quad \text{и} \quad \forall\, x \in U : \operatorname{rank} H_f(x) = n$$

тогда и только тогда, когда

$$\forall\, x \in U \quad \forall\, h \in \mathbb{R}^n \setminus \{0\} : \qquad h^T H_f(x) h > 0.$$

Аналогично,

$$f \text{ строго вогнута на } U \quad \text{и} \quad \forall\, x \in U : \operatorname{rank} H_f(x) = n$$

тогда и только тогда, когда

$$\forall\, x \in U \quad \forall\, h \in \mathbb{R}^n \setminus \{0\} : \qquad h^T H_f(x) h < 0.$$

Поскольку для функции $f \in C^2(U)$ матрица Гессе симметрична, для неё справедливо спектральное разложение

$$H_f(x) = Q \Lambda Q^T.$$

Пример 1. Рассмотрим функцию

$$f(x,y) = x^2 + y^2.$$

Её матрица Гессе имеет вид

$$H_f(x,y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}.$$

В данном случае спектральное разложение имеет вид

$$H_f(x, y) = I \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} I^T.$$

Следовательно,

$$\lambda_1 = \lambda_2 = 2.$$

Все собственные значения положительны, поэтому матрица Гессе положительно определена во всех точках. Следовательно, функция f строго выпукла.

Пример 2. Рассмотрим функцию

$$f(x, y) = x^2.$$

Её матрица Гессе имеет вид

$$H_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}.$$

Спектральное разложение имеет вид

$$H_f(x, y) = I \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} I^T.$$

Следовательно,

$$\lambda_1 = 2, \qquad \lambda_2 = 0.$$

Все собственные значения неотрицательны, поэтому матрица Гессе неотрицательно определена во всех точках. Следовательно, функция f выпукла.

Пример 3. Рассмотрим функцию

$$f(x, y) = -x^2 - y^2.$$

Её матрица Гессе имеет вид

$$H_f(x, y) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Спектральное разложение имеет вид

$$H_f(x,y) = I \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix} I^T.$$

Следовательно,

$$\lambda_1 = \lambda_2 = -2.$$

Все собственные значения отрицательны, поэтому матрица Гессе отрицательно определена во всех точках. Следовательно, функция f строго вогнута.

Далее будем рассматривать строго выпуклые функции класса C^2, у которых матрица Гессе в каждой точке имеет полный ранг.

Пользуясь утверждениями, доказанными в главе линейной алгебры, определим коэффициент обусловленности матрицы Гессе в точке x как

$$\kappa_2\big(H_f(x)\big) = \frac{\lambda_{\max}\big(H_f(x)\big)}{\lambda_{\min}\big(H_f(x)\big)}.$$

Для рассматриваемого класса функций матрица Гессе положительно определена, поэтому все её собственные значения положительны.

Поскольку матрица Гессе состоит из частных производных второго порядка и описывает локальную кривизну функции, её собственные значения естественно интерпретировать как величины локальной кривизны в соответствующих собственных направлениях.

Следовательно, коэффициент обусловленности матрицы Гессе характеризует отношение максимальной и минимальной локальных кривизн функции.

Пример 1. Рассмотрим функцию

$$f(x,y) = x^2 + y^2.$$

Её матрица Гессе имеет вид

$$H_f(x,y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix},$$

поэтому

$$\lambda_{\max} = \lambda_{\min} = 2.$$

Следовательно,

$$\kappa_2(H_f) = \frac{2}{2} = 1.$$

Таким образом, кривизна функции одинакова во всех собственных направлениях, а функция является идеально обусловленной.

Пример 2. Рассмотрим функцию

$$f(x, y) = x^2 + \varepsilon y^2, \qquad 0 < \varepsilon \ll 1.$$

Её матрица Гессе имеет вид

$$H_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 2\varepsilon \end{pmatrix}.$$

Следовательно,

$$\lambda_{\max} = 2, \qquad \lambda_{\min} = 2\varepsilon,$$

и

$$\kappa_2(H_f) = \frac{2}{2\varepsilon} = \frac{1}{\varepsilon}.$$

При малом ε коэффициент обусловленности велик: кривизна функции в направлении оси x значительно больше кривизны в направлении оси y. При $\varepsilon \to 0$ различие между этими кривизнами возрастает, а коэффициент обусловленности стремится к бесконечности.

6 МАТРИЧНО-ВЕКТОРНОЕ ДИФФЕРЕНЦИРОВАНИЕ

6.1 Пространство матриц

Рассмотрим линейное пространство $\mathbb{R}^{m\times n}$ вещественных матриц размера $m \times n$.

Определение. Скалярным произведением на пространстве $\mathbb{R}^{m\times n}$ называется отображение

$$\langle \cdot, \cdot \rangle : \mathbb{R}^{m\times n} \times \mathbb{R}^{m\times n} \to \mathbb{R},$$

такое, что для $\forall\, A, B, C \in \mathbb{R}^{m\times n}$ и $\forall\, \alpha, \beta \in \mathbb{R}$ выполняются следующие аксиомы:

– Линейность:

$$\langle \alpha A + \beta B, C \rangle = \alpha \langle A, C \rangle + \beta \langle B, C \rangle.$$

– Симметричность:

$$\langle A, B \rangle = \langle B, A \rangle.$$

– Неотрицательность:

$$\langle A, A \rangle \geq 0, \qquad \langle A, A \rangle = 0 \quad \Longleftrightarrow \quad A = 0.$$

Линейное пространство $\mathbb{R}^{m\times n}$ с заданным скалярным произведением является евклидовым пространством.

Поскольку $\mathbb{R}^{m\times n}$ является линейным пространством, все введённые ранее понятия линейного пространства непосредственно переносятся на пространство матриц.

Определение. Стандартным базисом пространства $\mathbb{R}^{m\times n}$ будем называть систему матриц

$$E_{ij}, \qquad i = 1, \ldots, m, \qquad j = 1, \ldots, n,$$

где матрица E_{ij} имеет единицу в позиции (i, j) и нули во всех остальных позициях:

$$(E_{ij})_{kl} = \delta_{ik}\delta_{jl}.$$

Любая матрица $A = (a_{ij}) \in \mathbb{R}^{m\times n}$ единственным образом представляется в виде

$$A = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}E_{ij}.$$

Далее будем считать, что работаем в стандартном базисе пространства $\mathbb{R}^{m\times n}$.

Определение. Скалярным произведением Фробениуса на пространстве $\mathbb{R}^{m\times n}$ называется скалярное произведение, которое в стандартном базисе имеет вид

$$\langle A, B\rangle_F = \operatorname{tr}(A^T B) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}b_{ij}.$$

Норма, индуцированная скалярным произведением Фробениуса, совпадает с введённой ранее нормой Фробениуса:

$$\|A\|_F = \sqrt{\langle A, A\rangle_F} = \sqrt{\operatorname{tr}(A^T A)} = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}^2}.$$

Определение. Операцией векторизации, или вытягивания матрицы в вектор, называется отображение

$$\operatorname{vec} : \mathbb{R}^{m\times n} \to \mathbb{R}^{mn},$$

которое последовательно записывает столбцы матрицы друг под другом:

$$\operatorname{vec}(A) = \begin{pmatrix} a_{11} \\ \vdots \\ a_{m1} \\ a_{12} \\ \vdots \\ a_{m2} \\ \vdots \\ a_{1n} \\ \vdots \\ a_{mn} \end{pmatrix}.$$

Иными словами, если $A = (a_{ij})$, то элемент a_{ij} переходит в координату с номером

$$i + (j-1)m.$$

Утверждение. Операция векторизации задаёт линейный изометрический изоморфизм пространств $\mathbb{R}^{m\times n}$ и $\mathbb{R}^{mn}$.

Для любых $A, B \in \mathbb{R}^{m\times n}$ и $\alpha, \beta \in \mathbb{R}$ выполняется

$$\operatorname{vec}(\alpha A + \beta B) = \alpha \operatorname{vec}(A) + \beta \operatorname{vec}(B),$$

а также

$$\langle A, B\rangle_F = \operatorname{vec}(A)^T \operatorname{vec}(B).$$

Следовательно,

$$\|A\|_F = \|\operatorname{vec}(A)\|_2.$$

Таким образом, евклидовы пространства $\mathbb{R}^{m\times n}$ и $\mathbb{R}^{mn}$ изометрически изоморфны:

$$\mathbb{R}^{m\times n} \cong \mathbb{R}^{mn}.$$

Рассмотрим теперь открытое множество $U \subseteq \mathbb{R}^{m\times n}$ и функцию $f : U \to \mathbb{R}$. Через векторизацию ей соответствует функция

$$\widetilde{f} : \operatorname{vec}(U) \to \mathbb{R}, \qquad \widetilde{f} = f \circ \operatorname{vec}^{-1}.$$

Поскольку vec является линейным изометрическим изоморфизмом, ранее введённые понятия дифференцируемости и дифференциала естественно переносятся на функции матричного аргумента.

Пусть функция f дифференцируема в точке $X \in U$. Тогда её дифференциал

$$df_X : \mathbb{R}^{m\times n} \to \mathbb{R}$$

является линейным функционалом на евклидовом пространстве матриц. Следовательно, существует единственная матрица $\nabla_X f(X) \in \mathbb{R}^{m\times n}$ такая, что для любого $H \in \mathbb{R}^{m\times n}$

$$df_X(H) = \langle \nabla_X f(X), H\rangle_F.$$

Определение. Матрица $\nabla_X f(X)$ называется **градиентом функции f по матрице X**.

Пусть $H = (h_{ij}) \in \mathbb{R}^{m\times n}$. Так как

$$H = \sum_{i=1}^{m}\sum_{j=1}^{n} h_{ij}E_{ij},$$

по линейности дифференциала имеем

$$df_X(H) = \sum_{i=1}^{m}\sum_{j=1}^{n} h_{ij}df_X(E_{ij}) = \sum_{i=1}^{m}\sum_{j=1}^{n} \frac{\partial f}{\partial x_{ij}}(X)h_{ij}.$$

Следовательно, градиент функции f по матрице X имеет вид

$$\nabla_X f(X) = \begin{pmatrix} \dfrac{\partial f}{\partial x_{11}}(X) & \cdots & \dfrac{\partial f}{\partial x_{1n}}(X) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial f}{\partial x_{m1}}(X) & \cdots & \dfrac{\partial f}{\partial x_{mn}}(X) \end{pmatrix}.$$

При этом из изометричности векторизации следует

$$\operatorname{vec}\big(\nabla_X f(X)\big) = \nabla \widetilde{f}\big(\operatorname{vec}(X)\big).$$

Для дальнейшего вычисления дифференциалов будем использовать сокращённую запись. Для векторного аргумента $x \in \mathbb{R}^n$ положим

$$dx = \begin{pmatrix} dx_1 \\ \vdots \\ dx_n \end{pmatrix},$$

а для матричного аргумента $X = (x_{ij}) \in \mathbb{R}^{m\times n}$ положим

$$dX = \begin{pmatrix} dx_{11} & \cdots & dx_{1n} \\ \vdots & \ddots & \vdots \\ dx_{m1} & \cdots & dx_{mn} \end{pmatrix}.$$

Тогда для функции матричного аргумента со скалярным выходом дифференциал записывается в виде

$$df = \operatorname{tr}\left((\nabla_X f)^T dX\right).$$

Для векторно-матричных функций выполняются следующие свойства дифференциала:

– Для произведения

$$d(AB) = (dA)B + A(dB),$$

причём в общем случае

$$(dA)B \neq B(dA).$$

– Для любых $\alpha, \beta \in \mathbb{R}$

$$d(\alpha A + \beta B) = \alpha\, dA + \beta\, dB.$$

– Для транспонированной матрицы

$$d(A^T) = (dA)^T.$$

– Если C — матрица из констант, то

$$dC = 0.$$

6.2 Основные типы дифференцирования

Рассмотрим основные формы дифференциала в зависимости от типа аргумента и значения отображения. В случаях, когда координатное представление производной имеет многомерную форму, будем использовать операцию vec, сводя его к обычной матричной форме:

	скаляр	вектор	матрица
скаляр	$df = f'(x)\,dx$	$dF = J_F\,dx$	$\operatorname{vec}(dF) = J_F\,dx$
вектор	$df = \nabla f^T dx$	$dF = J_F\,dx$	$\operatorname{vec}(dF) = J_F\,dx$
матрица	$df = \operatorname{tr}\left((\nabla_X f)^T dX\right)$	$dF = J_F \operatorname{vec}(dX)$	$\operatorname{vec}(dF) = J_F \operatorname{vec}(dX)$

6.2.1 $\mathbb{R} \to \mathbb{R}$

Для функции $f : \mathbb{R} \to \mathbb{R}$ дифференциал имеет вид

$$df = f'(x)\,dx.$$

Пример 1.1. Пусть $f(x) = x^2 + 3x$. Найдите производную функции f.
Решение. Получаем

$$f'(x) = 2x + 3.$$

6.2.2 $\mathbb{R} \to \mathbb{R}^m$

Пусть

$$F : \mathbb{R} \to \mathbb{R}^m, \qquad F(x) = \begin{pmatrix} F_1(x) \\ \vdots \\ F_m(x) \end{pmatrix}.$$

Тогда дифференциал каждой координатной функции имеет вид $dF_i = F_i'(x)\,dx$, поэтому

$$dF = \begin{pmatrix} F_1'(x) \\ \vdots \\ F_m'(x) \end{pmatrix} dx.$$

Матрица Якоби отображения F имеет один столбец:

$$J_F(x) = \begin{pmatrix} F_1'(x) \\ \vdots \\ F_m'(x) \end{pmatrix}.$$

Следовательно,

$$dF = J_F(x)\,dx.$$

Пример 1.2. Пусть

$$F : \mathbb{R} \to \mathbb{R}^2, \qquad F(x) = \begin{pmatrix} x^2 \\ \sin x \end{pmatrix}.$$

Найдите матрицу Якоби отображения F.

Решение. Дифференцируя координатные функции, получаем

$$dF = \begin{pmatrix} 2x \\ \cos x \end{pmatrix} dx.$$

Следовательно,

$$J_F(x) = \begin{pmatrix} 2x \\ \cos x \end{pmatrix}.$$

6.2.3 $\mathbb{R} \to \mathbb{R}^{m\times n}$

Пусть

$$F : \mathbb{R} \to \mathbb{R}^{m\times n}, \qquad F(x) = \big(F_{ij}(x)\big).$$

Дифференцируя каждый элемент матрицы, получаем

$$dF = \begin{pmatrix} F'_{11}(x) & \cdots & F'_{1n}(x) \\ \vdots & \ddots & \vdots \\ F'_{m1}(x) & \cdots & F'_{mn}(x) \end{pmatrix} dx.$$

После векторизации имеем

$$\operatorname{vec}(dF) = \operatorname{vec}\begin{pmatrix} F'_{11}(x) & \cdots & F'_{1n}(x) \\ \vdots & \ddots & \vdots \\ F'_{m1}(x) & \cdots & F'_{mn}(x) \end{pmatrix} dx.$$

Полученный вектор является матрицей Якоби отображения в координатах, полученных после векторизации матричного выхода. Следовательно,

$$\operatorname{vec}(dF) = J_F(x)\, dx.$$

Пример 1.3. Пусть

$$F : \mathbb{R} \to \mathbb{R}^{2\times 2}, \qquad F(x) = \begin{pmatrix} x & x^2 \\ \sin x & e^x \end{pmatrix}.$$

Найдите матрицу Якоби отображения F.

Решение. Дифференцируя элементы матрицы, получаем

$$dF = \begin{pmatrix} 1 & 2x \\ \cos x & e^x \end{pmatrix} dx.$$

После векторизации

$$\operatorname{vec}(dF) = \begin{pmatrix} 1 \\ \cos x \\ 2x \\ e^x \end{pmatrix} dx.$$

Следовательно,

$$J_F(x) = \begin{pmatrix} 1 \\ \cos x \\ 2x \\ e^x \end{pmatrix}.$$

6.2.4 $\mathbb{R}^n \to \mathbb{R}$

Для функции $f : \mathbb{R}^n \to \mathbb{R}$ дифференциал имеет вид

$$df = \nabla f(x)^T dx.$$

Пример 2.1. Пусть $a, x \in \mathbb{R}^n$ и

$$f(x) = a^T x.$$

Найдите $\nabla_x f(x)$.

Решение. Поскольку a не зависит от x, получаем

$$df = d(a^T x) = a^T dx.$$

Следовательно,

$$\nabla_x f(x) = a.$$

Пример 2.2. Пусть $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times n}$ и

$$f(x) = x^T Ax.$$

Найдите $\nabla_x f(x)$.

Решение. Получаем

$$df = d(x^T Ax) = d(x^T)Ax + x^T Adx.$$

Первое слагаемое является скаляром, поэтому

$$d(x^T)Ax = dx^T Ax = x^T A^T dx.$$

Следовательно,

$$df = x^T(A^T + A)dx.$$

Отсюда

$$\nabla_x f(x) = (A + A^T)x.$$

Пример 2.3. Пусть $x \in \mathbb{R}^n$ и

$$f(x) = \|x\|_2^2.$$

Найдите $\nabla_x f(x)$.

Решение. Поскольку

$$f(x) = x^T x,$$

получаем

$$df = d(x^T x) = d(x^T)x + x^T dx.$$

Первое слагаемое является скаляром, поэтому

$$d(x^T)x = dx^T x = x^T dx.$$

Следовательно,

$$df = 2x^T dx.$$

Отсюда

$$\nabla_x f(x) = 2x.$$

6.2.5 $\mathbb{R}^n \to \mathbb{R}^m$

Для отображения

$$F : \mathbb{R}^n \to \mathbb{R}^m, \qquad F(x) = \begin{pmatrix} F_1(x) \\ \vdots \\ F_m(x) \end{pmatrix},$$

дифференциал имеет вид

$$dF = J_F(x)\, dx,$$

где

$$J_F(x) = \begin{pmatrix} \dfrac{\partial F_1}{\partial x_1}(x) & \cdots & \dfrac{\partial F_1}{\partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial F_m}{\partial x_1}(x) & \cdots & \dfrac{\partial F_m}{\partial x_n}(x) \end{pmatrix}$$

— матрица Якоби отображения F.

Пример 2.4. Пусть $x \in \mathbb{R}^n$ и

$$F(x) = xx^T x.$$

Найдите $J_F(x)$.

Решение. Получаем

$$dF = d(xx^T x) = (dx)x^T x + x\, d(x^T)x + xx^T dx.$$

Поскольку $x^T x$ и $dx^T x$ являются скалярами,

$$(dx)x^T x = (x^T x) I_n\, dx,$$

а также

$$x\, d(x^T)x = x\, dx^T x = xx^T dx.$$

Следовательно,

$$dF = \left((x^T x) I_n + 2xx^T \right) dx.$$

Отсюда

$$J_F(x) = (x^T x) I_n + 2xx^T.$$

Определение. Для $u, v \in \mathbb{R}^n$ их произведением Адамара называется покоординатное произведение

$$u \odot v = \begin{pmatrix} u_1 v_1 \\ \vdots \\ u_n v_n \end{pmatrix}.$$

Пример 2.5. Пусть $\varphi : \mathbb{R} \to \mathbb{R}$ и отображение

$$F : \mathbb{R}^n \to \mathbb{R}^n$$

задано покоординатно:

$$F(x) = \begin{pmatrix} \varphi(x_1) \\ \vdots \\ \varphi(x_n) \end{pmatrix}.$$

Найдите $J_F(x)$.

Решение. Каждая координата $F_i(x) = \varphi(x_i)$ зависит только от переменной x_i. Поэтому

$$\frac{\partial F_i}{\partial x_j}(x) = \begin{cases} \varphi'(x_i), & i = j, \\ 0, & i \neq j. \end{cases}$$

Следовательно,

$$J_F(x) = \operatorname{diag}\left(\varphi'(x_1), \ldots, \varphi'(x_n)\right).$$

Если положить

$$\varphi'(x) = \begin{pmatrix} \varphi'(x_1) \\ \vdots \\ \varphi'(x_n) \end{pmatrix},$$

то дифференциал отображения F можно записать в эквивалентном виде

$$dF = J_F(x)\, dx = \varphi'(x) \odot dx.$$

Пример 2.6. Пусть $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times n}$ и

$$f(x) = x^T A x.$$

Ранее было получено

$$\nabla_x f(x) = (A + A^T)x.$$

Найдите вторую производную функции f по x.

Решение. Рассмотрим отображение

$$F(x) = \nabla_x f(x) = (A + A^T)x.$$

Поскольку матрица A не зависит от x, получаем

$$dF = (A + A^T)dx.$$

Следовательно,

$$J_F(x) = A + A^T.$$

Поскольку $F = \nabla_x f$, матрица Якоби отображения F является матрицей Гессе функции f:

$$H_f(x) = A + A^T.$$

6.2.6 $\mathbb{R}^n \to \mathbb{R}^{p \times q}$

Рассмотрим отображение

$$F : \mathbb{R}^n \to \mathbb{R}^{p \times q}, \qquad F(x) = \big(F_{ij}(x)\big).$$

В координатах производная такого отображения задаётся величинами

$$\frac{\partial F_{ij}}{\partial x_k}(x), \qquad i = 1, \ldots, p, \qquad j = 1, \ldots, q, \qquad k = 1, \ldots, n.$$

Таким образом, её координатное представление является тензором третьего порядка

$$\mathcal{J}_F(x) = \left(\frac{\partial F_{ij}}{\partial x_k}(x)\right) \in \mathbb{R}^{p\times q\times n}.$$

Дифференциал отображения F имеет вид

$$dF = \sum_{k=1}^{n} \frac{\partial F}{\partial x_k}(x)\, dx_k,$$

где

$$\frac{\partial F}{\partial x_k}(x) = \left(\frac{\partial F_{ij}}{\partial x_k}(x)\right) \in \mathbb{R}^{p\times q}.$$

Чтобы представить производную в обычной матричной форме, применим операцию векторизации к выходу отображения. Тогда

$$\operatorname{vec}(dF) = J_F(x)\, dx,$$

где

$$J_F(x) = \left(\operatorname{vec}\left(\frac{\partial F}{\partial x_1}(x)\right) \quad \cdots \quad \operatorname{vec}\left(\frac{\partial F}{\partial x_n}(x)\right)\right) \in \mathbb{R}^{pq\times n}.$$

Таким образом, тензорное координатное представление производной после векторизации выходной матрицы сводится к обычной матрице Якоби.

Пример 2.7. Пусть $x \in \mathbb{R}^n$ и

$$F(x) = \operatorname{diag}(x).$$

Найдите $J_F(x)$.

Решение. Отображение имеет вид

$$F(x) = \begin{pmatrix} x_1 & 0 & \cdots & 0 \\ 0 & x_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & x_n \end{pmatrix}.$$

Для каждой координаты x_k получаем

$$\frac{\partial F}{\partial x_k} = E_{kk},$$

где E_{kk} — матрица стандартного базиса пространства $\mathbb{R}^{n\times n}$.

Следовательно,

$$dF = \sum_{k=1}^{n} E_{kk}\, dx_k = \operatorname{diag}(dx).$$

После векторизации

$$\operatorname{vec}(dF) = \Big(\operatorname{vec}(E_{11}) \;\; \cdots \;\; \operatorname{vec}(E_{nn})\Big)\, dx.$$

Отсюда

$$J_F(x) = \Big(\operatorname{vec}(E_{11}) \;\; \cdots \;\; \operatorname{vec}(E_{nn})\Big).$$

Определение. Пусть

$$A = (a_{ij}) \in \mathbb{R}^{m\times n}, \qquad B \in \mathbb{R}^{r\times s}.$$

Произведением Кронекера матриц A и B называется матрица

$$A \otimes B = \begin{pmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{pmatrix} \in \mathbb{R}^{mr\times ns}.$$

Для матриц подходящих размеров выполняется равенство

$$\operatorname{vec}(ABC) = \Big(C^T \otimes A\Big)\operatorname{vec}(B).$$

Пример 2.8. Пусть $x \in \mathbb{R}^n$ и

$$F(x) = xx^T.$$

Найдите $J_F(x)$.

Решение. Получаем

$$dF = d(xx^T) = (dx)x^T + x(dx)^T.$$

После векторизации первого слагаемого имеем

$$\operatorname{vec}\left((dx)x^T\right) = (x \otimes I_n)\, dx.$$

Для второго слагаемого получаем

$$\operatorname{vec}\left(x(dx)^T\right) = (I_n \otimes x)\, dx.$$

Следовательно,

$$\operatorname{vec}(dF) = (x \otimes I_n + I_n \otimes x)\, dx.$$

Отсюда

$$J_F(x) = x \otimes I_n + I_n \otimes x.$$

6.2.7 Задачи с векторным аргументом

Задача 2.1. Пусть $w \in \mathbb{R}^d$ и

$$f(w) = \|w\|_1 = \sum_{i=1}^{d} |w_i|.$$

Найдите $\nabla_w f(w)$ в точках дифференцируемости функции.

Решение. В векторной форме

$$f(w) = \mathbf{1}^T |w|,$$

где модуль применяется покоординатно.

Пусть

$$h(w) = |w|.$$

При $w_i \neq 0$ для всех $i = 1, \ldots, n$ дифференциал покоординатного отображения имеет вид

$$dh = \operatorname{sign}(w) \odot dw.$$

Тогда

$$df = \mathbf{1}^T dh = \mathbf{1}^T \left(\operatorname{sign}(w) \odot dw\right).$$

Поскольку

$$\mathbf{1}^T(a \odot b) = a^T b,$$

получаем

$$df = \operatorname{sign}(w)^T dw.$$

Следовательно,

$$\nabla_w f(w) = \operatorname{sign}(w).$$

Если $w_i = 0$ хотя бы для одного i, то функция f в этой точке не дифференцируема.

Задача 2.2. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad w \in \mathbb{R}^d, \qquad y \in \mathbb{R}^\ell,$$

и

$$f(w) = \|Xw - y\|_2^2.$$

Найдите $\nabla_w f(w)$.

Решение. Обозначим

$$r = Xw - y.$$

Тогда

$$f(w) = r^T r.$$

Получаем

$$df = d(r^T)r + r^T dr.$$

Поскольку первое слагаемое является скаляром,

$$d(r^T)r = dr^T r = r^T dr.$$

Следовательно,

$$df = 2r^T dr.$$

Теперь

$$r = Xw - y.$$

Поскольку X и y фиксированы,

$$dr = X\,dw.$$

Подставляя,

$$df = 2r^T X\,dw = \left(2X^T r\right)^T dw.$$

Следовательно,

$$\nabla_w f(w) = 2X^T r = 2X^T(Xw - y).$$

Задача 2.3. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad w \in \mathbb{R}^d, \qquad y \in \mathbb{R}^\ell,$$

и

$$f(w) = \sum_{i=1}^{\ell} |(Xw - y)_i|.$$

Найдите $\nabla_w f(w)$ в точках дифференцируемости функции.

Решение. Обозначим

$$r = Xw - y.$$

В векторной форме

$$f(w) = \mathbf{1}^T |r|.$$

Пусть

$$h(r) = |r|.$$

При $r_i \neq 0$ для всех $i = 1, \ldots, \ell$ получаем

$$dh = \operatorname{sign}(r) \odot dr.$$

Тогда

$$df = \mathbf{1}^T dh = \mathbf{1}^T \left(\operatorname{sign}(r) \odot dr\right) = \operatorname{sign}(r)^T dr.$$

Поскольку

$$dr = X\,dw,$$

имеем

$$df = \operatorname{sign}(r)^T X\,dw = \left(X^T \operatorname{sign}(r)\right)^T dw.$$

Следовательно,

$$\nabla_w f(w) = X^T \operatorname{sign}(Xw - y).$$

Если $(Xw - y)_i = 0$ хотя бы для одного i, то функция f в этой точке не дифференцируема.

Задача 2.4. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad w \in \mathbb{R}^d, \qquad y \in \mathbb{R}^\ell,$$

и

$$f(w) = \sum_{i=1}^{\ell} \log\left(\cosh\left((Xw - y)_i\right)\right).$$

Найдите $\nabla_w f(w)$.

Решение. Для функции одной переменной

$$\varphi(t) = \log(\cosh t)$$

получаем

$$\varphi'(t) = \frac{\sinh t}{\cosh t} = \tanh t.$$

Поэтому для покоординатного отображения

$$h(r) = \log(\cosh r)$$

имеем

$$dh = \tanh(r) \odot dr,$$

где функции log, cosh и tanh применяются покоординатно.

Обозначим

$$r = Xw - y.$$

В векторной форме

$$f(w) = \mathbf{1}^T \log(\cosh r).$$

Пусть

$$h(r) = \log(\cosh r).$$

Тогда

$$dh = \tanh(r) \odot dr.$$

Получаем

$$df = \mathbf{1}^T dh = \mathbf{1}^T (\tanh(r) \odot dr) = \tanh(r)^T dr.$$

Поскольку

$$dr = X\, dw,$$

имеем

$$df = \tanh(r)^T X\, dw = \left(X^T \tanh(r)\right)^T dw.$$

Следовательно,

$$\nabla_w f(w) = X^T \tanh(Xw - y).$$

Задача 2.5. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad w \in \mathbb{R}^d, \qquad y \in \{-1, 1\}^\ell,$$

и

$$f(w) = \sum_{i=1}^{\ell} \max\left(0, 1 - y_i (Xw)_i\right).$$

Найдите $\nabla_w f(w)$ в точках дифференцируемости функции.

Решение. В векторной форме

$$f(w) = \mathbf{1}^T \max\left(0, \mathbf{1} - y \odot Xw\right),$$

где максимум применяется покоординатно.

Обозначим

$$s = \mathbf{1} - y \odot Xw.$$

Тогда

$$f(w) = \mathbf{1}^T \max(0, s).$$

Пусть

$$h(s) = \max(0, s).$$

В точках $s_i \neq 0$ дифференциал покоординатного отображения имеет вид

$$dh = \mathbb{I}_{\{s>0\}} \odot ds,$$

где

$$\mathbb{I}_{\{s>0\}} = \begin{pmatrix} \mathbf{1}_{\{s_1>0\}} \\ \vdots \\ \mathbf{1}_{\{s_\ell>0\}} \end{pmatrix}.$$

Поэтому

$$df = \mathbf{1}^T dh = \mathbf{1}^T \left(\mathbb{I}_{\{s>0\}} \odot ds\right) = \mathbb{I}_{\{s>0\}}^T ds.$$

Теперь

$$s = \mathbf{1} - y \odot Xw.$$

Поскольку X и y фиксированы,

$$ds = -y \odot (X\, dw).$$

Подставляя,

$$df = -\mathbb{I}_{\{s>0\}}^T \left(y \odot (X\, dw)\right).$$

Перенося произведение Адамара, получаем

$$df = -\left(y \odot \mathbb{I}_{\{s>0\}}\right)^T X\, dw.$$

Следовательно,

$$df = \left[-X^T \left(y \odot \mathbb{I}_{\{s>0\}}\right)\right]^T dw.$$

Отсюда

$$\nabla_w f(w) = -X^T \left(y \odot \mathbb{I}_{\{s>0\}}\right).$$

Поскольку

$$s = \mathbf{1} - y \odot Xw,$$

окончательно

$$\nabla_w f(w) = -X^T \left(y \odot \mathbb{I}_{\{y \odot Xw < \mathbf{1}\}}\right).$$

Если $y_i (Xw)_i = 1$ хотя бы для одного i, то функция f в этой точке не дифференцируема.

Задача 2.6. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad w \in \mathbb{R}^d, \qquad y \in \{0,1\}^\ell,$$

сигмоидальная функция определяется как

$$\sigma(t) = \frac{1}{1 + e^{-t}},$$

и

$$p = \sigma(Xw),$$

где σ применяется покоординатно. Пусть

$$f(w) = -\sum_{i=1}^{\ell} \left(y_i \log p_i + (1 - y_i) \log(1 - p_i)\right).$$

Найдите $\nabla_w f(w)$.

Решение. В векторной форме

$$f(w) = -\mathbf{1}^T \left(y \odot \log p + (\mathbf{1} - y) \odot \log(\mathbf{1} - p)\right),$$

где логарифм применяется покоординатно.

Дифференцируя по p, получаем

$$df = \left(-\frac{y}{p} + \frac{\mathbf{1} - y}{\mathbf{1} - p}\right)^T dp,$$

где деление выполняется покоординатно.

Обозначим

$$z = Xw.$$

Тогда

$$p = \sigma(z).$$

Поскольку

$$\sigma'(t) = \sigma(t)\left(1 - \sigma(t)\right),$$

для покоординатного отображения получаем

$$dp = p \odot (\mathbf{1} - p) \odot dz.$$

Подставляя,

$$df = \left(-\frac{y}{p} + \frac{\mathbf{1}-y}{\mathbf{1}-p}\right)^T (p \odot (\mathbf{1}-p) \odot dz) .$$

Перенося произведение Адамара, получаем

$$df = \left[\left(-\frac{y}{p} + \frac{\mathbf{1}-y}{\mathbf{1}-p}\right) \odot p \odot (\mathbf{1}-p)\right]^T dz.$$

Выражение в квадратных скобках упрощается:

$$\left(-\frac{y}{p} + \frac{\mathbf{1}-y}{\mathbf{1}-p}\right) \odot p \odot (\mathbf{1}-p) = p - y.$$

Следовательно,

$$df = (p-y)^T dz.$$

Поскольку

$$z = Xw,$$

имеем

$$dz = X\, dw.$$

Подставляя,

$$df = (p-y)^T X\, dw = \left(X^T(p-y)\right)^T dw.$$

Следовательно,

$$\nabla_w f(w) = X^T(p-y).$$

Так как

$$p = \sigma(Xw),$$

окончательно

$$\nabla_w f(w) = X^T\left(\sigma(Xw) - y\right).$$

6.2.8 $\mathbb{R}^{m\times n} \to \mathbb{R}$

Для функции $f : \mathbb{R}^{m\times n} \to \mathbb{R}$ дифференциал имеет вид

$$df = \langle \nabla_X f(X), dX \rangle_F = \operatorname{tr}\left((\nabla_X f(X))^T dX \right).$$

Пример 3.1. Пусть $A \in \mathbb{R}^{n\times n}$ и

$$f(A) = \operatorname{tr}(A).$$

Найдите $\nabla_A f(A)$.

Решение. Получаем

$$df = d\operatorname{tr}(A) = \operatorname{tr}(dA).$$

Поскольку

$$\operatorname{tr}(dA) = \operatorname{tr}\left(I_n^T dA \right),$$

имеем

$$\nabla_A f(A) = I_n.$$

Пример 3.2. Пусть $A, B \in \mathbb{R}^{n\times n}$ и

$$f(A) = \operatorname{tr}(AB),$$

где матрица B фиксирована. Найдите $\nabla_A f(A)$.

Решение. Получаем

$$df = d\operatorname{tr}(AB) = \operatorname{tr}(dA\, B).$$

По циклическому свойству следа

$$df = \operatorname{tr}(B\, dA) = \operatorname{tr}\left((B^T)^T dA \right).$$

Следовательно,

$$\nabla_A f(A) = B^T.$$

Пример 3.3. Пусть

$$x \in \mathbb{R}^n, \qquad A \in \mathbb{R}^{n\times m}, \qquad y \in \mathbb{R}^m,$$

и

$$f(A) = \operatorname{tr}\left(x^T A y\right).$$

Найдите $\nabla_A f(A)$.

Решение. Получаем

$$df = \operatorname{tr}\left(x^T dA\, y\right).$$

По циклическому свойству следа

$$df = \operatorname{tr}\left(yx^T dA\right).$$

Поскольку

$$yx^T = (xy^T)^T,$$

имеем

$$df = \operatorname{tr}\left((xy^T)^T dA\right).$$

Следовательно,

$$\nabla_A f(A) = xy^T.$$

Пример 3.4. Пусть

$$a \in \mathbb{R}^n, \qquad A, X \in \mathbb{R}^{n\times n},$$

и

$$f(X) = a^T XAXa,$$

где a и A фиксированы. Найдите $\nabla_X f(X)$.

Решение. Получаем

$$df = d(a^T XAXa) = a^T (dX)AXa + a^T XA(dX)a.$$

Оба слагаемых являются скалярами, поэтому их можно представить через след:

$$df = \operatorname{tr}\left(a^T (dX)AXa\right) + \operatorname{tr}\left(a^T XA(dX)a\right).$$

Используя циклическое свойство следа, получаем

$$df = \operatorname{tr}\left(AXaa^T dX\right) + \operatorname{tr}\left(aa^T XA dX\right).$$

Следовательно,

$$df = \operatorname{tr}\left(\left(AXaa^T + aa^T XA\right) dX\right).$$

Отсюда

$$\nabla_X f(X) = \left(AXaa^T + aa^T XA\right)^T.$$

Таким образом,

$$\nabla_X f(X) = aa^T X^T A^T + A^T X^T aa^T.$$

Пример 3.5. Пусть $X \in \mathbb{R}^{m\times n}$ и

$$f(X) = \|X\|_F^2.$$

Найдите $\nabla_X f(X)$.

Решение. По определению нормы Фробениуса

$$f(X) = \operatorname{tr}(X^T X).$$

Получаем

$$df = \operatorname{tr}\left(d(X^T)X + X^T dX\right).$$

Поскольку

$$d(X^T) = (dX)^T,$$

имеем

$$\operatorname{tr}\left((dX)^T X\right) = \operatorname{tr}\left(X^T dX\right).$$

Следовательно,

$$df = 2\operatorname{tr}\left(X^T dX\right).$$

Отсюда

$$\nabla_X f(X) = 2X.$$

Пример 3.6. Пусть $A \in \mathbb{R}^{n\times n}$ и

$$f(A) = \det A.$$

Найдите $\nabla_A f(A)$.

Решение. Для элементов матрицы A имеем

$$\frac{\partial \det A}{\partial a_{ij}} = C_{ij},$$

где C_{ij} — алгебраическое дополнение элемента a_{ij}. Следовательно,

$$\nabla_A f(A) = \begin{pmatrix} C_{11} & \cdots & C_{1n} \\ \vdots & \ddots & \vdots \\ C_{n1} & \cdots & C_{nn} \end{pmatrix}.$$

Если матрица A обратима, то

$$A^{-1} = \frac{1}{\det A} \begin{pmatrix} C_{11} & \cdots & C_{n1} \\ \vdots & \ddots & \vdots \\ C_{1n} & \cdots & C_{nn} \end{pmatrix}.$$

Поэтому

$$\nabla_A f(A) = (\det A) A^{-T}.$$

В этом случае дифференциал можно записать в виде

$$df = \operatorname{tr}\left((\det A) A^{-1} dA\right).$$

6.2.9 $\mathbb{R}^{m\times n} \to \mathbb{R}^p$

Для отображения

$$F : \mathbb{R}^{m\times n} \to \mathbb{R}^p$$

дифференциал после векторизации матричного аргумента имеет вид

$$dF = J_F(X) \operatorname{vec}(dX),$$

где

$$J_F(X) \in \mathbb{R}^{p\times mn}.$$

Пример 3.7. Пусть

$$W \in \mathbb{R}^{m\times n}, \qquad x \in \mathbb{R}^n,$$

и

$$F(W) = Wx,$$

где вектор x фиксирован. Найдите $J_F(W)$.

Решение. Получаем

$$dF = d(Wx) = (dW)x.$$

Используя свойство векторизации

$$\operatorname{vec}(ABC) = (C^T \otimes A)\operatorname{vec}(B),$$

имеем

$$(dW)x = \left(x^T \otimes I_m\right)\operatorname{vec}(dW).$$

Следовательно,

$$dF = \left(x^T \otimes I_m\right)\operatorname{vec}(dW),$$

откуда

$$J_F(W) = x^T \otimes I_m.$$

6.2.10 $\mathbb{R}^{m\times n} \to \mathbb{R}^{p\times q}$

Рассмотрим отображение

$$F : \mathbb{R}^{m\times n} \to \mathbb{R}^{p\times q}.$$

В координатах его производная задаётся величинами

$$\frac{\partial F_{ij}}{\partial x_{kl}}(X),$$

то есть имеет четыре индекса.

После векторизации аргумента и значения отображения дифференциал принимает обычную матричную форму

$$\operatorname{vec}(dF) = J_F(X)\operatorname{vec}(dX),$$

где

$$J_F(X) \in \mathbb{R}^{pq\times mn}.$$

Пример 3.8. Пусть $\varphi : \mathbb{R} \to \mathbb{R}$, $X \in \mathbb{R}^{m\times n}$ и отображение

$$F : \mathbb{R}^{m\times n} \to \mathbb{R}^{m\times n}$$

задано покоординатно:

$$F(X) = \begin{pmatrix} \varphi(x_{11}) & \cdots & \varphi(x_{1n}) \\ \vdots & \ddots & \vdots \\ \varphi(x_{m1}) & \cdots & \varphi(x_{mn}) \end{pmatrix}.$$

Найдите $J_F(X)$.

Решение. Каждый элемент выходной матрицы зависит только от соответствующего элемента матрицы X. Поэтому

$$dF = \begin{pmatrix} \varphi'(x_{11})\,dx_{11} & \cdots & \varphi'(x_{1n})\,dx_{1n} \\ \vdots & \ddots & \vdots \\ \varphi'(x_{m1})\,dx_{m1} & \cdots & \varphi'(x_{mn})\,dx_{mn} \end{pmatrix}.$$

Если обозначить

$$\varphi'(X) = \begin{pmatrix} \varphi'(x_{11}) & \cdots & \varphi'(x_{1n}) \\ \vdots & \ddots & \vdots \\ \varphi'(x_{m1}) & \cdots & \varphi'(x_{mn}) \end{pmatrix},$$

то дифференциал можно записать в виде

$$dF = \varphi'(X) \odot dX.$$

После векторизации получаем

$$\operatorname{vec}(dF) = \operatorname{vec}\left(\varphi'(X)\right) \odot \operatorname{vec}(dX).$$

Покоординатное произведение можно представить умножением на диагональную матрицу:

$$\operatorname{vec}(dF) = \operatorname{diag}\left(\operatorname{vec}\left(\varphi'(X)\right)\right)\operatorname{vec}(dX).$$

Следовательно,

$$J_F(X) = \operatorname{diag}\left(\operatorname{vec}\left(\varphi'(X)\right)\right).$$

Пример 3.9. Пусть

$$A \in \mathbb{R}^{m\times n}, \qquad X \in \mathbb{R}^{n\times p}, \qquad B \in \mathbb{R}^{m\times p},$$

и

$$F(X) = A^T(AX - B).$$

Найдите $J_F(X)$.

Решение. Поскольку A и B не зависят от X, получаем

$$dF = A^T d(AX - B) = A^T A\, dX.$$

После векторизации и использования равенства

$$\operatorname{vec}(ABC) = \left(C^T \otimes A\right)\operatorname{vec}(B)$$

имеем

$$\operatorname{vec}(dF) = \left(I_p \otimes A^T A\right)\operatorname{vec}(dX).$$

Следовательно,

$$J_F(X) = I_p \otimes A^T A.$$

Пример 3.10. Пусть $A \in \mathbb{R}^{n\times n}$ — обратимая матрица и

$$F(A) = A^{-1}.$$

Найдите $J_F(A)$.

Решение. Из определения обратной матрицы

$$A^{-1}A = I_n.$$

Дифференцируя обе части равенства, получаем

$$d(A^{-1})A + A^{-1}dA = 0.$$

Умножая справа на A^{-1}, имеем

$$d(A^{-1}) = -A^{-1}(dA)A^{-1}.$$

Следовательно,

$$dF = -A^{-1}(dA)A^{-1}.$$

После векторизации получаем

$$\mathrm{vec}(dF) = -\left(A^{-T} \otimes A^{-1}\right)\mathrm{vec}(dA).$$

Отсюда

$$J_F(A) = -A^{-T} \otimes A^{-1}.$$

6.2.11 Задачи с матричным аргументом

При вычислении градиента скалярной функции, заданной композицией матричных отображений, нет необходимости явно материализовывать тензоры производных всех промежуточных отображений.

Определение. Пусть

$$\mathcal{T} \in \mathbb{R}^{p\times q\times m\times n}.$$

Тензорной свёрткой $\mathcal{T}$ с матрицей $C \in \mathbb{R}^{m\times n}$ называется матрица

$$\mathcal{T}C \in \mathbb{R}^{p\times q},$$

элементы которой определяются как

$$(\mathcal{T}C)_{ij} = \sum_{a=1}^{m}\sum_{b=1}^{n}\mathcal{T}_{ijab}C_{ab}.$$

Аналогично, для $C \in \mathbb{R}^{p\times q}$ тензорной свёрткой матрицы C с тензором $\mathcal{T}$ называется матрица

$$C\mathcal{T} \in \mathbb{R}^{m\times n},$$

элементы которой определяются как

$$(C\mathcal{T})_{ab} = \sum_{i=1}^{p}\sum_{j=1}^{q} C_{ij}\mathcal{T}_{ijab}.$$

Определение. Пусть

$$\mathcal{T} \in \mathbb{R}^{p\times q\times m\times n}.$$

Транспонированным тензором называется тензор

$$\mathcal{T}^T \in \mathbb{R}^{m\times n\times p\times q},$$

полученный перестановкой групп индексов:

$$(\mathcal{T}^T)_{abij} = \mathcal{T}_{ijab}.$$

Пусть задана последовательность

$$X_0 \longmapsto X_1 = F_1(X_0) \longmapsto \cdots \longmapsto X_k = F_k(X_{k-1}),$$

где

$$F_1 : \mathbb{R}^{m_0\times n_0} \to \mathbb{R}^{m_1\times n_1}, \qquad \ldots, \qquad F_k : \mathbb{R}^{m_{k-1}\times n_{k-1}} \to \mathbb{R}^{m_k\times n_k},$$

а итоговая функция имеет скалярное значение:

$$f(X_0) = g(X_k), \qquad g : \mathbb{R}^{m_k\times n_k} \to \mathbb{R}.$$

Производная последнего промежуточного отображения F_k в координатах представляется тензором четвёртого порядка

$$\mathcal{J}_{F_k}(X_{k-1}) \in \mathbb{R}^{m_k\times n_k\times m_{k-1}\times n_{k-1}}.$$

Его действие на дифференциал входной матрицы задаёт дифференциал выходной матрицы:

$$dX_k = \mathcal{J}_{F_k}(X_{k-1})dX_{k-1}.$$

Поскольку функция g имеет скалярное значение, положим

$$G_k = \nabla_{X_k} g(X_k).$$

Тогда

$$df = \langle G_k, dX_k \rangle_F .$$

Подставляя

$$dX_k = \mathcal{J}_{F_k}(X_{k-1})dX_{k-1},$$

получаем

$$df = \left\langle G_k, \mathcal{J}_{F_k}(X_{k-1})dX_{k-1} \right\rangle_F .$$

Перенося действие тензора на градиент, имеем

$$df = \left\langle \mathcal{J}_{F_k}(X_{k-1})^T G_k, dX_{k-1} \right\rangle_F .$$

Следовательно,

$$G_{k-1} = \mathcal{J}_{F_k}(X_{k-1})^T G_k,$$

где

$$G_{k-1} = \nabla_{X_{k-1}} f.$$

На следующем шаге аналогично получаем

$$G_{k-2} = \mathcal{J}_{F_{k-1}}(X_{k-2})^T G_{k-1}.$$

Продолжая этот процесс, приходим к

$$G_0 = \mathcal{J}_{F_1}(X_0)^T G_1,$$

где

$$G_0 = \nabla_{X_0} f.$$

Таким образом, градиент последовательно распространяется в обратном направлении:

$$G_k \longmapsto G_{k-1} \longmapsto G_{k-2} \longmapsto \cdots \longmapsto G_0.$$

В результате

$$G_0 = \mathcal{J}_{F_1}(X_0)^T \mathcal{J}_{F_2}(X_1)^T \cdots \mathcal{J}_{F_k}(X_{k-1})^T G_k.$$

При непосредственном вычислении градиента явно строить тензоры производных промежуточных отображений не требуется. Достаточно последовательно раскрывать локальные дифференциалы и переходить от

$$df = \langle G_k, dX_k \rangle_F$$

к виду

$$df = \langle G_{k-1}, dX_{k-1} \rangle_F ,$$

Задача 3.1. Пусть

$$X \in \mathbb{R}^{\ell \times d}, \qquad W \in \mathbb{R}^{d \times p}, \qquad Y \in \mathbb{R}^{\ell \times p},$$

и

$$f(W) = \|XW - Y\|_F^2.$$

Найдите $\nabla_W f(W)$.

Решение. Обозначим

$$R = XW - Y.$$

Тогда

$$f(W) = \|R\|_F^2 = \operatorname{tr}(R^T R).$$

Получаем

$$df = \operatorname{tr}\left(d(R^T)R + R^T dR\right) = 2\operatorname{tr}\left(R^T dR\right).$$

Поскольку

$$R = XW - Y,$$

имеем

$$dR = X\, dW.$$

Следовательно,

$$df = 2\,\mathrm{tr}\left(R^T X\, dW\right).$$

Используя

$$R^T X = (X^T R)^T,$$

получаем

$$df = \mathrm{tr}\left((2X^T R)^T dW\right).$$

Следовательно,

$$\nabla_W f(W) = 2X^T R = 2X^T(XW - Y).$$

Задача 3.2. Пусть

$$H \in \mathbb{R}^{\ell\times d}, \qquad W_1 \in \mathbb{R}^{d\times h}, \qquad W_2 \in \mathbb{R}^{h\times d},$$

и

$$Z = HW_1, \qquad A = \varphi(Z), \qquad O = AW_2,$$

где скалярная функция $\varphi : \mathbb{R} \to \mathbb{R}$ применяется покоординатно.

Пусть f — скалярная функция от O и известен градиент

$$G = \nabla_O f \in \mathbb{R}^{\ell\times d}.$$

Найдите

$$\nabla_H f, \qquad \nabla_{W_1} f, \qquad \nabla_{W_2} f.$$

Решение. Начинаем с

$$df = \langle G, dO\rangle_F = \mathrm{tr}\left(G^T dO\right).$$

Поскольку

$$O = AW_2,$$

получаем

$$dO = dA\, W_2 + A\, dW_2.$$

Следовательно,

$$df = \mathrm{tr}\left(G^T dA\, W_2\right) + \mathrm{tr}\left(G^T A\, dW_2\right).$$

По циклическому свойству следа

$$df = \operatorname{tr}\left((GW_2^T)^T dA\right) + \operatorname{tr}\left((A^T G)^T dW_2\right).$$

Поэтому

$$G_A = GW_2^T, \quad \nabla_{W_2} f = A^T G.$$

Так как

$$A = \varphi(Z),$$

для покоординатного отображения имеем

$$dA = \varphi'(Z) \odot dZ.$$

Следовательно,

$$\langle G_A, dA\rangle_F = \langle G_A \odot \varphi'(Z), dZ\rangle_F .$$

Обозначим

$$G_Z = G_A \odot \varphi'(Z).$$

Поскольку

$$Z = HW_1,$$

получаем

$$dZ = dH\, W_1 + H\, dW_1.$$

Тогда

$$\langle G_Z, dZ\rangle_F = \operatorname{tr}\left(G_Z^T dH\, W_1\right) + \operatorname{tr}\left(G_Z^T H\, dW_1\right).$$

Следовательно,

$$\nabla_H f = G_Z W_1^T, \quad \nabla_{W_1} f = H^T G_Z.$$

Таким образом,

$$G_A = GW_2^T, \qquad G_Z = G_A \odot \varphi'(Z),$$

и окончательно

$$\nabla_{W_2} f = A^T G, \quad \nabla_{W_1} f = H^T \left(GW_2^T \odot \varphi'(Z)\right), \quad \nabla_H f = \left(GW_2^T \odot \varphi'(Z)\right) W_1^T.$$

Задача 3.3. Пусть

$$H \in \mathbb{R}^{\ell \times d}, \qquad W_g, W_u \in \mathbb{R}^{d \times h}, \qquad W_d \in \mathbb{R}^{h \times d},$$

и

$$Z_g = HW_g, \qquad Z_u = HW_u,$$

$$A = \varphi(Z_g) \odot Z_u, \qquad O = AW_d,$$

где скалярная функция $\varphi : \mathbb{R} \to \mathbb{R}$ применяется покоординатно.

Пусть f — скалярная функция от O и известен градиент

$$G = \nabla_O f \in \mathbb{R}^{\ell \times d}.$$

Найдите

$$\nabla_H f, \qquad \nabla_{W_g} f, \qquad \nabla_{W_u} f, \qquad \nabla_{W_d} f.$$

Решение. Начинаем с

$$df = \langle G, dO \rangle_F.$$

Поскольку

$$O = AW_d,$$

получаем

$$dO = dA\, W_d + A\, dW_d.$$

Следовательно,

$$G_A = GW_d^T, \quad \nabla_{W_d} f = A^T G.$$

Теперь

$$A = \varphi(Z_g) \odot Z_u.$$

По правилу дифференцирования произведения Адамара

$$dA = d\varphi(Z_g) \odot Z_u + \varphi(Z_g) \odot dZ_u.$$

Так как

$$d\varphi(Z_g) = \varphi'(Z_g) \odot dZ_g,$$

имеем

$$dA = \varphi'(Z_g) \odot Z_u \odot dZ_g + \varphi(Z_g) \odot dZ_u.$$

Следовательно,

$$G_{Z_g} = G_A \odot Z_u \odot \varphi'(Z_g),$$

а

$$G_{Z_u} = G_A \odot \varphi(Z_g).$$

Поскольку

$$Z_g = HW_g,$$

получаем

$$dZ_g = dH\, W_g + H\, dW_g.$$

Следовательно,

$$\nabla_{W_g} f = H^T G_{Z_g},$$

а вклад этой ветви в градиент по H равен

$$G_{Z_g} W_g^T.$$

Аналогично из

$$Z_u = HW_u$$

получаем

$$\nabla_{W_u} f = H^T G_{Z_u},$$

а вклад второй ветви в градиент по H равен

$$G_{Z_u} W_u^T.$$

Поскольку матрица H используется в обеих ветвях, их вклады складываются:

$$\nabla_H f = G_{Z_g} W_g^T + G_{Z_u} W_u^T.$$

Таким образом,

$$G_A = GW_d^T,$$

$$G_{Z_g} = GW_d^T \odot Z_u \odot \varphi'(Z_g),$$

$$G_{Z_u} = GW_d^T \odot \varphi(Z_g),$$

и

$$\nabla_{W_d} f = A^T G,$$

$$\nabla_{W_g} f = H^T \left(GW_d^T \odot Z_u \odot \varphi'(Z_g) \right),$$

$$\nabla_{W_u} f = H^T \left(GW_d^T \odot \varphi(Z_g) \right),$$

$$\nabla_H f = \left(GW_d^T \odot Z_u \odot \varphi'(Z_g) \right) W_g^T + \left(GW_d^T \odot \varphi(Z_g) \right) W_u^T.$$

Задача 3.4. Пусть

$$H \in \mathbb{R}^{\ell \times d}, \qquad W_Q, W_K \in \mathbb{R}^{d \times d},$$

и

$$Q = HW_Q, \qquad K = HW_K, \qquad S = QK^T.$$

Пусть f — скалярная функция от S и известен градиент

$$G = \nabla_S f \in \mathbb{R}^{\ell \times \ell}.$$

Найдите

$$\nabla_H f, \qquad \nabla_{W_Q} f, \qquad \nabla_{W_K} f.$$

Решение. Начинаем с

$$df = \langle G, dS \rangle_F = \operatorname{tr}\left(G^T dS \right).$$

Поскольку

$$S = QK^T,$$

получаем

$$dS = dQ\, K^T + Q\, dK^T.$$

Следовательно,

$$df = \operatorname{tr}\left(G^T dQ\, K^T \right) + \operatorname{tr}\left(G^T Q\, dK^T \right).$$

Для первого слагаемого

$$\operatorname{tr}\left(G^T dQ\, K^T \right) = \operatorname{tr}\left((GK)^T dQ \right).$$

Для второго слагаемого

$$\operatorname{tr}\left(G^T Q\, dK^T\right) = \operatorname{tr}\left((G^T Q)^T dK\right).$$

Следовательно,

$$G_Q = GK,$$

и

$$G_K = G^T Q.$$

Теперь

$$Q = HW_Q,$$

поэтому

$$dQ = dH\, W_Q + H\, dW_Q.$$

Отсюда

$$\nabla_{W_Q} f = H^T G_Q,$$

а вклад этой ветви в градиент по H равен

$$G_Q W_Q^T.$$

Аналогично

$$K = HW_K$$

даёт

$$\nabla_{W_K} f = H^T G_K,$$

а вклад второй ветви в градиент по H равен

$$G_K W_K^T.$$

Поскольку матрица H используется в обеих ветвях,

$$\nabla_H f = G_Q W_Q^T + G_K W_K^T.$$

Таким образом,

$$\nabla_{W_Q} f = H^T GK, \quad \nabla_{W_K} f = H^T G^T Q, \quad \nabla_H f = (GK) W_Q^T + (G^T Q) W_K^T.$$

7 БЕЗУСЛОВНАЯ И УСЛОВНАЯ ОПТИМИЗАЦИЯ

7.1 Безусловная оптимизация

Пусть $U \subseteq \mathbb{R}^n$ — открытое множество, $f : U \to \mathbb{R}$ и $a \in U$.

Определение. Точка a называется точкой **нестрогого экстремума** функции f, если существует её окрестность $B_r(a) \subseteq U$ такая, что для всех $x \in B_r(a)$ выполняется одно из условий:

$$f(a) \leq f(x) \qquad \text{или} \qquad f(a) \geq f(x).$$

В первом случае точка a называется точкой **нестрогого минимума**, во втором — точкой **нестрогого максимума**.

Определение. Точка a называется точкой **строгого экстремума** функции f, если существует её окрестность $B_r(a) \subseteq U$ такая, что для всех $x \in B_r(a) \setminus \{a\}$ выполняется одно из условий:

$$f(a) < f(x) \qquad \text{или} \qquad f(a) > f(x).$$

В первом случае точка a называется точкой **строгого минимума**, во втором — точкой **строгого максимума**.

Определение. Точка a называется точкой **глобального минимума** функции f, если

$$f(a) \leq f(x)$$

для всех $x \in U$.

Аналогично, точка a называется точкой **глобального максимума**, если

$$f(a) \geq f(x)$$

для всех $x \in U$.

Глобальный экстремум называется строгим, если соответствующее строгое неравенство выполняется для всех $x \in U \setminus \{a\}$.

Определение. Точка $a \in U$ называется **стационарной точкой** дифференцируемой функции f, если

$$\nabla f(a) = 0.$$

Теорема (необходимое условие первого порядка). Если функция f дифференцируема в точке экстремума a, то эта точка является стационарной:

$$\nabla f(a) = 0.$$

Замечание. Обратное утверждение в общем случае неверно: стационарная точка не обязательно является точкой экстремума.

Рассмотрим функцию

$$f(x, y) = x^2 - y^2.$$

Её градиент имеет вид

$$\nabla f(x, y) = \begin{pmatrix} 2x \\ -2y \end{pmatrix}.$$

В точке $a = (0, 0)^T$ имеем $\nabla f(a) = 0$, поэтому точка a является стационарной.

Однако для любого $t \neq 0$

$$f(t, 0) = t^2 > f(0, 0) = 0,$$

тогда как

$$f(0, t) = -t^2 < f(0, 0).$$

Следовательно, в любой окрестности точки a существуют точки, в которых функция принимает как большие, так и меньшие значения. Поэтому точка a не является точкой экстремума.

Теорема (достаточное условие первого порядка). Пусть $f \in C^1(U)$ и существует окрестность $B_r(a) \subseteq U$ такая, что для всех $x \in B_r(a)$ выполняется

$$\langle \nabla f(x), x - a \rangle \geq 0.$$

Тогда точка a является точкой нестрогого минимума.

Если для всех $x \in B_r(a) \setminus \{a\}$ выполняется строгое неравенство

$$\langle \nabla f(x), x - a \rangle > 0,$$

то точка a является точкой строгого минимума.

Аналогично, для нестрогого и строгого максимума достаточно выполнения соответствующих неравенств с противоположными знаками.

Теорема (необходимое условие второго порядка). Пусть $f \in C^2(U)$, точка a является точкой экстремума и матрица Гессе в этой точке имеет полный ранг. Тогда $\nabla f(a) = 0$, причём:

– Если точка a является точкой минимума, то

$$h^T H_f(a) h > 0$$

для любого $h \in \mathbb{R}^n$, $h \neq 0$.

– Если точка a является точкой максимума, то

$$h^T H_f(a) h < 0$$

для любого $h \in \mathbb{R}^n$, $h \neq 0$.

Теорема (достаточное условие второго порядка). Пусть $f \in C^2(U)$ и точка $a \in U$ является стационарной: $\nabla f(a) = 0$.

Если

$$h^T H_f(a) h > 0$$

для любого $h \in \mathbb{R}^n$, $h \neq 0$, то точка a является точкой строгого минимума.

Если

$$h^T H_f(a) h < 0$$

для любого $h \in \mathbb{R}^n$, $h \neq 0$, то точка a является точкой строгого максимума.

Теорема (критерий глобального экстремума выпуклой функции). Пусть $U \subseteq \mathbb{R}^n$ — открытое выпуклое множество, а функция $f : U \to \mathbb{R}$ выпукла и дифференцируема на U. Тогда точка $a \in U$ является точкой глобального минимума тогда и только тогда, когда

$$\nabla f(a) = 0.$$

Аналогично, для вогнутой дифференцируемой функции условие $\nabla f(a) = 0$ необходимо и достаточно для глобального максимума.

□ Необходимость уже следует из необходимого условия первого порядка.

Докажем достаточность. Пусть $\nabla f(a) = 0$. Возьмём произвольную точку $x \in U$.

Так как множество U выпукло, для любого $t \in [0, 1]$ точка $(1 - t)a + tx$ принадлежит U.

По определению выпуклой функции

$$f\big(a + t(x - a)\big) \leq (1 - t)f(a) + tf(x).$$

При $t \in (0, 1]$ получаем

$$\frac{f\big(a + t(x - a)\big) - f(a)}{t} \leq f(x) - f(a).$$

Переходя к пределу при $t \to 0+$ и пользуясь дифференцируемостью функции f, имеем

$$\langle \nabla f(a), x - a \rangle \leq f(x) - f(a).$$

Поскольку $\nabla f(a) = 0$, получаем

$$f(a) \leq f(x).$$

Так как точка $x \in U$ была выбрана произвольно, точка a является точкой глобального минимума.

Для вогнутой функции доказательство аналогично.

■

Следствие. Если функция f строго выпукла на U, то её глобальный минимум, если он существует, единственен и строгий. Аналогично, глобальный максимум строго вогнутой функции, если он существует, единственен и строгий.

Теорема (неравенство Йенсена). Пусть $U \subseteq \mathbb{R}^n$ — выпуклое множество, $x_1, \ldots, x_m \in U$ и числа $\alpha_1, \ldots, \alpha_m \geq 0$ удовлетворяют условию

$$\sum_{i=1}^{m} \alpha_i = 1.$$

Если функция $f : U \to \mathbb{R}$ выпукла, то

$$f\left(\sum_{i=1}^{m} \alpha_i x_i\right) \leq \sum_{i=1}^{m} \alpha_i f(x_i).$$

Если функция $f : U \to \mathbb{R}$ вогнута, то

$$f\left(\sum_{i=1}^{m} \alpha_i x_i\right) \geq \sum_{i=1}^{m} \alpha_i f(x_i).$$

7.1.1 Градиентные методы

7.1.1.1 Полный градиентный спуск

Пусть $U \subseteq \mathbb{R}^n$ — открытое выпуклое множество, а $f : U \to \mathbb{R}$ — дифференцируемая выпуклая функция. Рассмотрим задачу минимизации функции f на множестве U.

Для произвольной точки $x \in U$ и достаточно малого приращения $h \in \mathbb{R}^n$ по определению дифференцируемости имеем

$$f(x + h) = f(x) + \langle \nabla f(x), h \rangle + o(\|h\|_2).$$

Следовательно, в линейном приближении

$$f(x + h) - f(x) \approx \langle \nabla f(x), h \rangle.$$

Чтобы получить уменьшение значения функции, необходимо выбрать приращение h так, чтобы $\langle \nabla f(x), h \rangle < 0$.

Как известно, градиент $\nabla f(x)$ задаёт направление наискорейшего роста функции. Поэтому направление наискорейшего убывания задаётся антиградиентом.

Пусть $s > 0$ — длина перемещения. При $\nabla f(x) \neq 0$ выберем

$$h = -s \frac{\nabla f(x)}{\|\nabla f(x)\|_2}.$$

Тогда

$$f(x + h) - f(x) \approx \left\langle \nabla f(x), -s \frac{\nabla f(x)}{\|\nabla f(x)\|_2} \right\rangle = -s \|\nabla f(x)\|_2 < 0.$$

Следовательно, в линейном приближении движение вдоль антиградиента уменьшает значение функции.

Перепараметризуем длину перемещения, положив $\eta = s/\|\nabla f(x)\|_2$. Тогда

$$h = -\eta \nabla f(x),$$

и

$$f(x + h) - f(x) \approx -\eta \|\nabla f(x)\|_2^2.$$

Последовательно применяя полученное правило, приходим к итерации **градиентного спуска**:

$$x_{k+1} = x_k - \eta_k \nabla f(x_k), \qquad k = 0, 1, \ldots,$$

где $x_0 \in U$ — начальная точка, а $\eta_k > 0$ — величина шага.

Если $\nabla f(x_k) = 0$, то в силу выпуклости функции f точка x_k является точкой глобального минимума.

Теорема (о градиентном спуске). Пусть $U \subseteq \mathbb{R}^n$ — открытое выпуклое множество, $f : U \to \mathbb{R}$ — дифференцируемая выпуклая функция, градиент которой является L-липшицевым на U:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2$$

для любых $x, y \in U$. Тогда для любых $x, y \in U$ справедлива оценка

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|_2^2.$$

В частности, для итерации градиентного спуска с постоянным шагом $\eta > 0$, если $x_k, x_{k+1} \in U$, выполняется

$$f(x_{k+1}) \leq f(x_k) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(x_k)\|_2^2.$$

Пусть дополнительно функция f достигает глобального минимума в некоторой точке $x^* \in U$, все итерации остаются в U и постоянный шаг удовлетворяет условию

$$0 < \eta < \frac{2}{L}.$$

Тогда значения функции невозрастают и сходятся к глобальному минимуму:

$$f(x_k) \to f(x^*) \qquad \text{при} \qquad k \to \infty.$$

□ Возьмём произвольные точки $x, y \in U$ и положим $h = y - x$. Рассмотрим функцию одной переменной

$$\varphi(t) = f(x + th), \qquad t \in [0, 1].$$

Поскольку множество U выпукло, весь отрезок между точками x и y содержится в U.

По формуле Ньютона–Лейбница

$$f(y) - f(x) = \int_0^1 \varphi'(t)\, dt.$$

По правилу дифференцирования композиции

$$\varphi'(t) = \langle \nabla f(x + th), h \rangle.$$

Следовательно,

$$f(y) - f(x) = \int_0^1 \langle \nabla f(x + th), h \rangle\, dt.$$

Прибавляя и вычитая $\nabla f(x)$ под интегралом, получаем

$$f(y) - f(x) = \langle \nabla f(x), h \rangle + \int_0^1 \langle \nabla f(x + th) - \nabla f(x), h \rangle\, dt.$$

По неравенству Коши–Буняковского–Шварца

$$\langle \nabla f(x + th) - \nabla f(x), h \rangle \le \|\nabla f(x + th) - \nabla f(x)\|_2 \|h\|_2.$$

По липшицевости градиента

$$\|\nabla f(x + th) - \nabla f(x)\|_2 \le L\|th\|_2 = Lt\|h\|_2.$$

Поэтому

$$f(y) - f(x) \le \langle \nabla f(x), h \rangle + \int_0^1 Lt\|h\|_2^2 \, dt = \langle \nabla f(x), h \rangle + \frac{L}{2}\|h\|_2^2.$$

Возвращаясь к $h = y - x$, получаем

$$f(y) \le f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|_2^2.$$

Теперь положим $x = x_k$ и $y = x_{k+1} = x_k - \eta \nabla f(x_k)$. Тогда

$$f(x_{k+1}) \le f(x_k) - \eta\|\nabla f(x_k)\|_2^2 + \frac{L\eta^2}{2}\|\nabla f(x_k)\|_2^2 = f(x_k) - \eta\left(1 - \frac{L\eta}{2}\right)\|\nabla f(x_k)\|_2^2.$$

При $0 < \eta < 2/L$ имеем

$$1 - \frac{L\eta}{2} > 0.$$

Поэтому

$$f(x_{k+1}) \le f(x_k).$$

Покажем теперь её сходимость к глобальному минимуму. Поскольку функция f выпукла, для любого $t \in (0, 1]$ выполняется

$$f\big(x_k + t(x^* - x_k)\big) \le (1 - t) f(x_k) + t f(x^*).$$

Следовательно,

$$\frac{f\big(x_k + t(x^* - x_k)\big) - f(x_k)}{t} \le f(x^*) - f(x_k).$$

Переходя к пределу при $t \to 0+$ и пользуясь дифференцируемостью функции f, получаем

$$\langle \nabla f(x_k), x^* - x_k \rangle \le f(x^*) - f(x_k).$$

Отсюда

$$f(x_k) - f(x^*) \le \langle \nabla f(x_k), x_k - x^* \rangle.$$

С другой стороны, из определения итерации

$$x_{k+1} - x^* = x_k - x^* - \eta \nabla f(x_k).$$

Следовательно,

$$\|x_{k+1} - x^*\|_2^2 = \|x_k - x^*\|_2^2 - 2\eta\langle \nabla f(x_k), x_k - x^*\rangle + \eta^2 \|\nabla f(x_k)\|_2^2.$$

Выражая скалярное произведение, получаем

$$\langle \nabla f(x_k), x_k - x^*\rangle = \frac{\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2}{2\eta} + \frac{\eta}{2}\|\nabla f(x_k)\|_2^2.$$

Поэтому

$$f(x_k) - f(x^*) \leq \frac{\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2}{2\eta} + \frac{\eta}{2}\|\nabla f(x_k)\|_2^2.$$

Из полученной ранее оценки убывания следует

$$\eta\left(1 - \frac{L\eta}{2}\right)\|\nabla f(x_k)\|_2^2 \leq f(x_k) - f(x_{k+1}).$$

Поскольку $1 - L\eta/2 > 0$, имеем

$$\frac{\eta}{2}\|\nabla f(x_k)\|_2^2 \leq \frac{f(x_k) - f(x_{k+1})}{2\left(1 - \frac{L\eta}{2}\right)}.$$

Следовательно,

$$f(x_k) - f(x^*) \leq \frac{\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2}{2\eta} + \frac{f(x_k) - f(x_{k+1})}{2\left(1 - \frac{L\eta}{2}\right)}.$$

Суммируя данное неравенство по $k = 0, \ldots, m-1$, получаем

$$\sum_{k=0}^{m-1}\left(f(x_k) - f(x^*)\right) \leq \frac{\|x_0 - x^*\|_2^2 - \|x_m - x^*\|_2^2}{2\eta} + \frac{f(x_0) - f(x_m)}{2\left(1 - \frac{L\eta}{2}\right)}.$$

Так как x^* является точкой глобального минимума,

$$f(x_m) \geq f(x^*).$$

Поэтому

$$\sum_{k=0}^{m-1}\bigl(f(x_k)-f(x^*)\bigr)\le\frac{\|x_0-x^*\|_2^2}{2\eta}+\frac{f(x_0)-f(x^*)}{2\left(1-\frac{L\eta}{2}\right)}.$$

Все слагаемые в левой части неотрицательны, а их частичные суммы ограничены сверху. Следовательно, соответствующий ряд сходится, поэтому

$$f(x_k)-f(x^*)\to 0\qquad\text{при}\qquad k\to\infty.$$

■

7.1.1.2 Стохастический градиентный спуск

Рассмотрим случай, когда минимизируемая функция представляет собой среднее арифметическое конечного числа дифференцируемых функций:

$$f(x)=\frac{1}{N}\sum_{i=1}^{N}f_i(x),\qquad x\in U.$$

Её градиент имеет вид

$$\nabla f(x)=\frac{1}{N}\sum_{i=1}^{N}\nabla f_i(x).$$

В полном градиентном спуске на каждой итерации требуется вычислить градиенты всех N слагаемых. При большом размере выборки это может требовать значительных вычислений.

Вместо вычисления полного градиента выберем случайный индекс $i_k\in\{1,\dots,N\}$ равновероятно и независимо от текущей точки x_k. Определим **стохастический градиент**

$$g_k=\nabla f_{i_k}(x_k).$$

Тогда итерация **стохастического градиентного спуска** имеет вид

$$x_{k+1}=x_k-\eta_k g_k,\qquad k=0,1,\dots.$$

В отличие от полного градиента, величина g_k является случайным вектором, поскольку зависит от случайного выбора i_k.

Утверждение. Если индекс i_k выбирается равновероятно из множества $\{1, \ldots, N\}$ независимо от x_k, то стохастический градиент является несмещённой оценкой полного градиента:

$$\mathbb{M}[g_k \mid x_k] = \nabla f(x_k).$$

□ По определению стохастического градиента $g_k = \nabla f_{i_k}(x_k)$. При фиксированном x_k каждый индекс i выбирается с вероятностью $1/N$. Следовательно,

$$\mathbb{M}[g_k \mid x_k] = \sum_{i=1}^{N} \mathbb{P}(i_k = i \mid x_k) \nabla f_i(x_k) = \frac{1}{N} \sum_{i=1}^{N} \nabla f_i(x_k) = \nabla f(x_k).$$

■

Таким образом, условное математическое ожидание стохастического градиента совпадает с полным градиентом. Однако отдельная реализация g_k может существенно от него отличаться.

Для количественной характеристики этого отклонения введём дисперсию стохастического градиента:

$$\mathbb{D}(g_k \mid x_k) = \mathbb{M}\left[\|g_k - \mathbb{M}[g_k \mid x_k]\|_2^2 \,\middle|\, x_k\right].$$

С учётом несмещённости получаем

$$\mathbb{D}(g_k \mid x_k) = \mathbb{M}\left[\|g_k - \nabla f(x_k)\|_2^2 \,\middle|\, x_k\right].$$

Чем больше дисперсия, тем значительнее может быть отклонение стохастического градиента от полного градиента.

Для уменьшения дисперсии вместо одного индекса будем выбирать случайное подмножество $\mathcal{B}_k \subseteq \{1, \ldots, N\}$, состоящее из B различных индексов:

$$|\mathcal{B}_k| = B, \qquad 1 \leq B \leq N.$$

На каждой итерации подмножество $\mathcal{B}_k$ выбирается равновероятно среди всех подмножеств размера B, независимо от предыдущих итераций.

Определим **mini-batch градиент** как

$$g_{\mathcal{B}_k} = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k).$$

Итерация mini-batch градиентного спуска имеет вид

$$x_{k+1} = x_k - \eta_k g_{\mathcal{B}_k}.$$

Утверждение. При равновероятном выборе mini-batch без возвращения градиент $g_{\mathcal{B}_k}$ является несмещённой оценкой полного градиента:

$$\mathbb{M}[g_{\mathcal{B}_k} \mid x_k] = \nabla f(x_k).$$

Кроме того, при $N > 1$ его условная дисперсия удовлетворяет равенству

$$\mathbb{D}(g_{\mathcal{B}_k} \mid x_k) = \frac{N - B}{B(N-1)} \mathbb{D}(g_k \mid x_k).$$

□ Для каждого $i = 1, \ldots, N$ введём индикатор

$$I_i = \begin{cases} 1, & i \in \mathcal{B}_k, \\ 0, & i \notin \mathcal{B}_k. \end{cases}$$

Поскольку подмножество $\mathcal{B}_k$ выбирается равновероятно, вероятность включения любого индекса равна

$$\mathbb{M}[I_i \mid x_k] = \mathbb{P}(i \in \mathcal{B}_k \mid x_k) = \frac{B}{N}.$$

Тогда mini-batch градиент можно записать в виде

$$g_{\mathcal{B}_k} = \frac{1}{B} \sum_{i=1}^{N} I_i \nabla f_i(x_k).$$

По линейности математического ожидания

$$\mathbb{M}[g_{\mathcal{B}_k} \mid x_k] = \frac{1}{B}\sum_{i=1}^{N}\mathbb{M}[I_i \mid x_k]\nabla f_i(x_k) = \frac{1}{B}\sum_{i=1}^{N}\frac{B}{N}\nabla f_i(x_k)$$
$$= \frac{1}{N}\sum_{i=1}^{N}\nabla f_i(x_k) = \nabla f(x_k).$$

Теперь рассмотрим дисперсию. Для каждого $i = 1, \ldots, N$ обозначим

$$\xi_i = \nabla f_i(x_k) - \nabla f(x_k).$$

По определению полного градиента $\sum_{i=1}^{N}\xi_i = 0$ Тогда

$$g_{\mathcal{B}_k} - \nabla f(x_k) = \frac{1}{B}\sum_{i=1}^{N} I_i\xi_i.$$

Следовательно,

$$\mathbb{D}(g_{\mathcal{B}_k} \mid x_k) = \mathbb{M}\left[\left\|\frac{1}{B}\sum_{i=1}^{N} I_i\xi_i\right\|_2^2 \middle| x_k\right]$$
$$= \frac{1}{B^2}\left(\sum_{i=1}^{N}\mathbb{M}[I_i \mid x_k]\|\xi_i\|_2^2 + \sum_{i\neq j}\mathbb{M}[I_iI_j \mid x_k]\langle\xi_i, \xi_j\rangle\right).$$

Для двух различных индексов $i \neq j$ вероятность их одновременного включения в mini-batch равна

$$\mathbb{M}[I_iI_j \mid x_k] = \mathbb{P}(i, j \in \mathcal{B}_k \mid x_k) = \frac{B}{N}\frac{B-1}{N-1} = \frac{B(B-1)}{N(N-1)}.$$

Кроме того, поскольку $\sum_{i=1}^{N}\xi_i = 0$, имеем

$$0 = \left\|\sum_{i=1}^{N}\xi_i\right\|_2^2 = \sum_{i=1}^{N}\|\xi_i\|_2^2 + \sum_{i\neq j}\langle\xi_i, \xi_j\rangle.$$

Следовательно,

$$\sum_{i\neq j}\langle\xi_i, \xi_j\rangle = -\sum_{i=1}^{N}\|\xi_i\|_2^2.$$

Подставляя полученные равенства в выражение для дисперсии, получаем

$$\mathbb{D}(g_{\mathcal{B}_k} \mid x_k) = \frac{1}{B^2}\left(\frac{B}{N} - \frac{B(B-1)}{N(N-1)}\right)\sum_{i=1}^{N}\|\xi_i\|_2^2 = \frac{N-B}{BN(N-1)}\sum_{i=1}^{N}\|\xi_i\|_2^2.$$

Для стохастического градиента, полученного равновероятным выбором одного индекса, условная дисперсия равна

$$\mathbb{D}(g_k \mid x_k) = \frac{1}{N}\sum_{i=1}^{N}\|\xi_i\|_2^2.$$

Следовательно,

$$\mathbb{D}(g_{\mathcal{B}_k} \mid x_k) = \frac{N-B}{B(N-1)}\mathbb{D}(g_k \mid x_k).$$

■

Таким образом, выбор mini-batch без возвращения сохраняет несмещённость оценки полного градиента и уменьшает её дисперсию.

При $B \ll N$ выполняется приближение

$$\mathbb{D}(g_{\mathcal{B}_k} \mid x_k) \approx \frac{1}{B}\mathbb{D}(g_k \mid x_k).$$

При $B = N$ mini-batch градиент совпадает с полным градиентом, поэтому его дисперсия обращается в нуль.

7.1.1.3 Adam

Для ослабления влияния плохой обусловленности функции метод Adam использует покоординатную адаптацию шага, сочетая сглаживание направления градиента с учётом его масштаба.

Поскольку обновление выполняется покоординатно, достаточно рассмотреть одну произвольную координату. Далее через $g_k \in \mathbb{R}$ будем обозначать соответствующую компоненту градиента на итерации k.

Введём два экспоненциальных скользящих средних: **момент первой степени** m_k и **момент второй степени** v_k.

На начальной итерации положим

$$m_0 = (1 - \beta_1) g_0, \qquad v_0 = (1 - \beta_2) g_0^2,$$

где $0 \le \beta_1, \beta_2 < 1$.

Для последующих итераций $k \ge 1$ определим

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2.$$

Первый момент сглаживает направление движения, а второй учитывает масштаб предыдущих градиентов.

Раскроем рекуррентную формулу первого момента:

$$m_k = (1 - \beta_1) g_k + \beta_1 m_{k-1} = (1 - \beta_1) \left(g_k + \beta_1 g_{k-1} + \cdots + \beta_1^k g_0 \right) = (1 - \beta_1) \sum_{j=0}^{k} \beta_1^{k-j} g_j.$$

Аналогично для второго момента получаем

$$v_k = (1 - \beta_2) \sum_{j=0}^{k} \beta_2^{k-j} g_j^2.$$

Таким образом, моменты представляют собой взвешенные суммы предыдущих градиентов и их квадратов.

При этом вклад более ранних градиентов экспоненциально уменьшается. Чем ближе параметры β_1 и β_2 к единице, тем медленнее затухает влияние предыдущих итераций.

Рассмотрим сумму весов для произвольного $\beta \in [0, 1)$:

$$(1 - \beta) \sum_{j=0}^{k} \beta^{k-j} = (1 - \beta) \sum_{j=0}^{k} \beta^j = (1 - \beta) \frac{1 - \beta^{k+1}}{1 - \beta} = 1 - \beta^{k+1}.$$

Следовательно, сумма весов момента первой степени равна $1 - \beta_1^{k+1}$, а момента второй степени — $1 - \beta_2^{k+1}$.

При положительных параметрах β_1 и β_2 на начальных итерациях эти суммы меньше единицы, что связано с нулевой инициализацией накопленных момен-

тов. В результате их масштаб оказывается заниженным, что может искажать величину обновления параметров.

Для устранения данного эффекта введём **коррекцию моментов**:

$$\widehat{m}_k = \frac{m_k}{1-\beta_1^{k+1}}, \qquad \widehat{v}_k = \frac{v_k}{1-\beta_2^{k+1}}.$$

После коррекции суммы весов в обоих моментах становятся равными единице. Иными словами, моменты представляют собой взвешенные средние градиентов и их квадратов соответственно.

В частности, при $k = 0$ получаем

$$\widehat{m}_0 = \frac{(1-\beta_1)g_0}{1-\beta_1} = g_0,$$

$$\widehat{v}_0 = \frac{(1-\beta_2)g_0^2}{1-\beta_2} = g_0^2.$$

Итоговое обновление рассматриваемой координаты методом Adam имеет вид

$$x_{k+1,i} = x_{k,i} - \eta_k \frac{\widehat{m}_k}{\sqrt{\widehat{v}_k} + \varepsilon}, \qquad k = 0, 1, \ldots,$$

где i — номер фиксированной координаты, $\eta_k > 0$ — величина шага, а $\varepsilon > 0$ — параметр численной устойчивости.

Аналогичные обновления выполняются для всех координат вектора параметров.

7.2 Условная оптимизация

Пусть $f : \mathbb{R}^n \to \mathbb{R}$, а $\mathcal{D} \subseteq \mathbb{R}^n$ — множество допустимых точек.

Определение. Точка $a \in \mathcal{D}$ называется точкой **условного локального минимума** функции f на множестве $\mathcal{D}$, если существует её окрестность $B_r(a)$ такая, что

$$f(a) \le f(x)$$

для всех $x \in \mathcal{D} \cap B_r(a)$.

Если для всех $x \in \mathcal{D} \cap B_r(a) \setminus \{a\}$ выполняется строгое неравенство

$$f(a) < f(x),$$

то точка a называется точкой **строгого условного локального минимума**.

Аналогично определяются условный локальный максимум и строгий условный локальный максимум.

В отличие от безусловной оптимизации, движение из допустимой точки возможно не по всем направлениям пространства, а только по направлениям, сохраняющим ограничения. Поэтому в точке условного экстремума в общем случае $\nabla f(a)$ не обязан быть равен нулю.

7.2.1 Метод множителей Лагранжа

Рассмотрим задачу минимизации функции f при одном ограничении-равенстве

$$f(x) \to \min_x, \qquad h(x) = 0,$$

где $h : \mathbb{R}^n \to \mathbb{R}$ — дифференцируемая функция.

Допустимое множество имеет вид

$$\mathcal{D} = \{x \in \mathbb{R}^n \mid h(x) = 0\}$$

и является множеством уровня функции h.

Пусть $a \in \mathcal{D}$ и v — произвольное касательное направление к $\mathcal{D}$ в точке a. Поскольку при движении вдоль допустимого множества значение функции h не изменяется, её дифференциал на любом касательном направлении равен нулю:

$$dh_a(v) = 0.$$

Так как

$$dh_a(v) = \langle \nabla h(a), v \rangle,$$

получаем

$$\langle \nabla h(a), v \rangle = 0$$

для любого касательного направления v.

Таким образом, при $\nabla h(a) \neq 0$ градиент $\nabla h(a)$ ортогонален всем касательным направлениям допустимого множества и задаёт нормальное направление к нему в точке a.

Пусть теперь точка a является точкой условного локального экстремума функции f. Тогда для любого касательного направления v линейное изменение функции f должно отсутствовать:

$$df_a(v) = 0.$$

Действительно, если $df_a(v) < 0$, то в первом порядке движение в направлении v уменьшает значение функции. Если же $df_a(v) > 0$, то в первом порядке значение функции уменьшается при движении в противоположном направлении $-v$.

Так как

$$df_a(v) = \langle \nabla f(a), v \rangle,$$

имеем

$$\langle \nabla f(a), v \rangle = 0$$

для любого касательного направления v.

Таким образом, $\nabla f(a)$ и $\nabla h(a)$ ортогональны всем касательным направлениям допустимого множества. При $\nabla h(a) \neq 0$ они направлены вдоль одной нормали, поэтому существует число $\lambda \in \mathbb{R}$ такое, что

$$\nabla f(a) + \lambda \nabla h(a) = 0.$$

Пример 1. Рассмотрим задачу

$$f(x, y) = (x - 2)^2 + y^2 \to \min$$

при ограничении

$$x^2 + y^2 = 1.$$

Целевая функция представляет собой квадрат евклидова расстояния от точки $(x, y)^T$ до точки $(2, 0)^T$. Поэтому требуется найти точку единичной окружности, наиболее близкую к точке $(2, 0)^T$.

Запишем ограничение в виде

$$h(x, y) = x^2 + y^2 - 1 = 0.$$

Градиенты целевой функции и ограничения имеют вид

$$\nabla f(x, y) = \begin{pmatrix} 2(x-2) \\ 2y \end{pmatrix}, \qquad \nabla h(x, y) = \begin{pmatrix} 2x \\ 2y \end{pmatrix}.$$

Перейдём к полученному выше соотношению

$$\nabla f(x, y) + \lambda \nabla h(x, y) = 0.$$

Для рассматриваемой задачи получаем

$$\begin{pmatrix} 2(x-2) \\ 2y \end{pmatrix} + \lambda \begin{pmatrix} 2x \\ 2y \end{pmatrix} = 0.$$

Вместе с исходным ограничением получаем систему

$$\begin{cases} 2(x-2) + 2\lambda x = 0, \\ 2y + 2\lambda y = 0, \\ x^2 + y^2 = 1. \end{cases}$$

Из второго уравнения $y(1 + \lambda) = 0$. Случай $\lambda = -1$ не удовлетворяет первому уравнению, поэтому $y = 0$.

Тогда из ограничения $x^2 = 1$, и получаем две точки:

$$(x, y)^T = (1, 0)^T, \qquad (x, y)^T = (-1, 0)^T.$$

Значения целевой функции равны

$$f(1, 0) = 1, \qquad f(-1, 0) = 9.$$

Следовательно, точкой условного минимума является

$$a = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

В этой точке

$$\nabla f(a) = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \qquad \nabla h(a) = \begin{pmatrix} 2 \\ 0 \end{pmatrix}.$$

Таким образом, $\nabla f(a) \neq 0$, однако градиент целевой функции направлен по нормали к допустимой окружности. При $\lambda = 1$ выполняется

$$\nabla f(a) + \lambda \nabla h(a) = 0.$$

Определение. Допустимая точка a ограничения $h(x) = 0$ называется **регулярной**, если

$$\nabla h(a) \neq 0.$$

Условие регулярности гарантирует, что ограничение имеет ненулевую линейную часть, а его градиент задаёт нормальное направление к допустимому множеству.

Если же $\nabla h(a) = 0$, то условие для касательного направления

$$\langle \nabla h(a), v \rangle = 0$$

превращается в тождество $0 = 0$ и выполняется для любого $v \in \mathbb{R}^n$. Следовательно, первый порядок перестаёт различать допустимые и недопустимые направления движения.

Пример 2. Рассмотрим ту же единичную окружность, но зададим её ограничением

$$\widetilde{h}(x, y) = \left(x^2 + y^2 - 1\right)^2 = 0.$$

Данное ограничение задаёт то же допустимое множество, поскольку

$$\left(x^2 + y^2 - 1\right)^2 = 0 \quad \Longleftrightarrow \quad x^2 + y^2 - 1 = 0.$$

Однако

$$\nabla\widetilde{h}(x,y) = 4\left(x^2+y^2-1\right)\begin{pmatrix}x\\y\end{pmatrix}.$$

Во всех допустимых точках $x^2+y^2-1=0$, поэтому

$$\nabla\widetilde{h}(x,y) = 0.$$

Следовательно, первый порядок больше не задаёт нормальное направление к окружности. В частности, в точке $a=(1,0)^T$ имеем

$$\nabla f(a) = \begin{pmatrix}-2\\0\end{pmatrix}, \qquad \nabla\widetilde{h}(a) = \begin{pmatrix}0\\0\end{pmatrix}.$$

Поэтому равенство

$$\nabla f(a) + \lambda\nabla\widetilde{h}(a) = 0$$

не выполняется ни при каком $\lambda\in\mathbb{R}$, хотя точка a остаётся точкой условного минимума.

Рассмотрим теперь задачу с несколькими ограничениями-равенствами:

$$f(x)\to\min_x, \qquad h_j(x)=0, \qquad j=1,\dots,p,$$

где $h_j:\mathbb{R}^n\to\mathbb{R}$.

Объединим функции ограничений в отображение

$$h:\mathbb{R}^n\to\mathbb{R}^p, \qquad h(x)=\begin{pmatrix}h_1(x)\\\vdots\\h_p(x)\end{pmatrix}.$$

Если v является допустимым касательным направлением в точке a, то при движении вдоль него каждое ограничение должно сохранять своё значение. Следовательно,

$$\langle\nabla h_j(a), v\rangle = 0, \qquad j=1,\dots,p.$$

Таким образом, допустимое направление должно быть ортогонально одновременно всем градиентам ограничений

$$\nabla h_1(a), \ldots, \nabla h_p(a).$$

Матрица Якоби отображения h имеет вид

$$J_h(a) = \begin{pmatrix} \nabla h_1(a)^T \\ \vdots \\ \nabla h_p(a)^T \end{pmatrix} \in \mathbb{R}^{p \times n}.$$

Определение. Допустимая точка a системы ограничений $h_j(x) = 0$, $j = 1, \ldots, p$, называется **регулярной**, если

$$\operatorname{rank} J_h(a) = p.$$

Эквивалентно, градиенты $\nabla h_1(a), \ldots, \nabla h_p(a)$ линейно независимы.

Полный строчный ранг означает, что ограничения задают независимые условия первого порядка. В частности, ни один из градиентов ограничений не равен нулю и ни один из них не выражается через остальные. Кроме того, поскольку $\operatorname{rank} J_h(a) \leq n$, для регулярной системы необходимо $p \leq n$.

Пусть теперь точка a является регулярной точкой условного локального экстремума функции f. Тогда градиент $\nabla f(a)$ также ортогонален всем допустимым касательным направлениям.

Поскольку градиенты ограничений $\nabla h_1(a), \ldots, \nabla h_p(a)$ линейно независимы, они задают нормальные направления к допустимому множеству. Поэтому $\nabla f(a)$ принадлежит их линейной оболочке. Следовательно, существуют числа $\lambda_1, \ldots, \lambda_p \in \mathbb{R}$ такие, что

$$\nabla f(a) + \sum_{j=1}^{p} \lambda_j \nabla h_j(a) = 0.$$

Вернёмся к задаче из первого примера и добавим к ней второе ограничение $y = 0$. Тогда получаем систему

$$\begin{cases} x^2 + y^2 = 1, \\ y = 0. \end{cases}$$

Допустимое множество состоит из двух точек $(1, 0)^T$ и $(-1, 0)^T$. При этом в некоторой достаточно малой окрестности каждой из них других допустимых точек нет, то есть ненулевого допустимого направления движения не остаётся.

Например, в точке $a = (1, 0)^T$ имеем

$$\nabla h_1(a) = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \qquad \nabla h_2(a) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Градиенты линейно независимы, поэтому

$$\operatorname{rank} J_h(a) = 2.$$

Теорема (метод множителей Лагранжа). Пусть $f, h_1, \ldots, h_p \in C^1(\mathbb{R}^n)$, а точка $a \in \mathbb{R}^n$ является точкой условного локального экстремума функции f при ограничениях

$$h_j(x) = 0, \qquad j = 1, \ldots, p.$$

Если точка a регулярна, то существуют единственные числа $\lambda_1, \ldots, \lambda_p \in \mathbb{R}$ такие, что

$$\nabla f(a) + \sum_{j=1}^{p} \lambda_j \nabla h_j(a) = 0.$$

Введём функцию Лагранжа, объединяющую целевую функцию и ограничения с соответствующими множителями:

$$\mathscr{L}(x, \lambda) = f(x) + \sum_{j=1}^{p} \lambda_j h_j(x),$$

где

$$\lambda = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_p \end{pmatrix}.$$

Эквивалентно, выполняется

$$\nabla_x \mathscr{L}(a, \lambda) = 0.$$

Таким образом, необходимые условия условного экстремума можно записать в виде

$$\begin{cases} \nabla_x \mathscr{L}(a, \lambda) = 0, \\ h_j(a) = 0, \qquad j = 1, \ldots, p. \end{cases}$$

Полученные условия являются необходимыми, но в общем случае не являются достаточными.

Пример 3. Рассмотрим задачу

$$f(x, y) = x^3$$

при ограничении

$$h(x, y) = y = 0.$$

В точке

$$a = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

имеем

$$\nabla f(a) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \qquad \nabla h(a) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Поэтому при $\lambda = 0$ выполняется

$$\nabla f(a) + \lambda \nabla h(a) = 0.$$

Однако на допустимом множестве $y = 0$ целевая функция принимает вид

$$f(x, 0) = x^3.$$

При $x > 0$ она положительна, а при $x < 0$ отрицательна. Следовательно, точка a не является точкой условного экстремума.

7.2.2 Условия Каруша–Куна–Таккера

Рассмотрим более общую задачу условной минимизации:

$$f(x) \to \min_x$$

при ограничениях

$$g_i(x) \le 0, \qquad i = 1, \dots, m, \quad h_j(x) = 0, \qquad j = 1, \dots, p,$$

где

$$g_i, h_j : \mathbb{R}^n \to \mathbb{R}$$

— дифференцируемые функции.

Ограничения-равенства рассматриваются так же, как в методе множителей Лагранжа. Рассмотрим особенности, возникающие при наличии ограничений-неравенств.

Пусть a — допустимая точка. Ограничение $g_i(x) \le 0$ называется **активным** в точке a, если $g_i(a) = 0$, и **неактивным**, если $g_i(a) < 0$.

Неактивное ограничение выполняется строго, поэтому в достаточно малой окрестности точки a оно не ограничивает допустимое движение. Следовательно, при анализе условий первого порядка учитываются только активные ограничения.

Рассмотрим активное ограничение $g_i(a) = 0$. Если v — допустимое направление из точки a, то в первом порядке движение вдоль него не должно выводить точку из области $g_i(x) \le 0$. Поэтому

$$dg_{i,a}(v) = \langle \nabla g_i(a), v \rangle \le 0.$$

Если точка a является точкой условного локального минимума, то вдоль любого допустимого направления целевая функция в первом порядке не должна уменьшаться:

$$df_a(v) = \langle \nabla f(a), v \rangle \ge 0.$$

В отличие от ограничения-равенства, здесь противоположное направление $-v$ может быть недопустимым. Поэтому производная целевой функции по допустимому направлению не обязана обращаться в нуль.

Для одного активного ограничения соотношение между градиентами имеет вид

$$\nabla f(a) + \lambda \nabla g_i(a) = 0.$$

Тогда

$$\langle \nabla f(a), v \rangle = -\lambda \langle \nabla g_i(a), v \rangle.$$

Поскольку

$$\langle \nabla g_i(a), v \rangle \le 0 \quad \text{и} \quad \langle \nabla f(a), v \rangle \ge 0,$$

множитель при ограничении-неравенстве должен удовлетворять условию $\lambda \ge 0$.

Для неактивного ограничения $g_i(a) < 0$ соответствующий множитель равен нулю $\lambda_i = 0$. Следовательно, для каждого ограничения-неравенства выполняется

$$\lambda_i g_i(a) = 0.$$

Это равенство называется **условием дополняющей нежёсткости**.

Действительно, если ограничение неактивно, то $g_i(a) < 0$, и из $\lambda_i g_i(a) = 0$ следует $\lambda_i = 0$. Если же $\lambda_i > 0$, то обязательно $g_i(a) = 0$, то есть соответствующее ограничение активно.

Обозначим множество индексов активных ограничений через

$$I(a) = \{ i \in \{1, \dots, m\} \mid g_i(a) = 0 \}.$$

Пусть $I(a) = \{i_1, \dots, i_r\}$. Составим матрицу Якоби активных ограничений:

$$J_{\text{act}}(a) = \begin{pmatrix} \nabla h_1(a)^T \\ \vdots \\ \nabla h_p(a)^T \\ \nabla g_{i_1}(a)^T \\ \vdots \\ \nabla g_{i_r}(a)^T \end{pmatrix} \in \mathbb{R}^{(p+r)\times n}.$$

Определение. Допустимая точка a называется **регулярной**, если

$$\operatorname{rank} J_{\text{act}}(a) = p + r.$$

Эквивалентно, градиенты всех ограничений-равенств и всех активных ограничений-неравенств линейно независимы.

Таким образом, условие регулярности является прямым расширением условия регулярности для метода множителей Лагранжа: к градиентам ограничений-равенств добавляются градиенты активных ограничений-неравенств.

При выполнении условия регулярности в точке условного локального минимума существуют множители

$$\lambda_1, \ldots, \lambda_m \geq 0 \quad \text{и} \quad \nu_1, \ldots, \nu_p \in \mathbb{R}$$

такие, что

$$\nabla f(a) + \sum_{i=1}^{m} \lambda_i \nabla g_i(a) + \sum_{j=1}^{p} \nu_j \nabla h_j(a) = 0.$$

Пример 4. Вернёмся к задаче из первого примера, заменив ограничение-равенство ограничением-неравенством:

$$f(x, y) = (x - 2)^2 + y^2 \to \min$$

при

$$g(x, y) = x^2 + y^2 - 1 \leq 0.$$

Теперь допустимым множеством является не только единичная окружность, а весь единичный круг. Градиенты имеют вид

$$\nabla f(x, y) = \begin{pmatrix} 2(x - 2) \\ 2y \end{pmatrix}, \qquad \nabla g(x, y) = \begin{pmatrix} 2x \\ 2y \end{pmatrix}.$$

Для данной задачи условия принимают вид

$$\begin{cases} \nabla f(x,y) + \lambda \nabla g(x,y) = 0, \\ g(x,y) \le 0, \\ \lambda \ge 0, \\ \lambda g(x,y) = 0. \end{cases}$$

Следовательно,

$$\begin{cases} 2(x-2) + 2\lambda x = 0, \\ 2y + 2\lambda y = 0, \\ x^2 + y^2 - 1 \le 0, \\ \lambda \ge 0, \\ \lambda(x^2 + y^2 - 1) = 0. \end{cases}$$

Если $\lambda = 0$, то из первых двух уравнений получаем $x = 2$ и $y = 0$, однако эта точка не является допустимой. Следовательно, $\lambda > 0$. По условию дополняющей нежёсткости ограничение должно быть активным, поэтому

$$x^2 + y^2 = 1.$$

Из второго уравнения $y(1 + \lambda) = 0$. Поскольку $\lambda \ge 0$, имеем $y = 0$. Тогда $x^2 = 1$, то есть $x = \pm 1$. При $x = 1$ из первого уравнения получаем $\lambda = 1$. При $x = -1$ получаем $\lambda = -3$, что противоречит условию $\lambda \ge 0$. Таким образом, остаётся точка

$$a = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad \lambda = 1.$$

В этой точке ограничение активно и

$$\nabla g(a) = \begin{pmatrix} 2 \\ 0 \end{pmatrix} \neq 0,$$

поэтому точка a регулярна.

Кроме того, $\lambda g(a) = 1 \cdot 0 = 0$, то есть выполняется условие дополняющей нежёсткости.

Теорема (условия Каруша–Куна–Таккера). Пусть $f, g_1, \ldots, g_m, h_1, \ldots, h_p$ непрерывно дифференцируемы, а точка a является регулярной точкой условного локального минимума задачи

$$f(x) \to \min_x$$

при ограничениях

$$g_i(x) \le 0, \qquad i = 1, \ldots, m, \quad \text{и} \quad h_j(x) = 0, \qquad j = 1, \ldots, p.$$

Тогда существуют множители $\lambda_i \ge 0$ и $\nu_j \in \mathbb{R}$, для которых выполняются условия

$$\begin{cases} \nabla_x \mathscr{L}(a, \lambda, \nu) = 0, & \text{стационарность,} \\ g_i(a) \le 0, \quad i = 1, \ldots, m, \\ h_j(a) = 0, \quad j = 1, \ldots, p, & \text{прямая допустимость,} \\ \lambda_i \ge 0, \quad i = 1, \ldots, m, & \text{двойственная допустимость,} \\ \lambda_i g_i(a) = 0, \quad i = 1, \ldots, m, & \text{дополняющая нежёсткость.} \end{cases}$$

Таким образом, условия Каруша–Куна–Таккера расширяют метод множителей Лагранжа на задачи с ограничениями-неравенствами. Полученные условия в общем случае являются необходимыми, но не являются достаточными.

7.2.3 Двойственная задача

Рассмотрим задачу

$$f(x) \to \min_x$$

при ограничениях

$$g_i(x) \le 0, \qquad i = 1, \ldots, m, \quad \text{и} \quad h_j(x) = 0, \qquad j = 1, \ldots, p.$$

Пусть допустимое множество имеет вид

$$\mathcal{D} = \left\{ x \in \mathbb{R}^n \;\middle|\; g_i(x) \le 0,\ i = 1, \dots, m,\ h_j(x) = 0,\ j = 1, \dots, p \right\}.$$

Обозначим оптимальное значение исходной, или прямой, задачи как

$$p^* = \inf_{x \in \mathcal{D}} f(x).$$

Функция Лагранжа имеет вид

$$\mathscr{L}(x, \lambda, \nu) = f(x) + \sum_{i=1}^{m} \lambda_i g_i(x) + \sum_{j=1}^{p} \nu_j h_j(x), \quad \lambda_i \ge 0, \nu_j \in \mathbb{R}$$

Пусть $x \in \mathcal{D}$. Тогда $g_i(x) \le 0, h_j(x) = 0$. Следовательно, при $\lambda_i \ge 0$ имеем

$$\sum_{i=1}^{m} \lambda_i g_i(x) \le 0, \qquad \sum_{j=1}^{p} \nu_j h_j(x) = 0,$$

и поэтому

$$\mathscr{L}(x, \lambda, \nu) \le f(x).$$

Определение. Двойственной функцией называется функция

$$q(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} \mathscr{L}(x, \lambda, \nu).$$

Инфимум берётся по всем $x \in \mathbb{R}^n$, а не только по допустимым точкам исходной задачи.

По определению инфимума для любого $x \in \mathbb{R}^n$ выполняется

$$q(\lambda, \nu) \le \mathscr{L}(x, \lambda, \nu).$$

Поэтому для любой допустимой точки $x \in \mathcal{D}$ и любых $\lambda_i \ge 0$ имеем

$$q(\lambda, \nu) \le \mathscr{L}(x, \lambda, \nu) \le f(x).$$

Поскольку это неравенство выполняется для всех $x \in \mathcal{D}$, получаем

$$q(\lambda, \nu) \le p^*.$$

Таким образом, каждое допустимое значение двойственных переменных задаёт нижнюю оценку оптимального значения прямой задачи. Естественно выбрать среди таких оценок наибольшую.

Определение. Двойственной к исходной задаче минимизации называется задача

$$\sup_{\lambda,\nu} q(\lambda, \nu) \qquad \lambda_i \geq 0, \quad \nu_j \in \mathbb{R}.$$

Обозначим её оптимальное значение через

$$d^* = \sup_{\lambda \geq 0,\ \nu} q(\lambda, \nu).$$

Утверждение (слабая двойственность). Для прямой и двойственной задач выполняется

$$d^* \leq p^*.$$

□ Для любых допустимых двойственных переменных λ, ν имеем

$$q(\lambda, \nu) \leq p^*.$$

Следовательно, p^* является верхней гранью множества значений двойственной функции.

По определению

$$d^* = \sup_{\lambda \geq 0,\ \nu} q(\lambda, \nu).$$

Поскольку супремум является наименьшей верхней гранью, получаем

$$d^* \leq p^*.$$

■

7.2.4 Выпуклая условная оптимизация

Рассмотрим задачу

$$f(x) \to \min_x$$

при ограничениях

$$g_i(x) \le 0, \qquad i = 1, \dots, m, \quad \text{и} \quad h_j(x) = 0, \qquad j = 1, \dots, p,$$

где функции $f, g_1, \dots, g_m$ выпуклы, а функции $h_1, \dots, h_p$ аффинны.

Утверждение (достаточность условий ККТ). Пусть x^* — допустимая точка выпуклой задачи. Если существуют множители $\lambda_i^* \ge 0$ и $\nu_j^* \in \mathbb{R}$, для которых выполняются условия ККТ, то x^* является точкой глобального минимума.

□ Зафиксируем множители λ^*, ν^*. Функция Лагранжа

$$\mathscr{L}(x, \lambda^*, \nu^*) = f(x) + \sum_{i=1}^{m} \lambda_i^* g_i(x) + \sum_{j=1}^{p} \nu_j^* h_j(x)$$

выпукла по x, поскольку f и g_i выпуклы, $\lambda_i^* \ge 0$, а h_j аффинны.

Из условия стационарности

$$\nabla_x \mathscr{L}(x^*, \lambda^*, \nu^*) = 0$$

следует, что x^* является точкой глобального минимума функции $\mathscr{L}(\,\cdot\,, \lambda^*, \nu^*)$. Следовательно, для любого $x \in \mathbb{R}^n$

$$\mathscr{L}(x^*, \lambda^*, \nu^*) \le \mathscr{L}(x, \lambda^*, \nu^*).$$

Из прямой допустимости и условия дополняющей нежёсткости имеем

$$h_j(x^*) = 0, \qquad \lambda_i^* g_i(x^*) = 0,$$

поэтому

$$\mathscr{L}(x^*, \lambda^*, \nu^*) = f(x^*).$$

Для любой допустимой точки x выполняются $g_i(x) \leq 0$ и $h_j(x) = 0$. Так как $\lambda_i^* \geq 0$, получаем

$$\mathscr{L}(x, \lambda^*, \nu^*) \leq f(x).$$

Таким образом, для любой допустимой точки x

$$f(x^*) = \mathscr{L}(x^*, \lambda^*, \nu^*) \leq \mathscr{L}(x, \lambda^*, \nu^*) \leq f(x).$$

Следовательно, x^* является точкой глобального минимума.

■

Определение. Говорят, что для выпуклой задачи выполняется **условие Слейтера**, если существует точка $\bar{x} \in \mathbb{R}^n$ такая, что

$$g_i(\bar{x}) < 0, \qquad i = 1, \ldots, m, \quad \text{и} \quad h_j(\bar{x}) = 0, \qquad j = 1, \ldots, p.$$

Такая точка называется **строго допустимой**.

Условие Слейтера является условием регулярности для выпуклой задачи и позволяет получить необходимость условий ККТ без требования линейной независимости градиентов активных ограничений.

Утверждение (необходимость условий ККТ при условии Слейтера). Пусть выпуклая задача удовлетворяет условию Слейтера, а x^* является точкой её глобального минимума. Тогда существуют множители $\lambda_i^* \geq 0$ и $\nu_j^* \in \mathbb{R}$, для которых в точке x^* выполняются условия ККТ.

Замечание. Условие Слейтера гарантирует существование множителей ККТ, но в общем случае не гарантирует их единственность. В отличие от условия линейной независимости градиентов активных ограничений, множители могут быть определены неоднозначно.

Теорема (критерий ККТ для выпуклой задачи). Пусть выпуклая задача удовлетворяет условию Слейтера. Тогда допустимая точка x^* является точкой глобального минимума тогда и только тогда, когда существуют множители $\lambda_i^* \geq 0$

и $\nu_j^* \in \mathbb{R}$, для которых выполняются условия ККТ:

$$\begin{cases} \nabla_x \mathscr{L}(x^*, \lambda^*, \nu^*) = 0, & \text{стационарность,} \\ g_i(x^*) \le 0, \quad i = 1, \ldots, m, & \\ & \text{прямая допустимость,} \\ h_j(x^*) = 0, \quad j = 1, \ldots, p, & \\ \lambda_i^* \ge 0, \quad i = 1, \ldots, m, & \text{двойственная допустимость,} \\ \lambda_i^* g_i(x^*) = 0, \quad i = 1, \ldots, m, & \text{дополняющая нежёсткость.} \end{cases}$$

Утверждение (сильная двойственность). Пусть выпуклая задача удовлетворяет условию Слейтера и имеет точку глобального минимума x^*. Тогда оптимальные значения прямой и двойственной задач совпадают:

$$d^* = p^*.$$

□ По условию Слейтера для оптимальной точки x^* существуют множители λ^*, ν^*, для которых выполняются условия ККТ. Из прямой допустимости и условия дополняющей нежёсткости имеем

$$h_j(x^*) = 0, \qquad \lambda_i^* g_i(x^*) = 0.$$

Следовательно,

$$\mathscr{L}(x^*, \lambda^*, \nu^*) = f(x^*) = p^*.$$

Поскольку функция $\mathscr{L}(\,\cdot\,, \lambda^*, \nu^*)$ выпукла по x, из условия стационарности

$$\nabla_x \mathscr{L}(x^*, \lambda^*, \nu^*) = 0$$

следует, что x^* является точкой её глобального минимума. Поэтому

$$q(\lambda^*, \nu^*) = \inf_x \mathscr{L}(x, \lambda^*, \nu^*) = \mathscr{L}(x^*, \lambda^*, \nu^*) = p^*.$$

По определению двойственного оптимального значения

$$d^* = \sup_{\lambda \geq 0,\ \nu} q(\lambda, \nu),$$

следовательно,

$$d^* \geq q(\lambda^*, \nu^*) = p^*.$$

С другой стороны, по слабой двойственности

$$d^* \leq p^*.$$

Следовательно,

$$d^* = p^*.$$

■